

MI Teorija

| | |
|------------|----------------------------|
| 🕒 Created | @November 20, 2023 5:30 PM |
| 📁 Class | NEUMRE |
| 📁 Type | Theory Questions |
| ☑ Reviewed | <input type="checkbox"/> |

1. Proces Učenja

a. Objasnite Hebbovo učenje

- i. Hebbovo učenje počiva na principu aktivnosti sinapse između neurona A i B. Ako je aktivnost rijetka onda je sinapsa slaba (čak nepostojeca)

$$\Delta w_{kj} = \eta y_k(n) x_j(n)$$

$$\textit{Generalizirano} : \Delta w_{kj} = \alpha y_k(n) \left[\frac{\eta}{\alpha} x_j(n) - w_{kj}(n) \right]$$

b. Objasnite Coverov Teorem

- i. Postoji velika vjerojatnost da su linearno nerazdvojivi uzorci u ulaznom prostoru dimenzije P, linearno odvojivi u ulaznom prostoru dimenzije M ($M > P$) u koje se preslikavaju pomoću skrivene funkcije
- ii. PROF: Linearno nerjesivi (neseparabilni) problemi vrlo su vjerojatno linearno rjesivi u visedimenzionalnim "rijetkim" prostorima

2. Perceptron i ML-klasifikator

a. Objasnite ideju ML Klasifikatora

- i. ML klasifikator za razliku od perceptrona pretpostavlja da se klase preklapaju i da podliježu nekoj distribuciji. Tu distribuciju potrebno je znati unaprijed kako bi se mogao izračunati separator za te dvije klase.

$$l(x) = w^T x - \Theta$$

$$w = C^{-1}(\mu_1 - \mu_2)$$

$$\Theta = \frac{1}{2}(\mu_1^T C^{-1} \mu_1 - \mu_2^T C^{-1} \mu_2)$$

- b. Koje su sličnosti i razlike perceptrona i ML-Klasifikatora?
- i. ML klasifikator i perceptron su linearni klasifikatori, no perceptron pretpostavlja da su klase separabilne dok ML-klasifikator pretpostavlja da se klase preklapaju. Perceptron ne pretpostavlja nikakve distribucije dok za ML klasifikaciju treba znati distribucijske funkcije uzoraka. Učenje perceptrona je adaptivno i jednostavnije dok je ML-klasifikator složeniji.

3. LMS

- a. Objasnite glavnu ideju LMS algoritma
- i. LMS je specijalni slučaj algoritma s najbrzim spustom koji se, za razliku od Wienerovog filtra, ne oslanja na unaprijed poznatu kros-korelacijsku i autokorelacijsku funkciju, već se temelji na njihovim **trenutnim procjenama**.

$$\begin{aligned} w_k(n+1) &= w_k(n) + \eta[x_k(n)d(n) - \sum_{j=1}^p w_j(n)x_j(n)x_k(n)] \\ &= w_k(n) + \eta[d(n) - \sum_{j=1}^p w_j(n)x_j(n)]x_k(n) \\ &= w_k(n) + \eta[d(n) - y(n)]x_k(n), k = 1, 2, \dots, p \\ \Delta w_k(n) &= \eta e(n)x_k(n) \end{aligned}$$


4. Viseslojni Perceptron (MLP)

- a. Opcenito, opisite razliku između individualnog i grupnog načina treniranja viseslojnog perceptrona pomoću algoritma povratne propagacije pogreške (engl. backpropagation algorithm).
- b. Objasnite generalizaciju i kros-validaciju u kontekstu treniranja viseslojnog perceptrona.

5. Radijalne mreže RBF

- a. Objasnite ulogu skrivenog i izlaznog sloja u radijalnim mrežama.
- b. Objasnite generalizirane radijalne mreže.
- c. Koje uvjete mora zadovoljavati funkcija $f: X \rightarrow Y$ da bi njezina rekonstrukcija postala dobro postavljen problem? U kojem slučaju je rekonstrukcija funkcije $f(x) = \cos(x)$ dobro postavljen problem?

- i. Uvjeti koje funkcija F mora zadovoljiti kako bi njena rekonstrukcija bila dobro postavljena problem:
 1. **Egzistencija:** za svaki ulaz x postoji izlaz $y=F(x)$
 2. **Jedinstvenost:** $F(x)=F(t)$ ako i samo ako $x=t$
 3. **Kontinuiranost:** $\forall \epsilon > 0, \exists \delta = \delta(\epsilon) | \rho_x(x, t) < \delta \Rightarrow \rho_y(F(X), F(t)) < \epsilon$ gdje su ρ_x, ρ_y mjere udaljenosti između vektora u pripadnim prostorima
- ii. $f(x) = \cos(x)$ je dobro postavljena na sljedeći način
 1. Egzistencija: doista, za svaki x postoji y
 2. Jedinstvenost: postoji isključivo u zatvorenom intervalu $[0, 2\pi > +2k\pi$
 3. Kontinuiranost: ???
- d. Opisite ideju interpolacije RBF mrežama
 - i. kod rbf mreža ti zapravo želiš što više poboljšati plohu koja aproksimira nelinearno preslikavanje, tj. imaš preslikavanje iz R^n u R
 - ii. kad imaš dobivenu plohu (naučene težine) onda ti se generalizacija tj. predviđanje novih vrijednosti svode na interpolaciju s više ulaznih varijabli
 - iii. a kako bi odredio idealne težine problem zapiseš kao $F_i * w = d$ gdje je F_i interpolacijska matrica, w težine i d odziv tj. željeni izlaz
 - iv. pritom si do interpolacijske matrice došao tako što znaš da ti je fja koju aproksimiras oblika $Fx = \sum(w * \text{radijalna fja}(x, \text{nekiCentar}))$
 - v. di onda u interpolacijsku matricu stavljaš za sve ulaze vrijednosti redom za različite radijalne fje koje odraduju nelinearno preslikavanje u potencijalno visedimenzijski prostor
- e. Nacrtajte strukturu RBF mreže i označite glavne dijelove



6. Stroj Potpornih Vektora (SVM)

- a. Objasnite ulogu potpornih vektora u određivanju optimalne ravnine razdvajanja kod klasifikacije linearno separabilnih razreda. Potkrijepite vas odgovor formulom za udaljenost potpornih vektora od ravnine razdvajanja.
 - i. Ako i samo ako je x_j potporni vektor, onda je odgovarajući koeficijent $d_j \neq 0$, tj. samo oni podpiru ravinu razdvajanja (u jednakzbi dolje, x_0 je potporni vektor)

$$|w^T x_0 + b| = 1$$

- b. Navedite formule za barem dvije nelinearne jezgrene funkcije koje zadovoljavaju Mercerov teorem. Objasnite ulogu jezgrene funkcije kod SVM-a.

- i. $K(x_1, x_2) = (1 + x_1^T x_2)^P$

$$K(x_1, x_2) = e^{\frac{-(x_1^T x_2)^2}{2\delta}}$$

Jezgrena funkcija predstavlja preslikavanje skalarnog produkta u visedimenzionalnom prostoru (Coverov teorem)

7. OSTALO

- a. Kako glasi jednačba hiperravnine u četverodimenzionalnom prostoru?