

Neuronske mreže: Uvod

Prof. dr. sc. Sven Lončarić

Fakultet elektrotehnike i računarstva

sven.loncaric@fer.hr

https://www.fer.unizg.hr/predmet/neumre_c

Pregled predavanja

- Što su neuronske mreže ?
- Organizacija mozga
- Modeli neurona
- Arhitekture mreža
- Reprezentacija znanja
- Vizualizacija procesa u neuronskim mrežama
- Umjetna inteligencija i neuronske mreže
- Povijest

Motivacija

- Mozak “računa” na posve drugi način od konvencionalnih digitalnih računala
 - neuroni su pet-šest redova veličine sporiji od digitalne logike (ms i ns)
 - mozak nadoknađuje brzinu ogromnim brojem neurona (mozak ima oko 10 milijardi neurona i oko 60 000 milijardi međuspojeva)
 - mozak je enormno energetske efikasan (10^{-16} J po operaciji u sekundi prema 10^{-6} J po operaciji u sekundi)
 - mozak je veoma kompleksno, nelinearno, paralelno računalo

Primjeri efikasnosti


- Ljudski vid kao problem obrade informacija
 - npr. prepoznavanje lica čovjek obavlja u 100-200 ms, današnja računala trebaju više vremena (ako uopće mogu točno obaviti taj zadatak)
- Sonar šišmiša
 - detektira udaljenost objekta (npr. insekta), brzinu, veličinu, veličinu raznih dijelova objekta, azimut i elevaciju objekta
 - sve operacije odvijaju se u mozgu veličine šljive
 - šišmiš može locirati i uhvatiti svoj plijen sposobnošću i točnošću na kojoj bi pozavidio svaki sonarski ili radarski inženjer

Kako je to moguće ?

- Nakon rođenja mozak ima velike mogućnosti da se izgrađuje pomoću onoga što zovemo “iskustvo”
- Iskustvo se gradi godinama:
 - najbrži razvoj dešava se tijekom prve dvije godine života (tada se formira 1 milion sinapsi u sekundi)
 - razvoj mozga nastavlja se i nakon te početne faze

Piramidalni neuron

- Dendriti primaju ulaz s drugih neurona
- Axon prenosi impulse dalje
- Sinaptički terminali dotiču dendrite drugih neurona



Sinapse

- Sinapse omogućuju interakciju između neurona
- Presinaptički proces oslobađa tvar koja difundira kroz sinaptičku pukotinu i izaziva postsinaptički proces
- Sinapsu možemo zamisliti kao neregipročni četveropol
- Piramidalni neuron može imati:
 - 10000 ili više ulaznih sinapsi
 - njegov izlaz može se prenositi na tisuće drugih neurona

Podjela neuronskih mreža

- Biološke (prirodne) neuronske mreže
 - biološki organizmi
 - mozak ljudi i životinja
 - visoka složenost i paralelizam
- Umjetne neuronske mreže
 - motivirane biološkim neuronskim mrežama
 - za sada su dosta primitivne imitacije bioloških mreža
 - implementacija na digitalnim računalima opće namjene ili pomoću specijaliziranih sklopova (analognih, digitalnih, hibridnih)
 - tema ovog predmeta

Definicija umjetne neuronske mreže

- Alexander i Morton (1990)
- Umjetna neuronska mreža je masivno paralelni distribuirani procesor koji je dobar za pamćenje iskustvenog znanja
- Slična je mozgu u dva aspekta:
 - Znanje se stječe kroz proces učenja
 - Međusobne veze između neurona se koriste za spremanje znanja

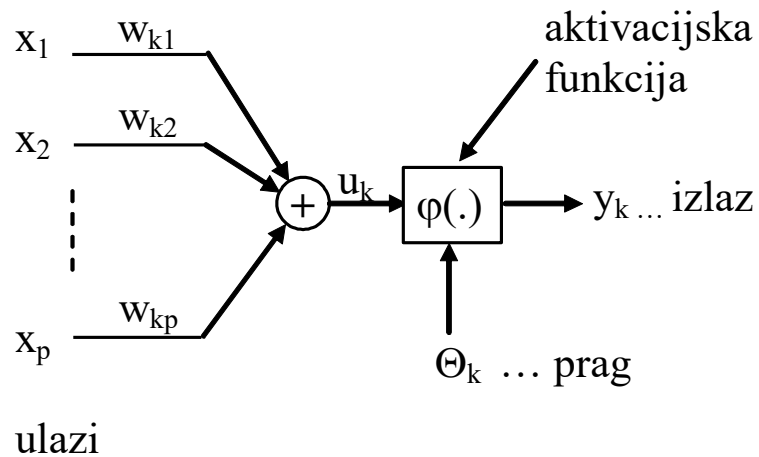
Svojstva neuronskih mreža

- Nelinearnost
- Preslikavanje ulaz-izlaz (učenje s nadzorom)
- Adaptivnost
- Tolerancija na greške (fault tolerance)
- Mogućnost VLSI implementacije
- Neurobiološka analogija

Modeli neurona

- Elementi modela neurona:
 - Skup sinapsi tj. ulaza od kojih svaki ima svoju jačinu tj. težinu. (Notacija: Signal x_j na ulazu j neurona k ima težinu w_{kj})
 - Sumator za zbrajanje otežanih ulaza. Ove operacije računaju linearnu kombinaciju ulaza
 - Nelinearna aktivacijska funkcija koja ograničava izlaz neurona na interval $[0,1]$


Modeli neurona



$$u_k = \sum_{j=1}^p w_{kj} x_j$$
$$y_k = \varphi(u_k - \Theta_k)$$

Modeli neurona


- Prag Θ_k može se prikazati kao dodatni ulaz iznosa -1 i težine Θ_k



Aktivacijske funkcije

- Aktivacijska funkcija tipa prag:


$$\varphi(v) = \begin{cases} 1, & v \geq 0 \\ 0, & v < 0 \end{cases}$$



Aktivacijske funkcije

- Aktivacijska funkcija linearna po odsječcima:


$$\varphi(v) = \begin{cases} 1, & v \geq 0,5 \\ v + 0,5, & -0,5 < v < 0,5 \\ 0, & v \leq -0,5 \end{cases}$$



Aktivacijske funkcije

- Sigmoidna aktivacijska funkcija


$$\varphi(v) = \frac{1}{1 + \exp(-av)}$$



Aktivacijske funkcije

- ReLu = rectified linear

$$\varphi(v) = \begin{cases} v, & v \geq 0 \\ 0, & v < 0 \end{cases}$$



Grafovi


- Neuronske mreže mogu se prikazati pomoću orijentiranih grafova slično grafu toka signala
- U grafu imamo dvije vrste grana:
 - Sinaptička grana koja označava linearnu ulazno-izlaznu relaciju (množenje s težinom)
 - Aktivacijska grana koja predstavlja nelinearnu ulazno-izlaznu karakteristiku aktivacijske funkcije

Arhitekture mreža

- Arhitektura ili topologija mreže određuje način na koji su neuroni međusobno povezani
- Postoje četiri glavne vrste mreža:
 - Jednoslojne mreže bez povratnih veza (single-layer feedforward networks)
 - Višeslojne mreže bez povratnih veza (multi-layer feedforward networks)
 - Mreže s povratnim vezama (recurrent networks)
 - Ljestvičaste mreže (lattice structures)

Jednoslojne mreže

- Jednoslojna mreža sastoji se od jednog sloja neurona (izlaznog sloja)
- Ulazni sloj neurona se ne broji jer u njemu nema procesiranja
- Ulazi u mrežu spojeni su na ulaze neurona čiji izlazi predstavljaju i izlaz mreže
- Nema povratnih veza s izlaza na ulaz
- Primjer jednoslojne mreže je linearna asocijativna memorija gdje ulazni vektor generira na izlazu asocijaciju




Višeslojne mreže

- Višeslojne mreže imaju osim ulaznog i izlaznog sloja i jedan ili više skrivenih slojeva neurona
- Izlazi neurona iz n -tog sloja predstavljaju ulaze u neurone iz $n+1$ -og sloja
- Pojam povezanosti mreže:
 - Mreža je potpuno povezana kada je svaki neuron u svakom sloju povezan na sve neurone u sljedećem sloju
 - Ako neke veze nedostaju mreža je djelomično povezana


Višeslojne mreže

- Primjer mreže s jednim skrivenim slojem u kojem ima četiri neurona
- Broj ulaznih neurona je četiri ali općenito može biti različit od broja skrivenih neurona
- Broj izlaznih neurona je dva



Višeslojne mreže

- Primjer djelomično povezanih mreža su lokalno povezane mreže
- Primjer: svaki neuron u skrivenom sloju spojen je samo na ulazne neurone u svom susjedstvu
- Takav skup lokaliziranih ulaza zove se receptivno polje




Mreže s povratnom vezom

- engl. recurrent networks
- Ove mreže imaju bar jednu povratnu vezu
- Mogu imati i skrivene neurone
- Prisutnost povratnih veza daje dodatnu kvalitetu ovim mrežama
- Veća složenost za analizu rada mreže
- U kombinaciji s elementima za kašnjenje dobivamo nelinearne dinamičke sustave što je ključno za sposobnost memoriranja u mreži

Mreže s povratnom vezom

- Primjer mreže s povratnom vezom bez skrivenih neurona gdje svaki neuron dobiva na ulaz izlaze ostalih neurona osim samog sebe
- Ovakva mreža je jedan nelinearni vremenski diskretni sustav




Ljestvičaste mreže

- Ljestvičaste mreže se sastoje od 1-D, 2-D ili višedimenzionalnog polja neurona s skupom izvornih čvorova koji daju ulazne signale
- Svaki ulaz spojen je na sve neurone u polju
- Ova mreža je zapravo mreža bez povratne veze gdje su neuroni raspoređeni u polje

Ljestvičaste mreže

- Primjer jednodimenzionalne ljestvičaste mreže



Predstavljanje znanja

- Jedna opća definicija znanja glasi (Fischler i Firschein, 1987): “Znanje je zapamćena informacija ili modeli koje koristi osoba ili stroj da interpretira, predvidi ili reagira na vanjski svijet”
- Glavne karakteristike znanja su:
 - same informacije
 - kako je informacija kodirana za kasniju upotrebu
- Kod projektiranja inteligentnih sustava dobro rješenje ovisi o dobrom predstavljanju (reprezentaciji ili uskladištenju) znanja

Učenje neuronske mreže

- Glavni zadatak mreže je da nauči model okoline (svijeta) u kojoj će raditi i da održava model dovoljno točnim da bi se mogli postići željeni ciljevi danog sustava
- Znanje o svijetu sastoji se od dvije vrste informacija:
 - Poznato stanje svijeta predstavljeno činjenicama o svemu poznatom (a priori informacija)
 - Opservacije (mjerjenja) svijeta koje se koriste kao primjeri da se nauči (trenira) neuronska mreža
- Svaki primjer za učenje sastoji se od para ulaznih i izlaznih vrijednosti

Neuronske mreže za raspoznavanje uzoraka

- Jedna od čestih primjena neuronskih mreža je za raspoznavanje uzoraka (pattern recognition)
- Kod raspoznavanja uzoraka potrebno je realizirati klasifikator koji za svaki ulazni uzorak (vektor) određuje klasu kojoj taj vektor pripada
- Neuronska mreža je zapravo jedan nelinearni klasifikator koja dijeli ulazni vektorski prostor uzoraka u klase koje imaju nelinearne granice
- Primjene: analiza slike, govora, signala, podataka

Primjer: Prepoznavanje slova

- Kod prepoznavanja slova ulaz može biti skup vrijednosti piksela (npr. matrica 5×7 piksela), a izlaz je identitet pripadne znamenke (0-9)
- Ulazni sloj mreže bi mogao imati $5 \times 7 = 35$ ulaza
- Izlazni sloj mreže mogao bi imati 10 neurona (za svaku znamenku po jedan)
- Mreža bi se trenirala parovima poznatih ulaznih i izlaznih vektora (ova se faza zove učenje)
- Nakon učenja na ulaz mreže postavila bi se slika koju mreža još nije “vidjela” i ispitala bi se točnost prepoznavanja

Usporedba s klasičnim pristupom

- Ovaj primjer ilustrira razliku između klasičnog pristupa i neuronskih mreža za problem prepoznavanja
 - U klasičnom pristupu prvo se razvije matematički model izmjerenih podataka i zatim se razvije sustav temeljen na izmjerenom modelu
 - Kod neuronskih mreža radi se direktno s podacima (mreža uči iz primjera) i nije potrebno znati model izmjerenih podataka
 - Mreža ne samo da sama koristi implicitni model nego i računa potreban izlaz

Pravila za predstavljanje znanja


- Anderson, 1988 (u kontekstu prepoznavanja objekata):
 1. Slični ulazi iz sličnih klasa trebaju imati i slične reprezentacije te biti klasificirani u istu klasu (grupu)
 2. Objekti koji trebaju biti klasificirani u različite klase trebaju imati i dovoljno različite reprezentacije u mreži
 3. Važne značajke objekta moraju biti predstavljene s većim brojem neurona
 4. A priori informacije i invarijantnosti trebaju biti ugrađene u dizajn mreže tako da ih mreža ne mora učiti

Korištenje a priori informacija

- U primjeru prepoznavanja slova a priori informacije su:
 - ulazni podaci (crno-bijela slika) su dvodimenzionalni
 - ulazni podaci imaju lokalnu strukturu (slova su lokalizirana)
- Zbog toga mrežu možemo formirati tako da su sinaptičke veze u ulaznom sloju mreže lokalne (lokalno povezana mreža)
 - Takvo lokalno područje ulaza za neki neuron zove se receptivno polje

Receptivno polje

- U primjeru na slici neuron j ima receptivno polje dimenzija 3×3 koje je centrirano oko piksela na poziciji tog neurona
- Svaki piksel na slici ima svoj korespondentni neuron



Receptivno polje

- Receptivno polje svakog neurona je jednako (težine se ponavljaju za svako polje)
- Neka je $\{w_{ji} \mid i=0,1, \dots, p-1\}$ skup težina za neuron j
- Izlaz neurona j dan je izrazom (konvolucija):

$$y_j(n) = \sum_{i=0}^{p-1} w_{ji} x(n-i)$$

gdje su $x(n)$ vrijednosti piksela unutar receptivnog polja

Receptivno polje

- Zbog računanja konvolucije se ovakva mreža nekad zove i konvolucijska mreža
- Ukupna obrada svodi se na konvoluciju s 2-D jezgrom malih dimenzija nakon čega primjenjujemo limitiranje aktivacijskom funkcijom
- Budući da neuroni obavljaju istu funkciju na raznim dijelovima slike tehnika se naziva dijeljenje težina (weight sharing)
- Prednost dijeljenja težina je i u tome da se smanjuje broj nepoznatih parametara (jer se težine ponavljaju)

A priori informacije - sažetak

- A priori saznanja i informacije o problemu mogu se ugraditi u neuronsku mrežu na dva načina:
 - ograničavanjem topologije mreže kroz upotrebu lokalnih veza (lokalno povezivanje mreže upotrebom receptivnih polja)
 - ograničavanjem izbora sinaptičkih težina upotrebom dijeljenja težina (weight sharing)
- Nisu poznata dobro definirana pravila već samo ad-hoc primjeri za koje se zna da često daju dobre rezultate u praksi
- Tehnike jako ovise o određenoj aplikaciji

Invarijantnost kod raspoznavanja uzoraka

- Ako sliku objekta rotiramo (ili npr. translatiramo ili skaliramo) još uvijek možemo prepoznati objekt kao takav
- Ako govornik govori tiše ili glasnije, dubljim ili višim glasom, ili ako je prehladen, još uvijek možemo prepoznati riječi koje je izgovorio
- Općenito, sustav za prepoznavanje mora biti neosjetljiv (invarijantan) na određene transformacije ulaznog signala
- Rezultat klasifikacije ne smije ovisiti o ovakvim transformacijama ulaznog signala

Realizacija invarijantnosti

- Postoje bar tri tehnike koje omogućuju da realiziramo neuronske mreže za klasifikaciju koje će biti invarijantne na određene transformacije:
 - Invarijantnost pomoću strukture (topologije) mreže
 - Invarijantnost treniranjem mreže (učenjem)
 - Invarijantnost upotrebom ekstrakcije značajki

Invarijantnost strukturom

- Struktura mreže može biti odabrana tako da omogućuje invarijantnost na neke transformacije
- Npr. pretpostavimo da želimo postići invarijantnost na rotaciju oko centra slike:
 - Neka je w_{ji} težina neurona j vezanog na piksel i u ulaznoj slici
 - Ako vrijedi da je $w_{ji}=w_{jk}$ za svaka dva piksela i i k koja su na jednakoj udaljenosti od centra slike onda će mreža biti invarijantna na rotaciju oko centra slike

Invarijantnost učenjem

- Invarijantnost se može postići učenjem na taj način da se mreža trenira različitim primjerima koji odgovaraju transformiranim verzijama istog objekta
- Npr. kod prepoznavanja objekata mrežu se može trenirati rotiranim verzijama istog objekta i tako postići invarijancija na rotaciju
- Nedostaci ovog pristupa su:
 - Nije nužno da će invarijantnost postojati i za rotirane verzije nekog drugog objekta za kojeg mreža nije trenirana
 - Računski zahtjevi na mrežu mogu biti preveliki naročito ako je dimenzija ulaznog vektora previsoka

Invarijantnost značajkama

- Invarijantnost se može postići i odabirom značajki (features) koje su invarijantne na željene transformacije
- Ako se koriste takve značajke za izračunavanje ulaza u mrežu onda je sama mreža oslobođena problema invarijantnosti

Invarijantnost značajkama

- Korištenje invarijantnih značajki ima slijedeće prednosti:
 - Može se smanjiti dimenzija ulaznog vektora
 - Zahtjevi na samu mrežu su manji
 - Osigurana je invarijantnost za sve objekte (a ne samo za trenirane)
- Zbog toga je ova metoda najpogodnija za neuronske klasifikatore

Vizualizacija procesa u NM



- Da bi se prevladale nerazumijevanje predstavljanja znanja i procesa učenja možemo se osloniti na upotrebu metoda vizualizacije procesa učenja
- Ovaj pristup dosada nije dovoljno istražen
- Dvije metode vizualizacije su:
 - Hinton dijagram, Rumelhart i McClelland, 1986
 - dijagram veza (bond diagram), Wejchert i Tesaro, 1991

Hinton dijagram

- Hinton dijagram sastoji se od stupaca koji se sastoje od kvadrata
- Svaki stupac ima jedan kvadrat za iznos praga i ostale kvadrate za iznose sinaptičkih težina
- Veličina kvadrata je proporcionalna iznosu veličine
- Boja kvadrata (crna i bijela) označava predznak (1, -1)

Primjer Hinton dijagrama

- U primjeru imamo mrežu s dva ulazna, dva skrivena i jednim izlaznim neuronom



Ograničenja Hinton dijagrama



- Nedostatak Hinton dijagrama je da samo prikazuje iznose težina i pragova ali ne prikazuje njihov odnos prema topologiji mreže
- Poželjno je imati prikaz vrijednosti težina i pragova integriran u grafički prikaz topologije mreže
- Tako se može vidjeti za određeni problem kako se vrijednosti težina mijenjaju i formiraju prilikom učenja
- Ovaj nedostatak Hinton dijagrama prevladan je pomoću dijagrama veza

Dijagram veza

- Iznosi težina su prikazan pomoću “veza” između neurona
- Duljina veze je proporcionalna iznosu težine
- Polaritet težine je prikazan pomoću boje veze (crna ili bijela)
- Prednosti u odnosu na Hinton dijagram su:
 - Dijagram prikazuje smjer veze (s kojim je neuronom povezan)
 - Skup težina prikazanih vezama predstavljaju određeni uzorak za promatrača koji može izvesti globalne zaključke gledajući takav dijagram

Primjer dijagrama veza

- U primjeru imamo mrežu s dva ulazna, dva skrivena i jednim izlaznim neuronom



Inteligentni sustavi i NM

- Cilj umjetne inteligencije (AI) je razvoj paradigmi i algoritama koji omogućuju strojevima da obave zadaće koje zahtjevaju shvaćanje (inteligenciju) kada ih obavljaju ljudi, Sage, 1990
- Zadaci koje rješava AI su percepcija, jezik, rješavanje problema, svjesni i nesvjesni procesi, Memmi, 1989
- Inteligentni sustav mora moći obaviti tri zadaće:
 - pohranjivanje znanja (reprezentacija)
 - primjena znanja da bi se riješio dani problem (zaključivanje)
 - prikupljanje novog znanja (učenje)

Reprezentacija znanja


- Znanje u inteligentnim sustavima se predstavlja kao skup podataka
- Znanje može biti deklarativno ili proceduralno
- Deklarativna reprezentacija znanja je u obliku skupa statičkih činjenica, s malim brojem procedura koje manipuliraju činjenicama
- Kod proceduralne reprezentacije znanje je prikazano kao izvršni kod čije izvođenje omogućuje zaključivanje

Zaključivanje

- Zaključivanje je sposobnost rješavanja problema
- Da bi neki sustav bio sustav za zaključivanje mora ispunjavati slijedeće uvjete:
 - Sustav mora moći izraziti i riješiti širok raspon problema i tipova problema
 - Sustav mora moći eksplicitno izraziti bilo koju implicitnu informaciju koja mu je poznata
 - Sustav mora imati upravljački mehanizam koji određuje koje operacije treba primijeniti na određeni problem

Učenje

- Jednostavni model učenja je prikazan na slici



Učenje

- Kod učenja okolina šalje neku informaciju elementu za učenje
- Element za učenje koristi tu informaciju da modificira (dopuni) bazu znanja
- Dodano znanje (hipoteze) se ispituju na okolini što daje povratnu informaciju elementu za učenje
- Stroj tako uči pogađanjem i prima ocjenu od elementa za provjeru znanja

Povijest

- Moderna era neuronskih mreža počinje radom McCullocha i Pittsa, 1943, koji su opisali model neurona i neuronskih mreža
- Wienerova knjiga “Cybernetics” izdana je 1948 i u njoj su opisani koncepti upravljanja, komunikacije i statističke obrade signala
- Hebbova knjiga “The Organization of Behavior” je izdana 1949 i u njoj je prvi put naglašeno učenje kao proces sinaptičkih modifikacija

Povijest

- Taylor, 1956, asocijativna memorija
- von Neumann, 1956, ideja redundancije za dizajn pouzdanih sustava (mreža) od nepouzdatih komponenti (neurona)
- Rosenblatt, 1958, perceptron
- Widrow i Hoff, 1960, LMS (least mean square) algoritam i Adaline (adaptive linear element)
- Uzlet do 1969 kad je objavljena knjiga, “Perceptrons” autora Minski i Papert gdje su analizirali ograničenja jednoslojnih perceptrona

Povijest

- Zastoj od 10 godina (1970-1980) zbog:
 - tehnoloških razloga (nije bilo računala)
 - psihološko-financijskih razloga (Minski-Papert knjiga)
- Grossberg, 1980, adaptive resonance theory
- Hopfield, 1982, energetska funkcija, veza s statističkom fizikom (puno fizičara ušlo je u područje)
- Kohonen, 1982, self-organizing maps
- Kirkpatrick, Galatt, Vecchi, 1983, simulirano hlađenje za rješavanje kombinacijskih problema

Povijest

- Rumelhart, Hinton, Williams, 1986, učenje s povratnom propagacijom pogreške (back-propagation)
- Rumelhart, McClelland, 1986, dvije knjige, “Parallel Distributed Processing: Exploration in Microstructures of Cognition”, imaju veliki utjecaj
- Broomhead, Lowe, 1988, radial-basis function (RBF) mreže

Zadaća

- Problem 1.15.
 - Višeslojna mreža bez povratnih veza ima neurone koji rade u linearnom području (nema nelinearnosti). Treba pokazati da je takva mreža ekvivalentna jednoslojnoj mreži
- Problem 1.19.
 - Mreža s povratnim vezama ima 3 ulazna neurona, 2 skrivena neurona i 4 izlazna neurona. Nacrtati graf mreže.