

# Neuronske mreže: Perceptron

Prof. dr. sc. Sven Lončarić

Fakultet elektrotehnike i računarstva

[https://www.fer.unizg.hr/predmet/neumre\\_c](https://www.fer.unizg.hr/predmet/neumre_c)


# Pregled predavanja

- Uvod
- Jednoslojni perceptron
- Algoritam učenja
- Klasifikator maksimalne vjerojatnosti
- Diskusija
- Zadaci

# Uvod

- Perceptron je najjednostavnija neuronska mreža za klasifikaciju uzoraka koji su linearno separabilni (koji leže na suprotnim stranama hiperravnine)
- Perceptron se sastoji od jednog neurona
- Algoritam učenja razvio je Rosenblatt, 1958
- Rosenblatt je dokazao da ako su uzorci linearno separabilni onda algoritam učenja konvergira i postavlja hiperravninu odluke točno između dvije klase (teorem konvergencije perceptrona)
- Da bi perceptron radio uzorci *moraju* biti linearno separabilni

# Jednoslojni perceptron



$$v = \sum_{j=1}^p w_j x_j - \Theta$$
$$y = \phi(v)$$

McCulloch-Pitts model neurona

# Jednoslojni perceptron

- Perceptron služi za klasifikaciju skupa ulaznih vektora oblika  $\mathbf{x} = [x_1 \ x_2 \ \dots \ x_p]^T$  u jednu od dvije klase  $C_1$  ili  $C_2$
- Klasifikacija se odvija tako da se vektor  $\mathbf{x}$  kojeg treba klasificirati dovede na ulaz perceptrona
- Ako je izlaz perceptrona:
  - $y = 1$  onda vektor  $\mathbf{x}$  pripada klasi  $C_1$
  - $y = -1$  onda vektor  $\mathbf{x}$  pripada klasi  $C_2$


# Područja klasifikacije

- Da bi se prikazala područja klasifikacije  $C_1$  i  $C_2$  može se promatrati iznos varijable  $v$  u ovisnosti o  $p$  ulaznih varijabli  $x_1, x_2, \dots, x_p$
- U slučaju elementarnog perceptrona postoje dva područja odvojena hiperravninom definiranom izrazom:

$$\sum_{j=1}^p w_j x_j - \Theta = 0$$


# Primjer klasifikacije u dvije dimenzije

- Kod 2-D klasifikacije granica između klasa definirana je pravcem  $w_1x_1 + w_2x_2 - \theta = 0$
- Točka koja leži iznad pravca pripada klasi  $C_1$
- Točka ispod pravca pripada klasi  $C_2$



# Jednoslojni perceptron

- Prag neurona možemo prikazati kao dodatni ulaz s fiksnim iznosom - 1 i pripadnom težinom  $\theta$





# Jednoslojni perceptron

- Definirajmo  $p+1$  dimenzionalni ulazni vektor kao:

$$\mathbf{x}(n) = [-1 \ x_1(n) \ x_2(n) \ \dots \ x_p(n)]^T$$

- Definirajmo  $p+1$  dimenzionalni vektor težina kao:

$$\mathbf{w}(n) = [\theta(n) \ w_1(n) \ w_2(n) \ \dots \ w_p(n)]^T$$

- Interna aktivnost neurona  $v(n)$  dana je izrazom za linearnu kombinaciju ulaza i težina (skalarni produkt vektora):

$$v(n) = \mathbf{w}^T(n) \mathbf{x}(n)$$

- Za fiksni  $n$  jednadžba  $\mathbf{w}^T(n) \mathbf{x}(n) = 0$  definira hiperravninu u  $p$ -dimenzionalnom prostoru koordinata  $x_1, x_2, \dots, x_p$

# Klasifikacija

- Ako su dvije klase uzoraka linearno separabilne onda postoji vektor težina  $\mathbf{w}$  tako da vrijedi:

$$\mathbf{w}^T \mathbf{x} \geq 0$$

za svaki vektor  $\mathbf{x}$  koji pripada klasi  $C_1$  i

$$\mathbf{w}^T \mathbf{x} < 0$$

za svaki vektor  $\mathbf{x}$  koji pripada klasi  $C_2$

- Problem učenja sastoji se u tome da se odredi vektor težina  $\mathbf{w}$  koji će omogućiti korektnu klasifikaciju

# Algoritam učenja

1. Ako je  $n$ -ti vektor  $\mathbf{x}(n)$  korektno klasificiran, težina  $\mathbf{w}(n)$  se ne mijenja:

- $\mathbf{w}(n+1) = \mathbf{w}(n)$   
ako je  $\mathbf{w}(n)^T \mathbf{x}(n) \geq 0$  i  $\mathbf{x}(n)$  pripada klasi  $C_1$
- $\mathbf{w}(n+1) = \mathbf{w}(n)$   
ako je  $\mathbf{w}(n)^T \mathbf{x}(n) < 0$  i  $\mathbf{x}(n)$  pripada klasi  $C_2$

# Algoritam učenja (nastavak)

2. Inače težinski vektor  $\mathbf{w}(n)$  se mijenja na slijedeći način:

- $\mathbf{w}(n+1) = \mathbf{w}(n) - \eta(n) \mathbf{x}(n)$   
ako je  $\mathbf{w}(n)^T \mathbf{x}(n) \geq 0$  i  $\mathbf{x}(n)$  pripada klasi  $C_2$
- $\mathbf{w}(n+1) = \mathbf{w}(n) + \eta(n) \mathbf{x}(n)$   
ako je  $\mathbf{w}(n)^T \mathbf{x}(n) < 0$  i  $\mathbf{x}(n)$  pripada klasi  $C_1$

gdje je  $\eta(n)$  pozitivni parametar koji određuje brzinu učenja

# Klasifikator maksimalne vjerojatnosti

- engl. maximum likelihood (ML) classifier
- Pomoću jednoslojnog perceptrona može se realizirati klasifikator koji radi na principu maksimalne vjerojatnosti (ML klasifikator)
- Problem klasifikacije uzoraka može se promatrati kao problem estimacije klase kojoj nepoznati uzorak pripada

# Klasifikator maksimalne vjerojatnosti

- To je problem estimacije parametara (engl. parameter estimation)
- Parametri su veličine koje su fiksne ali nepoznate (u slučaju klasifikatora nepoznati parametar koji želimo procijeniti je indeks klase kojoj uzorak pripada)

# Estimacija parametara

- Zamislimo da imamo skup uzoraka koji možemo prema klasama raspodjeliti u podskupove  $X_1, X_2, \dots, X_M$
- Neka je funkcija gustoće vjerojatnosti uzoraka  $\mathbf{x}$  za pojedine klase dana izrazima  $f(\mathbf{x}|\mathbf{z}_j)$  gdje je  $\mathbf{z}_j$  nepoznati vektor parametara koji opisuje klasu  $C_j$
- $f(\mathbf{x}|\mathbf{z})$  zove se vjerojatnost (engl. likelihood) od  $\mathbf{z}$  s obzirom na opaženi vektor  $\mathbf{x}$
- ML estimacija parametra  $\mathbf{z}$  je neka vrijednost  $\mathbf{z}'$  koja maksimizira vjerojatnost  $f(\mathbf{x}|\mathbf{z})$

# ML klasifikator

- Neka je uzorak opisan  $p$ -dimenzionalnim slučajnim vektorom  $\mathbf{x}$  koji ima vektor srednje vrijednosti  $\boldsymbol{\mu} = E[\mathbf{x}]$  i kovarijancijsku matricu  $\mathbf{C} = E[(\mathbf{x}-\boldsymbol{\mu})(\mathbf{x}-\boldsymbol{\mu})^T]$
- Ako pretpostavimo da slučajni vektor  $\mathbf{x}$  ima Gaussovu razdiobu onda je funkcija gustoće vjerojatnosti dana izrazom:

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} (\det \mathbf{C})^{1/2}} \exp \left[ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \mathbf{C}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right]$$



# ML klasifikator

- Pretpostavimo radi ilustracije da imamo problem s dvije klase ( $M=2$ ) i da je vektor uzorka  $\mathbf{x}$  karakteriziran slijedećim parametrima zavisno da li pripada klasi  $C_1$  ili  $C_2$
- Ako uzorak  $\mathbf{x}$  pripada klasi  $C_1$ :  
srednja vrijednost =  $\mu_1$  i kovarijancijska matrica =  $\mathbf{C}$
- Ako uzorak  $\mathbf{x}$  pripada klasi  $C_2$ :  
srednja vrijednost =  $\mu_2$  i kovarijancijska matrica =  $\mathbf{C}$

# ML klasifikator

- Problem ML estimacije parametara se sada sastoji u tome da za neki opaženi vektor  $\mathbf{x}$  trebamo procjeniti da li se veća vjerojatnost pojave tog vektora dobiva za vrijednost parametra  $\mu_1$  ili za  $\mu_2$

# ML klasifikator

- Za dane dvije klase možemo pisati pripadne funkcije gustoće vjerojatnosti kao:

$$f(\mathbf{x} | C_i) = \frac{1}{(2\pi)^{p/2} (\det \mathbf{C})^{1/2}} \exp \left[ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_i)^T \mathbf{C}^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) \right]$$

- Dakle treba odrediti za dani  $\mathbf{x}$  koja je od vjerojatnosti  $f(\mathbf{x} | C_1)$  i  $f(\mathbf{x} | C_2)$  veća
- Da bi to odredili radi pojednostavljenja možemo promatrati i logaritme vjerojatnosti  $\ln f(\mathbf{x} | C_1)$  i  $\ln f(\mathbf{x} | C_2)$

# ML klasifikator

- Logaritmi vjerojatnosti dani su izrazom gdje su samo zadnja dva pribrojnika ovisna o indeksu klase  $i$ :

$$\ln f(\mathbf{x} | C_i) = -\frac{p}{2} \ln(2\pi) - \frac{1}{2} \ln(\det \mathbf{C}) - \frac{1}{2} \mathbf{x}^T \mathbf{C}^{-1} \mathbf{x} + \boldsymbol{\mu}_i^T \mathbf{C}^{-1} \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_i^T \mathbf{C}^{-1} \boldsymbol{\mu}_i$$

- Dakle za usporedbu dvaju logaritama vjerojatnosti dovoljno je promatrati izraze:

$$l_1(\mathbf{x}) = \boldsymbol{\mu}_1^T \mathbf{C}^{-1} \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_1^T \mathbf{C}^{-1} \boldsymbol{\mu}_1$$
$$l_2(\mathbf{x}) = \boldsymbol{\mu}_2^T \mathbf{C}^{-1} \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_2^T \mathbf{C}^{-1} \boldsymbol{\mu}_2$$

# ML klasifikator

$$l(\mathbf{x}) = l_1(\mathbf{x}) - l_2(\mathbf{x}) = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T \mathbf{C}^{-1} \mathbf{x} - \frac{1}{2} (\boldsymbol{\mu}_1^T \mathbf{C}^{-1} \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2^T \mathbf{C}^{-1} \boldsymbol{\mu}_2)$$

- Razlika  $l(\mathbf{x})$  pokazuje koja je vjerojatnost veća:
  - ako je  $l(\mathbf{x}) \geq 0$  onda je  $f(\mathbf{x} | C_1)$  veća vjerojatnost (klasa  $C_1$ )
  - ako je  $l(\mathbf{x}) < 0$  onda je  $f(\mathbf{x} | C_2)$  veća vjerojatnost (klasa  $C_2$ )
- Može se vidjeti da je veza između  $l(\mathbf{x})$  i  $\mathbf{x}$  linearna:

$$l(\mathbf{x}) = \mathbf{w}^T \mathbf{x} - \Theta$$

gdje je:

$$\begin{aligned} \mathbf{w} &= \mathbf{C}^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) \\ \Theta &= \frac{1}{2} (\boldsymbol{\mu}_1^T \mathbf{C}^{-1} \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2^T \mathbf{C}^{-1} \boldsymbol{\mu}_2) \end{aligned}$$

# ML klasifikator


- Dakle ML klasifikator može se realizirati pomoću perceptrona koji ima vektor težina  $\mathbf{w}$  i prag  $\theta$
- Interna aktivnost takvog perceptrona jednaka je:

$$l = \mathbf{w}\mathbf{x} - \theta$$

- Klasifikacija nepoznatog uzorka  $\mathbf{x}$  se obavlja na slijedeći način:
  - ako je  $l > 0$  onda je  $l_1 > l_2$  i znači da  $\mathbf{x}$  pripada klasi  $C_1$
  - ako je  $l < 0$  onda je  $l_1 < l_2$  i znači da  $\mathbf{x}$  pripada klasi  $C_2$

# ML klasifikator i perceptron

- ML klasifikator i perceptron su linearni klasifikatori
- ML klasifikator je izveden uz pretpostavku da se klase preklapaju (zato se klase ne mogu točno separirati) dok perceptron radi uz pretpostavku da su klase separabilne




# ML klasifikator i perceptron

- Perceptron ne pretpostavlja nikakve distribucije dok za ML klasifikaciju treba pretpostaviti (tj. znati) distribucijske funkcije ulaznih uzoraka
- Učenje perceptrona je adaptivno i jednostavnije za realizaciju dok je dizajn adaptivnog Gaussovog ML klasifikatora složeniji



# Diskusija

- Minski je kritizirao Rosenblattov perceptron da ne može naučiti ni tako jednostavnu funkciju kao što je XOR
- To nije moguće jer dva skupa točaka na slici nisu linearno separabilni



# Zadaci

- Problem 4.1.
  - Jednoslojni perceptron je linearni klasifikator. Objasniti ovu tvrdnju.
- Problem 4.2.
  - Dane su dvije jednodimenzionalne klase C1 i C2 s Gausovim distribucijama koje imaju varijancu jednaku 1 i srednje vrijednosti  $\mu_1=-10$  i  $\mu_2=10$ . Izračunati klasifikator za separaciju ovih klasa.