

# Neuronske mreže: Radijalne mreže

Prof. dr. sc. Sven Lončarić

Fakultet elektrotehnike i računarstva  
[https://www.fer.unizg.hr/predmet/neumre\\_c](https://www.fer.unizg.hr/predmet/neumre_c)

# Pregled predavanja

- Uvod
- Coverov teorem o separabilnosti uzoraka
- Problem interpolacije
- Interpolacija radijalnom mrežom
- Generalizirane radijalne mreže
- Učenje pod nadzorom kao loše postavljani problem rekonstrukcije hiperplohe
- Teorija regularizacije
- Regularizacijske mreže
- XOR problem

# Pregled predavanja

- Usporedba višeslojnih i radijalnih mreža
- Strategije učenja
- Diskusija
- Zadaci


# Uvod

- Eng. *radial-basis function* (RBF) *networks*
- Kod višeslojnih mreža koje koriste algoritam unazadne propagacije učenje se interpretira kao problem optimizacije (minimizacija srednje kvadratne greške)
- Kod radijalnih mreža učenje se interpretira kao problem aproksimacije funkcije s više argumenata
- Funkcija koju treba aproksimirati je ulazno-izlazna funkcija definirana parovima za učenje

# Struktura radialne mreže

- Osnovna RBF mreža ima tri sloja:
  - ulazni sloj
  - skriveni sloj koji ima drugačiju ulogu nego kod višeslojnih mreža
  - izlazni sloj
- Transformacija ulaznog sloja u skriveni sloj je *nelinearna*
- Transformacija skrivenog sloja u izlazni sloj je *linearna*

# Struktura radijalne mreže



# Coverov teorem I.

- Kod upotrebe RBF mreže problem klasifikacije uzoraka rješava se nelinearnom transformacijom ulaznih uzoraka u prostor s više dimenzija nego što ih ima ulazni prostor
- Motivacija je Coverov teorem o razdvojivosti ili separabilnosti uzoraka koji kaže:

*Veća je vjerojatnost da nelinearno transformirani vektori u višedimenzionalnom prostoru budu linearno separabilni nego u originalnom nižedimenzionalnom prostoru*

# Coverov teorem II.

## Interpretacija

- Iz teorije perceptrona poznato je da klasifikacijski problem jednostavno rješiv kada su uzorci linearno razdvojivi
- Interpretacija radijalne mreže kao klasifikatora:
  1. **Skriveni sloj** nelinearno transformira ulazne uzorke tako da klase postanu linearno razdvojive
  2. **Izlazni sloj** je linearan i kao takav može jednostavno obaviti klasifikaciju dvaju linearno razdvojivih klasa



# Coverov teorem III.

- Neka je  $X = \{ \mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N \}$  skup ulaznih uzoraka gdje svaki uzorak pripada jednoj od dviju klasa  $X^+$  i  $X^-$
- Neka je ulazni vektor  $\mathbf{x}$   $P$ -dimenzionalan
- Za svaki vektor  $\mathbf{x}$  formiramo novi vektor:

$$\boldsymbol{\varphi}(\mathbf{x}) = [\varphi_1(\mathbf{x}), \varphi_2(\mathbf{x}), \dots, \varphi_M(\mathbf{x})]^T$$

- Tada je  $\boldsymbol{\varphi}(\mathbf{x})$  transformacija ulaznog vektora iz **ulaznog prostora** u novi  $M$ -dimenzionalni **skriveni prostor**
- Funkcija  $\varphi_i(\mathbf{x})$  zove se **skrivena funkcija**
  - Njena uloga je slična skrivenom neuronu u višeslojnoj mreži

# Coverov teorem IV.

- Za dvije klase ulaznih uzoraka  $X^+$  i  $X^-$  kaže se da su  $\phi$ -razdvojive ako postoji  $M$ -dimenzionalni vektor  $\mathbf{w}$  takav da vrijedi:

$$\mathbf{w}^T \phi(\mathbf{x}) \geq 0, \quad \mathbf{x} \in X^+$$

$$\mathbf{w}^T \phi(\mathbf{x}) < 0, \quad \mathbf{x} \in X^-$$

- Hiperravnina definirana jednađbom

$$\mathbf{w}^T \phi(\mathbf{x}) = 0$$

definira plohu razdvajanja u  $\phi$  (skrivenom) prostoru


# Coverov teorem V.

- Inverzna slika ove hiperravnine definira plohu razdvajanja u **ulaznom prostoru** (prostoru ulaznih uzoraka):

$$\{\mathbf{x} : \mathbf{w}^T \boldsymbol{\varphi}(\mathbf{x}) = 0\}$$

# Primjer: Funkcija XOR I.

- 0 XOR 0 = 0
- 1 XOR 1 = 0
- 0 XOR 1 = 1
- 1 XOR 0 = 1



## Primjer: Funkcija XOR II.


- Definirajmo **skrivenne funkcije** kao:

$$\begin{aligned}\varphi_1(\mathbf{x}) &= e^{-\|\mathbf{x}-\mathbf{t}_1\|^2}, & \mathbf{t}_1 &= [1,1]^T \\ \varphi_2(\mathbf{x}) &= e^{-\|\mathbf{x}-\mathbf{t}_2\|^2}, & \mathbf{t}_2 &= [0,0]^T\end{aligned}$$

- Ulazni vektori se preslikavaju u  $\varphi$  (**skriveni**) prostor na slijedeći način (sljedeća prikaznica)

# Primjer: Funkcija XOR III.

- Svi uzorci su linearno razdvojivi u novom prostoru
- Prema tome problem klasifikacije se može riješiti linearnim klasifikatorom kao što je perceptron (izlazni sloj radijalne mreže)



# Interpolacijski problem I.

- Razmotrimo mrežu s **ulaznim slojem**, **jednim skrivenim slojem** i **izlaznim slojem** koji sadrži samo **jedan neuron**
- Takva mreža vrši *nelinearno preslikavanje* **ulaza** u **skriveni sloj** te *linearno preslikavanje* **skrivenog sloja** u **izlazni sloj**

- Sveukupno, takva mreža realizira preslikavanje

$$s: \mathbb{R}^P \rightarrow \mathbb{R}$$

- Preslikavanje se može interpretirati i kao hiperploha

$$\Gamma \subset \mathbb{R}^{P+1}$$

# Interpolacijski problem II.

- Treniranje mreže se sada interpretira kao optimizacija neke aproksimacijske funkcije koja bi trebala biti što sličnija željenoj plohi  $\Gamma$  i koja je određena pomoću ulazno-izlaznih točaka za učenje
- Faza generalizacije je ekvivalentna interpolaciji između zadanih ulazno-izlaznih točaka
- Takva interpretacija vodi na teoriju *multivarijabilne interpolacije* u visko dimenzionalnom prostoru
- Unutar tog okvira problem se postavlja na sljedeći način (sljedeća prikaznica):



# Interpolacijski problem III.

- Za zadani skup od  $N$  različitih točaka

$$\{\mathbf{x}_i \in \mathbb{R}^P | i = 1, 2, \dots, N\}$$

i pripadni korespondentni skup od  $N$  realnih brojeva

$$\{d_i \in \mathbb{R} | i = 1, 2, \dots, N\}$$

nađi funkciju

$$F: \mathbb{R}^P \rightarrow \mathbb{R}$$

takvu da zadovoljava interpolacijski uvjet

$$F(\mathbf{x}_i) = d_i, \quad i = 1, 2, \dots, N$$

# Interpolacija radijalnom mrežom I

- Za radijalne mreže funkcija  $F$  je ograničena na oblik:

$$F(\mathbf{x}) = \sum_{i=1}^N w_i \varphi(\|\mathbf{x} - \mathbf{x}_i\|)$$

gdje je

$$\{\varphi(\|\mathbf{x} - \mathbf{x}_i\|) \mid i = 1, 2, \dots, N\}$$

skup proizvoljnih (općenito nelinearnih) funkcija koje zovemo radijalnim funkcijama (eng. *radial-basis functions*)

- Zadane točke  $\mathbf{x}_i$  se uzimaju kao centri radijalnih funkcija

# Interpolacija radijalnom mrežom II

- Ako interpolacijski uvjet izrazimo preko izraza za oblik funkcije  $F$  radijalne mreže onda dobivamo:

$$\begin{bmatrix} \varphi_{11} & \varphi_{12} & \cdots & \varphi_{1N} \\ \varphi_{21} & \varphi_{22} & \cdots & \varphi_{2N} \\ \vdots & \vdots & \vdots & \vdots \\ \varphi_{N1} & \varphi_{N2} & \cdots & \varphi_{NN} \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_N \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ \vdots \\ d_N \end{bmatrix}$$

gdje je

$$\varphi_{ji} = \varphi(\|\mathbf{x}_j - \mathbf{x}_i\|), \quad j, i = 1, 2, \dots, N$$

# Interpolacija radijalnom mrežom III

- Neka su  $\mathbf{d}$  i  $\mathbf{w}$  vektori željenog odziva i težina:

$$\mathbf{d} = [d_1, d_2, \dots, d_N]^T$$

$$\mathbf{w} = [w_1, w_2, \dots, w_N]^T$$

- Neka je  $\Phi$  matrica dimenzija  $N \times N$  s elementima  $\phi_{ij}$ :

$$\Phi = \{\phi_{ji}\}, \quad j, i = 1, 2, \dots, N$$

- Tu matrica nazivamo interpolacijskom matricom
- Ranije dobiveni sustav linearnih jednadžbi sad možemo zapisati u matričnom obliku:

$$\Phi \mathbf{w} = \mathbf{d}$$

# Interpolacija radijalnom mrežom IV

- Pretpostavimo da su  $\mathbf{x}_1, \dots, \mathbf{x}_N$  međusobno različiti.
- Promatrajmo klasu radijalnih funkcija koje imaju svojstvo da je pripadna interpolacijska matrica  $\Phi$  pozitivno definitna
- Neki primjeri takvih radijalnih funkcija (često korištenih u praksi) su:

$$\varphi(r) = \frac{1}{(r^2 + c^2)^{1/2}}, \quad c > 0, \quad r \geq 0$$

$$\varphi(r) = \exp\left(-\frac{r^2}{2\sigma^2}\right), \quad \sigma > 0, \quad r \geq 0$$

# Interpolacija radijalnom mrežom V


- Istraživanja su pokazala postoji veliki izbor nelinearnih funkcija za koje je  $\Phi$  invertibilna i/ili pozitivno definitna
  - Za detalje vidi Micchellijev teorem (1986)
- Ako je matrica  $\Phi$  pozitivno definitna onda postoji inverzna matrica pa nepoznati vektor težina možemo izračunati kao:

$$\mathbf{w} = \Phi^{-1} \mathbf{d}$$

- U praksi rješenje može biti numerički nestabilno ako je matrica  $\Phi$  bliska singularnoj matrici
- Taj problem se može riješiti korištenjem rezultata teorije regularizacije
  - O tome više malo kasnije

# Interpolacija radijalnom mrežom VI.

- $i$ -ti neuron **skrivenog sloja** realizira funkciju  $\varphi(||\mathbf{x}-\mathbf{x}_i||)$
- **Izlazni neuron** računa linearnu kombinaciju svojih ulaza



# Generalizirana radijalna mreža I

- Iz ranije izloženoga vidi se da svaki **ulazni** uzorak  $\mathbf{x}_i$  traži jedan neuron u **skrivenom sloju**
- Za veliki broj ulaznih uzoraka to može postati problem
- U tom slučaju se umjesto  $N$  koristi samo  $M \ll N$  radijalnih funkcija

$$F(\mathbf{x}) = \sum_{i=1}^M w_i \varphi(\|\mathbf{x} - \mathbf{x}_i\|)$$



# Generalizirana radialna mreža II

- Dobivena interpolacijska matrica  $\Phi$  u slučaju reduciranja broja radialnih funkcija ima dimenzije  $N \times M$  tako da inverzna matrica ne postoji

- Problem je preodređen

$$\begin{bmatrix} \varphi_{11} & \varphi_{12} & \cdots & \varphi_{1M} \\ \varphi_{21} & \varphi_{22} & \cdots & \varphi_{2M} \\ \vdots & \vdots & & \vdots \\ \varphi_{i1} & \varphi_{i2} & \cdots & \varphi_{iM} \\ \vdots & \vdots & & \vdots \\ \varphi_{N1} & \varphi_{N2} & \cdots & \varphi_{NM} \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_M \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ \vdots \\ d_i \\ \vdots \\ d_N \end{bmatrix}$$

- Težine za ovaj slučaj računamo pomoću pseudoinverzne matrice od matrice  $\Phi$

$$\mathbf{w} = \Phi^+ \mathbf{d} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{d}$$

# Modifikacije

- Osim smanjenja broja radijalnih funkcija moguće su i druge korisne modifikacije:
  1. Centri radijalnih funkcija ne moraju biti određeni vrijednostima ulaznih vektora nego mogu imati i neke druge vrijednosti.
  2. Ako se koriste Gausove funkcije onda svaka funkcija može imati različiti parametar širine  $\sigma$ .
  3. Izlaznom neuronu se može dodati prag.
- Ako modifikacija dodaje parametre onda se svi ti nepoznati parametri moraju odrediti tijekom procesa učenja

# Učenje kao inverzni problem

- *Učenje* se može promatrati kao problem rekonstrukcije neke plohe koja je zadana skupom točaka koje mogu biti i jako razmaknute
- U toj interpretaciji *učenje* je inverzni problem
  - Znamo samo konačan broj ulazno-izlaznih točaka iz kojih treba odrediti cijelu plohu odnosno funkciju  $F$
- Inverzni problem može biti dobro postavljen (eng. *well-posed*) ili loše postavljen (eng. *ill-posed*)
- Pretpostavimo nepoznato preslikavanje

$$F : X \rightarrow Y$$

gdje je  $X$  domena, a  $Y$  kodomena

# Dobro postavljani problem

- **Definicija:** Problem rekonstrukcije funkcije  $F$  je **dobro postavljen** ako su zadovoljena slijedeća tri uvjeta:

1. **Egzistencija:** za svaki ulaz  $\mathbf{x}$  postoji izlaz  $y = F(\mathbf{x})$

2. **Jedinstvenost:**  $F(\mathbf{x})=F(\mathbf{t})$  ako i samo ako  $\mathbf{x}=\mathbf{t}$

3. **Kontinuiranost:**

$$\forall \varepsilon > 0, \exists \delta = \delta(\varepsilon) \mid \rho_x(\mathbf{x}, \mathbf{t}) < \delta \Rightarrow \rho_y(F(\mathbf{x}), F(\mathbf{t})) < \varepsilon$$

gdje su  $\rho_x$  i  $\rho_y$  mjere udaljenosti između vektora u pripadnim prostorima

# Loše postavljani problem

- **Definicija:** Problem rekonstrukcije funkcije  $F$  je loše postavljen onda i samo onda ako nije dobro postavljen.

# Nadzirano učenje

- Nadzirano učenje je loše postavljen problem rekonstrukcije neke plohe:
  1. Nema dovoljno informacija u primjerima za učenje tako da jedinstvenost ne vrijedi.
  2. Zbog šuma i neodređenosti uvjeti kontinuiranosti i egzistencije ne moraju biti zadovoljeni.
- Da bi problem učenja učinili dobro postavljenim potrebno je dodatno **a priori** znanje o traženom preslikavanju  $F$
- Takvo znanje može biti sadržano u redundantnosti uzoraka za učenje

# Teorija regularizacije

- Andrej Tikhonov, 1963
- Teorija regularizacije omogućuje nalaženje prihvatljivog rješenja za loše postavljene inverzne probleme
- Ideja regularizacije jest stabilizacija rješenja uvođenjem dodatnog člana koji u sebi sadrži *a priori* informaciju o preslikavanju  $F$  (npr. kontinuiranost, glatkoća)
- Nepoznata funkcija  $F$  se sada određuje minimizacijom funkcije cijene  $E(F)$  koja se sastoji od dva člana

# Teorija regularizacije

- Standardni član interpolacijske greške mjeri odstupanje između željenog odziva  $d_i$  i dobivenog odziva  $F(\mathbf{x}_i)$  za ulaz  $\mathbf{x}_i$ :

$$E_s(F) = \sum_{i=1}^N [d_i - F(\mathbf{x}_i)]^2$$

- Regularizacijski član ovisi o geometrijskim svojstvima funkcije  $F$

$$E_c(F) = \|\mathbf{P}F\|^2$$

Ovdje je  $\mathbf{P}$  linearni diferencijalni operator koji djeluje na  $F$ .



# Rješenje regularizacijom I.

- U teoriji regularizacije minimiziramo veličinu

$$E(F) = E_s(F) + \lambda E_c(F)$$

pri čemu je  $\lambda$  regularizacijski parametar

- Za određeni izbor operatora  $\mathbf{P}$  može se izračunati optimalno rješenje  $F$  koje minimizira  $E(F)$  je oblika:

$$F_\lambda(\mathbf{x}) = \frac{1}{\lambda} \sum_{i=1}^N [d_i - F(\mathbf{x}_i)] G(\mathbf{x}; \mathbf{x}_i)$$

gdje je  $G(. ; .)$  Greenova funkcija koja ovisi o izboru operatora  $\mathbf{P}$

# Rješenje regularizacijom II.

- Opće rješenje regularizacijskog problema je oblika

$$F(\mathbf{x}) = \sum_{i=1}^N w_i G(\mathbf{x}, \mathbf{x}_i)$$

gdje je  $G(\mathbf{x}, \mathbf{x}_i)$  Greenova funkcija

- Ako je  $\mathbf{P}$  translacijski invarijantan onda Greenova funkcija ovisi samo o razlici:

$$F(\mathbf{x}) = \sum_{i=1}^N w_i G(\mathbf{x} - \mathbf{x}_i)$$

- Ako je  $\mathbf{P}$  i translacijski i rotacijski invarijantan onda Greenova funkcija mora biti **radijalna funkcija**:


$$F(\mathbf{x}) = \sum_{i=1}^N w_i G(\|\mathbf{x} - \mathbf{x}_i\|)$$

# Regularizacijske mreže

- Zaključak: regularizacija problema interpolacije prirodno vodi do radijalnih mreža kao rješenja.
- Radijalne mreže su arhitektura koja omogućuje rješenje interpolacijskog problema uz poželjna svojstva:
  1. One su **univerzalni aproksimatori** u smislu da mogu aproksimirati bilo koju multivarijantnu neprekinutu funkcij uz dovoljno mnogo skrivenih neurona.
  2. Imaju svojstvo **najbolje aproksimacije** u smislu da za fiksiranu arhitekturu mreže postoji izbor parametara koji aproksimira  $F$  bolje od svih preostalih izbora.
  3. Dobiveno rješenje je **optimalno** u smislu da minimizira funkcional cijene s prikaznice 33.

# Radialna mreža

- **Skriveni sloj** sadrži N **Greenovih funkcija**  $G(||\mathbf{x} - \mathbf{x}_i||)$  koje moraju biti pozitivno definitne
  - Jedan mogući izbor su Gaussove funkcije
- **Izlazni sloj** realizira linearnu kombinaciju



## Primjer: funkcija XOR (drugi put) I

- Neka radijalna funkcija bude ne-normalizirana Gaussova funkcija:


$$G(\|\mathbf{x} - \mathbf{t}_i\|) = \exp\left(\frac{1}{2} \|\mathbf{x} - \mathbf{t}_i\|^2\right) \quad i = 1, 2$$

gdje su centri  $\mathbf{t}_1 = [1 \ 1]^T$  i  $\mathbf{t}_2 = [0 \ 0]^T$  fiksirani

- Neka izlazni neuron uz to ima i prag  $b$

# Primjer: funkcija XOR (drugi put) II

- Struktura radialne mreže je:



# Primjer: funkcija XOR (drugi put) III

- Ulazno-izlazna jednačba je:

$$y(\mathbf{x}) = \sum_{i=1}^2 w_i G(\|\mathbf{x} - \mathbf{t}_i\|) + b$$

- Interpolacijski uvjet mora vrijediti za sve primjere:

$$y(\mathbf{x}_j) = d_j, \quad j = 1, 2, 3, 4$$

- Neka je:

$$g_{ji} = G(\|\mathbf{x}_j - \mathbf{t}_i\|), \quad j = 1, 2, 3, 4; \quad i = 1, 2$$

# Primjer: funkcija XOR (drugi put) IV

- Sada dobivamo matričnu jednadžbu

$$\mathbf{G}\mathbf{w} = \mathbf{d}$$

gdje je

$$\mathbf{G} = \begin{bmatrix} g_{11} & g_{12} & 1 \\ g_{21} & g_{22} & 1 \\ g_{31} & g_{32} & 1 \\ g_{41} & g_{42} & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0,1353 & 1 \\ 0,3679 & 0,3679 & 1 \\ 0,1353 & 1 & 1 \\ 0,3679 & 0,3679 & 1 \end{bmatrix}$$

Annotations for the matrix  $\mathbf{G}$ :

- $x_1 = (1, 1)$  (red text, points to the first row)
- $x_2 = (0, 1)$  (green text, points to the second row)
- $x_3 = (0, 0)$  (red text, points to the third row)
- $x_4 = (1, 0)$  (green text, points to the fourth row)

$$\mathbf{w} = [w_1 \quad w_2 \quad b]^T$$

$$\mathbf{d} = [1 \quad 0 \quad 1 \quad 0]^T$$



## Primjer: funkcija XOR (drugi put) V

- Ovaj sustav jednađbi je preodređen jer ima više jednađbi nego nepoznanica

- Matrica  $\mathbf{G}$  nije kvadratna

- Rješenje nalazimo pomoću pseudoinverzne matrice:

$$\mathbf{w} = \mathbf{G}^+ \mathbf{d} = (\mathbf{G}^T \mathbf{G})^{-1} \mathbf{G}^T$$

- Dobivamo  $\mathbf{w} = [2,5027 \ 2,5027 \ -1,8413]^T$
- Prve dvije dobivene težine su jednake zbog simetrije problema radi fiksiranih centara  $\mathbf{t}_1$  i  $\mathbf{t}_2$

# Usporedba radijalnih mreža (RBF) i višeslojnog preceptrona (MLP)

1. RBF mreža ima samo jedan skriveni sloj dok MLP ima više slojeva
2. Svi neuroni MLP-a obično koriste isti model dok skriveni neuroni RBF mreže mogu biti različiti.
3. Skriveni sloj RBF mreže je nelinearan, a izlazni linearan; kod MLP-a su svi neuroni nelinearni.
4. Argument aktivacijske funkcije kod RBF mreže je udaljenost između ulaznog uzorka i centra radijalne funkcije; kod MLP-a argument aktivacijske funkcije je skalarni produkt ulaznog vektora i vektora težine.

# Strategije učenja

- Postoji više različitih strategija učenja kod radijalnih mreža koje se tipično razlikuju u tome kako se tretiraju centri radijalnih funkcija
- Neke od mogućih strategija su:
  1. Fiksni centri koji su slučajno odabrani
  2. Samo-organizirani odabir centara
  3. Odabir centara pod nadzorom

# Fiksni centri

- U ovom pristupu centri RBF funkcija su nasumično postavljeni su na unaprijed određene vrijednosti  $\mathbf{t}_i$

$$G(\|\mathbf{x} - \mathbf{t}_i\|) = \exp\left(-\frac{M}{d^2} \|\mathbf{x} - \mathbf{t}_i\|^2\right), \quad i = 1, 2, \dots, M$$

gdje je  $M$  broj odabranih centara i gdje je  $d$  najveća udaljenost između centara.

- Ovakav odabir postavlja standardnu devijaciju Gausovih funkcija u

$$\sigma = \frac{d}{\sqrt{2M}}$$

# Fiksni centri

- Takav odabir standardne devijacije garantira da Gausove funkcije neće biti niti preuske ni preširoke
- Nepoznati parametri mreže koje trebamo naučiti su težine  $\mathbf{w}$
- Težine se mogu izračunati pseudoinverznom metodom:

$$\mathbf{w} = \mathbf{G}^+ \mathbf{d}$$

gdje je matrica  $\mathbf{G} = \{g_{ji}\}$  i gdje je

$$g_{ji} = \exp\left(-\frac{M}{d^2} \|\mathbf{x}_j - \mathbf{t}_i\|^2\right), \quad j = 1, \dots, N; \quad i = 1, \dots, M$$

# Samo-organizirani centri

- U ovom pristupu centri radijalnih funkcija nisu fiksirani nego se mogu pomicati na samoorganizirani način
- Samoorganizacija omogućuje da se centri funkcija postave samo u područjima gdje ima puno ulaznih vektora

# Samo-organizirani centri

- Položaji centara mogu se računati algoritmom grupiranja s  $K$  srednjih vrijednosti
- Iznosi težina  $w$  se računaju kroz proces učenja pod nadzorom
- Za učenje pod nadzorom može se koristiti LMS algoritam
- Izlazi skrivenih neurona služe kao ulazi za LMS algoritam

# Učenje pod nadzorom

- Ovo je najopćenitiji slučaj gdje se svi slobodni parametri mreže određuju učenjem pod nadzorom (korekcijom pogreške)
- U ovom pristupu promatramo pogrešku mreže za sve parove ulaz-izlaz:

$$E = \frac{1}{2} \sum_{j=1}^N e_j^2$$

gdje je  $N$  broj parova za učenje i gdje je  $e_j$  signal pogreške



# Učenje pod nadzorom

- Pogreška  $e_j$  definirana je kao:

$$\begin{aligned}e_j &= d_j - F(\mathbf{x}_j) \\ &= d_j - \sum_{i=1}^M w_i G(\|\mathbf{x}_j - \mathbf{t}_i\|_A)\end{aligned}$$

gdje je:

$$\|\mathbf{z}\|_A^2 = \langle \mathbf{z}, \mathbf{z} \rangle_A = \mathbf{z}^T \mathbf{A} \mathbf{z}$$

i gdje je matrica  $\mathbf{A}$  pozitivno definitna.

# Učenje pod nadzorom

- U ovom pristupu slobodni parametri radijalne mreže koje treba odrediti da bi se minimizirala trenutna vrijednost pogreške su:
  - izlazne težine  $\mathbf{w}_i$
  - centri radijalnih funkcija  $\mathbf{t}_i$
  - matrica skalarnih produkta  $\mathbf{A}$
- Iterativnom metodom najbržeg spusta izvode se korekcije gornjih parametara

# Učenje pod nadzorom

- Eksperimentalna studija Wettschercka i Diettericha (1992) je pokazala da:
  1. Radijalna mreža sa samo-organizirajućim centrima i učenjem izlaznih težina pod nadzorom nije generalizirala toliko dobro kao višeslojni perceptron.
  2. Generalizirane radijalne mreže za koje se svi parametri određuju nadziranim učenjem su generalizirale bolje od višeslojnog perceptrona.

# Primjene radijalnih mreža

- Obrada slike
- Prepoznavanje govora
- Adaptivna ekvalizacija
- Medicinska dijagnostika
- Lokalizacija izvora kod radara
- Analiza stohastičkih signala

# Zadaci

- Zadatak 7.3
- Težine  $\mathbf{w}$  dobivene u primjeru za rješenje XOR problema (prikaznice 37-47) predstavljaju samo jednu moguću realizaciju uz odabrane fiksne centre
- Pronađite barem još jedno rješenje težina  $\mathbf{w}$  koje rješava XOR problem i koje je različito od prikazanih rješenja