

# Neuronske mreže: Samoorganizirajuće mreže

Prof. dr. sc. Sven Lončarić

Fakultet elektrotehnike i računarstva  
[https://www.fer.unizg.hr/predmet/neumre\\_c](https://www.fer.unizg.hr/predmet/neumre_c)

# Uvod

- Samoorganizirajuće mreže su one koje uče bez nadzora
- Kod učenja bez nadzora ne postoji učitelj
- Nema informacije o tome koju bi vrijednosti izlazi trebali imati za pojedine ulaze
- Mreža mora sama otkriti uzorke, korelacije ili kategorije u ulaznim podacima
- Da bi učenje bez nadzora bilo moguće potrebna je redundancija u ulaznim podacima
- Bez redundancije ulazni podaci izgledali bi kao slučajni šum i učenje ne bi bilo moguće

# Uvod

- Vrsta uzorka koju mreža otkriva u ulaznim podacima ovisi o arhitekturi mreže
- Postoji više različitih arhitektura samoorganizirajućih mreža koje se mogu koristiti za razne namjene
- Općenito, samoorganizirajuća mreža može detektirati razna svojstva ulaznih podataka navedena u nastavku

# Što predstavljaju izlazi ?

1. Sličnost: Jedan kontinuirani izlaz može pokazivati koliko je novi ulaz sličan dosadašnjim (prosječnim) uzorcima
2. Analiza glavnih komponenti: Proširenje mjerenja sličnosti s jednim na mjerenje s više vektora. Npr. upotreba vlastitih vektora korelacijske matrice ulaznih uzoraka.
3. Grupiranje: Skup binarnih izlaza gdje je samo jedan aktivan u jednom trenutku može nam reći kojoj grupi pripada ulazni uzorak

# Što predstavljaju izlazi ?

4. Prototyping: Slično kao grupiranje samo izlaz je predstavnik grupe kojoj pripada ulazni uzorak (asocijativna memorija)
5. Kodiranje: Izlaz je kodirana verzija ulaza, uz korištenje manje bitova i očuvanje što više relevantnih informacija (za kompresiju podataka)
6. Preslikavanje značajki (engl. feature mapping): Ako su izlazni neuroni u nekom geometrijskom rasporedu (npr. dvodimenzionalno polje) i ako je samo jedan aktivan u svakom momentu

# Pregled predavanja

- Hebbovo učenje bez nadzora
  - Samoorganizirajuća mreža s jednim neuronom
  - Ojino pravilo učenja bez nadzora
  - Analiza glavnih komponenti
  - Jednoslojna samoorganizirajuća mreža s bez povratnih veza
  - Sangerovo pravilo učenja bez nadzora za jednoslojnu mrežu
- Kompetitivno učenje bez nadzora

# Jedan linearni neuron

- Neka je  $\xi$   $N$ -dimenzionalni slučajni vektor s komponentama  $\xi_i, i = 1, \dots, N$
- Samoorganizirajuća mreža s jednim linearnim neuronom radi tako da se u svakom koraku generira slučajni vektor  $\xi$  i postavi na ulaz mreže
- Nakon što je mreža “vidjela” dovoljan broj uzoraka može na izlazu dati odgovor kako pojedini ulazni uzorak odgovara svojoj distribuciji
- Najjednostavniji je slučaj s jednim *linearnim* neuronom

# Jedan linearni neuron

- Izlaz linearnog neurona dan je izrazom:

$$v = \sum_{j=1}^N w_j \xi_j = \mathbf{w}^T \boldsymbol{\xi} = \boldsymbol{\xi}^T \mathbf{w}$$

gdje je  $\mathbf{w}$  vektor težina

- Kad imamo samo jedan neuron onda nam izlaz može biti mjera sličnosti uzorka s ostalima: Što je vjerojatniji određen ulazni vektor  $\boldsymbol{\xi}$  to mora biti veći izlaz  $v$
- Da bi to postigli, možemo koristiti Hebbov zakon učenja:

$$\Delta w_i = \eta v \xi_i$$



# Ojino pravilo učenja

- Problem Hebbovog učenja je da vektor težina stalno raste i učenje nikad nije gotovo
- Jedno rješenje ovog problema našao je Oja kroz modifikaciju originalnog Hebbovog pravila
- Ojino pravilo učenja bez nadzora:

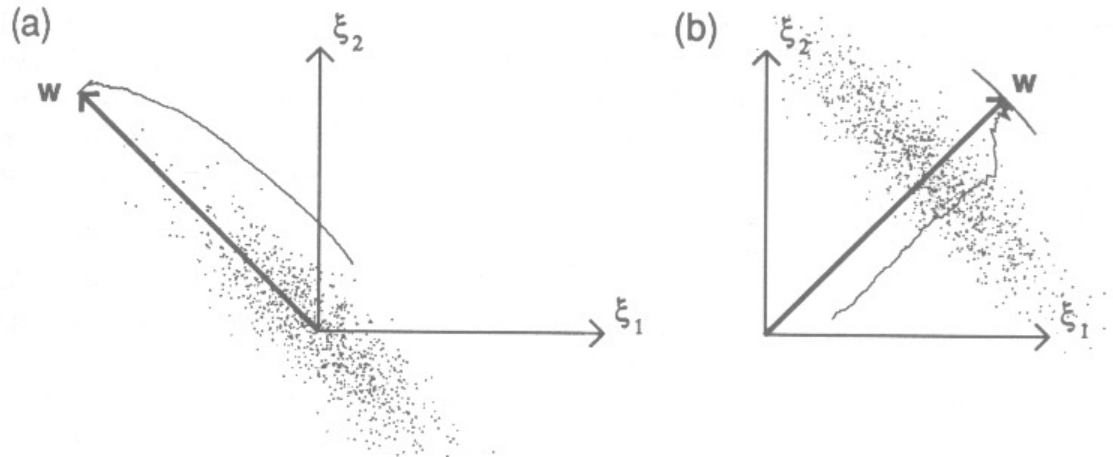
$$\Delta w_i = \eta v(\xi_i - v w_i)$$

# Oja pravilo: Svojstva

- Svojstva Ojinog algoritma učenja su takva da vektor težina konvergira ka vektoru  $\mathbf{w}$  koji ima slijedeća svojstva:
  1.  $|\mathbf{w}|=1$
  2.  $\mathbf{w}$  ima smjer maksimalnog vlastitog vektora korelacijske matrice  $\mathbf{C}$  ulaznih vektora
  3.  $\mathbf{w}$  ima smjer koji maksimizira  $E[v^2]$

# Primjer Oja učenja

- Slika prikazuje promjenu vektora težine za učenje prema Ojinom pravilu



# Analiza glavnih komponenti


- engl. principal component analysis
- Analiza glavnih komponenti je poznata metoda u raspoznavanju uzoraka i statistici
- Analiza glavnih komponenti poznata je u analizi signala i slika pod nazivom Karhunen-Loeve transformacija

# Analiza glavnih komponenti

- Ideja je da se za skup  $N$ -dimenzionalnih vektora nađe  $M < N$  ortogonalnih vektora u smjeru maksimalne varijacije podataka (ulaznih vektora)
- Projekcija podataka iz originalnog  $N$ -dimenzionalnog prostora u  $M$ -dimenzionalni obavlja redukciju dimenzionalnosti vektora
- Obično je  $M \ll N$  tako da su reducirani podaci puno lakši za analizu kada npr. želimo naći grupe (engl. clusters) podataka

# Analiza glavnih komponenti

- Grupe podataka je lakše prepoznati kad su podaci projecirani u smjeru velike varijance podataka (A) nego u smjeru male varijance podataka (B)



# Analiza glavnih komponenti

- Neka je  $\xi$   $N$ -dimenzionalni slučajni vektor
- Korelacijska matrica  $\mathbf{C}$  ovog slučajnog vektora definirana je kao:  $\mathbf{C} = E[\xi\xi^T]$
- Elementi matrice  $\mathbf{C}$  su korelacije parova slučajnih varijabli  $\xi_i$  i  $\xi_j$  :  $c_{ij} = E[\xi_i\xi_j]$
- Dijagonalni elementi predstavljaju varijance pojedinih slučajnih varijabli:  $c_{ii} = E[\xi_i^2]$
- $\mathbf{C}$  je simetrična matrica

# Analiza glavnih komponenti

- Tvrdnja: Smjer maksimalne varijacije podataka je smjer prve glavne komponente tj. maksimalnog vlastitog vektora (vektora koji odgovara maksimalnoj vlastitoj vrijednosti matrice **C**)
- Dokaz:

$$E[v^2] = E[(\mathbf{w}^T \boldsymbol{\xi})^2] = E[\mathbf{w}^T \boldsymbol{\xi} \boldsymbol{\xi}^T \mathbf{w}] = \mathbf{w}^T \mathbf{C} \mathbf{w}$$

Za fiksni  $|\mathbf{w}|$  i danu simetričnu matricu **C** poznato je iz linearne algebre da kvadratna forma  $\mathbf{w}^T \mathbf{C} \mathbf{w}$  ima maksimalnu vrijednost za vektor **w** koji je u smjeru maksimalnog vlastitog vektora korelacijske matrice **C**



# Analiza glavnih komponenti

- Može se pokazati da za ostale glavne komponente vrijedi sličan rezultat kako slijedi
- Druga glavna komponenta je ortogonalna na prvu i predstavlja glavnu komponentu za preostali  $N-1$ -dimenzionalni vektorski podprostor (u tom podprostoru druga komponenta predstavlja smjer najveće varijacije podataka)
- Druga glavna komponenta je u smjeru vlastitog vektora koji odgovara drugoj najvećoj vlastitoj vrijednosti

# Analiza glavnih komponenti: Sažetak

- Neka je  $A$  ortogonalna matrica čiji su stupci ortonormalizirani vlastiti vektori korelacijske matrice  $C=E[\xi\xi^T]$  ulaznog slučajnog vektora
- Navedeni vlastiti vektori pokazuju glavne komponente, tj. smjerove maksimalne varijacije podataka
- Transformacijom originalnog vektora  $\xi$  u novi vektor  $y=A^T\xi$  obavljamo projekciju iz originalnog prostora u novi prostor glavnih komponenti

# Analiza glavnih komponenti: Sažetak

- Ako zadržimo samo prvih  $M < N$  komponenti vektora  $y$  u novom prostoru onda smo uz najmanju moguću kvadratnu pogrešku prikazali originalni vektor  $\xi$
- Ne postoji niti jedna druga linearna transformacija koja će s  $M$  komponenti točnije (u smislu minimalne kvadrante pogreške) prikazati originalni vektor
- Promatranjem samo prvih  $M < N$  komponenti novog vektora  $y$  možemo lakše riješiti problem klasifikacije originalnih uzoraka  $\xi$

# Unaprijedna jednoslojna mreža

- Ojino pravilo se može iskoristiti za učenje u mreži s  $M$  izlaza koja daje prvih  $M$  glavnih komponenti
- Sanger i Oja su predložili takve mreže 1989
- Mreže su linearne i  $i$ -ti izlaz dan je izrazom:

$$v_i = \sum_{j=1}^N w_{ij} \xi_j = \mathbf{w}_i^T \boldsymbol{\xi} = \boldsymbol{\xi}^T \mathbf{w}_i$$

gdje je  $\mathbf{w}_i$   $N$ -dimenzionalni vektor težina za  $i$ -ti neuron

# Sangerovo pravilo učenja

- Kako je ranije rečeno, Ojino pravilo učenja za mrežu s jednim linearnim neuronom je:

$$\Delta w_i = \eta v(\xi_i - v w_i)$$

- Sangerovo pravilo učenja za jednoslojnu mrežu s  $M$  linearnih neurona definirano je izrazom:

$$\Delta w_{ij} = \eta v_i (\xi_j - \sum_{k=1}^i v_k w_{kj})$$

- Za prvi neuron ovo je pravilo jednako Ojinom, dakle njegov vektor težina konvergira ka prvoj glavnoj komponenti

# Sangerovo pravilo učenja

- Svaki od  $M$  linearnih neurona daje jedan izlaz koji odgovara jednog glavnoj komponenti
- Izlazi su prvih  $M$  glavnih komponenti za skup slučajnih ulaznih vektora

# Kompetitivno učenje bez nadzora

- Kod Hebbovog učenja može istovremeno biti aktivno više neurona
- Kod kompetitivnog učenja samo je jedan neuron (ili jedan neuron u grupi) aktivan u jednom trenutku
- Zato se ovakve mreže zovu engl. winner-takes-all (WTA) mreže
- Namjena ovakvih mreža je grupiranje ili kategorizacija podataka (slični ulazni vektori klasificiraju se u istu grupu)
- Mogu se koristiti za klasifikaciju uzoraka (objekata) u računalnom vidu ili za vektorsku kvantizaciju

# Winner-takes-all mreža

- U najjednostavnijem slučaju WTA mreža ima jedan sloj izlaznih neurona od kojih je svaki spojen na ulaze u mrežu
- Samo jedan neuron se može aktivirati (pobjednik)
- Pobjednik je neuron s najvećom aktivacijom:

$$h_i = \sum_j w_{ij} \xi_j = \mathbf{w}_i^T \boldsymbol{\xi}$$

- Za pobjednički neuron  $k$  vrijedi:

$$\mathbf{w}_k^T \boldsymbol{\xi} \geq \mathbf{w}_i^T \boldsymbol{\xi} \quad \forall i$$



# Winner-takes-all mreža

- Ako su težine normirane tako da je npr.  $|\mathbf{w}_i|=1$  onda je prethodni izraz ekvivalentan izrazu:

$$|\mathbf{w}_k - \xi| \leq |\mathbf{w}_i - \xi| \quad \forall i$$

- Drugim riječima pobjednik je neuron s težinom najbližom ulaznom vektoru  $\xi$
- Problem je sada kako odrediti težine  $\mathbf{w}_i$
- Jedan način učenja koji se može koristiti je standardno pravilo kompetitivnog učenja

# Kompetitivno učenje


- Vektori težina se inicijaliziraju na neke slučajne početne iznose
- Na ulaz mreže se dovode ulazni vektori prema slučajnom redoslijedu
- Za svaki ulazni vektor  $\xi$  odredi se neuron pobjednik i njegove težine se modificiraju prema pravilu:

$$\Delta w_{kj} = \eta(\xi_j - w_{kj})$$

- Standardno pravilo kompetitivnog učenja pomiče vektor težina u smjeru ulaznog vektora

# Kompetitivno učenje

- Primjer s tri neurona i dvodimenzionalnim vektorima
- Vektori težina su prikazani crveno, a ulazni vektori crno
- Lijeva slika prikazuje početno stanje
- Desna slika prikazuje stanje nakon završetka učenja



# Mjerenje kvalitete grupiranja

- Često je potrebno na neki način izmjeriti kvalitetu grupiranja koja je postignuta učenjem bez nadzora
- Standardnom pravilu za kompetitivno učenje pridružena je funkcija cijene definirana izrazom:

$$E = \frac{1}{2} \sum_{l=1}^L \sum_{i=1}^C \sum_{j=1}^N m_{il} (\xi_j^l - w_{ij})^2$$

gdje je  $L$  broj vektora,  $C$  broj grupa,  $N$  dimenzija vektora, a  $\mathbf{M}=\{m_{il}\}$  matrica pripadnosti grupama koja pokazuje da li uzorak  $\xi^l$  pripada grupi  $i$  :

$$m_{il} = \begin{cases} 1, & \xi^l \in C_i \\ 0, & \xi^l \notin C_i \end{cases}$$

# Mjerenje kvalitete grupiranja

- Ekvivalentan zapis funkcije cijene koja pokazuje kvalitetu grupiranja je:

$$E = \frac{1}{2} \sum_{l=1}^L |\xi^l - \mathbf{w}_{k(l)}|^2$$

gdje je  $k(l)$  indeks pobjedničkog neurona za  $l$ -ti ulazni uzorak  $\xi^l$

- Gornji izraz pokazuje sumu kvadrata udaljenosti svih ulaznih vektora od centara grupa kojima pripadaju
- To je mjera kvalitete grupiranja jer što je taj broj manji vektori su bolje koncentrirani oko centara grupa

# Primjene kompetitivnog učenja


- Primjeri primjena kompetitivnog učenja su:
  - Biparticija grafa
  - Kvantizacija vektora za kompresiju
  - Klasifikacija vektora za prepoznavanje objekata

# Primjer: Biparticija grafa

- Problem biparticije grafa sastoji se u podjeli grafa u dva podgrafa sa što manje grana koja ih povezuju
- Problem biparticije može se riješiti mrežom koja ima jedan binarni ulaz za svaki čvor grafa i dva izlazna neurona za indicaciju particije
- Ulazni skup vektora formira se tako da za svaku granu aktiviramo binarne ulaze koji odgovaraju incidentnim čvorovima
- Upotrebom kompetitivnog učenja mreža nauči podijeliti graf u dva dijela, tako da za svaki ulaz (granu) daje odgovor kojoj particiji ta grana pripada

# Primjer: Biparticija grafa

- Primjer rezultata biparticije grafa neuronskom mrežom
- Crni čvorovi pripadaju jednoj particiji, a bijeli drugoj






# Primjer: Kvantizacija vektora

- Problem se sastoji u tome da se kategorizira dani skup vektora u  $M$  klasa i zatim svaki vektor predstavi klasom kojoj pripada
- Na taj način se postiže kompresija podataka
- Prenosi se ili pohranjuje samo indeks klase u kodnoj stranici a ne cijeli vektor
- Kodna stranica sadrži po jedan vektor predstavnik pojedine klase
- Za svaki ulazni vektor traži se najbliži predstavnik u smislu Euklidske udaljenosti (to vodi na Voronoi teselaciju prostora)


# Voronoi teselacija prostora

- Kod Voronoi teselacije prostor je podijeljen u poligonalne regije koje su određene prototipnim vektorima
- Svaka regija predstavlja skup točaka koje su najbliže (u smislu Euklidskom udaljenosti) pripadnom prototipnom vektoru
- Granice su okomite na linije koje povezuju centre regija



# Primjer: Kvantizacija vektora

- Ilustracija upotrebe kompetitivnog učenja za vektorsku kvantizaciju



# Preslikavanje značajki

- engl. feature mapping
- Do sada nismo obraćali pažnju na geometrijski raspored kompetitivnih izlaznih neurona
- Često je korisno rasporediti izlazne neurone u 1-D raspored ili u 2-D raspored
- Tada možemo zamisliti mreže gdje bliski ulazi odgovaraju bliskim izlazima odnosno ako ulazi nisu blizu onda ni izlazi ne smiju biti blizu
- To je onda preslikavanje koje čuva topologiju
- Korisno pri vizualizaciji višedimenzijskih prostora

# Kohonenov algoritam





- Kohonen je koristio kompetitivnu mrežu i način učenja
- Kohonenov algoritam učenja podešava težine u nekoj okolini pobjedničkog neurona:

$$\Delta w_{ij} = \eta \Lambda(i, k) (\xi_j - w_{ij})$$

gdje je  $\Lambda(i, k)$  funkcija koja se smanjuje s udaljenošću od pobjedničkog neurona  $k$  i koja određuje susjedstvo unutar kojeg se vrši učenje

# Primjer 2-D preslikavanja značajki

- Kohonenovo 2-D preslikavanje značajki iz kvadratne regije ravnine na polje od  $10 \times 10$  neurona
- Prikazano je četiri stanja u procesu učenja, gdje je ulaz 2-D slučajni vektor



# Zaključak

- Samoorganizirajuće mreže koriste učenje bez nadzora
- Učenje bez nadzora korisno je u velikom broju aplikacija kad nije raspoloživa informacija o željenom izlazu
- Primjene uključuju: klasifikaciju objekata ili uzoraka, vektorsku kvantizaciju za upotrebu u kompresiji, grupiranje (clustering) za analizu podataka, preslikavanje značajki