

# Rješavanje optimizacijskih problema algoritmima evolucijskog računanja u Javi Numeričke optimizacije. Uspješnost generiranja početnih rješenja.

dr.sc. Marko Čupić

Fakultet elektrotehnike i računarstva  
Sveučilište u Zagrebu  
Akademska godina 2013./2014.

10. listopada 2013.

# Layout

- 1 Optimizacija derivabilnih funkcija
  - Primjer funkcije jedne varijable
  - Primjer funkcije više varijabli
  - Odgovarajući pomak
  
- 2 Povećanje uspješnosti generiranja početnih rješenja

## Prvi primjer

Pretpostavimo da je zadana funkcija  $f(x) = 3x^2 - 6x - 45$  čiji tražimo minimum. To je skalarna funkcija koja je definirana nad skalarom  $x \in \mathcal{R}$ .

- Funkcija ima prvu derivaciju definiranu u svim točkama.

## Prvi primjer

Pretpostavimo da je zadana funkcija  $f(x) = 3x^2 - 6x - 45$  čiji tražimo minimum. To je skalarna funkcija koja je definirana nad skalarom  $x \in \mathcal{R}$ .

- Funkcija ima prvu derivaciju definiranu u svim točkama.

$$\frac{df}{dx} = 6x - 6$$

## Prvi primjer

Pretpostavimo da je zadana funkcija  $f(x) = 3x^2 - 6x - 45$  čiji tražimo minimum. To je skalarna funkcija koja je definirana nad skalarom  $x \in \mathcal{R}$ .

- Funkcija ima prvu derivaciju definiranu u svim točkama.

$$\frac{df}{dx} = 6x - 6$$

- Funkcija ima drugu derivaciju definiranu u svim točkama.

## Prvi primjer

Pretpostavimo da je zadana funkcija  $f(x) = 3x^2 - 6x - 45$  čiji tražimo minimum. To je skalarna funkcija koja je definirana nad skalarom  $x \in \mathcal{R}$ .

- Funkcija ima prvu derivaciju definiranu u svim točkama.

$$\frac{df}{dx} = 6x - 6$$

- Funkcija ima drugu derivaciju definiranu u svim točkama.

$$\frac{d^2 f}{dx^2} = 6$$

## Prvi primjer

Pretpostavimo da je zadana funkcija  $f(x) = 3x^2 - 6x - 45$  čiji tražimo minimum. To je skalarna funkcija koja je definirana nad skalarom  $x \in \mathcal{R}$ .

- Funkcija ima prvu derivaciju definiranu u svim točkama.

$$\frac{df}{dx} = 6x - 6$$

- Funkcija ima drugu derivaciju definiranu u svim točkama.

$$\frac{d^2 f}{dx^2} = 6$$

- Kako izgleda graf ove funkcije?

## Prvi primjer

Pretpostavimo da je zadana funkcija  $f(x) = 3x^2 - 6x - 45$  čiji tražimo minimum. To je skalarna funkcija koja je definirana nad skalarom  $x \in \mathcal{R}$ .

- Funkcija ima prvu derivaciju definiranu u svim točkama.

$$\frac{df}{dx} = 6x - 6$$

- Funkcija ima drugu derivaciju definiranu u svim točkama.

$$\frac{d^2 f}{dx^2} = 6$$

- Kako izgleda graf ove funkcije?
- Gdje je minimum?



## Prvi primjer

Pretpostavimo da je zadana funkcija  $f(x) = 3x^2 - 6x - 45$  čiji tražimo minimum. To je skalarna funkcija koja je definirana nad skalarom  $x \in \mathcal{R}$ .

- Funkcija ima prvu derivaciju definiranu u svim točkama.

$$\frac{df}{dx} = 6x - 6$$

- Funkcija ima drugu derivaciju definiranu u svim točkama.

$$\frac{d^2 f}{dx^2} = 6$$

- Kako izgleda graf ove funkcije?
- Gdje je minimum? Za  $f' = 0$ .

## Prvi primjer

Pretpostavimo da je zadana funkcija  $f(x) = 3x^2 - 6x - 45$  čiji tražimo minimum. To je skalarna funkcija koja je definirana nad skalarom  $x \in \mathcal{R}$ .

- Funkcija ima prvu derivaciju definiranu u svim točkama.

$$\frac{df}{dx} = 6x - 6$$

- Funkcija ima drugu derivaciju definiranu u svim točkama.

$$\frac{d^2 f}{dx^2} = 6$$

- Kako izgleda graf ove funkcije?
- Gdje je minimum? Za  $f' = 0$ .  $6 \cdot x_{min} - 6 = 0 \rightarrow x_{min} = 1$

# Prvi primjer

Predznak prve derivacije u nekoj točki  $x$  definira što treba napraviti toj točki da bi vrijednost funkcije porasla.

$$f' = \frac{df}{dx} = 6x - 6$$

# Prvi primjer

Predznak prve derivacije u nekoj točki  $x$  definira što treba napraviti toj točki da bi vrijednost funkcije porasla.

$$f' = \frac{df}{dx} = 6x - 6$$

- Koja je vrijednost u minimumu?

# Prvi primjer

Predznak prve derivacije u nekoj točki  $x$  definira što treba napraviti toj točki da bi vrijednost funkcije porasla.

$$f' = \frac{df}{dx} = 6x - 6$$

- Koja je vrijednost u minimumu?

$$\left. \frac{df}{dx} \right|_{x=1} = 6x - 6|_{x=1} = 6 - 6 = 0$$

# Prvi primjer

Predznak prve derivacije u nekoj točki  $x$  definira što treba napraviti toj točki da bi vrijednost funkcije porasla.

$$f' = \frac{df}{dx} = 6x - 6$$

- Koja je vrijednost u  $x > 1$

## Prvi primjer

Predznak prve derivacije u nekoj točki  $x$  definira što treba napraviti toj točki da bi vrijednost funkcije porasla.

$$f' = \frac{df}{dx} = 6x - 6$$

- Koja je vrijednost u  $x > 1$

$$\left. \frac{df}{dx} \right|_{x>1} = 6x - 6|_{x>1} > 0$$

## Prvi primjer

Predznak prve derivacije u nekoj točki  $x$  definira što treba napraviti toj točki da bi vrijednost funkcije porasla.

$$f' = \frac{df}{dx} = 6x - 6$$

- Koja je vrijednost u  $x > 1$

$$\left. \frac{df}{dx} \right|_{x>1} = 6x - 6|_{x>1} > 0$$

- Koja je vrijednost u  $x < 1$



## Prvi primjer

Predznak prve derivacije u nekoj točki  $x$  definira što treba napraviti toj točki da bi vrijednost funkcije porasla.

$$f' = \frac{df}{dx} = 6x - 6$$

- Koja je vrijednost u  $x > 1$

$$\left. \frac{df}{dx} \right|_{x>1} = 6x - 6|_{x>1} > 0$$

- Koja je vrijednost u  $x < 1$

$$\left. \frac{df}{dx} \right|_{x<1} = 6x - 6|_{x<1} < 0$$

# Prvi primjer

Predznak prve derivacije u nekoj točki  $x$  definira što treba napraviti toj točki da bi vrijednost funkcije porasla.

$$f' = \frac{df}{dx} = 6x - 6$$

## Prvi primjer

Predznak prve derivacije u nekoj točki  $x$  definira što treba napraviti toj točki da bi vrijednost funkcije porasla.

$$f' = \frac{df}{dx} = 6x - 6$$

- Ako je  $f'(x) = 0$ , vrijednost  $x$  je lokalni optimum (ili točka infleksije, ili ...).

## Prvi primjer

Predznak prve derivacije u nekoj točki  $x$  definira što treba napraviti toj točki da bi vrijednost funkcije porasla.

$$f' = \frac{df}{dx} = 6x - 6$$

- Ako je  $f'(x) = 0$ , vrijednost  $x$  je lokalni optimum (ili točka infleksije, ili ...).
- Ako je  $f'(x) > 0$ , povećanjem  $x$ -a vrijednost funkcije će se također povećati.

## Prvi primjer

Predznak prve derivacije u nekoj točki  $x$  definira što treba napraviti toj točki da bi vrijednost funkcije porasla.

$$f' = \frac{df}{dx} = 6x - 6$$

- Ako je  $f'(x) = 0$ , vrijednost  $x$  je lokalni optimum (ili točka infleksije, ili ...).
- Ako je  $f'(x) > 0$ , povećanjem  $x$ -a vrijednost funkcije će se također povećati.
- Ako je  $f'(x) < 0$ , smanjenjem  $x$ -a vrijednost funkcije će se također povećati.

# Prvi primjer

Predznak prve derivacije u nekoj točki  $x$  definira što treba napraviti toj točki da bi vrijednost funkcije porasla.

$$f' = \frac{df}{dx} = 6x - 6$$

Za traženje minimuma funkcije tada ćemo okrenuti pravilo: potrebno je kretati se u smjeru negativne derivacije!

## Prvi primjer

Predznak prve derivacije u nekoj točki  $x$  definira što treba napraviti toj točki da bi vrijednost funkcije porasla.

$$f' = \frac{df}{dx} = 6x - 6$$

Za traženje minimuma funkcije tada ćemo okrenuti pravilo: potrebno je kretati se u smjeru negativne derivacije!

- Ako je  $f'(x) = 0$ , vrijednost  $x$  je lokalni optimum (ili točka infleksije, ili ...).

## Prvi primjer

Predznak prve derivacije u nekoj točki  $x$  definira što treba napraviti toj točki da bi vrijednost funkcije porasla.

$$f' = \frac{df}{dx} = 6x - 6$$

Za traženje minimuma funkcije tada ćemo okrenuti pravilo: potrebno je kretati se u smjeru negativne derivacije!

- Ako je  $f'(x) = 0$ , vrijednost  $x$  je lokalni optimum (ili točka infleksije, ili ...).
- Ako je  $f'(x) > 0$ ,  $x$  ćemo smanjiti kako bi vrijednost funkcije pala:  $x \leftarrow x - \delta$ ,  $\delta > 0$ .



## Prvi primjer

Predznak prve derivacije u nekoj točki  $x$  definira što treba napraviti toj točki da bi vrijednost funkcije porasla.

$$f' = \frac{df}{dx} = 6x - 6$$

Za traženje minimuma funkcije tada ćemo okrenuti pravilo: potrebno je kretati se u smjeru negativne derivacije!

- Ako je  $f'(x) = 0$ , vrijednost  $x$  je lokalni optimum (ili točka infleksije, ili ...).
- Ako je  $f'(x) > 0$ ,  $x$  ćemo smanjiti kako bi vrijednost funkcije pala:  $x \leftarrow x - \delta$ ,  $\delta > 0$ .
- Ako je  $f'(x) < 0$ ,  $x$  ćemo povećati kako bi vrijednost funkcije pala:  $x \leftarrow x + \delta$ ,  $\delta > 0$ .

## Prvi primjer

Predznak prve derivacije u nekoj točki  $x$  definira što treba napraviti toj točki da bi vrijednost funkcije porasla.

$$f' = \frac{df}{dx} = 6x - 6$$

Za traženje minimuma funkcije tada ćemo okrenuti pravilo: potrebno je kretati se u smjeru negativne derivacije!

- Ako je  $f'(x) = 0$ , vrijednost  $x$  je lokalni optimum (ili točka infleksije, ili ...).
- Ako je  $f'(x) > 0$ ,  $x$  ćemo smanjiti kako bi vrijednost funkcije pala:  $x \leftarrow x - \delta$ ,  $\delta > 0$ .
- Ako je  $f'(x) < 0$ ,  $x$  ćemo povećati kako bi vrijednost funkcije pala:  $x \leftarrow x + \delta$ ,  $\delta > 0$ .
- Ako je  $f'(x) \neq 0$ , možemo pisati  $x \leftarrow x - \lambda \cdot f'(x)$ ,  $\lambda > 0$ .

## Prvi primjer

Predznak prve derivacije u nekoj točki  $x$  definira što treba napraviti toj točki da bi vrijednost funkcije porasla.

$$f' = \frac{df}{dx} = 6x - 6$$

Za traženje minimuma funkcije tada ćemo okrenuti pravilo: potrebno je kretati se u smjeru negativne derivacije!

- Ako je  $f'(x) = 0$ , vrijednost  $x$  je lokalni optimum (ili točka infleksije, ili ...).
- Ako je  $f'(x) > 0$ ,  $x$  ćemo smanjiti kako bi vrijednost funkcije pala:  $x \leftarrow x - \delta$ ,  $\delta > 0$ .
- Ako je  $f'(x) < 0$ ,  $x$  ćemo povećati kako bi vrijednost funkcije pala:  $x \leftarrow x + \delta$ ,  $\delta > 0$ .
- Ako je  $f'(x) \neq 0$ , možemo pisati  $x \leftarrow x - \lambda \cdot f'(x)$ ,  $\lambda > 0$ .

Za koliki iznos  $\delta$  to smijemo promijeniti  $x$ ?

# Layout

## 1 Optimizacija derivabilnih funkcija

- Primjer funkcije jedne varijable
- Primjer funkcije više varijabli
- Odgovarajući pomak

## 2 Povećanje uspješnosti generiranja početnih rješenja

## Drugi primjer

Pretpostavimo da je zadana funkcija

$f(\vec{x}) = (x_1 - 4)^2 + (x_2 + 8)^2 + (x_3 + 5)^2$  čiji tražimo minimum. To je skalarna funkcija koja je definirana nad  $n$ -dimenzijskim vektorom  $\vec{x} \in \mathcal{R}^3$ .

- Više ne možemo računati *derivaciju* jer je to funkcija od više varijabli.

## Drugi primjer

Pretpostavimo da je zadana funkcija

$f(\vec{x}) = (x_1 - 4)^2 + (x_2 + 8)^2 + (x_3 + 5)^2$  čiji tražimo minimum. To je skalarna funkcija koja je definirana nad  $n$ -dimenzijskim vektorom  $\vec{x} \in \mathcal{R}^3$ .

- Više ne možemo računati *derivaciju* jer je to funkcija od više varijabli.
- Možemo računati **gradijent** – pisat ćemo ga kao jednostupčani vektor čiji je element u  $i$ -tom retku parcijalna derivacija zadane funkcije po  $i$ -toj varijabli odnosno  $i$ -toj komponenti vektora  $\vec{x}$ .

## Drugi primjer

Pretpostavimo da je zadana funkcija

$f(\vec{x}) = (x_1 - 4)^2 + (x_2 + 8)^2 + (x_3 + 5)^2$  čiji tražimo minimum. To je skalarna funkcija koja je definirana nad  $n$ -dimenzijskim vektorom  $\vec{x} \in \mathcal{R}^3$ .

- Više ne možemo računati *derivaciju* jer je to funkcija od više varijabli.
- Možemo računati **gradijent** – pisat ćemo ga kao jednostupčani vektor čiji je element u  $i$ -tom retku parcijalna derivacija zadane funkcije po  $i$ -toj varijabli odnosno  $i$ -toj komponenti vektora  $\vec{x}$ .

$$\nabla f(\vec{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \frac{\partial f}{\partial x_3} \end{bmatrix} = \begin{bmatrix} 2x_1 - 8 \\ 2x_2 + 16 \\ 2x_3 + 10 \end{bmatrix}$$

## Drugi primjer

$$\nabla f(\vec{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \frac{\partial f}{\partial x_3} \end{bmatrix} = \begin{bmatrix} 2x_1 - 8 \\ 2x_2 + 16 \\ 2x_3 + 10 \end{bmatrix}$$



## Drugi primjer

$$\nabla f(\vec{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \frac{\partial f}{\partial x_3} \end{bmatrix} = \begin{bmatrix} 2x_1 - 8 \\ 2x_2 + 16 \\ 2x_3 + 10 \end{bmatrix}$$

- Funkcija poprima ekstremnu vrijednost (ili sedlo, ili ...) u točkama u kojima je  $\nabla f(\vec{x}) = \vec{0}$ .

## Drugi primjer

$$\nabla f(\vec{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \frac{\partial f}{\partial x_3} \end{bmatrix} = \begin{bmatrix} 2x_1 - 8 \\ 2x_2 + 16 \\ 2x_3 + 10 \end{bmatrix}$$

- Funkcija poprima ekstremnu vrijednost (ili sedlo, ili ...) u točkama u kojima je  $\nabla f(\vec{x}) = \vec{0}$ .
- Rezultira sustavom jednadžbi koji nije uvijek moguće riješiti egzaktno  $\rightarrow$  vodi na iterativne postupke koji malo po malo mijenjaju vrijednost trenutnog rješenja  $\vec{x}$ .

## Drugi primjer

$$\nabla f(\vec{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \frac{\partial f}{\partial x_3} \end{bmatrix} = \begin{bmatrix} 2x_1 - 8 \\ 2x_2 + 16 \\ 2x_3 + 10 \end{bmatrix}$$

- Funkcija poprima ekstremnu vrijednost (ili sedlo, ili ...) u točkama u kojima je  $\nabla f(\vec{x}) = \vec{0}$ .
- Rezultira sustavom jednadžbi koji nije uvijek moguće riješiti egzaktno  $\rightarrow$  vodi na iterativne postupke koji malo po malo mijenjaju vrijednost trenutnog rješenja  $\vec{x}$ .
- Interpretacija gradijenta je međutim slična kao i interpretacija derivacije: promjena vrijednosti  $\vec{x}$  za skalirani iznos  $\lambda \cdot \nabla f(\vec{x})$ ,  $\lambda > 0$ , u okolini od  $\vec{x}$  vodi ka povećanju vrijednosti funkcije.

## Drugi primjer

$$\nabla f(\vec{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \frac{\partial f}{\partial x_3} \end{bmatrix} = \begin{bmatrix} 2x_1 - 8 \\ 2x_2 + 16 \\ 2x_3 + 10 \end{bmatrix}$$

- Funkcija poprima ekstremnu vrijednost (ili sedlo, ili ...) u točkama u kojima je  $\nabla f(\vec{x}) = \vec{0}$ .
- Rezultira sustavom jednadžbi koji nije uvijek moguće riješiti egzaktno  $\rightarrow$  vodi na iterativne postupke koji malo po malo mijenjaju vrijednost trenutnog rješenja  $\vec{x}$ .
- Interpretacija gradijenta je međutim slična kao i interpretacija derivacije: promjena vrijednosti  $\vec{x}$  za skalirani iznos  $\lambda \cdot \nabla f(\vec{x})$ ,  $\lambda > 0$ , u okolini od  $\vec{x}$  vodi ka povećanju vrijednosti funkcije.
- Za minimizaciju stoga biramo korekciju proporcionalnu iznosu  $-\lambda \cdot \nabla f(\vec{x})$ . Za koliki  $\lambda$  se smijemo pomaknuti?

# Layout

- 1 Optimizacija derivabilnih funkcija
  - Primjer funkcije jedne varijable
  - Primjer funkcije više varijabli
  - Odgovarajući pomak
  
- 2 Povećanje uspješnosti generiranja početnih rješenja

# Koliko je prikladno?

- U slučaju funkcije od jedne varijable došli smo do ažuriranja:

$$x \leftarrow x - \lambda \cdot f'(x)$$

# Koliko je prikladno?

- U slučaju funkcije od jedne varijable došli smo do ažuriranja:

$$x \leftarrow x - \lambda \cdot f'(x)$$

- U slučaju funkcije od više varijabli došli smo do ažuriranja:

$$\vec{x} \leftarrow \vec{x} - \lambda \cdot \nabla f(\vec{x})$$

# Koliko je prikladno?

- U slučaju funkcije od jedne varijable došli smo do ažuriranja:

$$x \leftarrow x - \lambda \cdot f'(x)$$

- U slučaju funkcije od više varijabli došli smo do ažuriranja:

$$\vec{x} \leftarrow \vec{x} - \lambda \cdot \nabla f(\vec{x})$$

- U oba slučaja ostalo je neodgovoreno za koliko se smijemo pomaknuti?



## Koliko je prikladno?

- U slučaju funkcije od jedne varijable došli smo do ažuriranja:

$$x \leftarrow x - \lambda \cdot f'(x)$$

- U slučaju funkcije od više varijabli došli smo do ažuriranja:

$$\vec{x} \leftarrow \vec{x} - \lambda \cdot \nabla f(\vec{x})$$

- U oba slučaja ostalo je neodgovoreno za koliko se smijemo pomaknuti?
  - Ako je  $\lambda > 0$  premali, da smo uzeli veći, mogli smo funkciju više minimizirati u trenutnom koraku.

## Koliko je prikladno?

- U slučaju funkcije od jedne varijable došli smo do ažuriranja:

$$x \leftarrow x - \lambda \cdot f'(x)$$

- U slučaju funkcije od više varijabli došli smo do ažuriranja:

$$\vec{x} \leftarrow \vec{x} - \lambda \cdot \nabla f(\vec{x})$$

- U oba slučaja ostalo je neodgovoreno za koliko se smijemo pomaknuti?
  - Ako je  $\lambda > 0$  premali, da smo uzeli veći, mogli smo funkciju više minimizirati u trenutnom koraku.
  - Ako je  $\lambda > 0$  preveliki, izlazimo iz *okolice* od  $\vec{x}$  pa tako daleko funkcija se može ponašati drugačije (npr. rasti).

# Algoritmi pretraživanja u zadanom smjeru?

U oba prethodna slučaja zadana je točka ( $x$  ili  $\vec{x}$ ) te smjer u kojem se treba pomaknuti ( $-\lambda \cdot f'(x)$  ili  $-\lambda \cdot \nabla f(\vec{x})$ ) – potrebno je pronaći prikladnu vrijednost za  $\lambda$ .

# Algoritmi pretraživanja u zadanom smjeru?

U oba prethodna slučaja zadana je točka ( $x$  ili  $\vec{x}$ ) te smjer u kojem se treba pomaknuti ( $-\lambda \cdot f'(x)$  ili  $-\lambda \cdot \nabla f(\vec{x})$ ) – potrebno je pronaći prikladnu vrijednost za  $\lambda$ .

- Postoji niz algoritama koji se mogu koristiti za rješavanje ovog problema.

# Algoritmi pretraživanja u zadanom smjeru?

U oba prethodna slučaja zadana je točka ( $x$  ili  $\vec{x}$ ) te smjer u kojem se treba pomaknuti ( $-\lambda \cdot f'(x)$  ili  $-\lambda \cdot \nabla f(\vec{x})$ ) – potrebno je pronaći prikladnu vrijednost za  $\lambda$ .

- Postoji niz algoritama koji se mogu koristiti za rješavanje ovog problema.
- Rijetko kada imamo egzaktno rješenje – najčešće se radi o iterativnim postupcima.

## Algoritmi pretraživanja u zadanom smjeru?

U oba prethodna slučaja zadana je točka ( $x$  ili  $\vec{x}$ ) te smjer u kojem se treba pomaknuti ( $-\lambda \cdot f'(x)$  ili  $-\lambda \cdot \nabla f(\vec{x})$ ) – potrebno je pronaći prikladnu vrijednost za  $\lambda$ .

- Postoji niz algoritama koji se mogu koristiti za rješavanje ovog problema.
- Rijetko kada imamo egzaktno rješenje – najčešće se radi o iterativnim postupcima.
- Kako je višedimenzijski slučaj općenitiji ( $\vec{x}$ ), njega ćemo razmotriti.

## Algoritmi pretraživanja u zadanom smjeru?

Zadana je funkcija  $f(\vec{x})$  čiji se traži minimum, pri čemu je  $\vec{x} \in \mathcal{R}^n$ . Neka je  $\vec{x}^{(0)}$  odabrano početno rješenje. Pretpostavimo također da je  $\vec{d}^{(0)} \in \mathcal{R}^n$  vektor koji pokazuje u smjeru u kojem je potrebno modificirati trenutno rješenje kako bi vrijednost funkcije pala, gledano iz trenutne točke  $\vec{x}^{(0)}$ .

Uvodimo parametar  $\lambda$  te definiramo novu funkciju:

$$\theta(\lambda) = f(\vec{x}^{(0)} + \lambda \cdot \vec{d}^{(0)}).$$

Funkcija  $\theta$  ovisi samo o  $\lambda$ ; za nju su  $\vec{x}^{(0)}$  i  $\vec{d}^{(0)}$  konstante. Sada je zadatak pronaći vrijednost  $\lambda^*$  koja minimizira funkciju  $\theta(\lambda)$  i potom kao novo rješenje uzeti vrijednost:

$$\vec{x}^{(1)} = \vec{x}^{(0)} + \lambda^* \cdot \vec{d}^{(0)}.$$

## Algoritmi pretraživanja u zadanom smjeru?

Neka je  $f(\vec{x}) = (x_1 - 4)^2 + (x_2 + 8)^2 + (x_3 + 5)^2$ ,  
 $\vec{x}^{(0)} = [6, -10, -9]^T$  te  $\vec{d} = [-1, 2, 1]^T$ . Lagano se možemo  
 uvjeriti da će za male vrijednosti  $\lambda$  funkcija padati te će potom u  
 jednom trenutku početi rasti:

$\lambda$	$\vec{x}^{(0)} + \lambda \cdot \vec{d}^{(0)}$	$\theta(\lambda)$
0	$[6, -10, -9]^T$	24
1	$[5, -8, -8]^T$	10
2	$[4, -6, -7]^T$	8
3	$[3, -4, -6]^T$	18
4	$[2, -2, -5]^T$	40



# Algoritmi pretraživanja u zadanom smjeru?

Pogledajmo

$$\frac{d\theta(\lambda)}{d\lambda} = \nabla f(\vec{x})^T \cdot \vec{d}.$$

# Algoritmi pretraživanja u zadanom smjeru?

Pogledajmo

$$\frac{d\theta(\lambda)}{d\lambda} = \nabla f(\vec{x})^T \cdot \vec{d}.$$

- Vrijedi

$$\left. \frac{d\theta(\lambda)}{d\lambda} \right|_{\lambda=0} < 0.$$

Zašto to vrijedi? Definirat ćemo stoga da je  $\lambda_{lower} = 0$ .

# Algoritmi pretraživanja u zadanom smjeru?

Pogledajmo

$$\frac{d\theta(\lambda)}{d\lambda} = \nabla f(\vec{x})^T \cdot \vec{d}.$$

- Vrijedi

$$\left. \frac{d\theta(\lambda)}{d\lambda} \right|_{\lambda=0} < 0.$$

Zašto to vrijedi? Definirat ćemo stoga da je  $\lambda_{lower} = 0$ .

- Trebamo gornju ogradu za  $\lambda$ , oznaka  $\lambda_{upper}$ , uz koju će funkcija  $f$  ponovno početi rasti, odnosno za koju će  $\frac{d\theta(\lambda)}{d\lambda_{upper}} > 0$ .

# Algoritmi pretraživanja u zadanom smjeru?

Pogledajmo

$$\frac{d\theta(\lambda)}{d\lambda} = \nabla f(\vec{x})^T \cdot \vec{d}.$$

- Vrijedi

$$\left. \frac{d\theta(\lambda)}{d\lambda} \right|_{\lambda=0} < 0.$$

Zašto to vrijedi? Definirat ćemo stoga da je  $\lambda_{lower} = 0$ .

- Trebamo gornju ogradu za  $\lambda$ , oznaka  $\lambda_{upper}$ , uz koju će funkcija  $f$  ponovno početi rasti, odnosno za koju će  $\frac{d\theta(\lambda)}{d\lambda_{upper}} > 0$ .
  - Ako takvu nemamo, možemo isprobavati  $\lambda_{upper} = 1$ ,  $\lambda_{upper} = 2$ ,  $\lambda_{upper} = 4$ ,  $\lambda_{upper} = 8$ , ... dok ne pronađemo potreban  $\lambda_{upper}$ .

## Algoritmi pretraživanja u zadanom smjeru?

Jednom kada imamo  $\lambda_{lower}$  i  $\lambda_{upper}$ , sigurno znamo da se  $\lambda$  koji minimizira funkciju nalazi između te dvije ograde. Možemo koristiti, primjerice, binarno raspolavljanje.

### Metoda bisekcije

**Korak 0.** Postavi  $k = 0$ . Postavi  $\lambda_l = \lambda_{lower}$  te  $\lambda_u = \lambda_{upper}$ .

**Korak k.** Postavi  $\lambda = \frac{\lambda_l + \lambda_u}{2}$  i izračunaj  $\left. \frac{d\theta(\lambda)}{d\lambda} \right|_{\lambda}$ .

Ako je  $\left. \frac{d\theta(\lambda)}{d\lambda} \right|_{\lambda} > 0$ , redefiniraj  $\lambda_u = \lambda$ ,  $k = k + 1$ .

Ako je  $\left. \frac{d\theta(\lambda)}{d\lambda} \right|_{\lambda} < 0$ , redefiniraj  $\lambda_l = \lambda$ ,  $k = k + 1$ .

Ako je  $\left. \frac{d\theta(\lambda)}{d\lambda} \right|_{\lambda} \approx 0$ , stani jer smo došli dovoljno blizu.

Postoji još niz drugih sličnih metoda.

## Algoritam pretraživanja u zadanom smjeru

Jednom kada znamo kako pronaći prikladan korak, možemo definirati porodicu algoritama pretraživanja u zadanom smjeru (engl. *line-search algorithms*).

### Pretraživanje u zadanom smjeru.

Ponavljaj za  $k = 1, 2, \dots$

Ako je  $\vec{x}^{(k)}$  optimum, prekini s izvođenjem i vrati  $\vec{x}^{(k)}$ .

Inače

Utvrdi  $\vec{d}^{(k)}$  – smjer pretrage

Pronađi  $\lambda^* > 0$  – korak

Definiraj  $\vec{x}^{(k+1)} = \vec{x}^{(k)} + \lambda^* \cdot \vec{d}^{(k)}$  – novo rješenje

# Algoritam gradijentnog spusta

Metoda gradi linearni model funkcije oko trenutnog rješenja. Kao vektor  $\vec{d}^{(k)}$  bira upravo minus gradijent funkcije koju je potrebno minimizirati.

$$\vec{d}^{(k)} = -\nabla f(\vec{x})$$

# Algoritam gradijentnog spusta

Metoda gradi linearni model funkcije oko trenutnog rješenja. Kao vektor  $\vec{d}^{(k)}$  bira upravo minus gradijent funkcije koju je potrebno minimizirati.

$$\vec{d}^{(k)} = -\nabla f(\vec{x})$$

- U ne baš rijetkim slučajevima, izračun gradijenta je računski skupa operacija!



# Algoritam gradijentnog spusta

Metoda gradi linearni model funkcije oko trenutnog rješenja. Kao vektor  $\vec{d}^{(k)}$  bira upravo minus gradijent funkcije koju je potrebno minimizirati.

$$\vec{d}^{(k)} = -\nabla f(\vec{x})$$

- U ne baš rijetkim slučajevima, izračun gradijenta je računski skupa operacija!
- Procjena optimalne vrijednosti  $\lambda^*$  može tražiti puno izračuna gradijenta funkcije; stoga se ponekad pomak radi i uz manje "dobru" vrijednost za  $\lambda$ .

# Algoritam gradijentnog spusta

Metoda gradi linearni model funkcije oko trenutnog rješenja. Kao vektor  $\vec{d}^{(k)}$  bira upravo minus gradijent funkcije koju je potrebno minimizirati.

$$\vec{d}^{(k)} = -\nabla f(\vec{x})$$

- U ne baš rijetkim slučajevima, izračun gradijenta je računski skupa operacija!
- Procjena optimalne vrijednosti  $\lambda^*$  može tražiti puno izračuna gradijenta funkcije; stoga se ponekad pomak radi i uz manje "dobru" vrijednost za  $\lambda$ .
- U najjednostavnijim varijantama za vrijednost  $\lambda$  se koristi mala pozitivna konstanta (npr.  $\lambda = 0.1$  ili čak  $\lambda = 0.01$ ) i ne provodi se pretraga za  $\lambda^*$ .

# Algoritam gradijentnog spusta

Metoda gradi linearni model funkcije oko trenutnog rješenja. Kao vektor  $\vec{d}^{(k)}$  bira upravo minus gradijent funkcije koju je potrebno minimizirati.

$$\vec{d}^{(k)} = -\nabla f(\vec{x})$$

- U ne baš rijetkim slučajevima, izračun gradijenta je računski skupa operacija!
- Procjena optimalne vrijednosti  $\lambda^*$  može tražiti puno izračuna gradijenta funkcije; stoga se ponekad pomak radi i uz manje "dobru" vrijednost za  $\lambda$ .
- U najjednostavnijim varijantama za vrijednost  $\lambda$  se koristi mala pozitivna konstanta (npr.  $\lambda = 0.1$  ili čak  $\lambda = 0.01$ ) i ne provodi se pretraga za  $\lambda^*$ .
- Primjer je vrlo poznati algoritam za učenje neuronskih mreža: *Backpropagation*.

## Newtonova metoda

Metoda gradi kvadratni model  $g(\vec{x})$  funkcije  $f(\vec{x})$  oko trenutnog rješenja.

$$f(\vec{x} + \vec{\tau}) = f(\vec{x}) + \nabla f(\vec{x})^T \cdot \vec{\tau} + \frac{1}{2!} \vec{\tau}^T \nabla^2 f(\vec{x}) \vec{\tau} + \zeta \quad (1)$$

pri čemu su s  $\zeta$  označene pogreške višeg reda. Za potrebe izgradnje Newtonovog algoritma u okolini točke  $\vec{x}$  funkcija  $f(\vec{x})$  modelira se kvadratnom funkcijom  $g(\vec{x})$  koja je definirana na sljedeći način:

$$g(\vec{x} + \vec{\tau}) = f(\vec{x}) + \nabla f(\vec{x})^T \cdot \vec{\tau} + \frac{1}{2!} \vec{\tau}^T \nabla^2 f(\vec{x}) \vec{\tau}. \quad (2)$$

$g(\vec{x} + \vec{\tau})$  pri tome promatramo kao funkciju od  $\vec{\tau}$  i pitamo se koji  $\vec{\tau}$  treba odabrati da bismo dobili minimum?

# Newtonova metoda

$H(f) = \nabla^2 f(\vec{x})$  je Hesseova matrica odnosno matrica drugih parcijalnih derivacija. Ova matrica računa se na sljedeći način:

$$\begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix} \quad (3)$$

# Newtonova metoda

Derivacijom

$$g(\vec{x} + \vec{\tau}) = f(\vec{x}) + \nabla f(\vec{x})^T \cdot \vec{\tau} + \frac{1}{2!} \vec{\tau}^T \nabla^2 f(\vec{x}) \vec{\tau}$$

po  $\vec{\tau}$  slijedi:

$$\nabla g = \nabla f(\vec{x}) + H(\vec{x}) \cdot \vec{\tau}. \quad (4)$$

Uvjet za optimum je da je gradijent jednak 0:

$$\nabla f(\vec{x}) + H(\vec{x}) \cdot \vec{\tau} = \vec{0} \quad (5)$$

iz čega slijedi:

$$H(\vec{x}) \cdot \vec{\tau} = -\nabla f(\vec{x}) \quad (6)$$

odnosno

$$\vec{\tau} = -H(\vec{x})^{-1} \cdot \nabla f(\vec{x}) \quad (7)$$

# Newtonova metoda

- Izraz  $H(\vec{x})^{-1}$  predstavlja matrični inverz Hesseove matrice i upravo potreba za računom inverza čini ovaj postupak računski vrlo zahtjevnim.
- Dobiveni vektor  $\vec{\tau}$  dalje se koristi kao vektor u čijem smjeru se radi pretraga prethodno opisanim algoritmom.

$$\vec{d}^{(k)} = \vec{\tau} = -H(\vec{x})^{-1} \cdot \nabla f(\vec{x})$$

- Treba odmah uočiti: ako je funkcija  $f$  kvadratna funkcija, tada joj njezin model  $g$  savršeno odgovara i postupak minimizacije će završiti u jednom koraku.

## Razlog za neuspjeh?

Postupak stvaranja početnog rješenja može ne-uspjeti; najčešći razlog je kršenje tvrdih ograničenja. Jedan od prokušanih načina koji može pomoći:

### Savjeti

- Pratite neuspjehe.
- Temeljem povijesti neuspjeha procijenjujte težinu (problematičnost; zahtjevnost) sastavnih dijelova rješenja.
- Dajte zahtjevnijim dijelovima rješenja priliku da prvi budu razriješeni.
- Izbor možete učiniti determinističkim ili vjerojatnosnim (teža komponenta, veća šansa da se ranije razriješi).

Pogledajte primjer i diskusiju u knjizi u poglavlju 5.3.