

3. Domaća zadaća

SVM I.

STRUJ POTPORNIH VEKTORA

ZADACI ZA UČENJE

1.

a) želimo hiperplanu tako da maksimizira marginu (udaljenost hiperplana do najbližeg primjera). Pretpostavimo da su primjeri lin. odvojeni
 \Rightarrow ovo iskoristimo u

$$y^{(i)}(\tilde{w}^T \tilde{x} + w_0) \geq 0$$

$$d = \frac{y^{(i)}(\tilde{w}^T \tilde{x} + w_0)}{\|\tilde{w}\|}$$

$$\boxed{\frac{1}{\|\tilde{w}\|} \min_i (y^{(i)}(\tilde{w}^T \tilde{x} + w_0))} \Rightarrow \text{to znamo da}$$

doljezmo najbliže primjere i sad ćemo naći takve parametre da doljezmo hiperplanu da ovo maksimiziramo.

$$\boxed{\arg \max_{\tilde{w}, w_0} \left\{ \frac{1}{\|\tilde{w}\|} \min_i (y^{(i)}(\tilde{w}^T \tilde{x} + w_0)) \right\}}$$

\rightarrow želimo ferme t.d. je to primjere na marginu $h(\tilde{x}) = 1$ ili -1 .

\hookrightarrow t.d. imamo da se ne primjere:

$$\boxed{y^{(i)}(\tilde{w}^T \tilde{x} + w_0) \geq 1}$$

$$\arg \max_{\tilde{w}, w_0} \frac{1}{\|\tilde{w}\|} \sim \arg \min_{\tilde{w}, w_0} \|\tilde{w}\|$$

finoćino: $\boxed{\arg \min_{\tilde{w}, w_0} \frac{1}{2} \|\tilde{w}\|^2}$

uz ogr:

$$y^{(i)}(\tilde{w}^T \tilde{x}^{(i)} + w_0) \geq 1, \\ i = 1, \dots, N$$

6) Imamo ciljno f-ju koju želimo minimizirati, ali uz neke ograničenja. Koristimo kvadratno programiranje kako bismo napravili optimizaciju!!

$$\min. f(\vec{x})$$

$$\text{ograničenja} \quad g_i(\vec{x}) \leq 0 \quad i=1 \dots m$$

$$h_i(\vec{x}) = 0 \quad i=1 \dots p$$

$$L(\vec{x}, \vec{L}, \vec{\beta}) = f(x) + \sum_{i=1}^m L_i g_i(\vec{x}) + \sum_{i=1}^p \beta_i h_i(\vec{x})$$

↳ u točki n.j. vrijede sledeći KKT.:

$$\begin{array}{ll} g_i(\vec{x}) \leq 0 & i=1 \dots m \\ h_i(\vec{x}) = 0 & i=1 \dots p \\ L_i \geq 0 & i=1 \dots m \\ L_i \cdot g_i(\vec{x}) = 0 & i=1 \dots m \end{array}$$

ograničenje
mogućnost

ograničenje
mogućnost

upot. Lagrangeovog
multiplikatora

komplementarna labavost.

↳ ogr. ili je neaktivno ($L_i = 0$)
ili je aktivno i postojeće
($g_i(\vec{x}) = 0$)

Kako bi dobili dualnu f-ju, trebamo minimizirati Lagrangeovu f-ju po primarnim promenima \vec{x} .

$$\tilde{L}(\vec{L}, \vec{\beta}) = \min_{\vec{x}} L(\vec{x}, \vec{L}, \vec{\beta})$$

↳ minimiziraj $\tilde{L}(\vec{L}, \vec{\beta})$

uz ogr.

$$L_i \geq 0$$

$$i=1 \dots m$$

c)

$$L(\vec{w}, w_0, \vec{L}) = \frac{1}{2} \|\vec{w}\|^2 - \sum_{i=1}^N L_i (y_i^{(i)} (\vec{w}^T \vec{x}^{(i)} + w_0) - 1)$$

↳ wo želimo minimizirati po nimmernim parametrima

$$\frac{\partial L}{\partial \vec{w}} = 0$$

$$\vec{w} = \sum_{i=1}^N L_i y_i^{(i)} \vec{x}^{(i)}$$

$$\frac{\partial L}{\partial w_0} = 0$$

$$\sum_{i=1}^N L_i y_i^{(i)} = 0$$

Nakon uvrštenja dobivamo:

$$\tilde{L}(\vec{L}) = \sum_{i=1}^N L_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N L_i L_j y_i^{(i)} y_j^{(j)} (\vec{x}^{(i)})^T \vec{x}^{(j)}$$

↳ wo maksimiziramo

uz ograničenje:

$$L_i \geq 0$$

$$i = 1, \dots, N$$

$$\sum_{i=1}^N L_i y_i^{(i)} = 0$$

KKT ujeti u točki nj:

$$y_i^{(i)} (\vec{w}^T \vec{x}^{(i)} + w_0) \geq 1$$

$$i = 1, \dots, N$$

$$L_i \geq 0$$

$$i = 1, \dots, N$$

$$L_i (y_i^{(i)} (\vec{w}^T \vec{x}^{(i)} + w_0) - 1) = 0$$

$$i = 1, \dots, N$$

d)

Prednosti su što sada možemo primijeniti algoritam (SMO) koji leho iskoristava uvjete

Primarni problem imao je $n+1$ parametara, a dualni ima N parametara.

e)

$$h(\vec{x}, \vec{w}) = \vec{w}^T \vec{x} + w_0 \quad \text{PRIMARNO}$$

$$h(\vec{x}; \vec{L}) = \sum_{i=1}^N L_i y^{(i)} x^T x^{(i)} + w_0 \quad \text{DUALNO}$$

f)

Podporni vektori su vektori koji leže na margini i na temelju njih radimo predikciju.

Znamo da leže na rubu ^{margin} iz uvjeta:

$$L_i (y^{(i)} \cdot h(x^{(i)})) - 1 = 0$$

za njih je $L_i > 0$, a onda mora vrijediti

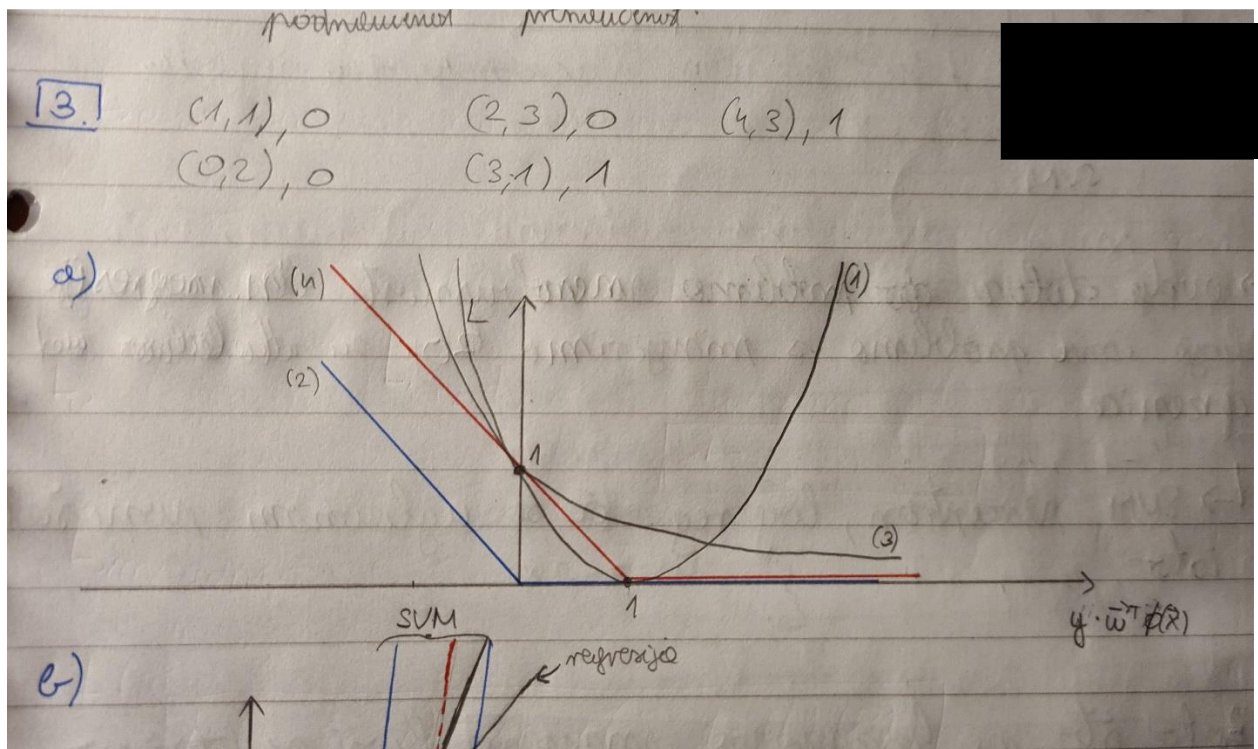
$$y^{(i)} h(x^{(i)}) = 1 \rightarrow \text{a to smo definirali da vrijedi za minjore koji su najbliže margini} \quad \nabla$$

\hookrightarrow leže na margini i to su podporni vektori ∇


$$N = \frac{1}{2} + \frac{1}{2} = 1$$

g) Potrebno je radi sličnosti: $\vec{x}^{(i)T} \vec{x}$. Nprasto ako
 neke vektorne ima veće vrednosti, dobijemo
 ogromnu sličnost vektora koji su različit.

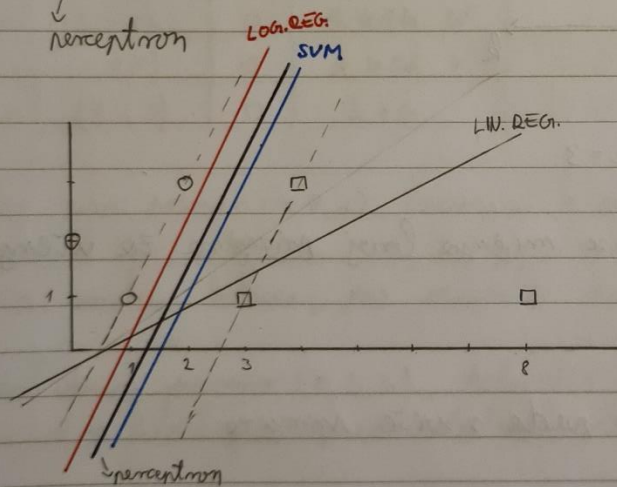
SVM II.



b)



c)



→ dolari do problema nerobustosti linearne regresije koje ima problem s minimizacijom koji su daleko od granice. Ostali algoritmi klasifikacije ispravno. Perceptron može izvesti drugačije jer ovise o početnim inicijalizacijama težina. SVM će biti isti jer su početni vektori isti. Dole će se logistička regresija normalizirati malo ubijeno. Prije je bila desnije jer je bilo manje minimizacije.

d) Zato jer ne koriste druge primjere koji su točno klasificirani (ne moraju gubiti) pa je model jednostavniji, više je točno prognozirano na 0.

JEZGRENE METODE

3

$$a) \quad K(\vec{x}, \vec{z}) = (\vec{x}^T \vec{z} + 1)^2 = (\vec{x}^T \vec{z})^2 + 2\vec{x}^T \vec{z} + 1 =$$

$$= (x_1 z_1 + x_2 z_2)^2 + 2(x_1 z_1 + x_2 z_2) + 1 =$$

$$= x_1^2 z_1^2 + \underbrace{2x_1 z_1 x_2 z_2}_{\sqrt{2}x_1 \sqrt{2}z_1 z_2} + x_2^2 z_2^2 + \underbrace{2x_1 z_1}_{\sqrt{2}x_1 \sqrt{2}z_1} + \underbrace{2x_2 z_2}_{\sqrt{2}x_2 \sqrt{2}z_2} + 1$$

$$[1, \sqrt{2}x_1, \sqrt{2}x_2, \sqrt{2}x_1x_2, x_1^2, x_2^2] = \phi(\vec{x})$$

$$[1, \sqrt{2}z_1, \sqrt{2}z_2, \sqrt{2}z_1z_2, z_1^2, z_2^2] = \phi(\vec{z})$$

$$K(\vec{x}, \vec{z}) = (\vec{x}^T \vec{z} + 1)^2 = \phi(\vec{x}) \cdot \phi(\vec{z})$$

↳ ova je Mercerova i to je lako zato što tako znamo da odgovara skalarnom produktu u nekom prostoru značajki

b)

$$\phi(\vec{x}) = [1, \sqrt{2}x_1, \sqrt{2}x_2, \sqrt{2}x_1x_2, x_1^2, x_2^2] \quad x = (2, 3)$$

$$= [1, 2.828, 4.243, 8.485, 4, 9]$$

5-dim prostor iz 2-dim prostora

c)

→ s obzirom da smo predložili u 5-D prostoru, bit će veći ako uzmemo 6 primjerice

d)

$$x^{(1)} (0, 0), 0 \quad (1, 0) 1 = x^{(3)}$$

$$x^{(2)} (1, 1), 0 \quad (0, 1) 1 = x^{(4)}$$

$$K(\vec{x}, \vec{z}) = (\vec{x}^T \vec{z} + 1)^2$$

$$\phi(\vec{x}^{(1)}) = (1, 0, 0, 0, 0, 0), 0$$

$$\phi(\vec{x}^{(2)}) = (1, \sqrt{2}, \sqrt{2}, \sqrt{2}, 1, 1), 0$$

$$\phi(\vec{x}^{(3)}) = (1, \sqrt{2}, 0, 0, 1, 0), 1$$

$$\phi(\vec{x}^{(4)}) = (1, 0, \sqrt{2}, 0, 0, 1), 1$$

→ vidimo da će biti linearno odvojivo, postoji neravna no dimenzijama ne možemo realizirati. da ćemo ih odvojiti


$$K(\vec{x}^T \vec{z})^2 \quad \phi(x) = (\sqrt{2} x_1, x_2, x_1^2, x_2^2)$$

$$\phi(\vec{x}^{(1)}) = (0, 0, 0), 0$$

$$\phi(\vec{x}^{(2)}) = (\sqrt{2}, 1, 1), 0$$

$$\phi(\vec{x}^{(3)}) = (0, 1, 0), 1$$

$$\phi(\vec{x}^{(4)}) = (0, 0, 1), 1$$



→ također postoji hiperneumino koje ovo može odvojiti

NEPARAMETARSKJE METODE

NEPARAMETARSKJE METODE

2) Zadatak za učenje

a) $x^{(1)} = (4, 2, 1)$ $x^{(2)} = (0, 3, 3)$

	x	y	$d(x^{(1)}, x^{(1)})$	$d(x^{(1)}, x^{(2)})$
1	(4, 4, 0)	1	2.236 ✓	5.099 ✓
2	(4, 3, 1)	1	1 ✓	4.472 ✓
3	(6, 0, 2)	1	3	6.782
4	(5, 2, 2)	0	1.414 ✓	5.196 ✓
5	(5, 1, 1)	0	1.414 ✓	5.745 ✓
6	(7, 2, 0)	0	3.16	7.681


→ za prvi primer (4, 2, 1) imamo 4 najbližje primere iz skupa D, a to su: 1, 2, 4, 5. Imamo po 2 glasove za vsako klaso, pa rečemo da čemo odločiti klaso 0.

→ za drugi primer (0, 3, 3), takoj kot je izračunali broj glasova za obe klase, pa čemo odločiti ponovno klaso 0.

b) $K = \frac{1}{1 + \|x - x^{(1)}\|^2}$

	x	y	$d(x^{(1)}, x^{(1)})$	$d(x^{(1)}, x^{(2)})$
1	(4, 4, 0)	1	0.7667 0.1667	0.037
2	(4, 3, 1)	1	0.5	0.0476
3	(6, 0, 2)	1	0.1	0.02127
4	(5, 2, 2)	0	0.333	0.0357
5	(5, 1, 1)	0	0.333	0.0284
6	(7, 2, 0)	0	0.091	0.01667

→ s obzirom na težinski k -NN, ~~načelo~~, što se povećavaju
težine, vidimo da li se dva primjera klasificirala
u klasu s vjeroškom 1 jer je suma težina veća.

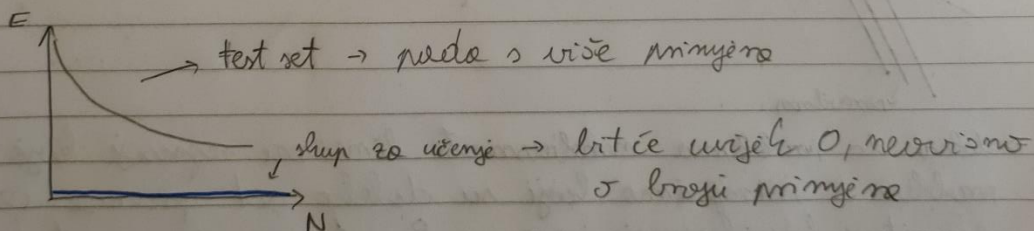


d)


→ za neki N , $k=1$, $k=3$

na x-os želimo se mijenjati broj primjera za učenje

$k=1$



$k=3$



\rightarrow ako je 2 primjera, pogreška je max 0.5, ako su u različitim klasama