

## Pismeni ispit iz Strojnog učenja 1 (ak. god. 2021./2022.)

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 70% bodova na predmetu). Pitanja nose po 1 bod, a 1/3 boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **150 minuta**. Primjerak ispita morate predati zajedno sa svojim rješenjima.

### Osnovni koncepti i linearna regresija (4 pitanja)

- 1** (T) Optimizacija modela hrbatne regresije ( $L_2$ -regularizirane linearne regresije) ima rješenje u zatvorenoj formi. Neka je  $\lambda$  regularizacijski faktor,  $n$  broj značajki u ulaznom prostoru (bez “dummy” jedinice),  $m$  broj značajki u prostoru značajki (također bez “dummy” jedinice) te  $N$  broj primjera. Glavna komponenta rješenja je izračun inverza matrice izračunate na temelju matrice dizajna  $\Phi$ . **Koliko redaka odnosno stupaca ima matrica koju invertiramo?**

☐ A  $N$    ☐ B  $m + 1$    ☐ C  $n + \lambda$    ☐ D  $m + \lambda$

- 2** (N) Raspoložemo sljedećim skupom primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((1, 0), 1), ((2, -3), 2), ((3, 5), -1), ((5, 0), -4)\}$$

Na ovom skupu gradijentnim spustom trenirali smo  $L_1$ -regularizirani model linearne regresije sa  $\lambda = 1$ . Dobili smo težine  $\mathbf{w} = (2.12, -0.94, -0.08)$ . **Koliko iznosi  $L_1$ -regularizirana pogreška  $E(\mathbf{w}|\mathcal{D})$ ?**

☐ A 2.69   ☐ B 7.10   ☐ C 1.58   ☐ D 0.29

- 3** (P) Skup označenih primjera u dvodimenzijaskome ulaznom prostoru je:

$$\mathcal{D} = \{((0, 0), 0), ((0, 1), 0), ((1, 1), 1)\}$$

**Koja je veličina prostora inačica,  $|\mathcal{V}_{\mathcal{H}, \mathcal{D}}|$ ?**

☐ A Pitanje nema smisla jer nije definiran model   ☐ B 14   ☐ C 16   ☐ D Beskonačno mnogo

- 4** (P) Koristimo regresiju za predviđanje uspjeha na studiju. Kao značajke možemo koristiti ocjene u četiri razreda srednje škole (značajke  $x_1$ – $x_4$ ), prosjek ocjena sva četiri razreda ( $x_5$ ) te uspjeh iz matematike ( $x_6$ ) i fizike ( $x_7$ ) na državnoj maturi (ukupno 7 značajki). Ne moramo iskoristiti sve značajke, ali ih želimo iskoristiti što više. Za preslikavanje u prostor značajki koristimo preslikavanje s kvadratnim, interakcijskim i linearnim značajkama. Od interakcijskih značajki uzimamo samo interakcije parova značajki (npr.  $x_1x_2$ ) i interakcije trojki (npr.  $x_1x_2x_3$ ) između svih značajki koje koristimo. **Koliko minimalno primjera za učenje trebamo imati, a da bi rješenje bilo stabilno i bez regularizacije?**

☐ A 75   ☐ B 48   ☐ C 63   ☐ D 38

### Linearni klasifikacijski modeli (3 pitanja)

- 5** (N) Raspoložemo označenim skupom primjera iz triju klasa ( $K = 3$ ) u trodimenzijaskome ulaznom prostoru ( $n = 3$ ). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer  $\mathbf{x} = (-4, 1, -3)$  s oznakom  $\mathbf{y} = (0, 1, 0)$ . **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

☐ A 4.02   ☐ B 8.00   ☐ C 12.02   ☐ D 6.00

**6** (P) Treniramo linearni diskriminativni model u dvodimenzijaskome prostoru primjera. Skup za učenje čine samo dva primjera,  $(\mathbf{x}_1, y_1) = ((1, 0), +1)$  i  $(\mathbf{x}_2, y_2) = ((0, 1), -1)$ . Na tom skupu treniramo model koji ima induktivnu pristranost takvu da rješenje maksimizira minimalnu udaljenost primjera od hiperravnine. Naučen model ispravno klasificira oba primjera, pri čemu za oba primjera vrijedi  $y \cdot h(\mathbf{x}) = 5$ . **Koliko iznosi težina  $w_2$  tako naučenog modela?**

- ☐ A  $-1$    ☐ B  $-5$    ☐ C  $1$    ☐ D  $5$

**7** (T) Neregularizirani model logističke regresije sklon je prenaučivosti. To je pogotovo slučaj ako se model trenira na linearno odvojivim podatcima, čak i onda kada u podatcima nema nikakvoga šuma i kada se ne koristi nikakvo preslikavanje u prostor značajki. **Zbog čega dolazi do prenaučivosti modela neregularizirane logističke regresije na linearno odvojivim skupovima podataka?**

- ☐ A Empirijska pogreška logističke regresije smanjuje se s porastom broja primjera  
☐ B Netočno klasificirani primjeri nanose gubitak koji je proporcionalan normi vektora težina  
☐ C Ispravno klasificirani primjeri koji su vrlo udaljeni od granice nanose malen gubitak  
☐ D S porastom norme vektora težina gubitak na točnim primjerima teži prema nuli

### Jezgrene i neparametarske metode (4 pitanja)

**8** (N) Na skupu primjera za učenje iz ulaznog prostora  $n = 4$  trenirali smo SVM s polinomijalnom jezgrenom funkcijom  $\kappa(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^T \mathbf{z} + 1)^3$ . Potporni vektori i njihove oznake su sljedeći:

$$(\mathbf{x}^{(1)}, y^{(1)}) = ((11, 32, 21), -1)$$

$$(\mathbf{x}^{(2)}, y^{(2)}) = ((5, 11, 6), -1)$$

$$(\mathbf{x}^{(3)}, y^{(3)}) = ((6, 12, 6), +1)$$

Lagrangeovi koeficijenti su  $\alpha_1 = 1.063 \cdot 10^{-7}$ ,  $\alpha_2 = 1.022 \cdot 10^{-5}$  i  $\alpha_3 = 1.032 \cdot 10^{-5}$ . **Upotrijebite jezgri trik da biste odredili vrijednost hipoteze  $h(\mathbf{x})$  za primjer  $\mathbf{x} = (3, 0, -3)$ .**

- ☐ A  $-0.676$    ☐ B  $-2.330$    ☐ C  $+1.434$    ☐ D  $-3.553$

**9** (T) Problem maksimalne margine ima svoju geometrijsku interpretaciju: maksimalna margina odgovara simetrali spojnice konveksnih ljusaka primjera iz dviju klasa. **Što je nužan i dovoljan uvjet da klasifikacijski problem bude rješiv SVM-om s tvrdom marginom?**

- ☐ A Svaka spojnica između primjera iz jedne klase treba biti izvan konveksne ljuske druge klase  
☐ B Najbliži primjeri iz suprotnih klasa moraju biti u vrhovima konveksnih ljusaka  
☐ C Konveksne ljuske dviju klasa ne smiju se preklapati (trebaju biti disjunktne)  
☐ D Primjeri iz obje klase trebaju činiti konveksne skupove u ulaznom prostoru

**10** (N) Algoritam k-NN koristimo za višeklasnu klasifikaciju riječi prema jeziku kojemu pripadaju. Skup za učenje sastoji se od sljedećih riječi i oznaka klase:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{(\text{"water"}, 0), (\text{"voda"}, 1), (\text{"zrak"}, 1), (\text{"luft"}, 2), (\text{"feuer"}, 2)\}$$

Kao mjeru sličnosti između primjera koristimo jezgenu funkciju nad znakovnim nizovima, definiranu kao  $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$ , gdje je su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Npr.,  $\kappa(\text{"water"}, \text{"voda"}) = 1/8 = 0.125$ . Razmatramo dvije varijante algoritma: 3-NN i težinski k-NN. Kod potonjeg u obzir uzimamo sve primjere, tj.  $k = N$ . Odredite klasifikaciju primjera  $\mathbf{x} = \text{"fire"}$  pomoću ova dva algoritma. U slučaju jednake sličnosti između dva primjera, kao susjed se uzima onaj koji je u skupu  $\mathcal{D}$  naveden prvi. U slučaju izjednačenja glasova između klasa, prednost se daje klasi s numerički manjom oznakom  $y$ . **U koju će klasu biti klasificiran primjer  $\mathbf{x}$  algoritmom 3-NN, a u koju algoritmom težinski k-NN?**

- ☐ A  $y = 0$  i  $y = 2$    ☐ B  $y = 0$  i  $y = 1$    ☐ C  $y = 0$  i  $y = 0$    ☐ D  $y = 1$  i  $y = 1$

- 11 (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), -1), ((-2, -2), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1))\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa  $C = 1$ . Kod modela s mekom marginom za dualne koeficijente vrijedi  $\alpha_1 = 1$ ,  $\alpha_2 > 0$ ,  $\alpha_3 > 0$ ,  $\alpha_4 > 0$  i  $\alpha_5 = 1$ . Skicirajte tvrdi i meku marginu u ulaznome prostoru. **Koliko je meka margina šira od tvrde margine?**

- ☐ A  $\frac{2}{5}\sqrt{10}$  puta    ☐ B  $\frac{3}{5}\sqrt{10}$  puta    ☐ C  $\frac{1}{6}\sqrt{2}$  puta    ☐ D  $\frac{4}{5}\sqrt{10}$  puta

### Procjena parametara i Bayesov klasifikator (3 pitanja)

- 12 (N) Treniramo Bayesov klasifikator za odluku o dobroj destinaciji za Erasmus+ studentski boravak. Skup primjera za učenje, izgrađen na temelju iskustava prijatelja i prijatelja prijatelja, je sljedeći:

$i$	Država	Stipendija	Semestar	Studij	GovoriJezik	$y^{(i)}$
1	Njemačka	da	ljetni	dipl	da	1
2	Poljska	ne	zimski	preddipl	ne	1
3	Italija	da	ljetni	dipl	da	1
4	Njemačka	ne	zimski	preddipl	ne	0
5	Austrija	da	ljetni	dipl	da	1
6	Poljska	ne	zimski	dipl	ne	1
7	Austrija	da	zimski	dipl	ne	1
8	Njemačka	ne	zimski	dipl	ne	0

Očekujemo zavisnost između varijabli *Država* i *Stipendija*, pa koristimo polunaivan Bayesov klasifikator u kojemu su te dvije varijable združene. Procjene izglednosti klasa radimo Laplaceovim MAP-procjeniteljem. Zanima nas klasifikacija za  $\mathbf{x} = (\text{Italija}, \text{ne}, \text{zimski}, \text{preddipl}, \text{ne})$ . **Koliko iznosi aposteriorna vjerojatnost  $P(y = 1|\mathbf{x})$ ?**

- ☐ A 0.488    ☐ B 0.741    ☐ C 0.322    ☐ D 0.588

- 13 (T) Nepriistranost je jedno od svojstava statističkih procjenitelja. Procjenitelj MLE ne mora nužno biti nepriistran, tj. može biti pristran. **Za koji od sljedećih parametara distribucije procjena MLE pristrana?**

- ☐ A Varijanca Bernoullijeve distribucije  
☐ B Kovarijacijska matrica Gaussove distribucije  
☐ C Srednja vrijednost Bernoullijeve distribucije  
☐ D Srednja vrijednost Gaussove distribucije

- 14 (P) Gaussov Bayesov klasifikator koristimo za klasifikaciju jednodimenzijaskih podataka u tri klase. Procijenjene izglednosti klasa su  $p(x|y = 1) = \mathcal{N}(-10, 2)$ ,  $p(x|y = 2) = \mathcal{N}(2, 2)$  i  $p(x|y = 3) = \mathcal{N}(8, 2)$ , a procijenjene apriorne vjerojatnosti klasa su  $P(y = 1) = P(y = 2) = 1/5$  i  $P(y = 3) = 3/5$ . Međutim, nakon što smo naučili ovaj model, zaključili smo da na ispitnom skupu postoji pomak u distribuciji podataka u odnosu na skup za učenje te da zbog toga model ne generalizira dobro. Zaključili smo da se ovo može ispraviti tako da se naučeni model malo izmijeni, i to tako da se varijanca izglednosti klase  $y = 1$  postavi na 1 i da se apriorne vjerojatnosti klasa ujednače,  $P(y = 1) = P(y = 2) = P(y = 3) = 1/3$ . Skicirajte gustoće zajedničke vjerojatnosti naučenog i izmijenjenog modela. Neka su  $h_1$  i  $h_2$  MAP-hipoteze prvog i drugog modela, te neka su  $a$  i  $b$  pozitivne konstante. Razmotrite segment ulaznog prostora za koji vrijedi  $-10 \leq x \leq 10$ . **Na kojim se dijelovima tog segmenta ulaznog prostora MAP-hipoteze prvog i drugog modela razlikuju?**

- ☐ A  $[-4 - a, -4] \cup [5 - b, 5]$     ☐ B  $[-4 - a, 5 + b]$     ☐ C  $[-4, -4 + a] \cup [5, 5 + b]$     ☐ D  $[-4 - a, -4 + b]$

### Probabilistički grafički modeli (3 pitanja)

- 15 (T) Glavna svrha probabilističkih grafičkih modela (PGM) jest provođenje probabilističkih upita. Jedna vrsta upita su MAP-upiti (upiti najvjerojatnijeg objašnjenja). Neka su  $\mathbf{x}_q$ ,  $\mathbf{x}_o$  i  $\mathbf{x}_n$  skupovi varijabli upita, opaženih varijabli odnosno varijabli smetnje. **Kako je definiran rezultat MAP-upita?**

- ☐ A  $\operatorname{argmax}_{\mathbf{x}_o} \sum_{\mathbf{x}_n} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$     ☐ C  $\operatorname{argmax}_{\mathbf{x}_q} \sum_{\mathbf{x}_o} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$   
☐ B  $\operatorname{argmax}_{\mathbf{x}_o} \sum_{\mathbf{x}_q} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$     ☐ D  $\operatorname{argmax}_{\mathbf{x}_q} \sum_{\mathbf{x}_n} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$

- 16 (N) Razmotrite jednostavnu Bayesovu mrežu koja odgovara faktorizaciji  $P(x, y, z) = P(x)P(y)P(z|x, y)$ . Sve varijable su binarne. Vrijedi  $P(x = 1) = 0.2$  i  $P(y = 1) = 0.3$ . Tablica uvjetne vjerojatnosti za čvor  $z$  je sljedeća:

$z$	$x$	$y$	$p(z x, y)$	$z$	$x$	$y$	$p(z x, y)$
0	0	0	0.1	1	0	0	0.9
0	0	1	0.2	1	0	1	0.8
0	1	0	0.5	1	1	0	0.5
0	1	1	0.9	1	1	1	0.1

Postupkom uzorkovanja s odbijanjem uzorkujemo iz aposteriorne distribucije  $P(y|x = 0, z = 1)$ . Uzorkovanje smo ponovili ukupno  $N = 500$  puta. **Koliki je očekivani broj vektora koje ćemo pri uzorkovanju morati odbaciti?**

- ☐ A 89    ☐ B 180    ☐ C 152    ☐ D 404

- 17 (P) Razmotrite Bayesovu mrežu koja zajedničku vjerojatnost faktorizira na sljedeći način:

$$P(w, x, y, z) = P(w)P(y)P(x|w, y)P(z|w)$$

Odredite topološki uređaj varijabli. Ako postoji više mogućih topoloških uređaja, izaberite onaj koji po leksičkom poretку dolazi prvi (npr.  $x, y, z$  dolazi prije  $x, z, y$ ). Zatim primijenite uređajno Markovljevo svojstvo te izvedite sve uvjetne nezavisnosti koje su kodirane u ovoj Bayesovoj mreži. **Koje sve uvjetne nezavisnosti vrijede u ovoj Bayesovoj mreži?**

- ☐ A  $w \perp y, z \perp x, x \perp w | \{z, y\}$     ☐ B  $y \perp w, y \perp x | \{w, z\}$     ☐ C  $x \perp y | z, z \perp w | y$     ☐ D  $w \perp y, z \perp \{x, y\} | w$

### Grupiranje (3 pitanja)

- 18 (P) Za grupiranje skupa primjera  $\mathcal{D}$  koristimo algoritam GMM. Koristimo nekoliko varijanti tog modela:

$\mathcal{H}_1$  : Model sa  $K = 50$  središta inicijaliziranim algoritmom k-sredina

$\mathcal{H}_2$  : Model sa  $K = 50$  središta inicijaliziranim algoritmom k-sredina i dijeljenom kovarijacijskom matricom

$\mathcal{H}_3$  : Model sa  $K = 50$  slučajno inicijaliziranim središtima i dijeljenom kovarijacijskom matricom

$\mathcal{H}_4$  : Model sa  $K = 10$  središta inicijaliziranim algoritmom k-sredina i dijeljenom kovarijacijskom matricom

Sa svakim modelom grupiranje ponavljamo 1000 puta i zatim za svaki model crtamo graf funkcije log-izglednosti kroz iteracije EM-algoritma, uprosječen kroz svih 1000 ponavljanja. Neka je  $LL_\alpha^0$  prosječna log-izglednost za model  $\mathcal{H}_\alpha$  na početku izvođenja EM-algoritma, a neka je  $LL_\alpha^*$  prosječna log-izglednost za taj model na kraju izvođenja EM-algoritma. **Što možemo unaprijed zaključiti o ovim log-izglednostima?**

- ☐ A  $LL_3^0 \geq LL_4^0, LL_1^* \geq LL_3^* \geq LL_4^*$     ☐ C  $LL_2^0 \geq LL_4^0 \geq LL_3^0, LL_1^* \geq LL_2^*$   
☐ B  $LL_2^0 \geq LL_4^0, LL_1^* \geq LL_2^* \geq LL_3^*$     ☐ D  $LL_2^0 \leq LL_4^0, LL_2^* \leq LL_1^* \geq LL_3^*$

- 19 (N) Algoritmom HAC grupiramo riječi engleskog jezika. Neoznačeni skup podataka sastoji se od sljedećih riječi:

$$\mathcal{D} = \{ \text{"water"}, \text{"watering"}, \text{"moon"}, \text{"air"} \}$$

Kao mjeru sličnosti između primjera koristimo jezgrenu funkciju nad znakovnim nizovima, definiranu kao  $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$ , gdje su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Npr.,  $\kappa(\text{"water"}, \text{"watering"}) = 5/8 = 0.625$ . Provedite prve dvije iteracije grupiranja algoritmom HAC uz prosječno povezivanje. **Na kojoj se razini sličnosti spajaju grupe u drugoj iteraciji algoritma HAC?**

- ☐ A 0.292    ☐ B 0.535    ☐ C 0.583    ☐ D 0.354

- 20 (N) Raspoložemo sljedećim neoznačenim skupom primjera:  $\mathcal{D} = \{(\mathbf{x}^{(i)})\}_i = \{(1, 1), (1, 2), (2, 2), (2, 3), (4, 3)\}$ . Primjere grupiramo algoritmom k-sredina sa  $K = 2$  grupe. Za početna središta odabrali smo primjere  $\mathbf{x}^{(2)} = (1, 2)$  i  $\mathbf{x}^{(5)} = (4, 3)$ . Provedite prvu iteraciju algoritma k-sredina. **Koliko iznosi vrijednost kriterijske funkcije  $J$  nakon ažuriranja centroida?**

- ☐ A 6.66    ☐ B 1.85    ☐ C 4.25    ☐ D 3.00

## Vrednovanje modela (2 pitanja)

**21** (P) Raspoložemo sa 1000 označenih primjera. Na tom skupu treniramo i evaluiramo algoritam SVM. Pritom razmatramo tri hiperparametra: jezgra (linearna ili RBF), regularizacijski faktor  $C$  i preciznost RBF jezgre  $\gamma$ . Posljednja dva hiperparametra optimiramo rešetkastim pretraživanjem u rasponima  $C \in \{2^{-15}, 2^{-14}, \dots, 2^{15}\}$  i  $\gamma \in \{2^{-15}, 2^{-14}, \dots, 2^{15}\}$ . Naravno, ako ne koristimo RBF-jezgru, onda hiperparametar  $\gamma$  ne optimiramo. Za treniranje i evaluaciju modela koristimo ugniježđenu unakrsnu provjeru s 10 ponavljanja u vanjskoj petlji i 5 ponavljanja u unutarnjoj petlji. **Koliko će puta svaki primjer biti iskorišten za treniranje modela?**

- ☐ A 49600    ☐ B 35721    ☐ C 44640    ☐ D 69201

**22** (T) Ugniježđena k-struka unakrsna provjera često se koristi za procjenu točnosti modela. **Što je prednost ugniježđene k-struke unakrsne provjere u odnosu na običnu unakrsnu provjeru?**

- ☐ A Procjenjujemo očekivanu ispitnu pogrešku modela optimalne složenosti  
☐ B Procjenjujemo pogrešku generalizacije, a ne pogrešku učenja  
☐ C Model ispitujemo na cijelom raspoloživom skupu primjera  
☐ D Procjenjujemo ispitnu pogrešku modela s najmanjom pogreškom učenja



## Pismeni ispit iz Strojnog učenja 1 (ak. god. 2021./2022.)

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 70% bodova na predmetu). Pitanja nose po 1 bod, a 1/3 boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **150 minuta**. Primjerak ispita morate predati zajedno sa svojim rješenjima.

### Osnovni koncepti i linearna regresija (4 pitanja)

- 1** (T) Optimizacija modela hrbatne regresije ( $L_2$ -regularizirane linearne regresije) ima rješenje u zatvorenoj formi. Neka je  $\lambda$  regularizacijski faktor,  $n$  broj značajki u ulaznom prostoru (bez “dummy” jedinice),  $m$  broj značajki u prostoru značajki (također bez “dummy” jedinice) te  $N$  broj primjera. Glavna komponenta rješenja je izračun inverza matrice izračunate na temelju matrice dizajna  $\Phi$ . **Koliko redaka odnosno stupaca ima matrica koju invertiramo?**

☐ A  $N$    ☐ B  $n + \lambda$    ☐ C  $m + 1$    ☐ D  $m + \lambda$

- 2** (P) Koristimo regresiju za predviđanje uspjeha na studiju. Kao značajke možemo koristiti ocjene u četiri razreda srednje škole (značajke  $x_1$ – $x_4$ ), prosjek ocjena sva četiri razreda ( $x_5$ ) te uspjeh iz matematike ( $x_6$ ) i fizike ( $x_7$ ) na državnoj maturi (ukupno 7 značajki). Ne moramo iskoristiti sve značajke, ali ih želimo iskoristiti što više. Za preslikavanje u prostor značajki koristimo preslikavanje s kvadratnim, interakcijskim i linearnim značajkama. Od interakcijskih značajki uzimamo samo interakcije parova značajki (npr.  $x_1x_2$ ) i interakcije trojki (npr.  $x_1x_2x_3$ ) između svih značajki koje koristimo. **Koliko minimalno primjera za učenje trebamo imati, a da bi rješenje bilo stabilno i bez regularizacije?**

☐ A 63   ☐ B 75   ☐ C 38   ☐ D 48

- 3** (N) Raspoložemo sljedećim skupom primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((1, 0), 1), ((2, -3), 2), ((3, 5), -1), ((5, 0), -4)\}$$

Na ovom skupu gradijentnim spustom trenirali smo  $L_1$ -regularizirani model linearne regresije sa  $\lambda = 1$ . Dobili smo težine  $\mathbf{w} = (2.12, -0.94, -0.08)$ . **Koliko iznosi  $L_1$ -regularizirana pogreška  $E(\mathbf{w}|\mathcal{D})$ ?**

☐ A 1.58   ☐ B 7.10   ☐ C 0.29   ☐ D 2.69

- 4** (P) Skup označenih primjera u dvodimenzijaskome ulaznom prostoru je:

$$\mathcal{D} = \{((0, 0), 0), ((0, 1), 0), ((1, 1), 1)\}$$

**Koja je veličina prostora inačica,  $|\mathcal{VS}_{\mathcal{H}, \mathcal{D}}|$ ?**

☐ A Beskonačno mnogo   ☐ B 14   ☐ C Pitanje nema smisla jer nije definiran model   ☐ D 16

### Linearni klasifikacijski modeli (3 pitanja)

- 5** (T) Neregularizirani model logističke regresije sklon je prenaučivosti. To je pogotovo slučaj ako se model trenira na linearno odvojivim podatcima, čak i onda kada u podatcima nema nikakvoga šuma i kada se ne koristi nikakvo preslikavanje u prostor značajki. **Zbog čega dolazi do prenaučivosti modela neregularizirane logističke regresije na linearno odvojivim skupovima podataka?**

- ☐ A Netočno klasificirani primjeri nanose gubitak koji je proporcionalan normi vektora težina  
☐ B S porastom norme vektora težina gubitak na točnim primjerima teži prema nuli  
☐ C Empirijska pogreška logističke regresije smanjuje se s porastom broja primjera  
☐ D Ispravno klasificirani primjeri koji su vrlo udaljeni od granice nanose malen gubitak

- 6 (N) Raspoložemo označenim skupom primjera iz triju klasa ( $K = 3$ ) u trodimenzijskome ulaznom prostoru ( $n = 3$ ). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer  $\mathbf{x} = (-4, -1, -3)$  s oznakom  $\mathbf{y} = (0, 0, 1)$ . **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

- ☐ A 8.00 ☐ B 6.00 ☐ C 4.02 ☐ D 12.02

- 7 (P) Treniramo linearni diskriminativni model u dvodimenzijskome prostoru primjera. Skup za učenje čine samo dva primjera,  $(\mathbf{x}_1, y_1) = ((1, 0), +1)$  i  $(\mathbf{x}_2, y_2) = ((0, 1), -1)$ . Na tom skupu treniramo model koji ima induktivnu pristranost takvu da rješenje maksimizira minimalnu udaljenost primjera od hiperravnine. Naučen model ispravno klasificira oba primjera, pri čemu za oba primjera vrijedi  $y \cdot h(\mathbf{x}) = 5$ . **Koliko iznosi težina  $w_2$  tako naučenog modela?**

- ☐ A -1 ☐ B -5 ☐ C 5 ☐ D 1

### Jezgrene i neparametarske metode (4 pitanja)

- 8 (N) Algoritam k-NN koristimo za višeklasnu klasifikaciju riječi prema jeziku kojemu pripadaju. Skup za učenje sastoji se od sljedećih riječi i oznaka klasa:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{("water", 0), ("voda", 1), ("zrak", 1), ("luft", 2), ("feuer", 2)\}$$

Kao mjeru sličnosti između primjera koristimo jezgreanu funkciju nad znakovnim nizovima, definiranu kao  $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$ , gdje je su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Npr.,  $\kappa("water", "voda") = 1/8 = 0.125$ . Razmatramo dvije varijante algoritma: 3-NN i težinski k-NN. Kod potonjeg u obzir uzimamo sve primjere, tj.  $k = N$ . Odredite klasifikaciju primjera  $\mathbf{x} = "fire"$  pomoću ova dva algoritma. U slučaju jednake sličnosti između dva primjera, kao susjed se uzima onaj koji je u skupu  $\mathcal{D}$  naveden prvi. U slučaju izjednačenja glasova između klasa, prednost se daje klasi s numerički manjom oznakom  $y$ . **U koju će klasu biti klasificiran primjer  $\mathbf{x}$  algoritmom 3-NN, a u koju algoritmom težinski k-NN?**

- ☐ A  $y = 0$  i  $y = 0$  ☐ B  $y = 0$  i  $y = 1$  ☐ C  $y = 0$  i  $y = 2$  ☐ D  $y = 1$  i  $y = 1$

- 9 (N) Na skupu primjera za učenje iz ulaznog prostora  $n = 4$  trenirali smo SVM s polinomijalnom jezgrenom funkcijom  $\kappa(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^T \mathbf{z} + 1)^3$ . Potporni vektori i njihove oznake su sljedeći:

$$(\mathbf{x}^{(1)}, y^{(1)}) = ((11, 32, 21), -1)$$

$$(\mathbf{x}^{(2)}, y^{(2)}) = ((5, 11, 6), -1)$$

$$(\mathbf{x}^{(3)}, y^{(3)}) = ((6, 12, 6), +1)$$

Lagrangeovi koeficijenti su  $\alpha_1 = 1.063 \cdot 10^{-7}$ ,  $\alpha_2 = 1.022 \cdot 10^{-5}$  i  $\alpha_3 = 1.032 \cdot 10^{-5}$ . **Upotrijebite jezgreni trik da biste odredili vrijednost hipoteze  $h(\mathbf{x})$  za primjer  $\mathbf{x} = (-3, -5, 3)$ .**

- ☐ A -3.553 ☐ B -2.330 ☐ C +1.434 ☐ D -4.093

- 10 (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), -1), ((-1, -1), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1))\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa  $C = 1$ . Kod modela s mekom marginom za dualne koeficijente vrijedi  $\alpha_1 = 1$ ,  $\alpha_2 > 0$ ,  $\alpha_3 > 0$ ,  $\alpha_4 > 0$  i  $\alpha_5 = 1$ . Skicirajte tvrdu i meku marginu u ulaznome prostoru. **Koliko je meka margina šira od tvrde margine?**

- ☐ A  $\frac{1}{6}\sqrt{2}$  puta ☐ B  $\frac{2}{5}\sqrt{10}$  puta ☐ C  $\frac{4}{5}\sqrt{10}$  puta ☐ D  $\frac{3}{5}\sqrt{10}$  puta



- 11** (T) Problem maksimalne margine ima svoju geometrijsku interpretaciju: maksimalna margina odgovara simetrali spojnice konveksnih ljusaka primjera iz dviju klasa. **Što je nužan i dovoljan uvjet da klasifikacijski problem bude rješiv SVM-om s tvrdom marginom?**
- ☐ A Konveksne ljuske dviju klasa ne smiju se preklapati (trebaju biti disjunktne)
- ☐ B Primjeri iz obje klase trebaju činiti konveksne skupove u ulaznom prostoru
- ☐ C Svaka spojnica između primjera iz jedne klase treba biti izvan konveksne ljuske druge klase
- ☐ D Najbliži primjeri iz suprotnih klasa moraju biti u vrhovima konveksnih ljusaka

### Procjena parametara i Bayesov klasifikator (3 pitanja)

- 12** (T) Nepriistranost je jedno od svojstava statističkih procjenitelja. Procjenitelj MLE ne mora nužno biti nepristran, tj. može biti pristran. **Za koji od sljedećih parametara distribucije procjena MLE pristrana?**
- ☐ A Kovarijacijska matrica Gaussove distribucije
- ☐ B Varijanca Bernoullijeve distribucije
- ☐ C Srednja vrijednost Bernoullijeve distribucije
- ☐ D Srednja vrijednost Gaussove distribucije
- 13** (P) Gaussov Bayesov klasifikator koristimo za klasifikaciju jednodimenzijskih podataka u tri klase. Procijenjene izglednosti klasa su  $p(x|y=1) = \mathcal{N}(-10, 2)$ ,  $p(x|y=2) = \mathcal{N}(2, 2)$  i  $p(x|y=3) = \mathcal{N}(8, 2)$ , a procijenjene apriorne vjerojatnosti klasa su  $P(y=1) = P(y=2) = 2/5$  i  $P(y=3) = 1/5$ . Međutim, nakon što smo naučili ovaj model, zaključili smo da na ispitnom skupu postoji pomak u distribuciji podataka u odnosu na skup za učenje te da zbog toga model ne generalizira dobro. Zaključili smo da se ovo može ispraviti tako da se naučeni model malo izmijeni, i to tako da se varijanca izglednosti klase  $y=1$  postavi na 5 i da se apriorne vjerojatnosti klasa ujednače,  $P(y=1) = P(y=2) = P(y=3) = 1/3$ . Skicirajte gustoće zajedničke vjerojatnosti naučenog i izmijenjenog modela. Neka su  $h_1$  i  $h_2$  MAP-hipoteze prvog i drugog modela, te neka su  $a$  i  $b$  pozitivne konstante. Razmotrite segment ulaznog prostora za koji vrijedi  $-10 \leq x \leq 10$ . **Na kojim se dijelovima tog segmenta ulaznog prostora MAP-hipoteze prvog i drugog modela razlikuju?**
- ☐ A  $[-4-a, -4] \cup [5-b, 5]$     ☐ B  $[-4-a, 5+b]$     ☐ C  $[-4-a, -4+b]$     ☐ D  $[-4, -4+a] \cup [5, 5+b]$
- 14** (N) Treniramo Bayesov klasifikator za odluku o dobroj destinaciji za Erasmus+ studentski boravak. Skup primjera za učenje, izgrađen na temelju iskustava prijatelja i prijatelja prijatelja, je sljedeći:

$i$	Država	Stipendija	Semestar	Studij	GovoriJezik	$y^{(i)}$
1	Njemačka	da	ljetni	dipl	da	1
2	Poljska	ne	zimski	preddipl	ne	1
3	Italija	da	ljetni	dipl	da	1
4	Njemačka	ne	zimski	preddipl	ne	0
5	Austrija	da	ljetni	dipl	da	1
6	Poljska	ne	zimski	dipl	ne	1
7	Austrija	da	zimski	dipl	ne	1
8	Njemačka	ne	zimski	dipl	ne	0

Očekujemo zavisnost između varijabli *Država* i *Stipendija*, pa koristimo polunaivan Bayesov klasifikator u kojemu su te dvije varijable združene. Procjene izglednosti klasa radimo Laplaceovim MAP-procjeniteljem. Zanima nas klasifikacija za  $\mathbf{x} = (\text{Italija}, \text{da}, \text{zimski}, \text{dipl}, \text{ne})$ . **Koliko iznosi aposteriorna vjerojatnost  $P(y=1|\mathbf{x})$ ?**

- ☐ A 0.488    ☐ B 0.588    ☐ C 0.741    ☐ D 0.322

### Probabilistički grafički modeli (3 pitanja)

- 15** (P) Razmotrite Bayesovu mrežu koja zajedničku vjerojatnost faktorizira na sljedeći način:

$$P(w, x, y, z) = P(w)P(y)P(x|w, y)P(z|w)$$

Odredite topološki uređaj varijabli. Ako postoji više mogućih topoloških uređaja, izaberite onaj koji po leksičkom poretku dolazi prvi (npr.  $x, y, z$  dolazi prije  $x, z, y$ ). Zatim primijenite uređajno Markovljevo svojstvo te izvedite sve uvjetne nezavisnosti koje su kodirane u ovoj Bayesovoj mreži. **Koje sve uvjetne nezavisnosti vrijede u ovoj Bayesovoj mreži?**

- ☐ A  $w \perp y, z \perp \{x, y\} | w$    ☐ B  $w \perp y, z \perp x, x \perp w | \{z, y\}$    ☐ C  $x \perp y | z, z \perp w | y$    ☐ D  $y \perp w, y \perp x | \{w, z\}$

- 16** (N) Razmotrite jednostavnu Bayesovu mrežu koja odgovara faktorizaciji  $P(x, y, z) = P(x)P(y)P(z|x, y)$ . Sve varijable su binarne. Vrijedi  $P(x = 1) = 0.2$  i  $P(y = 1) = 0.3$ . Tablica uvjetne vjerojatnosti za čvor  $z$  je sljedeća:

$z$	$x$	$y$	$p(z x, y)$	$z$	$x$	$y$	$p(z x, y)$
0	0	0	0.1	1	0	0	0.9
0	0	1	0.2	1	0	1	0.8
0	1	0	0.5	1	1	0	0.5
0	1	1	0.9	1	1	1	0.1

Postupkom uzorkovanja s odbijanjem uzorkujemo iz aposteriorne distribucije  $P(y|x = 0, z = 1)$ . Uzorkovanje smo ponovili ukupno  $N = 500$  puta. **Koliki je očekivani broj vektora koje ćemo pri uzorkovanju morati odbaciti?**

- ☐ A 89   ☐ B 152   ☐ C 404   ☐ D 180

- 17** (T) Glavna svrha probablističkih grafičkih modela (PGM) jest provođenje probablističkih upita. Jedna vrsta upita su MAP-upiti (upiti najvjerojatnijeg objašnjenja). Neka su  $\mathbf{x}_q$ ,  $\mathbf{x}_o$  i  $\mathbf{x}_n$  skupovi varijabli upita, opaženih varijabli odnosno varijabli smetnje. **Kako je definiran rezultat MAP-upita?**

- ☐ A  $\operatorname{argmax}_{\mathbf{x}_q} \sum_{\mathbf{x}_n} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$    ☐ C  $\operatorname{argmax}_{\mathbf{x}_o} \sum_{\mathbf{x}_n} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$   
☐ B  $\operatorname{argmax}_{\mathbf{x}_o} \sum_{\mathbf{x}_q} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$    ☐ D  $\operatorname{argmax}_{\mathbf{x}_q} \sum_{\mathbf{x}_o} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$

### Grupiranje (3 pitanja)

- 18** (N) Algoritmom HAC grupiramo riječi engleskog jezika. Neoznačeni skup podataka sastoji se od sljedećih riječi:

$$\mathcal{D} = \{\text{"water"}, \text{"watering"}, \text{"earth"}, \text{"air"}\}$$

Kao mjeru sličnosti između primjera koristimo jezgrenu funkciju nad znakovnim nizovima, definiranu kao  $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$ , gdje su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Npr.,  $\kappa(\text{"water"}, \text{"watering"}) = 5/8 = 0.625$ . Provedite prve dvije iteracije grupiranja algoritmom HAC uz prosječno povezivanje. **Na kojoj se razini sličnosti spajaju grupe u drugoj iteraciji algoritma HAC?**

- ☐ A 0.583   ☐ B 0.478   ☐ C 0.292   ☐ D 0.535

- 19** (N) Raspoložemo sljedećim neoznačenim skupom primjera:  $\mathcal{D} = \{(\mathbf{x}^{(i)})\}_i = \{(1, 1), (1, 2), (2, 2), (2, 3), (4, 3)\}$ . Primjere grupiramo algoritmom k-sredina sa  $K = 2$  grupe. Za početna središta odabrali smo primjere  $\mathbf{x}^{(2)} = (1, 2)$  i  $\mathbf{x}^{(5)} = (4, 3)$ . Provedite prvu iteraciju algoritma k-sredina. **Koliko iznosi vrijednost kriterijske funkcije  $J$  nakon ažuriranja centroida?**

- ☐ A 3.00   ☐ B 4.25   ☐ C 1.85   ☐ D 6.66

- 20** (P) Za grupiranje skupa primjera  $\mathcal{D}$  koristimo algoritam GMM. Koristimo nekoliko varijanti tog modela:

- $\mathcal{H}_1$  : Model sa  $K = 50$  središta inicijaliziranim algoritmom k-sredina  
 $\mathcal{H}_2$  : Model sa  $K = 50$  središta inicijaliziranim algoritmom k-sredina i dijeljenom kovarijacijskom matricom  
 $\mathcal{H}_3$  : Model sa  $K = 50$  slučajno inicijaliziranim središtima i dijeljenom kovarijacijskom matricom  
 $\mathcal{H}_4$  : Model sa  $K = 10$  središta inicijaliziranim algoritmom k-sredina i dijeljenom kovarijacijskom matricom

Sa svakim modelom grupiranje ponavljamo 1000 puta i zatim za svaki model crtamo graf funkcije log-izglednosti kroz iteracije EM-algoritma, uprosječen kroz svih 1000 ponavljanja. Neka je  $LL_\alpha^0$  prosječna log-izglednost za model  $\mathcal{H}_\alpha$  na početku izvođenja EM-algoritma, a neka je  $LL_\alpha^*$  prosječna log-izglednost za taj model na kraju izvođenja EM-algoritma. **Što možemo unaprijed zaključiti o ovim log-izglednostima?**

- ☐ A  $LL_2^0 \geq LL_4^0, LL_1^* \geq LL_2^* \geq LL_3^*$    ☐ C  $LL_2^0 \geq LL_4^0 \geq LL_3^0, LL_1^* \geq LL_2^*$   
☐ B  $LL_2^0 \leq LL_4^0, LL_2^* \leq LL_1^* \geq LL_3^*$    ☐ D  $LL_3^0 \geq LL_4^0, LL_1^* \geq LL_3^* \geq LL_4^*$

## Vrednovanje modela (2 pitanja)

- 21** (T) Ugniježdene k-struka unakrsna provjera često se koristi za procjenu točnosti modela. Što je prednost ugniježdene k-struke unakrsne provjere u odnosu na običnu unakrsnu provjeru?
- ☐ A Procjenjujemo pogrešku generalizacije, a ne pogrešku učenja
  - ☐ B Procjenjujemo ispitnu pogrešku modela s najmanjom pogreškom učenja
  - ☐ C Procjenjujemo očekivanu ispitnu pogrešku modela optimalne složenosti
  - ☐ D Model ispitujemo na cijelom raspoloživom skupu primjera
- 22** (P) Raspoložemo sa 1000 označenih primjera. Na tom skupu treniramo i evaluiramo algoritam SVM. Pritom razmatramo tri hiperparametra: jezgra (linearna ili RBF), regularizacijski faktor  $C$  i preciznost RBF jezgre  $\gamma$ . Posljednja dva hiperparametra optimiramo rešetkastim pretraživanjem u rasponima  $C \in \{2^{-15}, 2^{-14}, \dots, 2^{15}\}$  i  $\gamma \in \{2^{-15}, 2^{-14}, \dots, 2^{15}\}$ . Naravno, ako ne koristimo RBF-jezgru, onda hiperparametar  $\gamma$  ne optimiramo. Za treniranje i evaluaciju modela koristimo ugniježdenu unakrsnu provjeru s 10 ponavljanja u vanjskoj petlji i 5 ponavljanja u unutarnjoj petlji. **Koliko će puta svaki primjer biti iskorišten za treniranje modela?**
- ☐ A 49600    ☐ B 35721    ☐ C 69201    ☐ D 44640



## Pismeni ispit iz Strojnog učenja 1 (ak. god. 2021./2022.)

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 70% bodova na predmetu). Pitanja nose po 1 bod, a 1/3 boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **150 minuta**. Primjerak ispita morate predati zajedno sa svojim rješenjima.

### Osnovni koncepti i linearna regresija (4 pitanja)

- 1** (P) Koristimo regresiju za predviđanje uspjeha na studiju. Kao značajke možemo koristiti ocjene u četiri razreda srednje škole (značajke  $x_1-x_4$ ), prosjek ocjena sva četiri razreda ( $x_5$ ) te uspjeh iz matematike ( $x_6$ ) i fizike ( $x_7$ ) na državnoj maturi (ukupno 7 značajki). Ne moramo iskoristiti sve značajke, ali ih želimo iskoristiti što više. Za preslikavanje u prostor značajki koristimo preslikavanje s kvadratnim, interakcijskim i linearnim značajkama. Od interakcijskih značajki uzimamo samo interakcije parova značajki (npr.  $x_1x_2$ ) i interakcije trojki (npr.  $x_1x_2x_3$ ) između svih značajki koje koristimo. **Koliko minimalno primjera za učenje trebamo imati, a da bi rješenje bilo stabilno i bez regularizacije?**

☐ A 63   ☐ B 48   ☐ C 38   ☐ D 75

- 2** (P) Skup označenih primjera u dvodimenzijaskome ulaznom prostoru je:

$$\mathcal{D} = \{((0, 0), 0), ((0, 1), 0), ((1, 1), 1)\}$$

Koja je veličina prostora inačica,  $|\mathcal{V}_{\mathcal{H}, \mathcal{D}}|$ ?

☐ A 16   ☐ B 14   ☐ C Pitanje nema smisla jer nije definiran model   ☐ D Beskonačno mnogo

- 3** (T) Optimizacija modela hrbatne regresije ( $L_2$ -regularizirane linearne regresije) ima rješenje u zatvorenoj formi. Neka je  $\lambda$  regularizacijski faktor,  $n$  broj značajki u ulaznom prostoru (bez “dummy” jedinice),  $m$  broj značajki u prostoru značajki (također bez “dummy” jedinice) te  $N$  broj primjera. Glavna komponenta rješenja je izračun inverza matrice izračunate na temelju matrice dizajna  $\Phi$ . **Koliko redaka odnosno stupaca ima matrica koju invertiramo?**

☐ A  $m + \lambda$    ☐ B  $N$    ☐ C  $m + 1$    ☐ D  $n + \lambda$

- 4** (N) Raspoložemo sljedećim skupom primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((1, 0), 1), ((2, -3), 2), ((3, 5), -1), ((5, 0), -4)\}$$

Na ovom skupu gradijentnim spustom trenirali smo  $L_1$ -regularizirani model linearne regresije sa  $\lambda = 1$ . Dobili smo težine  $\mathbf{w} = (2.12, -0.94, -0.08)$ . **Koliko iznosi  $L_1$ -regularizirana pogreška  $E(\mathbf{w}|\mathcal{D})$ ?**

☐ A 1.58   ☐ B 7.10   ☐ C 2.69   ☐ D 0.29

### Linearni klasifikacijski modeli (3 pitanja)

- 5** (P) Treniramo linearni diskriminativni model u dvodimenzijaskome prostoru primjera. Skup za učenje čine samo dva primjera,  $(\mathbf{x}_1, y_1) = ((1, 0), +1)$  i  $(\mathbf{x}_2, y_2) = ((0, 1), -1)$ . Na tom skupu treniramo model koji ima induktivnu pristranost takvu da rješenje maksimizira minimalnu udaljenost primjera od hiperravnine. Naučen model ispravno klasificira oba primjera, pri čemu za oba primjera vrijedi  $y \cdot h(\mathbf{x}) = 5$ . **Koliko iznosi težina  $w_2$  tako naučenog modela?**

☐ A -1   ☐ B 1   ☐ C 5   ☐ D -5

**6** (T) Neregularizirani model logističke regresije sklon je prenaučivosti. To je pogotovo slučaj ako se model trenira na linearno odvojivim podacima, čak i onda kada u podacima nema nikakvoga šuma i kada se ne koristi nikakvo preslikavanje u prostor značajki. **Zbog čega dolazi do prenaučivosti modela neregularizirane logističke regresije na linearno odvojivim skupovima podataka?**

- ☐ A S porastom norme vektora težina gubitak na točnim primjerima teži prema nuli
- ☐ B Empirijska pogreška logističke regresije smanjuje se s porastom broja primjera
- ☐ C Netočno klasificirani primjeri nanose gubitak koji je proporcionalan normi vektora težina
- ☐ D Ispravno klasificirani primjeri koji su vrlo udaljeni od granice nanose malen gubitak

**7** (N) Raspoložemo označenim skupom primjera iz triju klasa ( $K = 3$ ) u trodimenzijskome ulaznom prostoru ( $n = 3$ ). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer  $\mathbf{x} = (-4, -1, -3)$  s oznakom  $\mathbf{y} = (0, 0, 1)$ . **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

- ☐ A 12.02
- ☐ B 4.02
- ☐ C 6.00
- ☐ D 8.00

### Jezgrene i neparametarske metode (4 pitanja)

**8** (N) Na skupu primjera za učenje iz ulaznog prostora  $n = 4$  trenirali smo SVM s polinomijalnom jezgrenom funkcijom  $\kappa(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^T \mathbf{z} + 1)^3$ . Potporni vektori i njihove oznake su sljedeći:

$$(\mathbf{x}^{(1)}, y^{(1)}) = ((11, 32, 21), -1)$$

$$(\mathbf{x}^{(2)}, y^{(2)}) = ((5, 11, 6), -1)$$

$$(\mathbf{x}^{(3)}, y^{(3)}) = ((6, 12, 6), +1)$$

Lagrangeovi koeficijenti su  $\alpha_1 = 1.063 \cdot 10^{-7}$ ,  $\alpha_2 = 1.022 \cdot 10^{-5}$  i  $\alpha_3 = 1.032 \cdot 10^{-5}$ . **Upotrijebite jezgreni trik da biste odredili vrijednost hipoteze  $h(\mathbf{x})$  za primjer  $\mathbf{x} = (5, 15, 1)$ .**

- ☐ A -4.093
- ☐ B +5.454
- ☐ C -2.330
- ☐ D -3.553

**9** (T) Problem maksimalne margine ima svoju geometrijsku interpretaciju: maksimalna margina odgovara simetrali spojnice konveksnih ljusaka primjera iz dviju klasa. **Što je nužan i dovoljan uvjet da klasifikacijski problem bude rješiv SVM-om s tvrdom marginom?**

- ☐ A Svaka spojnica između primjera iz jedne klase treba biti izvan konveksne ljuske druge klase
- ☐ B Konveksne ljuske dviju klasa ne smiju se preklapati (trebaju biti disjunktne)
- ☐ C Primjeri iz obje klase trebaju činiti konveksne skupove u ulaznom prostoru
- ☐ D Najbliži primjeri iz suprotnih klasa moraju biti u vrhovima konveksnih ljusaka

**10** (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), -1), ((-2, -2), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1))\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa  $C = 1$ . Kod modela s mekom marginom za dualne koeficijente vrijedi  $\alpha_1 = 1$ ,  $\alpha_2 > 0$ ,  $\alpha_3 > 0$ ,  $\alpha_4 > 0$  i  $\alpha_5 = 1$ . Skicirajte tvrdu i meku marginu u ulaznome prostoru. **Koliko je meka margina šira od tvrde margine?**

- ☐ A  $\frac{4}{5}\sqrt{10}$  puta
- ☐ B  $\frac{1}{6}\sqrt{2}$  puta
- ☐ C  $\frac{2}{5}\sqrt{10}$  puta
- ☐ D  $\frac{3}{5}\sqrt{10}$  puta

- 11** (N) Algoritam k-NN koristimo za višeklasnu klasifikaciju riječi prema jeziku kojemu pripadaju. Skup za učenje sastoji se od sljedećih riječi i oznaka klasa:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{(\text{"water"}, 0), (\text{"voda"}, 1), (\text{"zrak"}, 1), (\text{"luft"}, 2), (\text{"feuer"}, 2)\}$$

Kao mjeru sličnosti između primjera koristimo jezgrenu funkciju nad znakovnim nizovima, definiranu kao  $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$ , gdje je su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Npr.,  $\kappa(\text{"water"}, \text{"voda"}) = 1/8 = 0.125$ . Razmatramo dvije varijante algoritma: 3-NN i težinski k-NN. Kod potonjeg u obzir uzimamo sve primjere, tj.  $k = N$ . Odredite klasifikaciju primjera  $\mathbf{x} = \text{"wasser"}$  pomoću ova dva algoritma. U slučaju jednake sličnosti između dva primjera, kao susjed se uzima onaj koji je u skupu  $\mathcal{D}$  naveden prvi. U slučaju izjednačenja glasova između klasa, prednost se daje klasi s numerički manjom oznakom  $y$ . **U koju će klasu biti klasificiran primjer  $\mathbf{x}$  algoritmom 3-NN, a u koju algoritmom težinski k-NN?**

- ☐ A  $y = 0$  i  $y = 2$    ☐ B  $y = 0$  i  $y = 1$    ☐ C  $y = 0$  i  $y = 0$    ☐ D  $y = 1$  i  $y = 1$

## Procjena parametara i Bayesov klasifikator (3 pitanja)

- 12** (N) Treniramo Bayesov klasifikator za odluku o dobroj destinaciji za Erasmus+ studentski boravak. Skup primjera za učenje, izgrađen na temelju iskustava prijatelja i prijatelja prijatelja, je sljedeći:

$i$	Država	Stipendija	Semestar	Studij	GovoriJezik	$y^{(i)}$
1	Njemačka	da	ljetni	dipl	da	1
2	Poljska	ne	zimski	preddipl	ne	1
3	Italija	da	ljetni	dipl	da	1
4	Njemačka	ne	zimski	preddipl	ne	0
5	Austrija	da	ljetni	dipl	da	1
6	Poljska	ne	zimski	dipl	ne	1
7	Austrija	da	zimski	dipl	ne	1
8	Njemačka	ne	zimski	dipl	ne	0

Očekujemo zavisnost između varijabli *Država* i *Stipendija*, pa koristimo polunaivan Bayesov klasifikator u kojemu su te dvije varijable združene. Procjene izglednosti klasa radimo Laplaceovim MAP-procjeniteljem. Zanima nas klasifikacija za  $\mathbf{x} = (\text{Italija}, \text{da}, \text{zimski}, \text{preddipl}, \text{ne})$ . **Koliko iznosi aposteriorna vjerojatnost  $P(y = 1|\mathbf{x})$ ?**

- ☐ A 0.588   ☐ B 0.741   ☐ C 0.488   ☐ D 0.322

- 13** (T) Nepristranost je jedno od svojstava statističkih procjenitelja. Procjenitelj MLE ne mora nužno biti nepristran, tj. može biti pristran. **Za koji od sljedećih parametara distribucije procjena MLE pristrana?**

- ☐ A Srednja vrijednost Gaussove distribucije  
☐ B Varijanca Bernoullijeve distribucije  
☐ C Srednja vrijednost Bernoullijeve distribucije  
☐ D Kovarijacijska matrica Gaussove distribucije

- 14** (P) Gaussov Bayesov klasifikator koristimo za klasifikaciju jednodimenzijskih podataka u tri klase. Procijenjene izglednosti klasa su  $p(x|y = 1) = \mathcal{N}(-10, 2)$ ,  $p(x|y = 2) = \mathcal{N}(2, 2)$  i  $p(x|y = 3) = \mathcal{N}(8, 2)$ , a procijenjene apriorne vjerojatnosti klasa su  $P(y = 1) = P(y = 2) = 1/5$  i  $P(y = 3) = 3/5$ . Međutim, nakon što smo naučili ovaj model, zaključili smo da na ispitnom skupu postoji pomak u distribuciji podataka u odnosu na skup za učenje te da zbog toga model ne generalizira dobro. Zaključili smo da se ovo može ispraviti tako da se naučeni model malo izmijeni, i to tako da se varijanca izglednosti klase  $y = 1$  postavi na 1 i da se apriorne vjerojatnosti klasa ujednače,  $P(y = 1) = P(y = 2) = P(y = 3) = 1/3$ . Skicirajte gustoće zajedničke vjerojatnosti naučenog i izmijenjenog modela. Neka su  $h_1$  i  $h_2$  MAP-hipoteze prvog i drugog modela, te neka su  $a$  i  $b$  pozitivne konstante. Razmotrite segment ulaznog prostora za koji vrijedi  $-10 \leq x \leq 10$ . **Na kojim se dijelovima tog segmenta ulaznog prostora MAP-hipoteze prvog i drugog modela razlikuju?**

- ☐ A  $[-4 - a, -4] \cup [5 - b, 5]$    ☐ B  $[-4, -4 + a] \cup [5, 5 + b]$    ☐ C  $[-4 - a, 5 + b]$    ☐ D  $[-4 - a, -4 + b]$

## Probabilistički grafički modeli (3 pitanja)

- 15 (N) Razmotrite jednostavnu Bayesovu mrežu koja odgovara faktorizaciji  $P(x, y, z) = P(x)P(y)P(z|x, y)$ . Sve varijable su binarne. Vrijedi  $P(x = 1) = 0.2$  i  $P(y = 1) = 0.3$ . Tablica uvjetne vjerojatnosti za čvor  $z$  je sljedeća:

$z$	$x$	$y$	$p(z x, y)$	$z$	$x$	$y$	$p(z x, y)$
0	0	0	0.1	1	0	0	0.9
0	0	1	0.2	1	0	1	0.8
0	1	0	0.5	1	1	0	0.5
0	1	1	0.9	1	1	1	0.1

Postupkom uzorkovanja s odbijanjem uzorkujemo iz aposteriorne distribucije  $P(y|x = 0, z = 1)$ . Uzorkovanje smo ponovili ukupno  $N = 500$  puta. **Koliki je očekivani broj vektora koje ćemo pri uzorkovanju morati odbaciti?**

- ☐ A 404   ☐ B 152   ☐ C 180   ☐ D 89

- 16 (P) Razmotrite Bayesovu mrežu koja zajedničku vjerojatnost faktorizira na sljedeći način:

$$P(w, x, y, z) = P(w)P(y)P(x|w, y)P(z|w)$$

Odredite topološki uređaj varijabli. Ako postoji više mogućih topoloških uređaja, izaberite onaj koji po leksičkom poretku dolazi prvi (npr.  $x, y, z$  dolazi prije  $x, z, y$ ). Zatim primijenite uređajno Markovljevo svojstvo te izvedite sve uvjetne nezavisnosti koje su kodirane u ovoj Bayesovoj mreži. **Koje sve uvjetne nezavisnosti vrijede u ovoj Bayesovoj mreži?**

- ☐ A  $x \perp y | z, z \perp w | y$    ☐ B  $y \perp w, y \perp x | \{w, z\}$    ☐ C  $w \perp y, z \perp x, x \perp w | \{z, y\}$    ☐ D  $w \perp y, z \perp \{x, y\} | w$

- 17 (T) Glavna svrha probabilističkih grafičkih modela (PGM) jest provođenje probabilističkih upita. Jedna vrsta upita su MAP-upiti (upiti najvjerojatnijeg objašnjenja). Neka su  $\mathbf{x}_q$ ,  $\mathbf{x}_o$  i  $\mathbf{x}_n$  skupovi varijabli upita, opaženih varijabli odnosno varijabli smetnje. **Kako je definiran rezultat MAP-upita?**

- ☐ A  $\operatorname{argmax}_{\mathbf{x}_q} \sum_{\mathbf{x}_n} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$    ☐ C  $\operatorname{argmax}_{\mathbf{x}_q} \sum_{\mathbf{x}_o} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$   
☐ B  $\operatorname{argmax}_{\mathbf{x}_o} \sum_{\mathbf{x}_n} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$    ☐ D  $\operatorname{argmax}_{\mathbf{x}_o} \sum_{\mathbf{x}_q} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$

## Grupiranje (3 pitanja)

- 18 (N) Raspoložemo sljedećim neoznačenim skupom primjera:  $\mathcal{D} = \{(\mathbf{x}^{(i)})\}_i = \{(1, 1), (1, 2), (2, 2), (2, 3), (4, 3)\}$ . Primjere grupiramo algoritmom k-sredina sa  $K = 2$  grupe. Za početna središta odabrali smo primjere  $\mathbf{x}^{(2)} = (1, 2)$  i  $\mathbf{x}^{(5)} = (4, 3)$ . Provedite prvu iteraciju algoritma k-sredina. **Koliko iznosi vrijednost kriterijske funkcije  $J$  nakon ažuriranja centroida?**

- ☐ A 4.25   ☐ B 6.66   ☐ C 3.00   ☐ D 1.85

- 19 (P) Za grupiranje skupa primjera  $\mathcal{D}$  koristimo algoritam GMM. Koristimo nekoliko varijanti tog modela:

- $\mathcal{H}_1$  : Model sa  $K = 50$  središta inicijaliziranim algoritmom k-sredina  
 $\mathcal{H}_2$  : Model sa  $K = 50$  središta inicijaliziranim algoritmom k-sredina i dijeljenom kovarijacijskom matricom  
 $\mathcal{H}_3$  : Model sa  $K = 50$  slučajno inicijaliziranim središtima i dijeljenom kovarijacijskom matricom  
 $\mathcal{H}_4$  : Model sa  $K = 10$  središta inicijaliziranim algoritmom k-sredina i dijeljenom kovarijacijskom matricom

Sa svakim modelom grupiranje ponavljamo 1000 puta i zatim za svaki model crtamo graf funkcije log-izglednosti kroz iteracije EM-algoritma, uprosječen kroz svih 1000 ponavljanja. Neka je  $LL_\alpha^0$  prosječna log-izglednost za model  $\mathcal{H}_\alpha$  na početku izvođenja EM-algoritma, a neka je  $LL_\alpha^*$  prosječna log-izglednost za taj model na kraju izvođenja EM-algoritma. **Što možemo unaprijed zaključiti o ovim log-izglednostima?**

- ☐ A  $LL_2^0 \geq LL_4^0, LL_1^* \geq LL_2^* \geq LL_3^*$    ☐ C  $LL_2^0 \geq LL_4^0 \geq LL_3^0, LL_1^* \geq LL_2^*$   
☐ B  $LL_3^0 \geq LL_4^0, LL_1^* \geq LL_3^* \geq LL_4^*$    ☐ D  $LL_2^0 \leq LL_4^0, LL_2^* \leq LL_1^* \geq LL_3^*$



- 20 (N) Algoritmom HAC grupiramo riječi engleskog jezika. Neoznačeni skup podataka sastoji se od sljedećih riječi:

$$\mathcal{D} = \{\text{"water"}, \text{"waterloo"}, \text{"moon"}, \text{"air"}\}$$

Kao mjeru sličnosti između primjera koristimo jezgrenu funkciju nad znakovnim nizovima, definiranu kao  $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$ , gdje su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Npr.,  $\kappa(\text{"water"}, \text{"waterloo"}) = 5/7 = 0.714$ . Provedite prve dvije iteracije grupiranja algoritmom HAC uz prosječno povezivanje. **Na kojoj se razini sličnosti spajaju grupe u drugoj iteraciji algoritma HAC?**

- ☐ A 0.354   ☐ B 0.292   ☐ C 0.535   ☐ D 0.583

### Vrednovanje modela (2 pitanja)

- 21 (P) Raspoložemo sa 1000 označenih primjera. Na tom skupu treniramo i evaluiramo algoritam SVM. Pritom razmatramo tri hiperparametra: jezgra (linearna ili RBF), regularizacijski faktor  $C$  i preciznost RBF jezgre  $\gamma$ . Posljednja dva hiperparametra optimiramo rešetkastim pretraživanjem u rasponima  $C \in \{2^{-15}, 2^{-14}, \dots, 2^{15}\}$  i  $\gamma \in \{2^{-15}, 2^{-14}, \dots, 2^{15}\}$ . Naravno, ako ne koristimo RBF-jezgru, onda hiperparametar  $\gamma$  ne optimiramo. Za treniranje i evaluaciju modela koristimo ugniježđenu unakrsnu provjeru s 10 ponavljanja u vanjskoj petlji i 5 ponavljanja u unutarnjoj petlji. **Koliko će puta svaki primjer biti iskorišten za treniranje modela?**

- ☐ A 35721   ☐ B 44640   ☐ C 69201   ☐ D 49600

- 22 (T) Ugniježđena k-struka unakrsna provjera često se koristi za procjenu točnosti modela. **Što je prednost ugniježdene k-struke unakrsne provjere u odnosu na običnu unakrsnu provjeru?**

- ☐ A Procjenjujemo pogrešku generalizacije, a ne pogrešku učenja  
☐ B Procjenjujemo očekivanu ispitnu pogrešku modela optimalne složenosti  
☐ C Model ispitujemo na cijelom raspoloživom skupu primjera  
☐ D Procjenjujemo ispitnu pogrešku modela s najmanjom pogreškom učenja



## Pismeni ispit iz Strojnog učenja 1 (ak. god. 2021./2022.)

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 70% bodova na predmetu). Pitanja nose po 1 bod, a 1/3 boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **150 minuta**. Primjerak ispita morate predati zajedno sa svojim rješenjima.

### Osnovni koncepti i linearna regresija (4 pitanja)

- 1** (T) Optimizacija modela hrbatne regresije ( $L_2$ -regularizirane linearne regresije) ima rješenje u zatvorenoj formi. Neka je  $\lambda$  regularizacijski faktor,  $n$  broj značajki u ulaznom prostoru (bez “dummy” jedinice),  $m$  broj značajki u prostoru značajki (također bez “dummy” jedinice) te  $N$  broj primjera. Glavna komponenta rješenja je izračun inverza matrice izračunate na temelju matrice dizajna  $\Phi$ . **Koliko redaka odnosno stupaca ima matrica koju invertiramo?**

☐ A  $m + 1$    ☐ B  $N$    ☐ C  $m + \lambda$    ☐ D  $n + \lambda$

- 2** (N) Raspoložemo sljedećim skupom primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((1, 0), 1), ((2, -3), 2), ((3, 5), -1), ((5, 0), -4)\}$$

Na ovom skupu gradijentnim spustom trenirali smo  $L_1$ -regularizirani model linearne regresije sa  $\lambda = 1$ . Dobili smo težine  $\mathbf{w} = (2.12, -0.94, -0.08)$ . **Koliko iznosi  $L_1$ -regularizirana pogreška  $E(\mathbf{w}|\mathcal{D})$ ?**

☐ A 0.29   ☐ B 7.10   ☐ C 1.58   ☐ D 2.69

- 3** (P) Koristimo regresiju za predviđanje uspjeha na studiju. Kao značajke možemo koristiti ocjene u četiri razreda srednje škole (značajke  $x_1$ – $x_4$ ), prosjek ocjena sva četiri razreda ( $x_5$ ) te uspjeh iz matematike ( $x_6$ ) i fizike ( $x_7$ ) na državnoj maturi (ukupno 7 značajki). Ne moramo iskoristiti sve značajke, ali ih želimo iskoristiti što više. Za preslikavanje u prostor značajki koristimo preslikavanje s kvadratnim, interakcijskim i linearnim značajkama. Od interakcijskih značajki uzimamo samo interakcije parova značajki (npr.  $x_1x_2$ ) i interakcije trojki (npr.  $x_1x_2x_3$ ) između svih značajki koje koristimo. **Koliko minimalno primjera za učenje trebamo imati, a da bi rješenje bilo stabilno i bez regularizacije?**

☐ A 38   ☐ B 63   ☐ C 75   ☐ D 48

- 4** (P) Skup označenih primjera u dvodimenzijaskome ulaznom prostoru je:

$$\mathcal{D} = \{((0, 0), 0), ((0, 1), 0), ((1, 1), 1)\}$$

**Koja je veličina prostora inačica,  $|\mathcal{V}_{\mathcal{H}, \mathcal{D}}|$ ?**

☐ A Beskonačno mnogo   ☐ B Pitanje nema smisla jer nije definiran model   ☐ C 14   ☐ D 16

### Linearni klasifikacijski modeli (3 pitanja)

- 5** (N) Raspoložemo označenim skupom primjera iz triju klasa ( $K = 3$ ) u trodimenzijaskome ulaznom prostoru ( $n = 3$ ). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer  $\mathbf{x} = (-4, -1, -3)$  s oznakom  $\mathbf{y} = (1, 0, 0)$ . **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

☐ A 4.02   ☐ B 8.00   ☐ C 6.00   ☐ D 12.02

- 6 (P) Treniramo linearni diskriminativni model u dvodimenzijskome prostoru primjera. Skup za učenje čine samo dva primjera,  $(\mathbf{x}_1, y_1) = ((1, 0), +1)$  i  $(\mathbf{x}_2, y_2) = ((0, 1), -1)$ . Na tom skupu treniramo model koji ima induktivnu pristranost takvu da rješenje maksimizira minimalnu udaljenost primjera od hiperravnine. Naučen model ispravno klasificira oba primjera, pri čemu za oba primjera vrijedi  $y \cdot h(\mathbf{x}) = 5$ . **Koliko iznosi težina  $w_2$  tako naučenog modela?**

☐ A  $-1$    ☐ B  $1$    ☐ C  $5$    ☐ D  $-5$

- 7 (T) Neregularizirani model logističke regresije sklon je prenaučivosti. To je pogotovo slučaj ako se model trenira na linearno odvojivim podatcima, čak i onda kada u podatcima nema nikakvoga šuma i kada se ne koristi nikakvo preslikavanje u prostor značajki. **Zbog čega dolazi do prenaučivosti modela neregularizirane logističke regresije na linearno odvojivim skupovima podataka?**

- ☐ A Netočno klasificirani primjeri nanose gubitak koji je proporcionalan normi vektora težina  
☐ B Empirijska pogreška logističke regresije smanjuje se s porastom broja primjera  
☐ C Ispravno klasificirani primjeri koji su vrlo udaljeni od granice nanose malen gubitak  
☐ D S porastom norme vektora težina gubitak na točnim primjerima teži prema nuli

### Jezgrene i neparametarske metode (4 pitanja)

- 8 (N) Algoritam k-NN koristimo za višeklasnu klasifikaciju riječi prema jeziku kojemu pripadaju. Skup za učenje sastoji se od sljedećih riječi i oznaka klasa:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{("water", 0), ("voda", 1), ("zrak", 1), ("luft", 2), ("feuer", 2)\}$$

Kao mjeru sličnosti između primjera koristimo jezgrene funkcije nad znakovnim nizovima, definirane kao  $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$ , gdje je su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Npr.,  $\kappa("water", "voda") = 1/8 = 0.125$ . Razmatramo dvije varijante algoritma: 3-NN i težinski k-NN. Kod potonjeg u obzir uzimamo sve primjere, tj.  $k = N$ . Odredite klasifikaciju primjera  $\mathbf{x} = "wasser"$  pomoću ova dva algoritma. U slučaju jednake sličnosti između dva primjera, kao susjed se uzima onaj koji je u skupu  $\mathcal{D}$  naveden prvi. U slučaju izjednačenja glasova između klasa, prednost se daje klasi s numerički manjom oznakom  $y$ . **U koju će klasu biti klasificiran primjer  $\mathbf{x}$  algoritmom 3-NN, a u koju algoritmom težinski k-NN?**

☐ A  $y = 0$  i  $y = 0$    ☐ B  $y = 0$  i  $y = 2$    ☐ C  $y = 1$  i  $y = 1$    ☐ D  $y = 0$  i  $y = 1$

- 9 (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), -1), ((-1, -1), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1)\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa  $C = 1$ . Kod modela s mekom marginom za dualne koeficijente vrijedi  $\alpha_1 = 1$ ,  $\alpha_2 > 0$ ,  $\alpha_3 > 0$ ,  $\alpha_4 > 0$  i  $\alpha_5 = 1$ . Skicirajte tvrdi i meki margin u ulaznome prostoru. **Koliko je meka margina šira od tvrde margine?**

☐ A  $\frac{3}{5}\sqrt{10}$  puta   ☐ B  $\frac{4}{5}\sqrt{10}$  puta   ☐ C  $\frac{2}{5}\sqrt{10}$  puta   ☐ D  $\frac{1}{6}\sqrt{2}$  puta

- 10 (N) Na skupu primjera za učenje iz ulaznog prostora  $n = 4$  trenirali smo SVM s polinomijalnom jezgrenom funkcijom  $\kappa(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^T \mathbf{z} + 1)^3$ . Potporni vektori i njihove oznake su sljedeći:

$$(\mathbf{x}^{(1)}, y^{(1)}) = ((11, 32, 21), -1)$$

$$(\mathbf{x}^{(2)}, y^{(2)}) = ((5, 11, 6), -1)$$

$$(\mathbf{x}^{(3)}, y^{(3)}) = ((6, 12, 6), +1)$$

Lagrangeovi koeficijenti su  $\alpha_1 = 1.063 \cdot 10^{-7}$ ,  $\alpha_2 = 1.022 \cdot 10^{-5}$  i  $\alpha_3 = 1.032 \cdot 10^{-5}$ . **Upotrijebite jezgri trik da biste odredili vrijednost hipoteze  $h(\mathbf{x})$  za primjer  $\mathbf{x} = (-3, -5, 3)$ .**

☐ A  $-4.093$    ☐ B  $-2.330$    ☐ C  $-3.553$    ☐ D  $+1.434$

- 11** (T) Problem maksimalne margine ima svoju geometrijsku interpretaciju: maksimalna margina odgovara simetrali spojnice konveksnih ljusaka primjera iz dviju klasa. **Što je nužan i dovoljan uvjet da klasifikacijski problem bude rješiv SVM-om s tvrdom marginom?**
- ☐ A Primjeri iz obje klase trebaju činiti konveksne skupove u ulaznom prostoru
- ☐ B Konveksne ljuske dviju klasa ne smiju se preklapati (trebaju biti disjunktne)
- ☐ C Svaka spojnica između primjera iz jedne klase treba biti izvan konveksne ljuske druge klase
- ☐ D Najbliži primjeri iz suprotnih klasa moraju biti u vrhovima konveksnih ljusaka

### Procjena parametara i Bayesov klasifikator (3 pitanja)

- 12** (T) Nepriistranost je jedno od svojstava statističkih procjenitelja. Procjenitelj MLE ne mora nužno biti nepriistran, tj. može biti pristran. **Za koji od sljedećih parametara distribucije procjena MLE pristrana?**
- ☐ A Kovarijacijska matrica Gaussove distribucije
- ☐ B Varijanca Bernoullijeve distribucije
- ☐ C Srednja vrijednost Gaussove distribucije
- ☐ D Srednja vrijednost Bernoullijeve distribucije
- 13** (N) Treniramo Bayesov klasifikator za odluku o dobroj destinaciji za Erasmus+ studentski boravak. Skup primjera za učenje, izgrađen na temelju iskustava prijatelja i prijatelja prijatelja, je sljedeći:

$i$	Država	Stipendija	Semestar	Studij	GovoriJezik	$y^{(i)}$
1	Njemačka	da	ljetni	dipl	da	1
2	Poljska	ne	zimski	preddipl	ne	1
3	Italija	da	ljetni	dipl	da	1
4	Njemačka	ne	zimski	preddipl	ne	0
5	Austrija	da	ljetni	dipl	da	1
6	Poljska	ne	zimski	dipl	ne	1
7	Austrija	da	zimski	dipl	ne	1
8	Njemačka	ne	zimski	dipl	ne	0

Očekujemo zavisnost između varijabli *Država* i *Stipendija*, pa koristimo polunaivan Bayesov klasifikator u kojemu su te dvije varijable združene. Procjene izglednosti klasa radimo Laplaceovim MAP-procjeniteljem. Zanima nas klasifikacija za  $\mathbf{x} = (\text{Italija}, \text{ne}, \text{zimski}, \text{dipl}, \text{ne})$ . **Koliko iznosi aposteriorna vjerojatnost  $P(y = 1|\mathbf{x})$ ?**

- ☐ A 0.488    ☐ B 0.322    ☐ C 0.588    ☐ D 0.741
- 14** (P) Gaussov Bayesov klasifikator koristimo za klasifikaciju jednodimenzijskih podataka u tri klase. Procijenjene izglednosti klasa su  $p(x|y = 1) = \mathcal{N}(-10, 2)$ ,  $p(x|y = 2) = \mathcal{N}(2, 2)$  i  $p(x|y = 3) = \mathcal{N}(8, 2)$ , a procijenjene apriorne vjerojatnosti klasa su  $P(y = 1) = P(y = 2) = 2/5$  i  $P(y = 3) = 1/5$ . Međutim, nakon što smo naučili ovaj model, zaključili smo da na ispitnom skupu postoji pomak u distribuciji podataka u odnosu na skup za učenje te da zbog toga model ne generalizira dobro. Zaključili smo da se ovo može ispraviti tako da se naučeni model malo izmijeni, i to tako da se varijanca izglednosti klase  $y = 1$  postavi na 1 i da se apriorne vjerojatnosti klasa ujednače,  $P(y = 1) = P(y = 2) = P(y = 3) = 1/3$ . Skicirajte gustoće zajedničke vjerojatnosti naučenog i izmijenjenog modela. Neka su  $h_1$  i  $h_2$  MAP-hipoteze prvog i drugog modela, te neka su  $a$  i  $b$  pozitivne konstante. Razmotrite segment ulaznog prostora za koji vrijedi  $-10 \leq x \leq 10$ . **Na kojim se dijelovima tog segmenta ulaznog prostora MAP-hipoteze prvog i drugog modela razlikuju?**

- ☐ A  $[-4 - a, -4] \cup [5, 5 + b]$     ☐ B  $[-4 - a, -4 + b]$     ☐ C  $[-4 - a, 5 + b]$     ☐ D  $[-4, -4 + a] \cup [5 - b, 5]$

### Probabilistički grafički modeli (3 pitanja)

- 15** (T) Glavna svrha probabilističkih grafičkih modela (PGM) jest provođenje probabilističkih upita. Jedna vrsta upita su MAP-upiti (upiti najvjerojatnijeg objašnjenja). Neka su  $\mathbf{x}_q$ ,  $\mathbf{x}_o$  i  $\mathbf{x}_n$  skupovi varijabli upita, opaženih varijabli odnosno varijabli smetnje. **Kako je definiran rezultat MAP-upita?**
- ☐ A  $\operatorname{argmax}_{\mathbf{x}_o} \sum_{\mathbf{x}_q} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$     ☐ C  $\operatorname{argmax}_{\mathbf{x}_q} \sum_{\mathbf{x}_o} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$
- ☐ B  $\operatorname{argmax}_{\mathbf{x}_q} \sum_{\mathbf{x}_n} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$     ☐ D  $\operatorname{argmax}_{\mathbf{x}_o} \sum_{\mathbf{x}_n} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$

- 16 (N) Razmotrite jednostavnu Bayesovu mrežu koja odgovara faktorizaciji  $P(x, y, z) = P(x)P(y)P(z|x, y)$ . Sve varijable su binarne. Vrijedi  $P(x = 1) = 0.2$  i  $P(y = 1) = 0.3$ . Tablica uvjetne vjerojatnosti za čvor  $z$  je sljedeća:

$z$	$x$	$y$	$p(z x, y)$	$z$	$x$	$y$	$p(z x, y)$
0	0	0	0.1	1	0	0	0.9
0	0	1	0.2	1	0	1	0.8
0	1	0	0.5	1	1	0	0.5
0	1	1	0.9	1	1	1	0.1

Postupkom uzorkovanja s odbijanjem uzorkujemo iz aposteriorne distribucije  $P(y|x = 0, z = 1)$ . Uzorkovanje smo ponovili ukupno  $N = 500$  puta. **Koliki je očekivani broj vektora koje ćemo pri uzorkovanju morati odbaciti?**

- ☐ A 180   ☐ B 152   ☐ C 89   ☐ D 404

- 17 (P) Razmotrite Bayesovu mrežu koja zajedničku vjerojatnost faktorizira na sljedeći način:

$$P(w, x, y, z) = P(w)P(y)P(x|w, y)P(z|w)$$

Odredite topološki uređaj varijabli. Ako postoji više mogućih topoloških uređaja, izaberite onaj koji po leksičkom poretku dolazi prvi (npr.  $x, y, z$  dolazi prije  $x, z, y$ ). Zatim primijenite uređajno Markovljevo svojstvo te izvedite sve uvjetne nezavisnosti koje su kodirane u ovoj Bayesovoj mreži. **Koje sve uvjetne nezavisnosti vrijede u ovoj Bayesovoj mreži?**

- ☐ A  $w \perp y, z \perp \{x, y\} | w$    ☐ B  $w \perp y, z \perp x, x \perp w | \{z, y\}$    ☐ C  $x \perp y | z, z \perp w | y$    ☐ D  $y \perp w, y \perp x | \{w, z\}$

### Grupiranje (3 pitanja)

- 18 (N) Algoritmom HAC grupiramo riječi engleskog jezika. Neoznačeni skup podataka sastoji se od sljedećih riječi:

$$\mathcal{D} = \{\text{"water"}, \text{"watering"}, \text{"earth"}, \text{"air"}\}$$

Kao mjeru sličnosti između primjera koristimo jezgrenu funkciju nad znakovnim nizovima, definiranu kao  $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$ , gdje su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Npr.,  $\kappa(\text{"water"}, \text{"watering"}) = 5/8 = 0.625$ . Provedite prve dvije iteracije grupiranja algoritmom HAC uz prosječno povezivanje. **Na kojoj se razini sličnosti spajaju grupe u drugoj iteraciji algoritma HAC?**

- ☐ A 0.292   ☐ B 0.478   ☐ C 0.535   ☐ D 0.583

- 19 (P) Za grupiranje skupa primjera  $\mathcal{D}$  koristimo algoritam GMM. Koristimo nekoliko varijanti tog modela:

$\mathcal{H}_1$  : Model sa  $K = 50$  središta inicijaliziranim algoritmom k-sredina

$\mathcal{H}_2$  : Model sa  $K = 50$  središta inicijaliziranim algoritmom k-sredina i dijeljenom kovarijacijskom matricom

$\mathcal{H}_3$  : Model sa  $K = 50$  slučajno inicijaliziranim središtima i dijeljenom kovarijacijskom matricom

$\mathcal{H}_4$  : Model sa  $K = 10$  središta inicijaliziranim algoritmom k-sredina i dijeljenom kovarijacijskom matricom

Sa svakim modelom grupiranje ponavljamo 1000 puta i zatim za svaki model crtamo graf funkcije log-izglednosti kroz iteracije EM-algoritma, uprosječen kroz svih 1000 ponavljanja. Neka je  $LL_\alpha^0$  prosječna log-izglednost za model  $\mathcal{H}_\alpha$  na početku izvođenja EM-algoritma, a neka je  $LL_\alpha^*$  prosječna log-izglednost za taj model na kraju izvođenja EM-algoritma. **Što možemo unaprijed zaključiti o ovim log-izglednostima?**

- ☐ A  $LL_2^0 \geq LL_4^0 \geq LL_3^0, LL_1^* \geq LL_2^*$    ☐ C  $LL_2^0 \geq LL_4^0, LL_1^* \geq LL_2^* \geq LL_3^*$   
☐ B  $LL_2^0 \leq LL_4^0, LL_2^* \leq LL_1^* \geq LL_3^*$    ☐ D  $LL_3^0 \geq LL_4^0, LL_1^* \geq LL_3^* \geq LL_4^*$

- 20 (N) Raspoložemo sljedećim neoznačenim skupom primjera:  $\mathcal{D} = \{(\mathbf{x}^{(i)})\}_i = \{(1, 1), (1, 2), (2, 2), (2, 3), (4, 3)\}$ . Primjere grupiramo algoritmom k-sredina sa  $K = 2$  grupe. Za početna središta odabrali smo primjere  $\mathbf{x}^{(2)} = (1, 2)$  i  $\mathbf{x}^{(5)} = (4, 3)$ . Provedite prvu iteraciju algoritma k-sredina. **Koliko iznosi vrijednost kriterijske funkcije  $J$  nakon ažuriranja centroida?**

- ☐ A 3.00   ☐ B 6.66   ☐ C 4.25   ☐ D 1.85

## Vrednovanje modela (2 pitanja)

**21** (T) Ugniježdene k-struka unakrsna provjera često se koristi za procjenu točnosti modela. Što je prednost ugniježdene k-struke unakrsne provjere u odnosu na običnu unakrsnu provjeru?

- ☐ A Procjenjujemo očekivanu ispitnu pogrešku modela optimalne složenosti
- ☐ B Procjenjujemo ispitnu pogrešku modela s najmanjom pogreškom učenja
- ☐ C Procjenjujemo pogrešku generalizacije, a ne pogrešku učenja
- ☐ D Model ispitujemo na cijelom raspoloživom skupu primjera

**22** (P) Raspoložemo sa 1000 označenih primjera. Na tom skupu treniramo i evaluiramo algoritam SVM. Pritom razmatramo tri hiperparametra: jezgra (linearna ili RBF), regularizacijski faktor  $C$  i preciznost RBF jezgre  $\gamma$ . Posljednja dva hiperparametra optimiramo rešetkastim pretraživanjem u rasponima  $C \in \{2^{-15}, 2^{-14}, \dots, 2^{15}\}$  i  $\gamma \in \{2^{-15}, 2^{-14}, \dots, 2^{15}\}$ . Naravno, ako ne koristimo RBF-jezgru, onda hiperparametar  $\gamma$  ne optimiramo. Za treniranje i evaluaciju modela koristimo ugniježdenu unakrsnu provjeru s 10 ponavljanja u vanjskoj petlji i 5 ponavljanja u unutarnjoj petlji. **Koliko će puta svaki primjer biti iskorišten za treniranje modela?**

- ☐ A 44640    ☐ B 35721    ☐ C 49600    ☐ D 69201





## Pismeni ispit iz Strojnog učenja 1 (ak. god. 2021./2022.)

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 70% bodova na predmetu). Pitanja nose po 1 bod, a 1/3 boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **150 minuta**. Primjerak ispita morate predati zajedno sa svojim rješenjima.

### Osnovni koncepti i linearna regresija (4 pitanja)

- 1** (P) Skup označenih primjera u dvodimenzijaskome ulaznom prostoru je:

$$\mathcal{D} = \{((0, 0), 0), ((0, 1), 0), ((1, 1), 1)\}$$

Koja je veličina prostora inačica,  $|\mathcal{V}_{\mathcal{H}, \mathcal{D}}|$ ?

- ☐ A Pitanje nema smisla jer nije definiran model ☐ B 16 ☐ C 14 ☐ D Beskonačno mnogo

- 2** (T) Optimizacija modela hrbatne regresije ( $L_2$ -regularizirane linearne regresije) ima rješenje u zatvorenoj formi. Neka je  $\lambda$  regularizacijski faktor,  $n$  broj značajki u ulaznom prostoru (bez “dummy” jedinice),  $m$  broj značajki u prostoru značajki (također bez “dummy” jedinice) te  $N$  broj primjera. Glavna komponenta rješenja je izračun inverza matrice izračunate na temelju matrice dizajna  $\Phi$ . **Koliko redaka odnosno stupaca ima matrica koju invertiramo?**

- ☐ A  $m + \lambda$  ☐ B  $N$  ☐ C  $n + \lambda$  ☐ D  $m + 1$

- 3** (P) Koristimo regresiju za predviđanje uspjeha na studiju. Kao značajke možemo koristiti ocjene u četiri razreda srednje škole (značajke  $x_1$ – $x_4$ ), prosjek ocjena sva četiri razreda ( $x_5$ ) te uspjeh iz matematike ( $x_6$ ) i fizike ( $x_7$ ) na državnoj maturi (ukupno 7 značajki). Ne moramo iskoristiti sve značajke, ali ih želimo iskoristiti što više. Za preslikavanje u prostor značajki koristimo preslikavanje s kvadratnim, interakcijskim i linearnim značajkama. Od interakcijskih značajki uzimamo samo interakcije parova značajki (npr.  $x_1x_2$ ) i interakcije trojki (npr.  $x_1x_2x_3$ ) između svih značajki koje koristimo. **Koliko minimalno primjera za učenje trebamo imati, a da bi rješenje bilo stabilno i bez regularizacije?**

- ☐ A 75 ☐ B 38 ☐ C 63 ☐ D 48

- 4** (N) Raspoložemo sljedećim skupom primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((1, 0), 1), ((2, -3), 2), ((3, 5), -1), ((5, 0), -4)\}$$

Na ovom skupu gradijentnim spustom trenirali smo  $L_1$ -regularizirani model linearne regresije sa  $\lambda = 1$ . Dobili smo težine  $\mathbf{w} = (2.12, -0.94, -0.08)$ . **Koliko iznosi  $L_1$ -regularizirana pogreška  $E(\mathbf{w}|\mathcal{D})$ ?**

- ☐ A 2.69 ☐ B 7.10 ☐ C 1.58 ☐ D 0.29

### Linearni klasifikacijski modeli (3 pitanja)

- 5** (T) Neregularizirani model logističke regresije sklon je prenaučivosti. To je pogotovo slučaj ako se model trenira na linearno odvojivim podatcima, čak i onda kada u podatcima nema nikakvoga šuma i kada se ne koristi nikakvo preslikavanje u prostor značajki. **Zbog čega dolazi do prenaučivosti modela neregularizirane logističke regresije na linearno odvojivim skupovima podataka?**

- ☐ A S porastom norme vektora težina gubitak na točnim primjerima teži prema nuli  
☐ B Ispravno klasificirani primjeri koji su vrlo udaljeni od granice nanose malen gubitak  
☐ C Netočno klasificirani primjeri nanose gubitak koji je proporcionalan normi vektora težina  
☐ D Empirijska pogreška logističke regresije smanjuje se s porastom broja primjera

- 6 (P) Treniramo linearni diskriminativni model u dvodimenzijskome prostoru primjera. Skup za učenje čine samo dva primjera,  $(\mathbf{x}_1, y_1) = ((1, 0), +1)$  i  $(\mathbf{x}_2, y_2) = ((0, 1), -1)$ . Na tom skupu treniramo model koji ima induktivnu pristranost takvu da rješenje maksimizira minimalnu udaljenost primjera od hiperravnine. Naučen model ispravno klasificira oba primjera, pri čemu za oba primjera vrijedi  $y \cdot h(\mathbf{x}) = 5$ . **Koliko iznosi težina  $w_2$  tako naučenog modela?**

☐ A 5   ☐ B 1   ☐ C -1   ☐ D -5

- 7 (N) Raspoložemo označenim skupom primjera iz triju klasa ( $K = 3$ ) u trodimenzijskome ulaznom prostoru ( $n = 3$ ). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer  $\mathbf{x} = (-4, 1, -3)$  s oznakom  $y = (0, 1, 0)$ . **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

☐ A 8.00   ☐ B 6.00   ☐ C 4.02   ☐ D 12.02

### Jezgrene i neparametarske metode (4 pitanja)

- 8 (T) Problem maksimalne margine ima svoju geometrijsku interpretaciju: maksimalna margina odgovara simetrali spojnice konveksnih ljusaka primjera iz dviju klasa. **Što je nužan i dovoljan uvjet da klasifikacijski problem bude rješiv SVM-om s tvrdom marginom?**

- ☐ A Najbliži primjeri iz suprotnih klasa moraju biti u vrhovima konveksnih ljusaka  
☐ B Primjeri iz obje klase trebaju činiti konveksne skupove u ulaznom prostoru  
☐ C Svaka spojnica između primjera iz jedne klase treba biti izvan konveksne ljuske druge klase  
☐ D Konveksne ljuske dviju klasa ne smiju se preklapati (trebaju biti disjunktne)

- 9 (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), -1), ((-1, -1), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1))\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa  $C = 1$ . Kod modela s mekom marginom za dualne koeficijente vrijedi  $\alpha_1 = 1$ ,  $\alpha_2 > 0$ ,  $\alpha_3 > 0$ ,  $\alpha_4 > 0$  i  $\alpha_5 = 1$ . Skicirajte tvrdu i meku marginu u ulaznome prostoru. **Koliko je meka margina šira od tvrde margine?**

☐ A  $\frac{3}{5}\sqrt{10}$  puta   ☐ B  $\frac{2}{5}\sqrt{10}$  puta   ☐ C  $\frac{1}{6}\sqrt{2}$  puta   ☐ D  $\frac{4}{5}\sqrt{10}$  puta

- 10 (N) Algoritam k-NN koristimo za višeklasnu klasifikaciju riječi prema jeziku kojemu pripadaju. Skup za učenje sastoji se od sljedećih riječi i oznaka klasa:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{("water", 0), ("voda", 1), ("zrak", 1), ("luft", 2), ("feuer", 2)\}$$

Kao mjeru sličnosti između primjera koristimo jezgredu funkciju nad znakovnim nizovima, definiranu kao  $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$ , gdje su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Npr.,  $\kappa("water", "voda") = 1/8 = 0.125$ . Razmatramo dvije varijante algoritma: 3-NN i težinski k-NN. Kod potonjeg u obzir uzimamo sve primjere, tj.  $k = N$ . Odredite klasifikaciju primjera  $\mathbf{x} = "zemlja"$  pomoću ova dva algoritma. U slučaju jednake sličnosti između dva primjera, kao susjed se uzima onaj koji je u skupu  $\mathcal{D}$  naveden prvi. U slučaju izjednačenja glasova između klasa, prednost se daje klasi s numerički manjom oznakom  $y$ . **U koju će klasu biti klasificiran primjer  $\mathbf{x}$  algoritmom 3-NN, a u koju algoritmom težinski k-NN?**

☐ A  $y = 0$  i  $y = 2$    ☐ B  $y = 1$  i  $y = 1$    ☐ C  $y = 0$  i  $y = 0$    ☐ D  $y = 0$  i  $y = 1$

- 11 (N) Na skupu primjera za učenje iz ulaznog prostora  $n = 4$  trenirali smo SVM s polinomijalnom jezgrenom funkcijom  $\kappa(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^T \mathbf{z} + 1)^3$ . Potporni vektori i njihove oznake su sljedeći:

$$(\mathbf{x}^{(1)}, y^{(1)}) = ((11, 32, 21), -1)$$

$$(\mathbf{x}^{(2)}, y^{(2)}) = ((5, 11, 6), -1)$$

$$(\mathbf{x}^{(3)}, y^{(3)}) = ((6, 12, 6), +1)$$

Lagrangeovi koeficijenti su  $\alpha_1 = 1.063 \cdot 10^{-7}$ ,  $\alpha_2 = 1.022 \cdot 10^{-5}$  i  $\alpha_3 = 1.032 \cdot 10^{-5}$ . **Upotrijebite jezgri trik da biste odredili vrijednost hipoteze  $h(\mathbf{x})$  za primjer  $\mathbf{x} = (5, -15, -1)$ .**

- ☐ A  $-1.486$  ☐ B  $-4.093$  ☐ C  $+5.454$  ☐ D  $-3.553$

## Procjena parametara i Bayesov klasifikator (3 pitanja)

- 12 (P) Gaussov Bayesov klasifikator koristimo za klasifikaciju jednodimenzijskih podataka u tri klase. Procijenjene izglednosti klasa su  $p(x|y=1) = \mathcal{N}(-10, 2)$ ,  $p(x|y=2) = \mathcal{N}(2, 2)$  i  $p(x|y=3) = \mathcal{N}(8, 2)$ , a procijenjene apriorne vjerojatnosti klasa su  $P(y=1) = P(y=2) = 2/5$  i  $P(y=3) = 1/5$ . Međutim, nakon što smo naučili ovaj model, zaključili smo da na ispitnom skupu postoji pomak u distribuciji podataka u odnosu na skup za učenje te da zbog toga model ne generalizira dobro. Zaključili smo da se ovo može ispraviti tako da se naučeni model malo izmijeni, i to tako da se varijanca izglednosti klase  $y=1$  postavi na 1 i da se apriorne vjerojatnosti klasa ujednače,  $P(y=1) = P(y=2) = P(y=3) = 1/3$ . Skicirajte gustoće zajedničke vjerojatnosti naučenog i izmijenjenog modela. Neka su  $h_1$  i  $h_2$  MAP-hipoteze prvog i drugog modela, te neka su  $a$  i  $b$  pozitivne konstante. Razmotrite segment ulaznog prostora za koji vrijedi  $-10 \leq x \leq 10$ . **Na kojim se dijelovima tog segmenta ulaznog prostora MAP-hipoteze prvog i drugog modela razlikuju?**

- ☐ A  $[-4 - a, -4] \cup [5, 5 + b]$  ☐ B  $[-4 - a, -4 + b]$  ☐ C  $[-4 - a, 5 + b]$  ☐ D  $[-4, -4 + a] \cup [5 - b, 5]$

- 13 (T) Nepristranost je jedno od svojstava statističkih procjenitelja. Procjenitelj MLE ne mora nužno biti nepristran, tj. može biti pristran. **Za koji od sljedećih parametara distribucije procjena MLE pristrana?**

- ☐ A Srednja vrijednost Gaussove distribucije  
☐ B Varijanca Bernoullijeve distribucije  
☐ C Srednja vrijednost Bernoullijeve distribucije  
☐ D Kovarijacijska matrica Gaussove distribucije

- 14 (N) Treniramo Bayesov klasifikator za odluku o dobroj destinaciji za Erasmus+ studentski boravak. Skup primjera za učenje, izgrađen na temelju iskustava prijatelja i prijatelja prijatelja, je sljedeći:

$i$	Država	Stipendija	Semestar	Studij	GovoriJezik	$y^{(i)}$
1	Njemačka	da	ljetni	dipl	da	1
2	Poljska	ne	zimski	preddipl	ne	1
3	Italija	da	ljetni	dipl	da	1
4	Njemačka	ne	zimski	preddipl	ne	0
5	Austrija	da	ljetni	dipl	da	1
6	Poljska	ne	zimski	dipl	ne	1
7	Austrija	da	zimski	dipl	ne	1
8	Njemačka	ne	zimski	dipl	ne	0

Očekujemo zavisnost između varijabli *Država* i *Stipendija*, pa koristimo polunavisan Bayesov klasifikator u kojemu su te dvije varijable združene. Procjene izglednosti klasa radimo Laplaceovim MAP-procjeniteljem. Zanima nas klasifikacija za  $\mathbf{x} = (\text{Italija}, \text{ne}, \text{zimski}, \text{dipl}, \text{ne})$ . **Koliko iznosi aposteriorna vjerojatnost  $P(y=1|\mathbf{x})$ ?**

- ☐ A 0.741 ☐ B 0.588 ☐ C 0.488 ☐ D 0.322

## Probabilistički grafički modeli (3 pitanja)

- 15 (P) Razmotrite Bayesovu mrežu koja zajedničku vjerojatnost faktorizira na sljedeći način:

$$P(w, x, y, z) = P(w)P(y)P(x|w, y)P(z|w)$$

Odredite topološki uređaj varijabli. Ako postoji više mogućih topoloških uređaja, izaberite onaj koji po leksičkom poretku dolazi prvi (npr.  $x, y, z$  dolazi prije  $x, z, y$ ). Zatim primijenite uređajno Markovljevo svojstvo te izvedite sve uvjetne nezavisnosti koje su kodirane u ovoj Bayesovoj mreži. **Koje sve uvjetne nezavisnosti vrijede u ovoj Bayesovoj mreži?**

- ☐ A  $y \perp w, y \perp x | \{w, z\}$  ☐ B  $w \perp y, z \perp \{x, y\} | w$  ☐ C  $x \perp y | z, z \perp w | y$  ☐ D  $w \perp y, z \perp x, x \perp w | \{z, y\}$

- 16 (T) Glavna svrha probabilističkih grafičkih modela (PGM) jest provođenje probabilističkih upita. Jedna vrsta upita su MAP-upiti (upiti najvjerojatnijeg objašnjenja). Neka su  $\mathbf{x}_q$ ,  $\mathbf{x}_o$  i  $\mathbf{x}_n$  skupovi varijabli upita, opaženih varijabli odnosno varijabli smetnje. **Kako je definiran rezultat MAP-upita?**

- ☐ A  $\operatorname{argmax}_{\mathbf{x}_q} \sum_{\mathbf{x}_n} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$  ☐ C  $\operatorname{argmax}_{\mathbf{x}_o} \sum_{\mathbf{x}_q} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$   
☐ B  $\operatorname{argmax}_{\mathbf{x}_o} \sum_{\mathbf{x}_n} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$  ☐ D  $\operatorname{argmax}_{\mathbf{x}_q} \sum_{\mathbf{x}_o} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$

- 17 (N) Razmotrite jednostavnu Bayesovu mrežu koja odgovara faktorizaciji  $P(x, y, z) = P(x)P(y)P(z|x, y)$ . Sve varijable su binarne. Vrijedi  $P(x = 1) = 0.2$  i  $P(y = 1) = 0.3$ . Tablica uvjetne vjerojatnosti za čvor  $z$  je sljedeća:

$z$	$x$	$y$	$p(z x, y)$	$z$	$x$	$y$	$p(z x, y)$
0	0	0	0.1	1	0	0	0.9
0	0	1	0.2	1	0	1	0.8
0	1	0	0.5	1	1	0	0.5
0	1	1	0.9	1	1	1	0.1

Postupkom uzorkovanja s odbijanjem uzorkujemo iz aposteriorne distribucije  $P(y|x = 0, z = 1)$ . Uzorkovanje smo ponovili ukupno  $N = 500$  puta. **Koliki je očekivani broj vektora koje ćemo pri uzorkovanju morati odbaciti?**

- ☐ A 180 ☐ B 89 ☐ C 404 ☐ D 152

## Grupiranje (3 pitanja)

- 18 (N) Raspoložemo sljedećim neoznačenim skupom primjera:  $\mathcal{D} = \{(\mathbf{x}^{(i)})\}_i = \{(1, 1), (1, 2), (2, 2), (2, 3), (4, 3)\}$ . Primjere grupiramo algoritmom k-sredina sa  $K = 2$  grupe. Za početna središta odabrali smo primjere  $\mathbf{x}^{(2)} = (1, 2)$  i  $\mathbf{x}^{(5)} = (4, 3)$ . Provedite prvu iteraciju algoritma k-sredina. **Koliko iznosi vrijednost kriterijske funkcije  $J$  nakon ažuriranja centroida?**

- ☐ A 3.00 ☐ B 4.25 ☐ C 6.66 ☐ D 1.85

- 19 (P) Za grupiranje skupa primjera  $\mathcal{D}$  koristimo algoritam GMM. Koristimo nekoliko varijanti tog modela:

- $\mathcal{H}_1$  : Model sa  $K = 50$  središta inicijaliziranim algoritmom k-sredina  
 $\mathcal{H}_2$  : Model sa  $K = 50$  središta inicijaliziranim algoritmom k-sredina i dijeljenom kovarijacijskom matricom  
 $\mathcal{H}_3$  : Model sa  $K = 50$  slučajno inicijaliziranim središtima i dijeljenom kovarijacijskom matricom  
 $\mathcal{H}_4$  : Model sa  $K = 10$  središta inicijaliziranim algoritmom k-sredina i dijeljenom kovarijacijskom matricom

Sa svakim modelom grupiranje ponavljamo 1000 puta i zatim za svaki model crtamo graf funkcije log-izglednosti kroz iteracije EM-algoritma, uprosječen kroz svih 1000 ponavljanja. Neka je  $LL_\alpha^0$  prosječna log-izglednost za model  $\mathcal{H}_\alpha$  na početku izvođenja EM-algoritma, a neka je  $LL_\alpha^*$  prosječna log-izglednost za taj model na kraju izvođenja EM-algoritma. **Što možemo unaprijed zaključiti o ovim log-izglednostima?**

- ☐ A  $LL_2^0 \geq LL_4^0, LL_1^* \geq LL_2^* \geq LL_3^*$  ☐ C  $LL_2^0 \geq LL_4^0 \geq LL_3^0, LL_1^* \geq LL_2^*$   
☐ B  $LL_3^0 \geq LL_4^0, LL_1^* \geq LL_3^* \geq LL_4^*$  ☐ D  $LL_2^0 \leq LL_4^0, LL_2^* \leq LL_1^* \geq LL_3^*$

- 20 (N) Algoritmom HAC grupiramo riječi engleskog jezika. Neoznačeni skup podataka sastoji se od sljedećih riječi:

$$\mathcal{D} = \{\text{"water"}, \text{"waterloo"}, \text{"earth"}, \text{"air"}\}$$

Kao mjeru sličnosti između primjera koristimo jezgrenu funkciju nad znakovnim nizovima, definiranu kao  $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$ , gdje su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Npr.,  $\kappa(\text{"water"}, \text{"waterloo"}) = 5/7 = 0.714$ . Provedite prve dvije iteracije grupiranja algoritmom HAC uz prosječno povezivanje. **Na kojoj se razini sličnosti spajaju grupe u drugoj iteraciji algoritma HAC?**

- ☐ A 0.354    ☐ B 0.292    ☐ C 0.535    ☐ D 0.583

### Vrednovanje modela (2 pitanja)

- 21 (T) Ugniježdjena k-struka unakrsna provjera često se koristi za procjenu točnosti modela. **Što je prednost ugniježdjene k-struke unakrsne provjere u odnosu na običnu unakrsnu provjeru?**

- ☐ A Procjenjujemo ispitnu pogrešku modela s najmanjom pogreškom učenja  
☐ B Model ispitujemo na cijelom raspoloživom skupu primjera  
☐ C Procjenjujemo očekivanu ispitnu pogrešku modela optimalne složenosti  
☐ D Procjenjujemo pogrešku generalizacije, a ne pogrešku učenja

- 22 (P) Raspoložemo sa 1000 označenih primjera. Na tom skupu treniramo i evaluiramo algoritam SVM. Pritom razmatramo tri hiperparametra: jezgra (linearna ili RBF), regularizacijski faktor  $C$  i preciznost RBF jezgre  $\gamma$ . Posljednja dva hiperparametra optimiramo rešetkastim pretraživanjem u rasponima  $C \in \{2^{-15}, 2^{-14}, \dots, 2^{15}\}$  i  $\gamma \in \{2^{-15}, 2^{-14}, \dots, 2^{15}\}$ . Naravno, ako ne koristimo RBF-jezgru, onda hiperparametar  $\gamma$  ne optimiramo. Za treniranje i evaluaciju modela koristimo ugniježdjenu unakrsnu provjeru s 10 ponavljanja u vanjskoj petlji i 5 ponavljanja u unutarnjoj petlji. **Koliko će puta svaki primjer biti iskorišten za treniranje modela?**

- ☐ A 35721    ☐ B 49600    ☐ C 69201    ☐ D 44640



## Pismeni ispit iz Strojnog učenja 1 (ak. god. 2021./2022.)

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 70% bodova na predmetu). Pitanja nose po 1 bod, a 1/3 boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **150 minuta**. Primjerak ispita morate predati zajedno sa svojim rješenjima.

### Osnovni koncepti i linearna regresija (4 pitanja)

- 1** (N) Raspoložemo sljedećim skupom primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((1, 0), 1), ((2, -3), 2), ((3, 5), -1), ((5, 0), -4)\}$$

Na ovom skupu gradijentnim spustom trenirali smo  $L_1$ -regularizirani model linearne regresije sa  $\lambda = 1$ . Dobili smo težine  $\mathbf{w} = (2.12, -0.94, -0.08)$ . **Koliko iznosi  $L_1$ -regularizirana pogreška  $E(\mathbf{w}|\mathcal{D})$ ?**

- ☐ A 1.58   ☐ B 2.69   ☐ C 7.10   ☐ D 0.29

- 2** (T) Optimizacija modela hrbatne regresije ( $L_2$ -regularizirane linearne regresije) ima rješenje u zatvorenoj formi. Neka je  $\lambda$  regularizacijski faktor,  $n$  broj značajki u ulaznom prostoru (bez “dummy” jedinice),  $m$  broj značajki u prostoru značajki (također bez “dummy” jedinice) te  $N$  broj primjera. Glavna komponenta rješenja je izračun inverza matrice izračunate na temelju matrice dizajna  $\Phi$ . **Koliko redaka odnosno stupaca ima matrica koju invertiramo?**

- ☐ A  $n + \lambda$    ☐ B  $m + 1$    ☐ C  $N$    ☐ D  $m + \lambda$

- 3** (P) Koristimo regresiju za predviđanje uspjeha na studiju. Kao značajke možemo koristiti ocjene u četiri razreda srednje škole (značajke  $x_1$ – $x_4$ ), prosjek ocjena sva četiri razreda ( $x_5$ ) te uspjeh iz matematike ( $x_6$ ) i fizike ( $x_7$ ) na državnoj maturi (ukupno 7 značajki). Ne moramo iskoristiti sve značajke, ali ih želimo iskoristiti što više. Za preslikavanje u prostor značajki koristimo preslikavanje s kvadratnim, interakcijskim i linearnim značajkama. Od interakcijskih značajki uzimamo samo interakcije parova značajki (npr.  $x_1x_2$ ) i interakcije trojki (npr.  $x_1x_2x_3$ ) između svih značajki koje koristimo. **Koliko minimalno primjera za učenje trebamo imati, a da bi rješenje bilo stabilno i bez regularizacije?**

- ☐ A 48   ☐ B 38   ☐ C 63   ☐ D 75

- 4** (P) Skup označenih primjera u dvodimenzijaskome ulaznom prostoru je:

$$\mathcal{D} = \{((0, 0), 0), ((0, 1), 0), ((1, 1), 1)\}$$

Koja je veličina prostora inačica,  $|\mathcal{V}_{\mathcal{H}, \mathcal{D}}|$ ?

- ☐ A Beskonačno mnogo   ☐ B Pitanje nema smisla jer nije definiran model   ☐ C 14   ☐ D 16

### Linearni klasifikacijski modeli (3 pitanja)

- 5** (N) Raspoložemo označenim skupom primjera iz triju klasa ( $K = 3$ ) u trodimenzijaskome ulaznom prostoru ( $n = 3$ ). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer  $\mathbf{x} = (-4, -1, -3)$  s oznakom  $\mathbf{y} = (1, 0, 0)$ . **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

- ☐ A 6.00   ☐ B 4.02   ☐ C 8.00   ☐ D 12.02

**6** (P) Treniramo linearni diskriminativni model u dvodimenzijskome prostoru primjera. Skup za učenje čine samo dva primjera,  $(\mathbf{x}_1, y_1) = ((1, 0), +1)$  i  $(\mathbf{x}_2, y_2) = ((0, 1), -1)$ . Na tom skupu treniramo model koji ima induktivnu pristranost takvu da rješenje maksimizira minimalnu udaljenost primjera od hiperravnine. Naučen model ispravno klasificira oba primjera, pri čemu za oba primjera vrijedi  $y \cdot h(\mathbf{x}) = 5$ . **Koliko iznosi težina  $w_2$  tako naučenog modela?**

- ☐ A  $-5$    ☐ B  $1$    ☐ C  $-1$    ☐ D  $5$

**7** (T) Neregularizirani model logističke regresije sklon je prenaučivosti. To je pogotovo slučaj ako se model trenira na linearno odvojivim podatcima, čak i onda kada u podatcima nema nikakvoga šuma i kada se ne koristi nikakvo preslikavanje u prostor značajki. **Zbog čega dolazi do prenaučivosti modela neregularizirane logističke regresije na linearno odvojivim skupovima podataka?**

- ☐ A S porastom norme vektora težina gubitak na točnim primjerima teži prema nuli  
☐ B Empirijska pogreška logističke regresije smanjuje se s porastom broja primjera  
☐ C Netočno klasificirani primjeri nanose gubitak koji je proporcionalan normi vektora težina  
☐ D Ispravno klasificirani primjeri koji su vrlo udaljeni od granice nanose malen gubitak

### Jezgrene i neparametarske metode (4 pitanja)

**8** (N) Na skupu primjera za učenje iz ulaznog prostora  $n = 4$  trenirali smo SVM s polinomijalnom jezgrenom funkcijom  $\kappa(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^T \mathbf{z} + 1)^3$ . Potporni vektori i njihove oznake su sljedeći:

$$(\mathbf{x}^{(1)}, y^{(1)}) = ((11, 32, 21), -1)$$

$$(\mathbf{x}^{(2)}, y^{(2)}) = ((5, 11, 6), -1)$$

$$(\mathbf{x}^{(3)}, y^{(3)}) = ((6, 12, 6), +1)$$

Lagrangeovi koeficijenti su  $\alpha_1 = 1.063 \cdot 10^{-7}$ ,  $\alpha_2 = 1.022 \cdot 10^{-5}$  i  $\alpha_3 = 1.032 \cdot 10^{-5}$ . **Upotrijebite jezgri trik da biste odredili vrijednost hipoteze  $h(\mathbf{x})$  za primjer  $\mathbf{x} = (3, 0, -3)$ .**

- ☐ A  $-2.330$    ☐ B  $+1.434$    ☐ C  $-0.676$    ☐ D  $-3.553$

**9** (N) Algoritam k-NN koristimo za višeklasnu klasifikaciju riječi prema jeziku kojemu pripadaju. Skup za učenje sastoji se od sljedećih riječi i oznaka klasa:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{("water", 0), ("voda", 1), ("zrak", 1), ("luft", 2), ("feuer", 2)\}$$

Kao mjeru sličnosti između primjera koristimo jezgrenu funkciju nad znakovnim nizovima, definiranu kao  $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$ , gdje je su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Npr.,  $\kappa("water", "voda") = 1/8 = 0.125$ . Razmatramo dvije varijante algoritma: 3-NN i težinski k-NN. Kod potonjeg u obzir uzimamo sve primjere, tj.  $k = N$ . Odredite klasifikaciju primjera  $\mathbf{x} = "love"$  pomoću ova dva algoritma. U slučaju jednake sličnosti između dva primjera, kao susjed se uzima onaj koji je u skupu  $\mathcal{D}$  naveden prvi. U slučaju izjednačenja glasova između klasa, prednost se daje klasi s numerički manjom oznakom  $y$ . **U koju će klasu biti klasificiran primjer  $\mathbf{x}$  algoritmom 3-NN, a u koju algoritmom težinski k-NN?**

- ☐ A  $y = 2$  i  $y = 1$    ☐ B  $y = 0$  i  $y = 0$    ☐ C  $y = 0$  i  $y = 2$    ☐ D  $y = 1$  i  $y = 1$

**10** (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), -1), ((-1, -1), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1)\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa  $C = 1$ . Kod modela s mekom marginom za dualne koeficijente vrijedi  $\alpha_1 = 1$ ,  $\alpha_2 > 0$ ,  $\alpha_3 > 0$ ,  $\alpha_4 > 0$  i  $\alpha_5 = 1$ . Skicirajte tvrdi i meki marginu u ulaznome prostoru. **Koliko je meka margina šira od tvrde margine?**

- ☐ A  $\frac{1}{6}\sqrt{2}$  puta   ☐ B  $\frac{3}{5}\sqrt{10}$  puta   ☐ C  $\frac{4}{5}\sqrt{10}$  puta   ☐ D  $\frac{2}{5}\sqrt{10}$  puta



- 11** (T) Problem maksimalne margine ima svoju geometrijsku interpretaciju: maksimalna margina odgovara simetrali spojnice konveksnih ljusaka primjera iz dviju klasa. **Što je nužan i dovoljan uvjet da klasifikacijski problem bude rješiv SVM-om s tvrdom marginom?**
- ☐ A Konveksne ljuske dviju klasa ne smiju se preklapati (trebaju biti disjunktne)
- ☐ B Primjeri iz obje klase trebaju činiti konveksne skupove u ulaznom prostoru
- ☐ C Najbliži primjeri iz suprotnih klasa moraju biti u vrhovima konveksnih ljusaka
- ☐ D Svaka spojnica između primjera iz jedne klase treba biti izvan konveksne ljuske druge klase

### Procjena parametara i Bayesov klasifikator (3 pitanja)

- 12** (P) Gaussov Bayesov klasifikator koristimo za klasifikaciju jednodimenzijskih podataka u tri klase. Procijenjene izglednosti klasa su  $p(x|y=1) = \mathcal{N}(-10, 2)$ ,  $p(x|y=2) = \mathcal{N}(2, 2)$  i  $p(x|y=3) = \mathcal{N}(8, 2)$ , a procijenjene apriorne vjerojatnosti klasa su  $P(y=1) = P(y=2) = 1/5$  i  $P(y=3) = 3/5$ . Međutim, nakon što smo naučili ovaj model, zaključili smo da na ispitnom skupu postoji pomak u distribuciji podataka u odnosu na skup za učenje te da zbog toga model ne generalizira dobro. Zaključili smo da se ovo može ispraviti tako da se naučeni model malo izmijeni, i to tako da se varijanca izglednosti klase  $y=1$  postavi na 5 i da se apriorne vjerojatnosti klasa ujednače,  $P(y=1) = P(y=2) = P(y=3) = 1/3$ . Skicirajte gustoće zajedničke vjerojatnosti naučenog i izmijenjenog modela. Neka su  $h_1$  i  $h_2$  MAP-hipoteze prvog i drugog modela, te neka su  $a$  i  $b$  pozitivne konstante. Razmotrite segment ulaznog prostora za koji vrijedi  $-10 \leq x \leq 10$ . **Na kojim se dijelovima tog segmenta ulaznog prostora MAP-hipoteze prvog i drugog modela razlikuju?**

- ☐ A  $[-4-a, -4+b]$     ☐ B  $[-4-a, 5+b]$     ☐ C  $[-4, -4-a] \cup [5, 5+b]$     ☐ D  $[-4, -4+a] \cup [5-b, 5]$

- 13** (N) Treniramo Bayesov klasifikator za odluku o dobroj destinaciji za Erasmus+ studentski boravak. Skup primjera za učenje, izgrađen na temelju iskustava prijatelja i prijatelja prijatelja, je sljedeći:

$i$	Država	Stipendija	Semestar	Studij	GovoriJezik	$y^{(i)}$
1	Njemačka	da	ljetni	dipl	da	1
2	Poljska	ne	zimski	preddipl	ne	1
3	Italija	da	ljetni	dipl	da	1
4	Njemačka	ne	zimski	preddipl	ne	0
5	Austrija	da	ljetni	dipl	da	1
6	Poljska	ne	zimski	dipl	ne	1
7	Austrija	da	zimski	dipl	ne	1
8	Njemačka	ne	zimski	dipl	ne	0

Očekujemo zavisnost između varijabli *Država* i *Stipendija*, pa koristimo polunaivan Bayesov klasifikator u kojemu su te dvije varijable združene. Procjene izglednosti klasa radimo Laplaceovim MAP-procjeniteljem. Zanima nas klasifikacija za  $\mathbf{x} = (\text{Italija}, \text{ne}, \text{zimski}, \text{dipl}, \text{ne})$ . **Koliko iznosi aposteriorna vjerojatnost  $P(y=1|\mathbf{x})$ ?**

- ☐ A 0.488    ☐ B 0.322    ☐ C 0.588    ☐ D 0.741

- 14** (T) Nepristranost je jedno od svojstava statističkih procjenitelja. Procjenitelj MLE ne mora nužno biti nepristran, tj. može biti pristran. **Za koji od sljedećih parametara distribucije procjena MLE pristrana?**

- ☐ A Varijanca Bernoullijeve distribucije
- ☐ B Srednja vrijednost Gaussove distribucije
- ☐ C Kovarijacijska matrica Gaussove distribucije
- ☐ D Srednja vrijednost Bernoullijeve distribucije

### Probabilistički grafički modeli (3 pitanja)

- 15** (P) Razmotrite Bayesovu mrežu koja zajedničku vjerojatnost faktorizira na sljedeći način:

$$P(w, x, y, z) = P(w)P(y)P(x|w, y)P(z|w)$$

Odredite topološki uređaj varijabli. Ako postoji više mogućih topoloških uređaja, izaberite onaj koji po leksičkom poretu dolazi prvi (npr.  $x, y, z$  dolazi prije  $x, z, y$ ). Zatim primijenite uređajno Markovljevo svojstvo te izvedite sve uvjetne nezavisnosti koje su kodirane u ovoj Bayesovoj mreži. **Koje sve uvjetne nezavisnosti vrijede u ovoj Bayesovoj mreži?**

- ☐ A  $w \perp y, z \perp x, x \perp w | \{z, y\}$     ☐ B  $y \perp w, y \perp x | \{w, z\}$     ☐ C  $w \perp y, z \perp \{x, y\} | w$     ☐ D  $x \perp y | z, z \perp w | y$

- 16** (T) Glavna svrha probabilističkih grafičkih modela (PGM) jest provođenje probabilističkih upita. Jedna vrsta upita su MAP-upiti (upiti najvjerojatnijeg objašnjenja). Neka su  $\mathbf{x}_q$ ,  $\mathbf{x}_o$  i  $\mathbf{x}_n$  skupovi varijabli upita, opaženih varijabli odnosno varijabli smetnje. **Kako je definiran rezultat MAP-upita?**

- ☐ A  $\operatorname{argmax}_{\mathbf{x}_o} \sum_{\mathbf{x}_q} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$     ☐ C  $\operatorname{argmax}_{\mathbf{x}_q} \sum_{\mathbf{x}_n} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$   
☐ B  $\operatorname{argmax}_{\mathbf{x}_q} \sum_{\mathbf{x}_o} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$     ☐ D  $\operatorname{argmax}_{\mathbf{x}_o} \sum_{\mathbf{x}_n} p(\mathbf{x}_q, \mathbf{x}_o, \mathbf{x}_n)$

- 17** (N) Razmotrite jednostavnu Bayesovu mrežu koja odgovara faktorizaciji  $P(x, y, z) = P(x)P(y)P(z|x, y)$ . Sve varijable su binarne. Vrijedi  $P(x = 1) = 0.2$  i  $P(y = 1) = 0.3$ . Tablica uvjetne vjerojatnosti za čvor  $z$  je sljedeća:

$z$	$x$	$y$	$p(z x, y)$	$z$	$x$	$y$	$p(z x, y)$
0	0	0	0.1	1	0	0	0.9
0	0	1	0.2	1	0	1	0.8
0	1	0	0.5	1	1	0	0.5
0	1	1	0.9	1	1	1	0.1

Postupkom uzorkovanja s odbijanjem uzorkujemo iz aposteriorne distribucije  $P(y|x = 0, z = 1)$ . Uzorkovanje smo ponovili ukupno  $N = 500$  puta. **Koliki je očekivani broj vektora koje ćemo pri uzorkovanju morati odbaciti?**

- ☐ A 152    ☐ B 180    ☐ C 89    ☐ D 404

### Grupiranje (3 pitanja)

- 18** (N) Raspoložemo sljedećim neoznačenim skupom primjera:  $\mathcal{D} = \{(\mathbf{x}^{(i)})\}_i = \{(1, 1), (1, 2), (2, 2), (2, 3), (4, 3)\}$ . Primjere grupiramo algoritmom k-sredina sa  $K = 2$  grupe. Za početna središta odabrali smo primjere  $\mathbf{x}^{(2)} = (1, 2)$  i  $\mathbf{x}^{(5)} = (4, 3)$ . Provedite prvu iteraciju algoritma k-sredina. **Koliko iznosi vrijednost kriterijske funkcije  $J$  nakon ažuriranja centroida?**

- ☐ A 1.85    ☐ B 4.25    ☐ C 6.66    ☐ D 3.00

- 19** (P) Za grupiranje skupa primjera  $\mathcal{D}$  koristimo algoritam GMM. Koristimo nekoliko varijanti tog modela:

- $\mathcal{H}_1$  : Model sa  $K = 50$  središta inicijaliziranim algoritmom k-sredina  
 $\mathcal{H}_2$  : Model sa  $K = 50$  središta inicijaliziranim algoritmom k-sredina i dijeljenom kovarijacijskom matricom  
 $\mathcal{H}_3$  : Model sa  $K = 50$  slučajno inicijaliziranim središtima i dijeljenom kovarijacijskom matricom  
 $\mathcal{H}_4$  : Model sa  $K = 10$  središta inicijaliziranim algoritmom k-sredina i dijeljenom kovarijacijskom matricom

Sa svakim modelom grupiranje ponavljamo 1000 puta i zatim za svaki model crtamo graf funkcije log-izglednosti kroz iteracije EM-algoritma, uprosječen kroz svih 1000 ponavljanja. Neka je  $LL_\alpha^0$  prosječna log-izglednost za model  $\mathcal{H}_\alpha$  na početku izvođenja EM-algoritma, a neka je  $LL_\alpha^*$  prosječna log-izglednost za taj model na kraju izvođenja EM-algoritma. **Što možemo unaprijed zaključiti o ovim log-izglednostima?**

- ☐ A  $LL_2^0 \leq LL_4^0, LL_2^* \leq LL_1^* \geq LL_3^*$     ☐ C  $LL_3^0 \geq LL_4^0, LL_1^* \geq LL_3^* \geq LL_4^*$   
☐ B  $LL_2^0 \geq LL_4^0, LL_1^* \geq LL_2^* \geq LL_3^*$     ☐ D  $LL_2^0 \geq LL_4^0 \geq LL_3^0, LL_1^* \geq LL_2^*$

- 20** (N) Algoritmom HAC grupiramo riječi engleskog jezika. Neoznačeni skup podataka sastoji se od sljedećih riječi:

$$\mathcal{D} = \{\text{"water"}, \text{"watering"}, \text{"earth"}, \text{"air"}\}$$

Kao mjeru sličnosti između primjera koristimo jezgrenu funkciju nad znakovnim nizovima, definiranu kao  $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$ , gdje su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Npr.,  $\kappa(\text{"water"}, \text{"watering"}) = 5/8 = 0.625$ . Provedite prve dvije iteracije grupiranja algoritmom HAC uz prosječno povezivanje. **Na kojoj se razini sličnosti spajaju grupe u drugoj iteraciji algoritma HAC?**

- ☐ A 0.535    ☐ B 0.292    ☐ C 0.478    ☐ D 0.583

## Vrednovanje modela (2 pitanja)

**21** (P) Raspoložemo sa 1000 označenih primjera. Na tom skupu treniramo i evaluiramo algoritam SVM. Pritom razmatramo tri hiperparametra: jezgra (linearna ili RBF), regularizacijski faktor  $C$  i preciznost RBF jezgre  $\gamma$ . Posljednja dva hiperparametra optimiramo rešetkastim pretraživanjem u rasponima  $C \in \{2^{-15}, 2^{-14}, \dots, 2^{15}\}$  i  $\gamma \in \{2^{-15}, 2^{-14}, \dots, 2^{15}\}$ . Naravno, ako ne koristimo RBF-jezgru, onda hiperparametar  $\gamma$  ne optimiramo. Za treniranje i evaluaciju modela koristimo ugniježđenu unakrsnu provjeru s 10 ponavljanja u vanjskoj petlji i 5 ponavljanja u unutarnjoj petlji. **Koliko će puta svaki primjer biti iskorišten za treniranje modela?**

- ☐ A 35721    ☐ B 49600    ☐ C 69201    ☐ D 44640

**22** (T) Ugniježđena k-struka unakrsna provjera često se koristi za procjenu točnosti modela. **Što je prednost ugniježđene k-struke unakrsne provjere u odnosu na običnu unakrsnu provjeru?**

- ☐ A Procjenjujemo pogrešku generalizacije, a ne pogrešku učenja  
☐ B Procjenjujemo ispitnu pogrešku modela s najmanjom pogreškom učenja  
☐ C Model ispitujemo na cijelom raspoloživom skupu primjera  
☐ D Procjenjujemo očekivanu ispitnu pogrešku modela optimalne složenosti



		0	0	0	0	0	0	0	0	0	1	1	1	1	1	1	1	1	1	1	2	2	2
		1	2	3	4	5	6	7	8	9	0	1	2	3	4	5	6	7	8	9	0	1	2
		-----+-----																					
Grupa A		B	A	A	B	C	B	D	D	C	A	D	C	B	A	D	C	D	B	D	D	B	A
Grupa B		C	D	D	C	B	A	B	C	D	D	A	A	D	C	A	B	A	D	A	A	C	B
Grupa C		B	C	C	C	D	A	D	B	B	A	C	C	D	A	B	D	A	C	A	B	A	B
Grupa D		A	D	D	B	C	D	D	A	A	A	B	A	C	A	B	B	A	C	C	A	A	B
Grupa E		A	D	D	A	A	D	D	D	A	B	A	A	D	B	B	A	D	A	A	D	C	A
Grupa F		B	B	A	B	A	A	A	D	A	B	A	D	C	C	C	C	A	D	B	A	A	D