

Međuispit iz Strojnog učenja 1 (ak. god. 2022./2023.)

– NEKORIGIRANA VERZIJA –

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 35% bodova na predmetu). Pitanja nose po 1 bod, a 1/3 boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **180 minuta**. Primjerak ispita morate predati zajedno sa svojim rješenjima.

Cjelina 1: Osnovni koncepti i linearna regresija (6 pitanja)

- 1** (P) Jednostavnom regresijom modeliramo ovisnost nezavisne varijable y o zavisnoj varijabli x . Model treniramo postupkom običnih najmanjih kvadrata (OLS) na skupu podataka $\mathcal{D} = \{(x^{(i)}, y^{(i)})\} = \{(0, 0), (2, 0), (3, 2), (5, 2)\}$. Neka je h hipoteza koju dobivamo treniranjem modela te neka je L^i gubitak hipoteze h na primjeru $x^{(i)}$, tj. $L^i = L(y^{(i)}, h(x^{(i)}))$. Što vrijedi za gubitke hipoteze na pojedinim primjerima?

- ☐ A $L^1 = L^3 = 0, L^2 = L^4 < 1$ ☐ C $L^1 = L^2 = 1 < L^3 < L^4$
☐ B $L^1 = L^4 < L^2 = L^3$ ☐ D $L^1 = L^4 = 1, L^2 < L^3$

- 2** (P) Razmatramo klasifikacijski problem u ulaznome prostoru $\mathcal{X} = \mathbb{Z}^2$. Skup označenih primjera je $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((0, 0), 0), ((0, 2), 0), ((0, -1), 0), ((-1, 0), 1), ((0, 1), 1), ((1, 0), 1)\}$. Razmatramo sljedeće modele, parametrizirane sa $\boldsymbol{\theta} \in \mathbb{R}^{n+1}$:

$$\mathcal{H}_1 : h_1(\mathbf{x}; \boldsymbol{\theta}) = \mathbf{1}\{\boldsymbol{\theta}^T \mathbf{x} \geq 0\}$$
$$\mathcal{H}_2 : h_2(\mathbf{x}; \boldsymbol{\theta}) = \mathbf{1}\{(x_1 - \theta_1)^2 + (x_2 - \theta_2)^2 \geq \theta_0^2\}$$

Pored ova dva modela, razmatramo i njihove kombinacije, modele \mathcal{H}_3 i \mathcal{H}_4 . Neka je $\mathcal{H}_3 = \mathcal{H}_1 \cup \mathcal{H}_2$ te neka je \mathcal{H}_4 skup funkcija definiranih kao $h_4(\mathbf{x}; \boldsymbol{\theta}) = h_1(\mathbf{x}) \cdot h_2(\mathbf{x})$. Neka je E_k minimalna empirijska pogreška koja se modelom \mathcal{H}_k može ostvariti na skupu \mathcal{D} , tj. $E_k = \arg\min_{h \in \mathcal{H}_k} E(h|\mathcal{D})$. **Koji odnosi vrijede između minimalnih empirijskih pogrešaka ovih modela?**

- ☐ A $E_1 > E_2 = E_3 > E_4$ ☐ B $E_1 = E_2 = E_3 > E_4$ ☐ C $E_1 > E_2 > E_3 = E_4$ ☐ D $E_1 = E_2 > E_3 = E_4$

- 3** (T) Modeli strojnog učenja općenito su različite složenosti. S porastom složenosti modela raste vjerojatnost da model bude prenaučeni. Ta vjerojatnost raste s količinom šuma u podacima. **Zašto šum u podacima za učenje može dovesti do prenaučeniosti klasifikacijskog modela?**

- ☐ A Povećanjem količine šuma granica između klasa postaje sve nelinearnija, pa raste i složenost modela te dobivena hipoteza očekivano neće odgovarati granici između klasa na ispitnom skupu
- ☐ B Zbog šuma granica između klasa izgleda nelinearnijom nego što ona to zapravo jest, pa primjeri blizu granice znatno više doprinose pogrešci učenja nego primjeri koji su udaljeni od granice
- ☐ C Zbog šuma su oznake nekih primjera u skupu za učenje pogrešne, pa sve hipoteze iz modela imaju na tom skupu pogrešku koja je veća od nula, a još veća na ispitnom skupu
- ☐ D Efekt šuma je slučajna, pa će hipoteza koja se previše prilagodi šumu na skupu za učenje očekivano imati veliku pogrešku na ispitnom skupu gdje je šum drugačiji ili ga nema

- 4** (N) Raspoložemo sljedećim skupom primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((1, 0), 1), ((2, -3), 2), ((3, 5), -1), ((5, 0), -4)\}$$

Na ovom skupu gradijentnim spustom trenirali smo L_1 -regularizirani model linearne regresije sa $\lambda = 1$. Dobili smo težine $\mathbf{w} = (2.12, -0.94, -0.08)$. **Koliko iznosi L_1 -regularizirana pogreška $E(\mathbf{w}|\mathcal{D})$?**

- ☐ A 2.69 ☐ B 1.58 ☐ C 0.29 ☐ D 7.10

5 (T) Multikolinearnost značajki jedan je od problema koji može nastupiti kod primjene modela regresije na stvarnim podacima. Efekt multikolinearnosti i savršene multikolinearnosti dobro je uočljiv kod optimizacijskoga postupka običnih najmanjih kvadrata (OLS) kada se on provodi izračunom pseudoinverza matrice dizajna. Neka je m broj značajki, Φ je matrica dizajna i $\mathbf{G} = \Phi^T \Phi$ je Gramova matrica. **Koji je efekt savršene multikolinearnosti kod postupka OLS?**

- ☐ A Φ ima puni rang, $\text{rang}(\mathbf{G}) > m$ i \mathbf{G} ima inverz, ali s visokim kondicijskim brojem
- ☐ B $\text{rang}(\Phi) < m + 1$, \mathbf{G} nema puni rang i nema inverz, no ima pseudoinverz koji nije numerički stabilan
- ☐ C $\text{rang}(\Phi) = N$, no $\text{rang}(\mathbf{G}) < N$, pa \mathbf{G} ima pseudoinverz, ali nema numerički stabilan inverz
- ☐ D Φ nema puni rang, $\text{rang}(\mathbf{G}) < m + 1$ i \mathbf{G} nema pseudoinverz

6 (P) Raspoložemo modelom \mathcal{H}_α koji ima hiperparametar α kojim se može ugađati složenost modela. Isprobavamo dvije vrijednosti hiperparametra: α_1 i α_2 . Treniramo modele \mathcal{H}_{α_1} i \mathcal{H}_{α_2} te dobivamo hipoteze h_{α_1} i h_{α_2} . Zatim računamo empirijske pogreške tih hipoteza na skupu za učenje \mathcal{D}_u i na skupu za ispitivanje \mathcal{D}_i . Utvrđujemo da vrijedi:

$$E(h_{\alpha_1}|\mathcal{D}_i) - E(h_{\alpha_1}|\mathcal{D}_u) < E(h_{\alpha_2}|\mathcal{D}_i) - E(h_{\alpha_2}|\mathcal{D}_u)$$

Što iz toga možemo zaključiti?

- ☐ A Model \mathcal{H}_{α_1} je podnaučen
- ☐ B Model \mathcal{H}_{α_1} je manje složenosti od modela \mathcal{H}_{α_2}
- ☐ C Optimalan model je onaj s hiperparametrom iz intervala $[\alpha_1, \alpha_2]$
- ☐ D Model \mathcal{H}_{α_2} je prenaučan

Cjelina 2: Linearni klasifikacijski modeli (8 pitanja)

7 (P) Skup za učenje čine sljedeći označeni primjeri:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((-2, 3), 0), ((-1, 2), 0), ((0, 1), 0), ((0, 0), 0), ((1, 1), 0), ((1, -1), 1), ((2, 0), 1)\}$$

Na skupu \mathcal{D} treniramo logističku regresiju (LR) i stroj potpornih vektora s tvrdom marginom (SVM). Dodatno, treniramo model linearne regresije (LINR), gdje izlaz tog modela koristimo za klasifikaciju, tj. $h(\mathbf{x}) = \mathbf{1}\{\mathbf{w}^T \mathbf{x} \geq 0\}$. Za modele SVM i LINR umjesto oznake $y = 0$ koristimo oznaku $y = -1$. Za treniranje modela LR koristimo dovoljan broj iteracija tako da možemo pretpostaviti da je dobivena pogreška unakrsne entropije praktički jednaka nuli. Razmotrite primjer $\mathbf{x}^{(7)} = (2, 0)$. Neka je $d(m)$ udaljenost primjera $\mathbf{x}^{(7)}$ od granice između klasa dobivene modelom m . **Što od navedenog vrijedi za tu udaljenost?**

- ☐ A $d(\text{SVM}) < d(\text{LINR}) < d(\text{LR})$ ☐ C $d(\text{SVM}) < d(\text{LR}) < d(\text{LINR})$
- ☐ B $d(\text{LR}) < d(\text{SVM}) < d(\text{LINR})$ ☐ D $d(\text{LINR}) < d(\text{LR}) < d(\text{SVM})$

8 (N) Na skupu označenih primjera \mathcal{D} trenirali smo model logističke regresije. Dobili smo neki vektor težina \mathbf{w} i pomak $w_0 = 3.15$. Tako naučenom modelu neki primjer \mathbf{x} , čija je oznaka u skupu primjera $y = 0$, nanosi gubitak unakrsne entropije od $L(0, h(\mathbf{x})) = 0.5$. **Koliki gubitak unakrsne entropije bi nanosio primjer \mathbf{x} kada bismo njegove značajke pomnožili sa dva i promijenili mu oznaku?**

- ☐ A 2.54 ☐ B 7.11 ☐ C 4.03 ☐ D 1.19

9 (N) Raspoložemo označenim skupom primjera iz triju klasa ($K = 3$) u trodimenzijskome ulaznom prostoru ($n = 3$). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer $\mathbf{x} = (-4, -1, -3)$ s oznakom $\mathbf{y} = (1, 0, 0)$. **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

- ☐ A 12.02 ☐ B 4.02 ☐ C 8.00 ☐ D 6.00

- 10 (N) Raspoložemo sljedećim skupom za učenje u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((-1, 4), +1), ((2, -3), -1), ((2, 5), -1)\}$$

Na ovom skupu treniramo perceptron. Pritom koristimo funkciju preslikavanja u šesterodimenzijaski prostor značajki, definiranu na sljedeći način:

$$\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2, x_1^2, x_2^2)$$

Početne težine perceptrona neka su $\mathbf{w} = (1, 0, -1, 2, 3, 2)$. **Koliko iznosi empirijska pogreška perceptrona na skupu za učenje prije početka treniranja (dakle, s početnim težinama)?**

- ☐ A 18 ☐ B 100 ☐ C 96 ☐ D 40

- 11 (N) Model logističke regresije treniramo stohastičkim gradijentnim spustom. Primjere iz dvodimenzijaskog ulaznog prostora preslikali smo u prostor značajki funkcijom $\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2)$. U jednoj iteraciji treniranja modela vektor parametara jednak je $\mathbf{w} = (0.1, 0.5, -2, -0.5)$. **Koliko u toj iteraciji iznosi L_2 -norma gradijenta gubitka za primjer $(\mathbf{x}, y) = ((1, -1), 1)$?**

- ☐ A 0.50 ☐ B 0.09 ☐ C 1.42 ☐ D 0.22

- 12 (T) Višeklasni problem može se riješiti binarnim klasifikatorom uz primjenu sheme OVO ili sheme OVR. Obje sheme imaju svoje prednosti i nedostatke. Pretpostavite da raspoložemo sa K klasa i da svaka klasa ima N/K primjera, gdje je N ukupan broj primjera u skupu za učenje. **Što su prednosti odnosno nedostaci OVO i OVR sheme u takvom slučaju?**

- ☐ A OVO iziskuje $(K - 1)/2$ puta više parametara nego OVR, ali svaki OVR klasifikator ima $K - 1$ puta manje pozitivnih primjera nego negativnih
- ☐ B OVR iziskuje $K - 1$ puta više klasifikatora od sheme OVO, ali kod OVO pozitivne klase imaju $K - 1$ puta manje primjera nego kod OVR
- ☐ C OVO svaki klasifikator trenira s $K/2$ puta manje primjera nego OVR, ali pozitivne klase kod OVR imaju K puta manje primjera nego kod OVO
- ☐ D OVR treba K puta više klasifikatora nego OVO, ali su kod OVO pozitivne klase $K/2$ puta manje zastupljene nego OVR

- 13 (P) Na primjerima iz dvodimenzijaskoga ulaznog prostora treniramo L_2 -regulariziranu logističku regresiju. Neka su $\mathbf{w}_0 = (1, -4, 4)$, $\mathbf{w}_1 = (1, -4, 6)$, $\mathbf{w}_2 = (1, -1, 7)$, $\mathbf{w}_3 = (1, -7, 1)$ i $\mathbf{w}_4 = (1, -7, -3)$ vektori u prostoru parametara. Neka je $E(\mathbf{w}|\mathcal{D})$ neregularizirana pogreška unakrsne entropije na skupu za učenje \mathcal{D} . Pritom je \mathbf{w}_0 minimizator funkcije $E(\mathbf{w}|\mathcal{D})$ te vrijedi $E(\mathbf{w}_1|\mathcal{D}) = E(\mathbf{w}_2|\mathcal{D}) = E(\mathbf{w}_3|\mathcal{D})$. Napravite skicu izokontura funkcije pogreške u potprostoru $w_1 \times w_2$. Za treniranje modela koristimo gradijentni spust s linijskim pretraživanjem uz regularizacijski faktor $\lambda = 100$. Za tako naučen model vrijednost regularizacijskog izraza $\frac{\lambda}{2}\|\mathbf{w}\|^2$ jednaka je 400. Međutim, broj koraka gradijentnog spusta (broj poziva linijskog pretraživanja) ovisi o tome koliko će spust krivudati, a to ovisi o odabiru inicijalnih parametara. Kao moguće inicijalne parametre razmotrite vektore \mathbf{w}_1 – \mathbf{w}_4 . **S kojim inicijalnim parametarima će algoritam gradijentnog spusta konvergirati u najmanjem broju koraka?**

- ☐ A \mathbf{w}_1 ☐ B \mathbf{w}_3 ☐ C \mathbf{w}_4 ☐ D \mathbf{w}_2

- 14 (T) Za optimizaciju parametara poopćenih linearnih modela može se koristiti stohastički gradijentni spust, odnosno pravilo LMS. Neka je (\mathbf{x}, y) označeni primjer za koji radimo ažuriranje težina pomoću pravila LMS. **Što možemo reći o razlici između novih (ažuriranih) i starih težina (težina prije ažuriranja)?**

- ☐ A Razlika je to manja što je vektor $\phi(\mathbf{x})$ bliži ishodištu
- ☐ B Razlika je to veća što je stopa učenja η bliža jedinici
- ☐ C Razlika je to manja što je oznaka y bliže jedinici
- ☐ D Razlika je to veća što je izlaz modela $h(\mathbf{x})$ bliži nuli

Cjelina 3: SVM, jezgrene i neparametarske metode (8 pitanja)

- 15** (N) Rješavamo problem određivanja podrijetla pojedinih riječi u jeziku: za svaku riječ trebamo odrediti je li engleskog ($y = 1$) ili francuskog ($y = 0$) podrijetla. Problem rješavamo logističkom regresijom izvedenom kao rijetki jezgreni stroj, gdje za bazne funkcije koristimo jezgru κ nad znakovnim nizovima. Funkcija κ definirana je kao $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$, gdje su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Na primjer, $\kappa(\text{water}, \text{eau}) = 2/6 = 0.33$. Skup za učenje je sljedeći:

$$\mathcal{D} = \{(\mathbf{x}, y)\}_i = \{(\text{water}, 1), (\text{eau}, 0), (\text{dog}, 1), (\text{chien}, 0), (\text{paperclip}, 1), (\text{trombone}, 0), (\text{chance}, 1), (\text{hasard}, 0)\}$$

Treniranjem rijetkoga jezgrenog stroja dobili smo vektor težina $\mathbf{w} = (-0.5, 0, 0, -3.5, 0, -1, 0, 0, 1)$. Razmotrite primjer $(\mathbf{x}, y) = (\text{nounours}, 0)$. **Koliko iznosi gubitak modela na primjeru (\mathbf{x}, y) ?**

- ☐ A 0.359 ☐ B 0.552 ☐ C 0.456 ☐ D 0.795

- 16** (N) Treniramo SVM s Gaussovom jezgrenom funkcijom. Model treniramo na skupu od $N = 5$ označenih primjera. Vektor oznaka je $\mathbf{y} = (+1, +1, -1, -1, +1)$. Euklidske udaljenosti između primjera dane su sljedećom matricom udaljenosti:

$$\mathbf{D} = \begin{pmatrix} 0.0 & 7.48 & 6.16 & 13.42 & 12.21 \\ 7.48 & 0.0 & 12.73 & 20.1 & 14.18 \\ 6.16 & 12.73 & 0.0 & 10.49 & 9.95 \\ 13.42 & 20.1 & 10.49 & 0.0 & 20.02 \\ 12.21 & 14.18 & 9.95 & 20.02 & 0.0 \end{pmatrix}$$

Treniranjem uz $C = 10$ i $\gamma = 0.0001$ za vektor dualnih parametara dobili smo $\boldsymbol{\alpha} = (10, 1.052, 10, 10, 8.948)$. **Koliko iznosi gubitak zglobnice ovako naučenog modela SVM za treći primjer, $L(y^{(3)}, h(\mathbf{x}^{(3)}))$?**

- ☐ A 1.64 ☐ B 1.18 ☐ C 0.03 ☐ D 0.24

- 17** (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((0, 0), -1), ((-2, -2), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1))\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa $C = 1$. Kod modela s mekom marginom za dualne koeficijente vrijedi $\alpha_1 = 1$, $\alpha_2 > 0$, $\alpha_3 > 0$, $\alpha_4 > 0$ i $\alpha_5 = 1$. Skicirajte tvrdu i meku marginu u ulaznome prostoru. **Koliko je meka margina veća od tvrde margine?**

- ☐ A $\frac{4}{5}\sqrt{10}$ puta ☐ B $\frac{1}{6}\sqrt{2}$ puta ☐ C $\frac{3}{5}\sqrt{10}$ puta ☐ D $\frac{2}{5}\sqrt{10}$ puta

- 18** (P) Neka je $\mathcal{H}_{C,\gamma}$ model SVM-a s Gaussovom jezgrom. Hiperparametri tog modela su regularizacijski faktor C i preciznost jezgre γ . Odabir modela provodimo unakrsnom provjerom i to pretraživanjem po rešetci za sljedeće vrijednosti hiperparametara:

$$C = \{2^{-5}, 2^{-4}, \dots, 2^4, 2^5\}$$

$$\gamma = \{10^{-5}, 10^{-4}, \dots, 10^4, 10^5\}$$

Već ranije smo utvrdili da je model sa $C = 2^{-2}$ i $\gamma = 10^{-1}$ podnaučen, a da je model sa $C = 2^1$ i $\gamma = 10^1$ prenaučeni. Za sve ostale modele ne znamo jesu li prenaučeni, podnaučeni ili optimalni. **Koliko modela još ima smisla ispitati jer su moguće optimalni?**

- ☐ A 10 ☐ B 25 ☐ C 96 ☐ D 76

- 19** (P) Na 900 primjera sa 50 značajki treniramo rijetki jezgreni stroj s Gausovim jezgrama. Sve Gaussove jezgre imaju istu varijancu. Nakon treniranja, dobivamo model koji ima 52 prototipa. **Koliko parametara moramo optimirati te koliko parametara ima naučeni model?**

- ☐ A Optimiramo 901 parametar, a naučeni model ima 3501 parametar
☐ B Optimiramo 51 parametar, a naučeni model ima 2653 parametara
☐ C Optimiramo 51 parametar, a naučeni model ima 2600 parametara
☐ D Optimiramo 901 parametar, a naučeni model ima 2653 parametara

- 20 (T) Optimizacijski problem algoritma SVM može se postaviti u formulaciji meke ili tvrde margine te u primarnoj ili dualnoj formulaciji. Ovisno o formulaciji, kvadratni program sadrži različit broj varijabli po kojima optimiramo (optimizacijske varijable). **Ako matrica dizajna ima više redaka nego stupaca, koja formulacija ima najmanje optimizacijskih varijabli?**
- ☐ A Dualni problem tvrde margine ☐ C Primarni problem tvrde margine
☐ B Primarni problem meke margine ☐ D Dualni problem meke margine
- 21 (T) Algoritmi strojnog učenja mogu biti parametarski ili neparametarski. **Što je karakteristika neparametarskih algoritama strojnog učenja?**
- ☐ A Broj parametara ovisi o broju primjera
☐ B Složenost modela raste s normom vektora parametara
☐ C Pretpostavljaju teorijsku distribuciju podataka
☐ D Hiperparametri nemaju utjecaja na složenost modela
- 22 (N) U ulaznome prostoru dimenzije $n = 3$ trenirali smo model SVM-a s linearnom jezgrom. Potporne vektore naučenog modela čine označeni primjeri $((2, -5, 15), -1)$, $((1, 8, -305), -1)$ i $((1, -6, 225), +1)$, a njima odgovarajući dualni koeficijenti su $\alpha_1 = 0.5$, $\alpha_2 = 0.8$ i $\alpha_3 = 0.9$. Treniranje smo proveli na skaliranim značajkama: svaku smo značajku x_j standardizirali primjenom transformacije $\frac{x_j - \mu_j}{\sigma_j}$, gdje su μ_j i σ_j srednja vrijednost odnosno varijanca značajke x_j u skupu označenih podataka \mathcal{D} . Parametri skaliranja su $\boldsymbol{\mu} = (15, -2, 100)$ i $\boldsymbol{\sigma} = (4, 1, 12)$. Model SVM-a koristimo za predikciju klase primjera $\mathbf{x} = (1, 2, -30)$. **Koliko će se promijeniti izlaz modela ako kod predikcije propustimo skalirati značajke primjera \mathbf{x} ?**
- ☐ A +907.43 ☐ B +541.53 ☐ C -739.13 ☐ D -373.22

Međuispit iz Strojnog učenja 1 (ak. god. 2022./2023.) – NEKORIGIRANA VERZIJA –

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 35% bodova na predmetu). Pitanja nose po 1 bod, a 1/3 boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **180 minuta**. Primjerak ispita morate predati zajedno sa svojim rješenjima.

Cjelina 1: Osnovni koncepti i linearna regresija (6 pitanja)

- 1** (T) Modeli strojnog učenja općenito su različite složenosti. S porastom složenosti modela raste vjerojatnost da model bude prenaučan. Ta vjerojatnost raste s količinom šuma u podacima. **Zašto šum u podacima za učenje može dovesti do prenaučnosti klasifikacijskog modela?**
- ☐ A Zbog šuma granica između klasa izgleda nelinearnijom nego što ona to zapravo jest, pa primjeri blizu granice znatno više doprinose pogrešci učenja nego primjeri koji su udaljeni od granice
- ☐ B Povećanjem količine šuma granica između klasa postaje sve nelinearnija, pa raste i složenost modela te dobivena hipoteza očekivano neće odgovarati granici između klasa na ispitnom skupu
- ☐ C Efekt šuma je slučajna, pa će hipoteza koja se previše prilagodi šumu na skupu za učenje očekivano imati veliku pogrešku na ispitnom skupu gdje je šum drugačiji ili ga nema
- ☐ D Zbog šuma su oznake nekih primjera u skupu za učenje pogrešne, pa sve hipoteze iz modela imaju na tom skupu pogrešku koja je veća od nula, a još veća na ispitnom skupu
- 2** (P) Jednostavnom regresijom modeliramo ovisnost nezavisne varijable y o zavisnoj varijabli x . Model treniramo postupkom običnih najmanjih kvadrata (OLS) na skupu podataka $\mathcal{D} = \{(x^{(i)}, y^{(i)})\} = \{(0, 0), (2, 0), (3, 2), (5, 2)\}$. Neka je h hipoteza koju dobivamo treniranjem modela te neka je L^i gubitak hipoteze h na primjeru $x^{(i)}$, tj. $L^i = L(y^{(i)}, h(x^{(i)}))$. **Što vrijedi za gubitke hipoteze na pojedinim primjerima?**
- ☐ A $L^1 = L^4 = 1, L^2 < L^3$ ☐ C $L^1 = L^2 = 1 < L^3 < L^4$
- ☐ B $L^1 = L^4 < L^2 = L^3$ ☐ D $L^1 = L^3 = 0, L^2 = L^4 < 1$
- 3** (T) Multikolinearnost značajki jedan je od problema koji može nastupiti kod primjene modela regresije na stvarnim podacima. Efekt multikolinearnosti i savršene multikolinearnosti dobro je uočljiv kod optimizacijskoga postupka običnih najmanjih kvadrata (OLS) kada se on provodi izračunom pseudoinverza matrice dizajna. Neka je m broj značajki, Φ je matrica dizajna i $\mathbf{G} = \Phi^T \Phi$ je Gramova matrica. **Koji je efekt savršene multikolinearnosti kod postupka OLS?**
- ☐ A Φ ima puni rang, $\text{rang}(\mathbf{G}) > m$ i \mathbf{G} ima inverz, ali s visokim kondicijskim brojem
- ☐ B Φ nema puni rang, $\text{rang}(\mathbf{G}) < m + 1$ i \mathbf{G} nema pseudoinverz
- ☐ C $\text{rang}(\Phi) = N$, no $\text{rang}(\mathbf{G}) < N$, pa \mathbf{G} ima pseudoinverz, ali nema numerički stabilan inverz
- ☐ D $\text{rang}(\Phi) < m + 1$, \mathbf{G} nema puni rang i nema inverz, no ima pseudoinverz koji nije numerički stabilan
- 4** (P) Razmatramo klasifikacijski problem u ulaznome prostoru $\mathcal{X} = \mathbb{Z}^2$. Skup označenih primjera je $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((0, 0), 0), ((0, 2), 0), ((0, -1), 0), ((-1, 0), 1), ((0, 1), 1), ((1, 0), 1)\}$. Razmatramo sljedeće modele, parametrizirane sa $\boldsymbol{\theta} \in \mathbb{R}^{n+1}$:

$$\mathcal{H}_1 : h_1(\mathbf{x}; \boldsymbol{\theta}) = \mathbf{1}\{\boldsymbol{\theta}^T \mathbf{x} \geq 0\}$$

$$\mathcal{H}_2 : h_2(\mathbf{x}; \boldsymbol{\theta}) = \mathbf{1}\{(x_1 - \theta_1)^2 + (x_2 - \theta_2)^2 \geq \theta_0^2\}$$

Pored ova dva modela, razmatramo i njihove kombinacije, modele \mathcal{H}_3 i \mathcal{H}_4 . Neka je $\mathcal{H}_3 = \mathcal{H}_1 \cup \mathcal{H}_2$ te neka je \mathcal{H}_4 skup funkcija definiranih kao $h_4(\mathbf{x}; \boldsymbol{\theta}) = h_1(\mathbf{x}) \cdot h_2(\mathbf{x})$. Neka je E_k minimalna empirijska pogreška koja se modelom \mathcal{H}_k može ostvariti na skupu \mathcal{D} , tj. $E_k = \arg\min_{h \in \mathcal{H}_k} E(h|\mathcal{D})$. **Koji odnosi vrijede između minimalnih empirijskih pogrešaka ovih modela?**

- ☐ A $E_1 = E_2 > E_3 = E_4$ ☐ B $E_1 > E_2 > E_3 = E_4$ ☐ C $E_1 > E_2 = E_3 > E_4$ ☐ D $E_1 = E_2 = E_3 > E_4$

- 5 (P) Raspoložemo modelom \mathcal{H}_α koji ima hiperparametar α kojim se može ugađati složenost modela. Isprobavamo dvije vrijednosti hiperparametra: α_1 i α_2 . Treniramo modele \mathcal{H}_{α_1} i \mathcal{H}_{α_2} te dobivamo hipoteze h_{α_1} i h_{α_2} . Zatim računamo empirijske pogreške tih hipoteza na skupu za učenje \mathcal{D}_u i na skupu za ispitivanje \mathcal{D}_i . Utvrđujemo da vrijedi:

$$E(h_{\alpha_1}|\mathcal{D}_i) - E(h_{\alpha_1}|\mathcal{D}_u) < E(h_{\alpha_2}|\mathcal{D}_i) - E(h_{\alpha_2}|\mathcal{D}_u)$$

Što iz toga možemo zaključiti?

- ☐ A Model \mathcal{H}_{α_1} je podnaučen
- ☐ B Optimalan model je onaj s hiperparametrom iz intervala $[\alpha_1, \alpha_2]$
- ☐ C Model \mathcal{H}_{α_1} je manje složenosti od modela \mathcal{H}_{α_2}
- ☐ D Model \mathcal{H}_{α_2} je prenaučan
- 6 (N) Raspoložemo sljedećim skupom primjera u dvodimenzijskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((1, 0), 1), ((2, -3), 2), ((3, 5), -1), ((5, 0), -4)\}$$

Na ovom skupu gradijentnim spustom trenirali smo L_1 -regularizirani model linearne regresije sa $\lambda = 1$. Dobili smo težine $\mathbf{w} = (2.12, -0.94, -0.08)$. **Koliko iznosi L_1 -regularizirana pogreška $E(\mathbf{w}|\mathcal{D})$?**

- ☐ A 0.29 ☐ B 7.10 ☐ C 1.58 ☐ D 2.69

Cjelina 2: Linearni klasifikacijski modeli (8 pitanja)

- 7 (P) Na primjerima iz dvodimenzijskoga ulaznog prostora treniramo L_2 -regulariziranu logističku regresiju. Neka su $\mathbf{w}_0 = (1, -4, 4)$, $\mathbf{w}_1 = (1, -4, 6)$, $\mathbf{w}_2 = (1, -1, 7)$, $\mathbf{w}_3 = (1, -7, 1)$ i $\mathbf{w}_4 = (1, -7, -3)$ vektori u prostoru parametara. Neka je $E(\mathbf{w}|\mathcal{D})$ neregularizirana pogreška unakrsne entropije na skupu za učenje \mathcal{D} . Pritom je \mathbf{w}_0 minimizator funkcije $E(\mathbf{w}|\mathcal{D})$ te vrijedi $E(\mathbf{w}_1|\mathcal{D}) = E(\mathbf{w}_2|\mathcal{D}) = E(\mathbf{w}_3|\mathcal{D})$. Napravite skicu izokontura funkcije pogreške u potprostoru $w_1 \times w_2$. Za treniranje modela koristimo gradijentni spust s linijskim pretraživanjem uz regularizacijski faktor $\lambda = 100$. Za tako naučen model vrijednost regularizacijskog izraza $\frac{\lambda}{2}\|\mathbf{w}\|^2$ jednaka je 400. Međutim, broj koraka gradijentnog spusta (broj poziva linijskog pretraživanja) ovisi o tome koliko će spust krivudati, a to ovisi o odabiru inicijalnih parametara. Kao moguće inicijalne parametre razmotrite vektore \mathbf{w}_1 – \mathbf{w}_4 . **S kojim inicijalnim parametarima će algoritam gradijentnog spusta konvergirati u najmanjem broju koraka?**

- ☐ A \mathbf{w}_2 ☐ B \mathbf{w}_3 ☐ C \mathbf{w}_1 ☐ D \mathbf{w}_4

- 8 (N) Raspoložemo označenim skupom primjera iz triju klasa ($K = 3$) u trodimenzijskome ulaznom prostoru ($n = 3$). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer $\mathbf{x} = (-4, 1, -3)$ s oznakom $\mathbf{y} = (0, 1, 0)$. **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

- ☐ A 4.02 ☐ B 6.00 ☐ C 8.00 ☐ D 12.02

- 9 (N) Na skupu označenih primjera \mathcal{D} trenirali smo model logističke regresije. Dobili smo neki vektor težina \mathbf{w} i pomak $w_0 = 0.15$. Tako naučenom modelu neki primjer \mathbf{x} , čija je oznaka u skupu primjera $y = 0$, nanosi gubitak unakrsne entropije od $L(0, h(\mathbf{x})) = 0.274$. **Koliki gubitak unakrsne entropije bi nanosio primjer \mathbf{x} kada bismo njegove značajke pomnožili sa dva i promijenili mu oznaku?**

- ☐ A 1.19 ☐ B 2.54 ☐ C 7.11 ☐ D 4.03

- 10 (N) Model logističke regresije treniramo stohastičkim gradijentnim spustom. Primjere iz dvodimenzijanskog ulaznog prostora preslikali smo u prostor značajki funkcijom $\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2)$. U jednoj iteraciji treniranja modela vektor parametara jednak je $\mathbf{w} = (0.1, 0.5, -2, 0.5)$. **Koliko u toj iteraciji iznosi L_2 -norma gradijenta gubitka za primjer $(\mathbf{x}, y) = ((1, -1), 1)$?**

☐ A 0.09 ☐ B 0.22 ☐ C 1.42 ☐ D 0.50

- 11 (N) Raspolažemo sljedećim skupom za učenje u dvodimenzijanskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((-1, 4), +1), ((2, -3), -1), ((2, 5), -1)\}$$

Na ovom skupu treniramo perceptron. Pritom koristimo funkciju preslikavanja u šesterodimenzijanski prostor značajki, definiranu na sljedeći način:

$$\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2, x_1^2, x_2^2)$$

Početne težine perceptrona neka su $\mathbf{w} = (1, 0, -1, 2, 3, 0)$. **Koliko iznosi empirijska pogreška perceptrona na skupu za učenje prije početka treniranja (dakle, s početnim težinama)?**

☐ A 100 ☐ B 18 ☐ C 96 ☐ D 40

- 12 (P) Skup za učenje čine sljedeći označeni primjeri:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((-2, 3), 0), ((-1, 2), 0), ((0, 1), 0), ((0, 0), 0), ((1, 1), 0), ((1, -1), 1), ((2, 0), 1)\}$$

Na skupu \mathcal{D} treniramo logističku regresiju (LR) i stroj potpornih vektora s tvrdom marginom (SVM). Dodatno, treniramo model linearne regresije (LINR), gdje izlaz tog modela koristimo za klasifikaciju, tj. $h(\mathbf{x}) = \mathbf{1}\{\mathbf{w}^T \mathbf{x} \geq 0\}$. Za modele SVM i LINR umjesto oznake $y = 0$ koristimo oznaku $y = -1$. Za treniranje modela LR koristimo dovoljan broj iteracija tako da možemo pretpostaviti da je dobivena pogreška unakrsne entropije praktički jednaka nuli. Razmotrite primjer $\mathbf{x}^{(7)} = (2, 0)$. Neka je $d(m)$ udaljenost primjera $\mathbf{x}^{(7)}$ od granice između klasa dobivene modelom m . **Što od navedenog vrijedi za tu udaljenost?**

☐ A $d(\text{LR}) < d(\text{SVM}) < d(\text{LINR})$ ☐ C $d(\text{LINR}) < d(\text{LR}) < d(\text{SVM})$
☐ B $d(\text{SVM}) < d(\text{LR}) < d(\text{LINR})$ ☐ D $d(\text{SVM}) < d(\text{LINR}) < d(\text{LR})$

- 13 (T) Za optimizaciju parametara poopćenih linearnih modela može se koristiti stohastički gradijentni spust, odnosno pravilo LMS. Neka je (\mathbf{x}, y) označeni primjer za koji radimo ažuriranje težina pomoću pravila LMS. **Što možemo reći o razlici između novih (ažuriranih) i starih težina (težina prije ažuriranja)?**

☐ A Razlika je to manja što je vektor $\phi(\mathbf{x})$ bliži ishodištu
☐ B Razlika je to veća što je izlaz modela $h(\mathbf{x})$ bliži nuli
☐ C Razlika je to veća što je stopa učenja η bliža jedinici
☐ D Razlika je to manja što je oznaka y bliže jedinici

- 14 (T) Višeklasni problem može se riješiti binarnim klasifikatorom uz primjenu sheme OVO ili sheme OVR. Obje sheme imaju svoje prednosti i nedostatke. Pretpostavite da raspolažemo sa K klasa i da svaka klasa ima N/K primjera, gdje je N ukupan broj primjera u skupu za učenje. **Što su prednosti odnosno nedostatci OVO i OVR sheme u takvom slučaju?**

☐ A OVR treba K puta više klasifikatora nego OVO, ali su kod OVO pozitivne klase $K/2$ puta manje zastupljene nego OVR
☐ B OVO iziskuje $(K - 1)/2$ puta više parametara nego OVR, ali svaki OVR klasifikator ima $K - 1$ puta manje pozitivnih primjera nego negativnih
☐ C OVO svaki klasifikator trenira s $K/2$ puta manje primjera nego OVR, ali pozitivne klase kod OVR imaju K puta manje primjera nego kod OVO
☐ D OVR iziskuje $K - 1$ puta više klasifikatora od sheme OVO, ali kod OVO pozitivne klase imaju $K - 1$ puta manje primjera nego kod OVR

Cjelina 3: SVM, jezgrene i neparametarske metode (8 pitanja)

- 15** (P) Na 500 primjera sa 80 značajki treniramo rijetki jezgreni stroj s Gaussovim jezgrama. Sve Gaussove jezgre imaju istu varijancu. Nakon treniranja, dobivamo model koji ima 38 prototipa. **Koliko parametara moramo optimirati te koliko parametara ima naučeni model?**

☐ A Optimiramo 501 parametara, a naučeni model ima 3541 parametar
☐ B Optimiramo 81 parametar, a naučeni model ima 3040 parametara
☐ C Optimiramo 81 parametar, a naučeni model ima 3079 parametara
☐ D Optimiramo 501 parametara, a naučeni model ima 3079 parametara

- 16** (N) U ulaznome prostoru dimenzije $n = 3$ trenirali smo model SVM-a s linearnom jezgrom. Potporne vektore naučenog modela čine označeni primjeri $((2, -5, 15), -1)$, $((1, 8, -305), -1)$ i $((1, -6, 225), +1)$, a njima odgovarajući dualni koeficijenti su $\alpha_1 = 0.5$, $\alpha_2 = 0.8$ i $\alpha_3 = 0.9$. Treniranje smo proveli na skaliranim značajkama: svaku smo značajku x_j standardizirali primjenom transformacije $\frac{x_j - \mu_j}{\sigma_j}$, gdje su μ_j i σ_j srednja vrijednost odnosno varijanca značajke x_j u skupu označenih podataka \mathcal{D} . Parametri skaliranja su $\boldsymbol{\mu} = (15, -2, 100)$ i $\boldsymbol{\sigma} = (4, 1, 12)$. Model SVM-a koristimo za predikciju klase primjera $\mathbf{x} = (1, -2, 5)$. **Koliko će se promijeniti izlaz modela ako kod predikcije propustimo skalirati značajke primjera \mathbf{x} ?**

☐ A -373.22 ☐ B $+907.43$ ☐ C $+541.53$ ☐ D -739.13

- 17** (P) Neka je $\mathcal{H}_{C,\gamma}$ model SVM-a s Gaussovom jezgrom. Hiperparametri tog modela su regularizacijski faktor C i preciznost jezgre γ . Odabir modela provodimo unakrsnom provjerom i to pretraživanjem po rešetci za sljedeće vrijednosti hiperparametara:

$$C = \{2^{-5}, 2^{-4}, \dots, 2^4, 2^5\}$$
$$\gamma = \{10^{-5}, 10^{-4}, \dots, 10^4, 10^5\}$$

Već ranije smo utvrdili da je model sa $C = 2^{-2}$ i $\gamma = 10^{-1}$ podnaučen, a da je model sa $C = 2^1$ i $\gamma = 10^1$ prenaučeni. Za sve ostale modele ne znamo jesu li prenaučeni, podnaučeni ili optimalni. **Koliko modela još ima smisla ispitati jer su moguće optimalni?**

☐ A 76 ☐ B 25 ☐ C 96 ☐ D 10

- 18** (N) Treniramo SVM s Gaussovom jezgrenom funkcijom. Model treniramo na skupu od $N = 5$ označenih primjera. Vektor oznaka je $\mathbf{y} = (+1, +1, -1, -1, +1)$. Euklidske udaljenosti između primjera dane su sljedećom matricom udaljenosti:

$$\mathbf{D} = \begin{pmatrix} 0.0 & 7.48 & 6.16 & 13.42 & 12.21 \\ 7.48 & 0.0 & 12.73 & 20.1 & 14.18 \\ 6.16 & 12.73 & 0.0 & 10.49 & 9.95 \\ 13.42 & 20.1 & 10.49 & 0.0 & 20.02 \\ 12.21 & 14.18 & 9.95 & 20.02 & 0.0 \end{pmatrix}$$

Treniranjem uz $C = 10$ i $\gamma = 0.0001$ za vektor dualnih parametara dobili smo $\boldsymbol{\alpha} = (10, 1.052, 10, 10, 8.948)$. **Koliko iznosi gubitak zglobnice ovako naučenog modela SVM za prvi primjer, $L(y^{(1)}, h(\mathbf{x}^{(1)}))$?**

☐ A 1.64 ☐ B 0.03 ☐ C 0.24 ☐ D 1.18

- 19** (T) Algoritmi strojnog učenja mogu biti parametarski ili neparametarski. **Što je karakteristika neparametarskih algoritama strojnog učenja?**

☐ A Broj parametara ovisi o broju primjera
☐ B Broj značajki ne ovisi o dimenziji ulaznog prostora
☐ C Svaki primjer ima globalan utjecaj na izgled hipoteze
☐ D Hiperparametri nemaju utjecaja na složenost modela

- 20 (N) Rješavamo problem određivanja podrijetla pojedinih riječi u jeziku: za svaku riječ trebamo odrediti je li engleskog ($y = 1$) ili francuskog ($y = 0$) podrijetla. Problem rješavamo logističkom regresijom izvedenom kao rijetki jezgri stroj, gdje za bazne funkcije koristimo jezgru κ nad znakovnim nizovima. Funkcija κ definirana je kao $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$, gdje su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Na primjer, $\kappa(\text{water}, \text{eau}) = 2/6 = 0.33$. Skup za učenje je sljedeći:

$$\mathcal{D} = \{(\mathbf{x}, y)\}_i = \{(\text{water}, 1), (\text{eau}, 0), (\text{dog}, 1), (\text{chien}, 0), (\text{paperclip}, 1), (\text{trombone}, 0), (\text{chance}, 1), (\text{hasard}, 0)\}$$

Treniranjem rijetkoga jezgrenog stroja dobili smo vektor težina $\mathbf{w} = (-0.5, 0, 0, -3.5, 0, -1, 0, 0, 1)$. Razmotrite primjer $(\mathbf{x}, y) = (\text{nounours}, 0)$. **Koliko iznosi gubitak modela na primjeru (\mathbf{x}, y) ?**

- ☐ A 0.552 ☐ B 0.795 ☐ C 0.456 ☐ D 0.359

- 21 (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((0, 0), -1), ((-1, -1), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1))\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa $C = 1$. Kod modela s mekom marginom za dualne koeficijente vrijedi $\alpha_1 = 1$, $\alpha_2 > 0$, $\alpha_3 > 0$, $\alpha_4 > 0$ i $\alpha_5 = 1$. Skicirajte tvrdi i meki marginu u ulaznome prostoru. **Koliko je meka margina veća od tvrde margine?**

- ☐ A $\frac{3}{5}\sqrt{10}$ puta ☐ B $\frac{4}{5}\sqrt{10}$ puta ☐ C $\frac{2}{5}\sqrt{10}$ puta ☐ D $\frac{1}{6}\sqrt{2}$ puta

- 22 (T) Optimizacijski problem algoritma SVM može se postaviti u formulaciji meke ili tvrde margine te u primarnoj ili dualnoj formulaciji. Ovisno o formulaciji, kvadratni program sadrži različit broj varijabli po kojima optimiramo (optimizacijske varijable). **Ako matrica dizajna ima više redaka nego stupaca, koja formulacija ima najmanje optimizacijskih varijabli?**

- ☐ A Primarni problem tvrde margine ☐ C Dualni problem meke margine
☐ B Primarni problem meke margine ☐ D Dualni problem tvrde margine

Međuispit iz Strojnog učenja 1 (ak. god. 2022./2023.)

– NEKORIGIRANA VERZIJA –

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 35% bodova na predmetu). Pitanja nose po 1 bod, a 1/3 boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **180 minuta**. Primjerak ispita morate predati zajedno sa svojim rješenjima.

Cjelina 1: Osnovni koncepti i linearna regresija (6 pitanja)

- 1** (P) Raspolažemo modelom \mathcal{H}_α koji ima hiperparametar α kojim se može ugađati složenost modela. Isprobavamo dvije vrijednosti hiperparametra: α_1 i α_2 . Treniramo modele \mathcal{H}_{α_1} i \mathcal{H}_{α_2} te dobivamo hipoteze h_{α_1} i h_{α_2} . Zatim računamo empirijske pogreške tih hipoteza na skupu za učenje \mathcal{D}_u i na skupu za ispitivanje \mathcal{D}_i . Utvrđujemo da vrijedi:

$$E(h_{\alpha_1}|\mathcal{D}_i) - E(h_{\alpha_1}|\mathcal{D}_u) < E(h_{\alpha_2}|\mathcal{D}_i) - E(h_{\alpha_2}|\mathcal{D}_u)$$

Što iz toga možemo zaključiti?

- ☐ A Optimalan model je onaj s hiperparametrom iz intervala $[\alpha_1, \alpha_2]$
- ☐ B Model \mathcal{H}_{α_1} je manje složenosti od modela \mathcal{H}_{α_2}
- ☐ C Model \mathcal{H}_{α_1} je podnaučen
- ☐ D Model \mathcal{H}_{α_2} je prenaučan
- 2** (T) Modeli strojnog učenja općenito su različite složenosti. S porastom složenosti modela raste vjerojatnost da model bude prenaučan. Ta vjerojatnost raste s količinom šuma u podacima. **Zašto šum u podacima za učenje može dovesti do prenaučnosti klasifikacijskog modela?**
- ☐ A Zbog šuma granica između klasa izgleda nelinearnijom nego što ona to zapravo jest, pa primjeri blizu granice znatno više doprinose pogrešci učenja nego primjeri koji su udaljeni od granice
- ☐ B Povećanjem količine šuma granica između klasa postaje sve nelinearnija, pa raste i složenost modela te dobivena hipoteza očekivano neće odgovarati granici između klasa na ispitnom skupu
- ☐ C Efekt šuma je slučajna, pa će hipoteza koja se previše prilagodi šumu na skupu za učenje očekivano imati veliku pogrešku na ispitnom skupu gdje je šum drugačiji ili ga nema
- ☐ D Zbog šuma su oznake nekih primjera u skupu za učenje pogrešne, pa sve hipoteze iz modela imaju na tom skupu pogrešku koja je veća od nula, a još veća na ispitnom skupu
- 3** (T) Multikolinearnost značajki jedan je od problema koji može nastupiti kod primjene modela regresije na stvarnim podacima. Efekt multikolinearnosti i savršene multikolinearnosti dobro je uočljiv kod optimizacijskoga postupka običnih najmanjih kvadrata (OLS) kada se on provodi izračunom pseudoinverza matrice dizajna. Neka je m broj značajki, Φ je matrica dizajna i $\mathbf{G} = \Phi^T \Phi$ je Gramova matrica. **Koji je efekt savršene multikolinearnosti kod postupka OLS?**
- ☐ A Φ ima puni rang, $\text{rang}(\mathbf{G}) > m$ i \mathbf{G} ima inverz, ali s visokim kondicijskim brojem
- ☐ B $\text{rang}(\Phi) = N$, no $\text{rang}(\mathbf{G}) < N$, pa \mathbf{G} ima pseudoinverz, ali nema numerički stabilan inverz
- ☐ C $\text{rang}(\Phi) < m + 1$, \mathbf{G} nema puni rang i nema inverz, no ima pseudoinverz koji nije numerički stabilan
- ☐ D Φ nema puni rang, $\text{rang}(\mathbf{G}) < m + 1$ i \mathbf{G} nema pseudoinverz
- 4** (P) Razmatramo klasifikacijski problem u ulaznome prostoru $\mathcal{X} = \mathbb{Z}^2$. Skup označenih primjera je $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((0, 0), 0), ((0, 2), 0), ((0, -1), 0), ((-1, 0), 1), ((0, 1), 1), ((1, 0), 1)\}$. Razmatramo sljedeće modele, parametrizirane sa $\boldsymbol{\theta} \in \mathbb{R}^{n+1}$:

$$\mathcal{H}_1 : h_1(\mathbf{x}; \boldsymbol{\theta}) = \mathbf{1}\{\boldsymbol{\theta}^T \mathbf{x} \geq 0\}$$

$$\mathcal{H}_2 : h_2(\mathbf{x}; \boldsymbol{\theta}) = \mathbf{1}\{(x_1 - \theta_1)^2 + (x_2 - \theta_2)^2 \geq \theta_0^2\}$$

Pored ova dva modela, razmatramo i njihove kombinacije, modele \mathcal{H}_3 i \mathcal{H}_4 . Neka je $\mathcal{H}_3 = \mathcal{H}_1 \cup \mathcal{H}_2$ te neka je \mathcal{H}_4 skup funkcija definiranih kao $h_4(\mathbf{x}; \boldsymbol{\theta}) = h_1(\mathbf{x}) \cdot h_2(\mathbf{x})$. Neka je E_k minimalna empirijska pogreška koja se modelom \mathcal{H}_k može ostvariti na skupu \mathcal{D} , tj. $E_k = \arg\min_{h \in \mathcal{H}_k} E(h|\mathcal{D})$. **Koji odnosi vrijede između minimalnih empirijskih pogrešaka ovih modela?**

- ☐ A $E_1 > E_2 > E_3 = E_4$ ☐ B $E_1 = E_2 = E_3 > E_4$ ☐ C $E_1 = E_2 > E_3 = E_4$ ☐ D $E_1 > E_2 = E_3 > E_4$

5 (N) Raspoložemo sljedećim skupom primjera u dvodimenzijskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((1, 0), 1), ((2, -3), 2), ((3, 5), -1), ((5, 0), -4)\}$$

Na ovom skupu gradijentnim spustom trenirali smo L_1 -regularizirani model linearne regresije sa $\lambda = 1$. Dobili smo težine $\mathbf{w} = (2.12, -0.94, -0.08)$. **Koliko iznosi L_1 -regularizirana pogreška $E(\mathbf{w}|\mathcal{D})$?**

- ☐ A 0.29 ☐ B 2.69 ☐ C 1.58 ☐ D 7.10

6 (P) Jednostavnom regresijom modeliramo ovisnost nezavisne varijable y o zavisnoj varijabli x . Model treniramo postupkom običnih najmanjih kvadrata (OLS) na skupu podataka $\mathcal{D} = \{(x^{(i)}, y^{(i)})\} = \{(0, 0), (2, 0), (3, 2), (5, 2)\}$. Neka je h hipoteza koju dobivamo treniranjem modela te neka je L^i gubitak hipoteze h na primjeru $x^{(i)}$, tj. $L^i = L(y^{(i)}, h(x^{(i)}))$. **Što vrijedi za gubitke hipoteze na pojedinim primjerima?**

- ☐ A $L^1 = L^3 = 0, L^2 = L^4 < 1$ ☐ C $L^1 = L^2 = 1 < L^3 < L^4$
☐ B $L^1 = L^4 < L^2 = L^3$ ☐ D $L^1 = L^4 = 1, L^2 < L^3$

Cjelina 2: Linearni klasifikacijski modeli (8 pitanja)

7 (N) Model logističke regresije treniramo stohastičkim gradijentnim spustom. Primjere iz dvodimenzijskog ulaznog prostora preslikali smo u prostor značajki funkcijom $\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2)$. U jednoj iteraciji treniranja modela vektor parametara jednak je $\mathbf{w} = (0.1, 0.5, -2, -0.5)$. **Koliko u toj iteraciji iznosi L_2 -norma gradijenta gubitka za primjer $(\mathbf{x}, y) = ((1, -1), 1)$?**

- ☐ A 1.42 ☐ B 0.22 ☐ C 0.09 ☐ D 0.50

8 (T) Za optimizaciju parametara poopćenih linearnih modela može se koristiti stohastički gradijentni spust, odnosno pravilo LMS. Neka je (\mathbf{x}, y) označeni primjer za koji radimo ažuriranje težina pomoću pravila LMS. **Što možemo reći o razlici između novih (ažuriranih) i starih težina (težina prije ažuriranja)?**

- ☐ A Razlika je to veća što je izlaz modela $h(\mathbf{x})$ bliži nuli
☐ B Razlika je to manja što je oznaka y bliže jedinici
☐ C Razlika je to veća što je stopa učenja η bliža jedinici
☐ D Razlika je to manja što je vektor $\phi(\mathbf{x})$ bliži ishodištu

9 (T) Višeklasni problem može se riješiti binarnim klasifikatorom uz primjenu sheme OVO ili sheme OVR. Obje sheme imaju svoje prednosti i nedostatke. Pretpostavite da raspoložemo sa K klasa i da svaka klasa ima N/K primjera, gdje je N ukupan broj primjera u skupu za učenje. **Što su prednosti odnosno nedostatci OVO i OVR sheme u takvom slučaju?**

- ☐ A OVR treba K puta više klasifikatora nego OVO, ali su kod OVO pozitivne klase $K/2$ puta manje zastupljene nego OVR
☐ B OVO iziskuje $(K - 1)/2$ puta više parametara nego OVR, ali svaki OVR klasifikator ima $K - 1$ puta manje pozitivnih primjera nego negativnih
☐ C OVO svaki klasifikator trenira s $K/2$ puta manje primjera nego OVR, ali pozitivne klase kod OVR imaju K puta manje primjera nego kod OVO
☐ D OVR iziskuje $K - 1$ puta više klasifikatora od sheme OVO, ali kod OVO pozitivne klase imaju $K - 1$ puta manje primjera nego kod OVR

- 10 (N) Raspoložemo sljedećim skupom za učenje u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((-1, 4), +1), ((2, -3), -1), ((2, 5), -1))\}$$

Na ovom skupu treniramo perceptron. Pritom koristimo funkciju preslikavanja u šesterodimenzijaski prostor značajki, definiranu na sljedeći način:

$$\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2, x_1^2, x_2^2)$$

Početne težine perceptrona neka su $\mathbf{w} = (1, 0, -1, 2, 3, 0)$. **Koliko iznosi empirijska pogreška perceptrona na skupu za učenje prije početka treniranja (dakle, s početnim težinama)?**

- ☐ A 40 ☐ B 96 ☐ C 100 ☐ D 18

- 11 (P) Na primjerima iz dvodimenzijaskoga ulaznog prostora treniramo L_2 -regulariziranu logističku regresiju. Neka su $\mathbf{w}_0 = (1, -4, 4)$, $\mathbf{w}_1 = (1, -4, 6)$, $\mathbf{w}_2 = (1, -1, 7)$, $\mathbf{w}_3 = (1, -7, 1)$ i $\mathbf{w}_4 = (1, -7, -3)$ vektori u prostoru parametara. Neka je $E(\mathbf{w}|\mathcal{D})$ neregularizirana pogreška unakrsne entropije na skupu za učenje \mathcal{D} . Pritom je \mathbf{w}_0 minimizator funkcije $E(\mathbf{w}|\mathcal{D})$ te vrijedi $E(\mathbf{w}_1|\mathcal{D}) = E(\mathbf{w}_2|\mathcal{D}) = E(\mathbf{w}_3|\mathcal{D})$. Napravite skicu izokontura funkcije pogreške u potprostoru $w_1 \times w_2$. Za treniranje modela koristimo gradijentni spust s linijskim pretraživanjem uz regularizacijski faktor $\lambda = 100$. Za tako naučen model vrijednost regularizacijskog izraza $\frac{\lambda}{2}\|\mathbf{w}\|^2$ jednaka je 400. Međutim, broj koraka gradijentnog spusta (broj poziva linijskog pretraživanja) ovisi o tome koliko će spust krivudati, a to ovisi o odabiru inicijalnih parametara. Kao moguće inicijalne parametre razmotrite vektore \mathbf{w}_1 – \mathbf{w}_4 . **S kojim inicijalnim parametarima će algoritam gradijentnog spusta konvergirati u najmanjem broju koraka?**

- ☐ A \mathbf{w}_3 ☐ B \mathbf{w}_1 ☐ C \mathbf{w}_2 ☐ D \mathbf{w}_4

- 12 (P) Skup za učenje čine sljedeći označeni primjeri:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((-2, 3), 0), ((-1, 2), 0), ((0, 1), 0), ((0, 0), 0), ((1, 1), 0), ((1, -1), 1), ((2, 0), 1)\}$$

Na skupu \mathcal{D} treniramo logističku regresiju (LR) i stroj potpornih vektora s tvrdom marginom (SVM). Dodatno, treniramo model linearne regresije (LINR), gdje izlaz tog modela koristimo za klasifikaciju, tj. $h(\mathbf{x}) = \mathbf{1}\{\mathbf{w}^T \mathbf{x} \geq 0\}$. Za modele SVM i LINR umjesto oznake $y = 0$ koristimo oznaku $y = -1$. Za treniranje modela LR koristimo dovoljan broj iteracija tako da možemo pretpostaviti da je dobivena pogreška unakrsne entropije praktički jednaka nuli. Razmotrite primjer $\mathbf{x}^{(7)} = (2, 0)$. Neka je $d(m)$ udaljenost primjera $\mathbf{x}^{(7)}$ od granice između klasa dobivene modelom m . **Što od navedenog vrijedi za tu udaljenost?**

- ☐ A $d(\text{LINR}) < d(\text{LR}) < d(\text{SVM})$ ☐ C $d(\text{LR}) < d(\text{SVM}) < d(\text{LINR})$
☐ B $d(\text{SVM}) < d(\text{LINR}) < d(\text{LR})$ ☐ D $d(\text{SVM}) < d(\text{LR}) < d(\text{LINR})$

- 13 (N) Na skupu označenih primjera \mathcal{D} trenirali smo model logističke regresije. Dobili smo neki vektor težina \mathbf{w} i pomak $w_0 = 0.15$. Tako naučenom modelu neki primjer \mathbf{x} , čija je oznaka u skupu primjera $y = 0$, nanosi gubitak unakrsne entropije od $L(0, h(\mathbf{x})) = 0.274$. **Koliki gubitak unakrsne entropije bi nanosio primjer \mathbf{x} kada bismo njegove značajke pomnožili sa dva i promijenili mu oznaku?**

- ☐ A 1.19 ☐ B 7.11 ☐ C 2.54 ☐ D 4.03

- 14 (N) Raspoložemo označenim skupom primjera iz triju klasa ($K = 3$) u trodimenzijaskome ulaznom prostoru ($n = 3$). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer $\mathbf{x} = (-4, -1, -3)$ s oznakom $\mathbf{y} = (0, 0, 1)$. **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

- ☐ A 6.00 ☐ B 8.00 ☐ C 4.02 ☐ D 12.02

Cjelina 3: SVM, jezgrene i neparametarske metode (8 pitanja)

- 15 (T) Algoritmi strojnog učenja mogu biti parametarski ili neparametarski. Što je karakteristika neparametarskih algoritama strojnog učenja?

☐ A Složenost modela raste s normom vektora parametara
☐ B Pretpostavljaju teorijsku distribuciju podataka
☐ C Eksplicitno modeliraju granicu između primjera
☐ D Broj parametara ovisi o broju primjera

- 16 (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((0, 0), -1), ((-2, -2), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1))\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa $C = 1$. Kod modela s mekom marginom za dualne koeficijente vrijedi $\alpha_1 = 1$, $\alpha_2 > 0$, $\alpha_3 > 0$, $\alpha_4 > 0$ i $\alpha_5 = 1$. Skicirajte tvrdi i meki marginu u ulaznome prostoru. **Koliko je meka margina veća od tvrde margine?**

☐ A $\frac{2}{5}\sqrt{10}$ puta ☐ B $\frac{4}{5}\sqrt{10}$ puta ☐ C $\frac{3}{5}\sqrt{10}$ puta ☐ D $\frac{1}{6}\sqrt{2}$ puta

- 17 (T) Optimizacijski problem algoritma SVM može se postaviti u formulaciji meke ili tvrde margine te u primarnoj ili dualnoj formulaciji. Ovisno o formulaciji, kvadratni program sadrži različit broj varijabli po kojima optimiramo (optimizacijske varijable). **Ako matrica dizajna ima više redaka nego stupaca, koja formulacija ima najmanje optimizacijskih varijabli?**

☐ A Dualni problem tvrde margine ☐ C Dualni problem meke margine
☐ B Primarni problem meke margine ☐ D Primarni problem tvrde margine

- 18 (P) Neka je $\mathcal{H}_{C,\gamma}$ model SVM-a s Gaussovom jezgrom. Hiperparametri tog modela su regularizacijski faktor C i preciznost jezgre γ . Odabir modela provodimo unakrsnom provjerom i to pretraživanjem po rešetci za sljedeće vrijednosti hiperparametara:

$$C = \{2^{-5}, 2^{-4}, \dots, 2^4, 2^5\}$$
$$\gamma = \{10^{-5}, 10^{-4}, \dots, 10^4, 10^5\}$$

Već ranije smo utvrdili da je model sa $C = 2^{-2}$ i $\gamma = 10^{-1}$ podnaučen, a da je model sa $C = 2^1$ i $\gamma = 10^1$ prenaučeni. Za sve ostale modele ne znamo jesu li prenaučeni, podnaučeni ili optimalni. **Koliko modela još ima smisla ispitati jer su moguće optimalni?**

☐ A 96 ☐ B 76 ☐ C 25 ☐ D 10

- 19 (P) Na 500 primjera sa 80 značajki treniramo rijetki jezgreni stroj s Gausovim jezgrama. Sve Gaussove jezgre imaju istu varijancu. Nakon treniranja, dobivamo model koji ima 38 prototipa. **Koliko parametara moramo optimirati te koliko parametara ima naučeni model?**

☐ A Optimiramo 81 parametar, a naučeni model ima 3079 parametara
☐ B Optimiramo 501 parametara, a naučeni model ima 3040 parametara
☐ C Optimiramo 501 parametara, a naučeni model ima 3079 parametara
☐ D Optimiramo 501 parametara, a naučeni model ima 3541 parametar

- 20 (N) Treniramo SVM s Gaussovom jezgrenom funkcijom. Model treniramo na skupu od $N = 5$ označenih primjera. Vektor oznaka je $\mathbf{y} = (+1, +1, -1, -1, +1)$. Euklidske udaljenosti između primjera dane su sljedećom matricom udaljenosti:

$$\mathbf{D} = \begin{pmatrix} 0.0 & 7.48 & 6.16 & 13.42 & 12.21 \\ 7.48 & 0.0 & 12.73 & 20.1 & 14.18 \\ 6.16 & 12.73 & 0.0 & 10.49 & 9.95 \\ 13.42 & 20.1 & 10.49 & 0.0 & 20.02 \\ 12.21 & 14.18 & 9.95 & 20.02 & 0.0 \end{pmatrix}$$

Treniranjem uz $C = 10$ i $\gamma = 0.0001$ za vektor dualnih parametara dobili smo $\alpha = (10, 1.052, 10, 10, 8.948)$. **Koliko iznosi gubitak zglobnice ovako naučenog modela SVM za prvi primjer, $L(y^{(1)}, h(\mathbf{x}^{(1)}))$?**

- ☐ A 0.24 ☐ B 1.64 ☐ C 0.03 ☐ D 1.18

- 21** (N) U ulaznome prostoru dimenzije $n = 3$ trenirali smo model SVM-a s linearnom jezgrom. Potporne vektore naučenog modela čine označeni primjeri $((2, -5, 15), -1)$, $((1, 8, -305), -1)$ i $((1, -6, 225), +1)$, a njima odgovarajući dualni koeficijenti su $\alpha_1 = 0.5$, $\alpha_2 = 0.8$ i $\alpha_3 = 0.9$. Treniranje smo proveli na skaliranim značajkama: svaku smo značajku x_j standardizirali primjenom transformacije $\frac{x_j - \mu_j}{\sigma_j}$, gdje su μ_j i σ_j srednja vrijednost odnosno varijanca značajke x_j u skupu označenih podataka \mathcal{D} . Parametri skaliranja su $\mu = (15, -2, 100)$ i $\sigma = (4, 1, 12)$. Model SVM-a koristimo za predikciju klase primjera $\mathbf{x} = (1, 2, -30)$. **Koliko će se promijeniti izlaz modela ako kod predikcije propustimo skalirati značajke primjera \mathbf{x} ?**

- ☐ A +541.53 ☐ B -739.13 ☐ C +907.43 ☐ D -373.22

- 22** (N) Rješavamo problem određivanja podrijetla pojedinih riječi u jeziku: za svaku riječ trebamo odrediti je li engleskog ($y = 1$) ili francuskog ($y = 0$) podrijetla. Problem rješavamo logističkom regresijom izvedenom kao rijetki jezgreni stroj, gdje za bazne funkcije koristimo jezgru κ nad znakovnim nizovima. Funkcija κ definirana je kao $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$, gdje su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Na primjer, $\kappa(\text{water}, \text{eau}) = 2/6 = 0.33$. Skup za učenje je sljedeći:

$$\mathcal{D} = \{(\mathbf{x}, y)\}_i = \{(\text{water}, 1), (\text{eau}, 0), (\text{dog}, 1), (\text{chien}, 0), (\text{paperclip}, 1), (\text{trombone}, 0), (\text{chance}, 1), (\text{hasard}, 0)\}$$

Treniranjem rijetkoga jezgrenog stroja dobili smo vektor težina $\mathbf{w} = (-0.5, 0, 0, -3.5, 0, -1, 0, 0, 1)$. Razmotrite primjer $(\mathbf{x}, y) = (\text{nounours}, 0)$. **Koliko iznosi gubitak modela na primjeru (\mathbf{x}, y) ?**

- ☐ A 0.552 ☐ B 0.359 ☐ C 0.795 ☐ D 0.456

Međuispit iz Strojnog učenja 1 (ak. god. 2022./2023.) – NEKORIGIRANA VERZIJA –

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 35% bodova na predmetu). Pitanja nose po 1 bod, a 1/3 boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **180 minuta**. Primjerak ispita morate predati zajedno sa svojim rješenjima.

Cjelina 1: Osnovni koncepti i linearna regresija (6 pitanja)

1 (T) Modeli strojnog učenja općenito su različite složenosti. S porastom složenosti modela raste vjerojatnost da model bude prenaučan. Ta vjerojatnost raste s količinom šuma u podacima. **Zašto šum u podacima za učenje može dovesti do prenaučnosti klasifikacijskog modela?**

- ☐ A Efekt šuma je slučajna, pa će hipoteza koja se previše prilagodi šumu na skupu za učenje očekivano imati veliku pogrešku na ispitnom skupu gdje je šum drugačiji ili ga nema
- ☐ B Zbog šuma granica između klasa izgleda nelinearnijom nego što ona to zapravo jest, pa primjeri blizu granice znatno više doprinose pogrešci učenja nego primjeri koji su udaljeni od granice
- ☐ C Povećanjem količine šuma granica između klasa postaje sve nelinearnija, pa raste i složenost modela te dobivena hipoteza očekivano neće odgovarati granici između klasa na ispitnom skupu
- ☐ D Zbog šuma su oznake nekih primjera u skupu za učenje pogrešne, pa sve hipoteze iz modela imaju na tom skupu pogrešku koja je veća od nula, a još veća na ispitnom skupu

2 (T) Multikolinearnost značajki jedan je od problema koji može nastupiti kod primjene modela regresije na stvarnim podacima. Efekt multikolinearnosti i savršene multikolinearnosti dobro je uočljiv kod optimizacijskoga postupka običnih najmanjih kvadrata (OLS) kada se on provodi izračunom pseudoinverza matrice dizajna. Neka je m broj značajki, Φ je matrica dizajna i $\mathbf{G} = \Phi^T \Phi$ je Gramova matrica. **Koji je efekt savršene multikolinearnosti kod postupka OLS?**

- ☐ A $\text{rang}(\Phi) < m + 1$, \mathbf{G} nema puni rang i nema inverz, no ima pseudoinverz koji nije numerički stabilan
- ☐ B $\text{rang}(\Phi) = N$, no $\text{rang}(\mathbf{G}) < N$, pa \mathbf{G} ima pseudoinverz, ali nema numerički stabilan inverz
- ☐ C Φ ima puni rang, $\text{rang}(\mathbf{G}) > m$ i \mathbf{G} ima inverz, ali s visokim kondicijskim brojem
- ☐ D Φ nema puni rang, $\text{rang}(\mathbf{G}) < m + 1$ i \mathbf{G} nema pseudoinverz

3 (N) Raspoložemo sljedećim skupom primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((1, 0), 1), ((2, -3), 2), ((3, 5), -1), ((5, 0), -4)\}$$

Na ovom skupu gradijentnim spustom trenirali smo L_1 -regularizirani model linearne regresije sa $\lambda = 1$. Dobili smo težine $\mathbf{w} = (2.12, -0.94, -0.08)$. **Koliko iznosi L_1 -regularizirana pogreška $E(\mathbf{w}|\mathcal{D})$?**

- ☐ A 7.10
- ☐ B 1.58
- ☐ C 0.29
- ☐ D 2.69

4 (P) Raspoložemo modelom \mathcal{H}_α koji ima hiperparametar α kojim se može ugađati složenost modela. Isprobavamo dvije vrijednosti hiperparametra: α_1 i α_2 . Treniramo modele \mathcal{H}_{α_1} i \mathcal{H}_{α_2} te dobivamo hipoteze h_{α_1} i h_{α_2} . Zatim računamo empirijske pogreške tih hipoteza na skupu za učenje \mathcal{D}_u i na skupu za ispitivanje \mathcal{D}_i . Utvrđujemo da vrijedi:

$$E(h_{\alpha_1}|\mathcal{D}_i) - E(h_{\alpha_1}|\mathcal{D}_u) < E(h_{\alpha_2}|\mathcal{D}_i) - E(h_{\alpha_2}|\mathcal{D}_u)$$

Što iz toga možemo zaključiti?

- ☐ A Model \mathcal{H}_{α_1} je manje složenosti od modela \mathcal{H}_{α_2}
- ☐ B Optimalan model je onaj s hiperparametrom iz intervala $[\alpha_1, \alpha_2]$
- ☐ C Model \mathcal{H}_{α_1} je podnaučen
- ☐ D Model \mathcal{H}_{α_2} je prenaučan

- 5 (P) Razmatramo klasifikacijski problem u ulaznome prostoru $\mathcal{X} = \mathbb{Z}^2$. Skup označenih primjera je $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((0, 0), 0), ((0, 2), 0), ((0, -1), 0), ((-1, 0), 1), ((0, 1), 1), ((1, 0), 1)\}$. Razmatramo sljedeće modele, parametrizirane sa $\boldsymbol{\theta} \in \mathbb{R}^{n+1}$:

$$\mathcal{H}_1 : h_1(\mathbf{x}; \boldsymbol{\theta}) = \mathbf{1}\{\boldsymbol{\theta}^T \mathbf{x} \geq 0\}$$

$$\mathcal{H}_2 : h_2(\mathbf{x}; \boldsymbol{\theta}) = \mathbf{1}\{(x_1 - \theta_1)^2 + (x_2 - \theta_2)^2 \geq \theta_0^2\}$$

Pored ova dva modela, razmatramo i njihove kombinacije, modele \mathcal{H}_3 i \mathcal{H}_4 . Neka je $\mathcal{H}_3 = \mathcal{H}_1 \cup \mathcal{H}_2$ te neka je \mathcal{H}_4 skup funkcija definiranih kao $h_4(\mathbf{x}; \boldsymbol{\theta}) = h_1(\mathbf{x}) \cdot h_2(\mathbf{x})$. Neka je E_k minimalna empirijska pogreška koja se modelom \mathcal{H}_k može ostvariti na skupu \mathcal{D} , tj. $E_k = \arg\min_{h \in \mathcal{H}_k} E(h|\mathcal{D})$. **Koji odnosi vrijede između minimalnih empirijskih pogrešaka ovih modela?**

- ☐ A $E_1 = E_2 = E_3 > E_4$ ☐ B $E_1 > E_2 = E_3 > E_4$ ☐ C $E_1 = E_2 > E_3 = E_4$ ☐ D $E_1 > E_2 > E_3 = E_4$

- 6 (P) Jednostavnom regresijom modeliramo ovisnost nezavisne varijable y o zavisnoj varijabli x . Model treniramo postupkom običnih najmanjih kvadrata (OLS) na skupu podataka $\mathcal{D} = \{(x^{(i)}, y^{(i)})\} = \{(0, 0), (2, 0), (3, 2), (5, 2)\}$. Neka je h hipoteza koju dobivamo treniranjem modela te neka je L^i gubitak hipoteze h na primjeru $x^{(i)}$, tj. $L^i = L(y^{(i)}, h(x^{(i)}))$. **Što vrijedi za gubitke hipoteze na pojedinim primjerima?**

- ☐ A $L^1 = L^4 < L^2 = L^3$ ☐ C $L^1 = L^2 = 1 < L^3 < L^4$
☐ B $L^1 = L^3 = 0, L^2 = L^4 < 1$ ☐ D $L^1 = L^4 = 1, L^2 < L^3$

Cjelina 2: Linearni klasifikacijski modeli (8 pitanja)

- 7 (N) Na skupu označenih primjera \mathcal{D} trenirali smo model logističke regresije. Dobili smo neki vektor težina \mathbf{w} i pomak $w_0 = 0.15$. Tako naučenom modelu neki primjer \mathbf{x} , čija je oznaka u skupu primjera $y = 0$, nanosi gubitak unakrsne entropije od $L(0, h(\mathbf{x})) = 0.274$. **Koliki gubitak unakrsne entropije bi nanosio primjer \mathbf{x} kada bismo njegove značajke pomnožili sa dva i promijenili mu oznaku?**

- ☐ A 2.54 ☐ B 1.19 ☐ C 4.03 ☐ D 7.11

- 8 (N) Raspoložemo sljedećim skupom za učenje u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((-1, 4), +1), ((2, -3), -1), ((2, 5), -1)\}$$

Na ovom skupu treniramo perceptron. Pritom koristimo funkciju preslikavanja u šesterodimenzijaski prostor značajki, definiranu na sljedeći način:

$$\phi(\mathbf{x}) = (1, x_1, x_2, x_1 x_2, x_1^2, x_2^2)$$

Početne težine perceptrona neka su $\mathbf{w} = (-1, 0, -1, 2, 3, 2)$. **Koliko iznosi empirijska pogreška perceptrona na skupu za učenje prije početka treniranja (dakle, s početnim težinama)?**

- ☐ A 40 ☐ B 100 ☐ C 18 ☐ D 96

- 9 (P) Na primjerima iz dvodimenzijaskoga ulaznog prostora treniramo L_2 -regulariziranu logističku regresiju. Neka su $\mathbf{w}_0 = (1, -4, 4)$, $\mathbf{w}_1 = (1, -4, 6)$, $\mathbf{w}_2 = (1, -1, 7)$, $\mathbf{w}_3 = (1, -7, 1)$ i $\mathbf{w}_4 = (1, -7, -3)$ vektori u prostoru parametara. Neka je $E(\mathbf{w}|\mathcal{D})$ neregularizirana pogreška unakrsne entropije na skupu za učenje \mathcal{D} . Pritom je \mathbf{w}_0 minimizator funkcije $E(\mathbf{w}|\mathcal{D})$ te vrijedi $E(\mathbf{w}_1|\mathcal{D}) = E(\mathbf{w}_2|\mathcal{D}) = E(\mathbf{w}_3|\mathcal{D})$. Napravite skicu izokontura funkcije pogreške u potprostoru $w_1 \times w_2$. Za treniranje modela koristimo gradijentni spust s linijskim pretraživanjem uz regularizacijski faktor $\lambda = 100$. Za tako naučen model vrijednost regularizacijskog izraza $\frac{\lambda}{2} \|\mathbf{w}\|^2$ jednaka je 400. Međutim, broj koraka gradijentnog spusta (broj poziva linijskog pretraživanja) ovisi o tome koliko će spust krivudati, a to ovisi o odabiru inicijalnih parametara. Kao moguće inicijalne parametre razmotrite vektore $\mathbf{w}_1 - \mathbf{w}_4$. **S kojim inicijalnim parametarima će algoritam gradijentnog spusta konvergirati u najmanjem broju koraka?**

- ☐ A \mathbf{w}_3 ☐ B \mathbf{w}_1 ☐ C \mathbf{w}_2 ☐ D \mathbf{w}_4

- 10 (N) Model logističke regresije treniramo stohastičkim gradijentnim spustom. Primjere iz dvodimenzijaskog ulaznog prostora preslikali smo u prostor značajki funkcijom $\phi(\mathbf{x}) = (1, x_1, x_2, x_1 x_2)$. U jednoj iteraciji treniranja modela vektor parametara jednak je $\mathbf{w} = (0.1, 0.5, -2, 0.5)$. **Koliko u toj iteraciji iznosi L_2 -norma gradijenta gubitka za primjer $(\mathbf{x}, y) = ((1, -1), 1)$?**

- ☐ A 1.42 ☐ B 0.50 ☐ C 0.09 ☐ D 0.22

11 (T) Višeklasni problem može se riješiti binarnim klasifikatorom uz primjenu sheme OVO ili sheme OVR. Obje sheme imaju svoje prednosti i nedostatke. Pretpostavite da raspoložemo sa K klasa i da svaka klasa ima N/K primjera, gdje je N ukupan broj primjera u skupu za učenje. **Što su prednosti odnosno nedostatci OVO i OVR sheme u takvom slučaju?**

- ☐ A OVO svaki klasifikator trenira s $K/2$ puta manje primjera nego OVR, ali pozitivne klase kod OVR imaju K puta manje primjera nego kod OVO
- ☐ B OVR treba K puta više klasifikatora nego OVO, ali su kod OVO pozitivne klase $K/2$ puta manje zastupljene nego OVR
- ☐ C OVR iziskuje $K - 1$ puta više klasifikatora od sheme OVO, ali kod OVO pozitivne klase imaju $K - 1$ puta manje primjera nego kod OVR
- ☐ D OVO iziskuje $(K - 1)/2$ puta više parametara nego OVR, ali svaki OVR klasifikator ima $K - 1$ puta manje pozitivnih primjera nego negativnih

12 (N) Raspoložemo označenim skupom primjera iz triju klasa ($K = 3$) u trodimenzijskome ulaznom prostoru ($n = 3$). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer $\mathbf{x} = (-4, 1, -3)$ s oznakom $\mathbf{y} = (0, 1, 0)$. **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

- ☐ A 6.00 ☐ B 12.02 ☐ C 8.00 ☐ D 4.02

13 (P) Skup za učenje čine sljedeći označeni primjeri:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((-2, 3), 0), ((-1, 2), 0), ((0, 1), 0), ((0, 0), 0), ((1, 1), 0), ((1, -1), 1), ((2, 0), 1)\}$$

Na skupu \mathcal{D} treniramo logističku regresiju (LR) i stroj potpornih vektora s tvrdom marginom (SVM). Dodatno, treniramo model linearne regresije (LINR), gdje izlaz tog modela koristimo za klasifikaciju, tj. $h(\mathbf{x}) = \mathbf{1}\{\mathbf{w}^T \mathbf{x} \geq 0\}$. Za modele SVM i LINR umjesto oznake $y = 0$ koristimo oznaku $y = -1$. Za treniranje modela LR koristimo dovoljan broj iteracija tako da možemo pretpostaviti da je dobivena pogreška unakrsne entropije praktički jednaka nuli. Razmotrite primjer $\mathbf{x}^{(7)} = (2, 0)$. Neka je $d(m)$ udaljenost primjera $\mathbf{x}^{(7)}$ od granice između klasa dobivene modelom m . **Što od navedenog vrijedi za tu udaljenost?**

- ☐ A $d(\text{SVM}) < d(\text{LINR}) < d(\text{LR})$ ☐ C $d(\text{SVM}) < d(\text{LR}) < d(\text{LINR})$
- ☐ B $d(\text{LINR}) < d(\text{LR}) < d(\text{SVM})$ ☐ D $d(\text{LR}) < d(\text{SVM}) < d(\text{LINR})$

14 (T) Za optimizaciju parametara poopćenih linearnih modela može se koristiti stohastički gradijentni spust, odnosno pravilo LMS. Neka je (\mathbf{x}, y) označeni primjer za koji radimo ažuriranje težina pomoću pravila LMS. **Što možemo reći o razlici između novih (ažuriranih) i starih težina (težina prije ažuriranja)?**

- ☐ A Razlika je to manja što je oznaka y bliže jedinici
- ☐ B Razlika je to veća što je stopa učenja η bliža jedinici
- ☐ C Razlika je to veća što je izlaz modela $h(\mathbf{x})$ bliži nuli
- ☐ D Razlika je to manja što je vektor $\phi(\mathbf{x})$ bliži ishodištu

Cjelina 3: SVM, jezgrene i neparametarske metode (8 pitanja)

15 (T) Optimizacijski problem algoritma SVM može se postaviti u formulaciji meke ili tvrde margine te u primarnoj ili dualnoj formulaciji. Ovisno o formulaciji, kvadratni program sadrži različit broj varijabli po kojima optimiramo (optimizacijske varijable). **Ako matrica dizajna ima više redaka nego stupaca, koja formulacija ima najmanje optimizacijskih varijabli?**

- ☐ A Dualni problem tvrde margine ☐ C Primarni problem tvrde margine
- ☐ B Dualni problem meke margine ☐ D Primarni problem meke margine

- 16 (P) Na 800 primjera sa 50 značajki treniramo rijetki jezgri stroj s Gaussovim jezgrama. Sve Gaussove jezgre imaju istu varijancu. Nakon treniranja, dobivamo model koji ima 28 prototipa. **Koliko parametara moramo optimirati te koliko parametara ima naučeni model?**

- ☐ A Optimiramo 51 parametar, a naučeni model ima 1429 parametara
☐ B Optimiramo 51 parametar, a naučeni model ima 1400 parametara
☐ C Optimiramo 801 parametar, a naučeni model ima 1429 parametara
☐ D Optimiramo 801 parametar, a naučeni model ima 1400 parametara

- 17 (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((0, 0), -1), ((-1, -1), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1))\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa $C = 1$. Kod modela s mekom marginom za dualne koeficijente vrijedi $\alpha_1 = 1$, $\alpha_2 > 0$, $\alpha_3 > 0$, $\alpha_4 > 0$ i $\alpha_5 = 1$. Skicirajte tvrdi i meku marginu u ulaznome prostoru. **Koliko je meka margina veća od tvrde margine?**

- ☐ A $\frac{2}{5}\sqrt{10}$ puta ☐ B $\frac{1}{6}\sqrt{2}$ puta ☐ C $\frac{3}{5}\sqrt{10}$ puta ☐ D $\frac{4}{5}\sqrt{10}$ puta

- 18 (N) Rješavamo problem određivanja podrijetla pojedinih riječi u jeziku: za svaku riječ trebamo odrediti je li engleskog ($y = 1$) ili francuskog ($y = 0$) podrijetla. Problem rješavamo logističkom regresijom izvedenom kao rijetki jezgri stroj, gdje za bazne funkcije koristimo jezgru κ nad znakovnim nizovima. Funkcija κ definirana je kao $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$, gdje su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Na primjer, $\kappa(\text{water}, \text{eau}) = 2/6 = 0.33$. Skup za učenje je sljedeći:

$$\mathcal{D} = \{(\mathbf{x}, y)\}_i = \{(\text{water}, 1), (\text{eau}, 0), (\text{dog}, 1), (\text{chien}, 0), (\text{paperclip}, 1), (\text{trombone}, 0), (\text{chance}, 1), (\text{hasard}, 0)\}$$

Treniranjem rijetkoga jezgrenog stroja dobili smo vektor težina $\mathbf{w} = (-0.5, 0, 0, -3.5, 0, -1, 0, 0, 1)$. Razmotrite primjer $(\mathbf{x}, y) = (\text{nounours}, 0)$. **Koliko iznosi gubitak modela na primjeru (\mathbf{x}, y) ?**

- ☐ A 0.359 ☐ B 0.456 ☐ C 0.552 ☐ D 0.795

- 19 (P) Neka je $\mathcal{H}_{C, \gamma}$ model SVM-a s Gaussovom jezgrom. Hiperparametri tog modela su regularizacijski faktor C i preciznost jezgre γ . Odabir modela provodimo unakrsnom provjerom i to pretraživanjem po rešetci za sljedeće vrijednosti hiperparametara:

$$C = \{2^{-5}, 2^{-4}, \dots, 2^4, 2^5\}$$

$$\gamma = \{10^{-5}, 10^{-4}, \dots, 10^4, 10^5\}$$

Za model sa $C = 2^{-2}$ i $\gamma = 10^1$ utvrdili smo da je podnaučen, a za model sa $C = 2^1$ i $\gamma = 10^1$ utvrdili smo da je prenaučan. **Koliko modela još ima smisla ispitati jer su moguće optimalni?**

- ☐ A 10 ☐ B 25 ☐ C 96 ☐ D 68

- 20 (N) Treniramo SVM s Gaussovom jezgrenom funkcijom. Model treniramo na skupu od $N = 5$ označenih primjera. Vektor oznaka je $\mathbf{y} = (+1, +1, -1, -1, +1)$. Euklidske udaljenosti između primjera dane su sljedećom matricom udaljenosti:

$$\mathbf{D} = \begin{pmatrix} 0.0 & 7.48 & 6.16 & 13.42 & 12.21 \\ 7.48 & 0.0 & 12.73 & 20.1 & 14.18 \\ 6.16 & 12.73 & 0.0 & 10.49 & 9.95 \\ 13.42 & 20.1 & 10.49 & 0.0 & 20.02 \\ 12.21 & 14.18 & 9.95 & 20.02 & 0.0 \end{pmatrix}$$

Treniranjem uz $C = 10$ i $\gamma = 0.0001$ za vektor dualnih parametara dobili smo $\boldsymbol{\alpha} = (10, 1.052, 10, 10, 8.948)$. **Koliko iznosi gubitak zglobnice ovako naučenog modela SVM za treći primjer, $L(y^{(3)}, h(\mathbf{x}^{(3)}))$?**

- ☐ A 1.64 ☐ B 0.03 ☐ C 1.18 ☐ D 0.24

21 (T) Algoritmi strojnog učenja mogu biti parametarski ili neparametarski. Što je karakteristika neparametarskih algoritama strojnog učenja?

- ☐ A Hiperparametri nemaju utjecaja na složenost modela
- ☐ B Eksplicitno modeliraju granicu između primjera
- ☐ C Broj parametara ovisi o broju primjera
- ☐ D Pretpostavljaju teorijsku distribuciju podataka

22 (N) U ulaznome prostoru dimenzije $n = 3$ trenirali smo model SVM-a s linearnom jezgrom. Potporne vektore naučenog modela čine označeni primjeri $((2, -5, 15), -1)$, $((1, 8, -305), -1)$ i $((1, -6, 225), +1)$, a njima odgovarajući dualni koeficijenti su $\alpha_1 = 0.5$, $\alpha_2 = 0.8$ i $\alpha_3 = 0.9$. Treniranje smo proveli na skaliranim značajkama: svaku smo značajku x_j standardizirali primjenom transformacije $\frac{x_j - \mu_j}{\sigma_j}$, gdje su μ_j i σ_j srednja vrijednost odnosno varijanca značajke x_j u skupu označenih podataka \mathcal{D} . Parametri skaliranja su $\boldsymbol{\mu} = (15, -2, 100)$ i $\boldsymbol{\sigma} = (4, 1, 12)$. Model SVM-a koristimo za predikciju klase primjera $\mathbf{x} = (1, -2, 5)$. **Koliko će se promijeniti izlaz modela ako kod predikcije propustimo skalirati značajke primjera \mathbf{x} ?**

- ☐ A -739.13
- ☐ B $+907.43$
- ☐ C -373.22
- ☐ D $+541.53$

Međuispit iz Strojnog učenja 1 (ak. god. 2022./2023.) – NEKORIGIRANA VERZIJA –

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 35% bodova na predmetu). Pitanja nose po 1 bod, a 1/3 boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **180 minuta**. Primjerak ispita morate predati zajedno sa svojim rješenjima.

Cjelina 1: Osnovni koncepti i linearna regresija (6 pitanja)

- 1** (N) Raspoložemo sljedećim skupom primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((1, 0), 1), ((2, -3), 2), ((3, 5), -1), ((5, 0), -4)\}$$

Na ovom skupu gradijentnim spustom trenirali smo L_1 -regularizirani model linearne regresije sa $\lambda = 1$. Dobili smo težine $\mathbf{w} = (2.12, -0.94, -0.08)$. **Koliko iznosi L_1 -regularizirana pogreška $E(\mathbf{w}|\mathcal{D})$?**

- ☐ A 2.69 ☐ B 1.58 ☐ C 0.29 ☐ D 7.10

- 2** (T) Modeli strojnog učenja općenito su različite složenosti. S porastom složenosti modela raste vjerojatnost da model bude prenaučeni. Ta vjerojatnost raste s količinom šuma u podacima. **Zašto šum u podacima za učenje može dovesti do prenaučnosti klasifikacijskog modela?**

- ☐ A Efekt šuma je slučajna, pa će hipoteza koja se previše prilagodi šumu na skupu za učenje očekivano imati veliku pogrešku na ispitnom skupu gdje je šum drugačiji ili ga nema
- ☐ B Zbog šuma su oznake nekih primjera u skupu za učenje pogrešne, pa sve hipoteze iz modela imaju na tom skupu pogrešku koja je veća od nula, a još veća na ispitnom skupu
- ☐ C Povećanjem količine šuma granica između klasa postaje sve nelinearnija, pa raste i složenost modela te dobivena hipoteza očekivano neće odgovarati granici između klasa na ispitnom skupu
- ☐ D Zbog šuma granica između klasa izgleda nelinearnijom nego što ona to zapravo jest, pa primjeri blizu granice znatno više doprinose pogrešci učenja nego primjeri koji su udaljeni od granice

- 3** (P) Raspoložemo modelom \mathcal{H}_α koji ima hiperparametar α kojim se može ugađati složenost modela. Isprobavamo dvije vrijednosti hiperparametra: α_1 i α_2 . Treniramo modele \mathcal{H}_{α_1} i \mathcal{H}_{α_2} te dobivamo hipoteze h_{α_1} i h_{α_2} . Zatim računamo empirijske pogreške tih hipoteza na skupu za učenje \mathcal{D}_u i na skupu za ispitivanje \mathcal{D}_i . Utvrđujemo da vrijedi:

$$E(h_{\alpha_1}|\mathcal{D}_i) - E(h_{\alpha_1}|\mathcal{D}_u) < E(h_{\alpha_2}|\mathcal{D}_i) - E(h_{\alpha_2}|\mathcal{D}_u)$$

Što iz toga možemo zaključiti?

- ☐ A Optimalan model je onaj s hiperparametrom iz intervala $[\alpha_1, \alpha_2]$
- ☐ B Model \mathcal{H}_{α_1} je podnaučeni
- ☐ C Model \mathcal{H}_{α_1} je manje složenosti od modela \mathcal{H}_{α_2}
- ☐ D Model \mathcal{H}_{α_2} je prenaučeni

- 4** (P) Razmatramo klasifikacijski problem u ulaznome prostoru $\mathcal{X} = \mathbb{Z}^2$. Skup označenih primjera je $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((0, 0), 0), ((0, 2), 0), ((0, -1), 0), ((-1, 0), 1), ((0, 1), 1), ((1, 0), 1)\}$. Razmatramo sljedeće modele, parametrizirane sa $\boldsymbol{\theta} \in \mathbb{R}^{n+1}$:

$$\mathcal{H}_1 : h_1(\mathbf{x}; \boldsymbol{\theta}) = \mathbf{1}\{\boldsymbol{\theta}^T \mathbf{x} \geq 0\}$$

$$\mathcal{H}_2 : h_2(\mathbf{x}; \boldsymbol{\theta}) = \mathbf{1}\{(x_1 - \theta_1)^2 + (x_2 - \theta_2)^2 \geq \theta_0^2\}$$

Pored ova dva modela, razmatramo i njihove kombinacije, modele \mathcal{H}_3 i \mathcal{H}_4 . Neka je $\mathcal{H}_3 = \mathcal{H}_1 \cup \mathcal{H}_2$ te neka je \mathcal{H}_4 skup funkcija definiranih kao $h_4(\mathbf{x}; \boldsymbol{\theta}) = h_1(\mathbf{x}) \cdot h_2(\mathbf{x})$. Neka je E_k minimalna empirijska pogreška koja se modelom \mathcal{H}_k može ostvariti na skupu \mathcal{D} , tj. $E_k = \arg\min_{h \in \mathcal{H}_k} E(h|\mathcal{D})$. **Koji odnosi vrijede između minimalnih empirijskih pogrešaka ovih modela?**

- ☐ A $E_1 > E_2 > E_3 = E_4$ ☐ B $E_1 > E_2 = E_3 > E_4$ ☐ C $E_1 = E_2 > E_3 = E_4$ ☐ D $E_1 = E_2 = E_3 > E_4$

- 5 (P) Jednostavnom regresijom modeliramo ovisnost nezavisne varijable y o zavisnoj varijabli x . Model treniramo postupkom običnih najmanjih kvadrata (OLS) na skupu podataka $\mathcal{D} = \{(x^{(i)}, y^{(i)})\} = \{(0, 0), (2, 0), (3, 2), (5, 2)\}$. Neka je h hipoteza koju dobivamo treniranjem modela te neka je L^i gubitak hipoteze h na primjeru $x^{(i)}$, tj. $L^i = L(y^{(i)}, h(x^{(i)}))$. Što vrijedi za gubitke hipoteze na pojedinim primjerima?

- ☐ A $L^1 = L^3 = 0, L^2 = L^4 < 1$ ☐ C $L^1 = L^4 = 1, L^2 < L^3$
☐ B $L^1 = L^4 < L^2 = L^3$ ☐ D $L^1 = L^2 = 1 < L^3 < L^4$

- 6 (T) Multikolinearnost značajki jedan je od problema koji može nastupiti kod primjene modela regresije na stvarnim podatcima. Efekt multikolinearnosti i savršene multikolinearnosti dobro je uočljiv kod optimizacijskoga postupka običnih najmanjih kvadrata (OLS) kada se on provodi izračunom pseudoinverza matrice dizajna. Neka je m broj značajki, Φ je matrica dizajna i $\mathbf{G} = \Phi^T \Phi$ je Gramova matrica. Koji je efekt savršene multikolinearnosti kod postupka OLS?

- ☐ A $\text{rang}(\Phi) = N$, no $\text{rang}(\mathbf{G}) < N$, pa \mathbf{G} ima pseudoinverz, ali nema numerički stabilan inverz
☐ B $\text{rang}(\Phi) < m + 1$, \mathbf{G} nema puni rang i nema inverz, no ima pseudoinverz koji nije numerički stabilan
☐ C Φ ima puni rang, $\text{rang}(\mathbf{G}) > m$ i \mathbf{G} ima inverz, ali s visokim kondicijskim brojem
☐ D Φ nema puni rang, $\text{rang}(\mathbf{G}) < m + 1$ i \mathbf{G} nema pseudoinverz

Cjelina 2: Linearni klasifikacijski modeli (8 pitanja)

- 7 (N) Na skupu označenih primjera \mathcal{D} trenirali smo model logističke regresije. Dobili smo neki vektor težina \mathbf{w} i pomak $w_0 = 3.15$. Tako naučenom modelu neki primjer \mathbf{x} , čija je oznaka u skupu primjera $y = 0$, nanosi gubitak unakrsne entropije od $L(0, h(\mathbf{x})) = 0.5$. Koliki gubitak unakrsne entropije bi nanosio primjer \mathbf{x} kada bismo njegove značajke pomnožili sa dva i promijenili mu oznaku?

- ☐ A 2.54 ☐ B 7.11 ☐ C 4.03 ☐ D 1.19

- 8 (N) Model logističke regresije treniramo stohastičkim gradijentnim spustom. Primjere iz dvodimenzijanskog ulaznog prostora preslikali smo u prostor značajki funkcijom $\phi(\mathbf{x}) = (1, x_1, x_2, x_1 x_2)$. U jednoj iteraciji treniranja modela vektor parametara jednak je $\mathbf{w} = (0.1, 0.5, -2, -0.5)$. Koliko u toj iteraciji iznosi L_2 -norma gradijenta gubitka za primjer $(\mathbf{x}, y) = ((1, -1), 1)$?

- ☐ A 0.09 ☐ B 0.22 ☐ C 1.42 ☐ D 0.50

- 9 (P) Na primjerima iz dvodimenzijanskog ulaznog prostora treniramo L_2 -regulariziranu logističku regresiju. Neka su $\mathbf{w}_0 = (1, -4, 4)$, $\mathbf{w}_1 = (1, -4, 6)$, $\mathbf{w}_2 = (1, -1, 7)$, $\mathbf{w}_3 = (1, -7, 1)$ i $\mathbf{w}_4 = (1, -7, -3)$ vektori u prostoru parametara. Neka je $E(\mathbf{w}|\mathcal{D})$ neregularizirana pogreška unakrsne entropije na skupu za učenje \mathcal{D} . Pritom je \mathbf{w}_0 minimizator funkcije $E(\mathbf{w}|\mathcal{D})$ te vrijedi $E(\mathbf{w}_1|\mathcal{D}) = E(\mathbf{w}_2|\mathcal{D}) = E(\mathbf{w}_3|\mathcal{D})$. Napravite skicu izokontura funkcije pogreške u potprostoru $w_1 \times w_2$. Za treniranje modela koristimo gradijentni spust s linijskim pretraživanjem uz regularizacijski faktor $\lambda = 100$. Za tako naučen model vrijednost regularizacijskog izraza $\frac{\lambda}{2} \|\mathbf{w}\|^2$ jednaka je 400. Međutim, broj koraka gradijentnog spusta (broj poziva linijskog pretraživanja) ovisi o tome koliko će spust krivudati, a to ovisi o odabiru inicijalnih parametara. Kao moguće inicijalne parametre razmotrite vektore \mathbf{w}_1 – \mathbf{w}_4 . S kojim inicijalnim parametarima će algoritam gradijentnog spusta konvergirati u najmanjem broju koraka?

- ☐ A \mathbf{w}_2 ☐ B \mathbf{w}_3 ☐ C \mathbf{w}_1 ☐ D \mathbf{w}_4

- 10 (T) Za optimizaciju parametara poopćenih linearnih modela može se koristiti stohastički gradijentni spust, odnosno pravilo LMS. Neka je (\mathbf{x}, y) označeni primjer za koji radimo ažuriranje težina pomoću pravila LMS. Što možemo reći o razlici između novih (ažuriranih) i starih težina (težina prije ažuriranja)?

- ☐ A Razlika je to manja što je oznaka y bliže jedinici
☐ B Razlika je to manja što je vektor $\phi(\mathbf{x})$ bliži ishodištu
☐ C Razlika je to veća što je stopa učenja η bliža jedinici
☐ D Razlika je to veća što je izlaz modela $h(\mathbf{x})$ bliži nuli

11 (T) Višeklasni problem može se riješiti binarnim klasifikatorom uz primjenu sheme OVO ili sheme OVR. Obje sheme imaju svoje prednosti i nedostatke. Pretpostavite da raspolažemo sa K klasa i da svaka klasa ima N/K primjera, gdje je N ukupan broj primjera u skupu za učenje. **Što su prednosti odnosno nedostatci OVO i OVR sheme u takvom slučaju?**

- ☐ A OVR treba K puta više klasifikatora nego OVO, ali su kod OVO pozitivne klase $K/2$ puta manje zastupljene nego OVR
- ☐ B OVO iziskuje $(K - 1)/2$ puta više parametara nego OVR, ali svaki OVR klasifikator ima $K - 1$ puta manje pozitivnih primjera nego negativnih
- ☐ C OVR iziskuje $K - 1$ puta više klasifikatora od sheme OVO, ali kod OVO pozitivne klase imaju $K - 1$ puta manje primjera nego kod OVR
- ☐ D OVO svaki klasifikator trenira s $K/2$ puta manje primjera nego OVR, ali pozitivne klase kod OVR imaju K puta manje primjera nego kod OVO

12 (N) Raspolažemo označenim skupom primjera iz triju klasa ($K = 3$) u trodimenzijskome ulaznom prostoru ($n = 3$). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer $\mathbf{x} = (-4, 1, -3)$ s oznakom $\mathbf{y} = (0, 1, 0)$. **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

- ☐ A 6.00 ☐ B 4.02 ☐ C 12.02 ☐ D 8.00

13 (P) Skup za učenje čine sljedeći označeni primjeri:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((-2, 3), 0), ((-1, 2), 0), ((0, 1), 0), ((0, 0), 0), ((1, 1), 0), ((1, -1), 1), ((2, 0), 1)\}$$

Na skupu \mathcal{D} treniramo logističku regresiju (LR) i stroj potpornih vektora s tvrdom marginom (SVM). Dodatno, treniramo model linearne regresije (LINR), gdje izlaz tog modela koristimo za klasifikaciju, tj. $h(\mathbf{x}) = \mathbf{1}\{\mathbf{w}^T \mathbf{x} \geq 0\}$. Za modele SVM i LINR umjesto oznake $y = 0$ koristimo oznaku $y = -1$. Za treniranje modela LR koristimo dovoljan broj iteracija tako da možemo pretpostaviti da je dobivena pogreška unakrsne entropije praktički jednaka nuli. Razmotrite primjer $\mathbf{x}^{(7)} = (2, 0)$. Neka je $d(m)$ udaljenost primjera $\mathbf{x}^{(7)}$ od granice između klasa dobivene modelom m . **Što od navedenog vrijedi za tu udaljenost?**

- ☐ A $d(\text{SVM}) < d(\text{LR}) < d(\text{LINR})$ ☐ C $d(\text{LINR}) < d(\text{LR}) < d(\text{SVM})$
- ☐ B $d(\text{SVM}) < d(\text{LINR}) < d(\text{LR})$ ☐ D $d(\text{LR}) < d(\text{SVM}) < d(\text{LINR})$

14 (N) Raspolažemo sljedećim skupom za učenje u dvodimenzijskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((-1, 4), +1), ((2, -3), -1), ((2, 5), -1)\}$$

Na ovom skupu treniramo perceptron. Pritom koristimo funkciju preslikavanja u šesterodimenzijski prostor značajki, definiranu na sljedeći način:

$$\phi(\mathbf{x}) = (1, x_1, x_2, x_1 x_2, x_1^2, x_2^2)$$

Početne težine perceptrona neka su $\mathbf{w} = (1, 0, -1, 2, -3, 0)$. **Koliko iznosi empirijska pogreška perceptrona na skupu za učenje prije početka treniranja (dakle, s početnim težinama)?**

- ☐ A 96 ☐ B 100 ☐ C 18 ☐ D 40

Cjelina 3: SVM, jezgrene i neparametarske metode (8 pitanja)

- 15 (T) Optimizacijski problem algoritma SVM može se postaviti u formulaciji meke ili tvrde margine te u primarnoj ili dualnoj formulaciji. Ovisno o formulaciji, kvadratni program sadrži različit broj varijabli po kojima optimiramo (optimizacijske varijable). **Ako matrica dizajna ima više redaka nego stupaca, koja formulacija ima najmanje optimizacijskih varijabli?**

☐ A Dualni problem meke margine ☐ C Primarni problem tvrde margine
☐ B Dualni problem tvrde margine ☐ D Primarni problem meke margine

- 16 (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((0, 0), -1), ((-1, -1), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1))\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa $C = 1$. Kod modela s mekom marginom za dualne koeficijente vrijedi $\alpha_1 = 1$, $\alpha_2 > 0$, $\alpha_3 > 0$, $\alpha_4 > 0$ i $\alpha_5 = 1$. Skicirajte tvrdu i meku marginu u ulaznome prostoru. **Koliko je meka margina veća od tvrde margine?**

☐ A $\frac{1}{6}\sqrt{2}$ puta ☐ B $\frac{2}{5}\sqrt{10}$ puta ☐ C $\frac{3}{5}\sqrt{10}$ puta ☐ D $\frac{4}{5}\sqrt{10}$ puta

- 17 (N) Rješavamo problem određivanja podrijetla pojedinih riječi u jeziku: za svaku riječ trebamo odrediti je li engleskog ($y = 1$) ili francuskog ($y = 0$) podrijetla. Problem rješavamo logističkom regresijom izvedenom kao rijetki jezgreni stroj, gdje za bazne funkcije koristimo jezgru κ nad znakovnim nizovima. Funkcija κ definirana je kao $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$, gdje su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Na primjer, $\kappa(\text{water}, \text{eau}) = 2/6 = 0.33$. Skup za učenje je sljedeći:

$$\mathcal{D} = \{(\mathbf{x}, y)\}_i = \{(\text{water}, 1), (\text{eau}, 0), (\text{dog}, 1), (\text{chien}, 0), (\text{paperclip}, 1), (\text{trombone}, 0), (\text{chance}, 1), (\text{hasard}, 0)\}$$

Treniranjem rijetkoga jezgrenog stroja dobili smo vektor težina $\mathbf{w} = (-0.5, 0, 0, 0, -3.5, 0, 1, 0, 1)$. Razmotrite primjer $(\mathbf{x}, y) = (\text{nounours}, 0)$. **Koliko iznosi gubitak modela na primjeru (\mathbf{x}, y) ?**

☐ A 0.359 ☐ B 0.552 ☐ C 0.795 ☐ D 0.456

- 18 (T) Algoritmi strojnog učenja mogu biti parametarski ili neparametarski. **Što je karakteristika neparametarskih algoritama strojnog učenja?**

☐ A Složenost modela raste s normom vektora parametara
☐ B Broj značajki ne ovisi o dimenziji ulaznog prostora
☐ C Svaki primjer ima globalan utjecaj na izgled hipoteze
☐ D Broj parametara ovisi o broju primjera

- 19 (N) U ulaznome prostoru dimenzije $n = 3$ trenirali smo model SVM-a s linearnom jezgrom. Potporne vektore naučenog modela čine označeni primjeri $((2, -5, 15), -1)$, $((1, 8, -305), -1)$ i $((1, -6, 225), +1)$, a njima odgovarajući dualni koeficijenti su $\alpha_1 = 0.5$, $\alpha_2 = 0.8$ i $\alpha_3 = 0.9$. Treniranje smo proveli na skaliranim značajkama: svaku smo značajku x_j standardizirali primjenom transformacije $\frac{x_j - \mu_j}{\sigma_j}$, gdje su μ_j i σ_j srednja vrijednost odnosno varijanca značajke x_j u skupu označenih podataka \mathcal{D} . Parametri skaliranja su $\boldsymbol{\mu} = (15, -2, 100)$ i $\boldsymbol{\sigma} = (4, 1, 12)$. Model SVM-a koristimo za predikciju klase primjera $\mathbf{x} = (1, 2, -30)$. **Koliko će se promijeniti izlaz modela ako kod predikcije propustimo skalirati značajke primjera \mathbf{x} ?**

☐ A -373.22 ☐ B -739.13 ☐ C +907.43 ☐ D +541.53

- 20 (P) Neka je $\mathcal{H}_{C, \gamma}$ model SVM-a s Gaussovom jezgrom. Hiperparametri tog modela su regularizacijski faktor C i preciznost jezgre γ . Odabir modela provodimo unakrsnom provjerom i to pretraživanjem po rešetci za sljedeće vrijednosti hiperparametara:

$$C = \{2^{-5}, 2^{-4}, \dots, 2^4, 2^5\}$$
$$\gamma = \{10^{-5}, 10^{-4}, \dots, 10^4, 10^5\}$$

Za model sa $C = 2^{-2}$ i $\gamma = 10^1$ utvrdili smo da je podnaučen, a za model sa $C = 2^1$ i $\gamma = 10^1$ utvrdili smo da je prenaučan. **Koliko modela još ima smisla ispitati jer su moguće optimalni?**

☐ A 10 ☐ B 96 ☐ C 68 ☐ D 25

- 21 (N) Treniramo SVM s Gaussovom jezgrenom funkcijom. Model treniramo na skupu od $N = 5$ označenih primjera. Vektor oznaka je $\mathbf{y} = (+1, +1, -1, -1, +1)$. Euklidske udaljenosti između primjera dane su sljedećom matricom udaljenosti:

$$\mathbf{D} = \begin{pmatrix} 0.0 & 7.48 & 6.16 & 13.42 & 12.21 \\ 7.48 & 0.0 & 12.73 & 20.1 & 14.18 \\ 6.16 & 12.73 & 0.0 & 10.49 & 9.95 \\ 13.42 & 20.1 & 10.49 & 0.0 & 20.02 \\ 12.21 & 14.18 & 9.95 & 20.02 & 0.0 \end{pmatrix}$$

Treniranjem uz $C = 10$ i $\gamma = 0.001$ za vektor dualnih parametara dobili smo $\boldsymbol{\alpha} = (10, 0, 10, 2.779, 2.779)$. **Koliko iznosi gubitak zglobnice ovako naučenog modela SVM za prvi primjer, $L(y^{(1)}, h(\mathbf{x}^{(1)}))$?**

- ☐ A 0.24 ☐ B 1.64 ☐ C 1.18 ☐ D 0.03

- 22 (P) Na 500 primjera sa 80 značajki treniramo rijetki jezgreni stroj s Gausovim jezgrama. Sve Gaussove jezgre imaju istu varijancu. Nakon treniranja, dobivamo model koji ima 38 prototipa. **Koliko parametara moramo optimirati te koliko parametara ima naučeni model?**

- ☐ A Optimiramo 81 parametar, a naučeni model ima 3040 parametara
☐ B Optimiramo 81 parametar, a naučeni model ima 3079 parametara
☐ C Optimiramo 501 parametara, a naučeni model ima 3079 parametara
☐ D Optimiramo 501 parametara, a naučeni model ima 3040 parametara

Međuispit iz Strojnog učenja 1 (ak. god. 2022./2023.)

– NEKORIGIRANA VERZIJA –

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 35% bodova na predmetu). Pitanja nose po 1 bod, a 1/3 boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **180 minuta**. Primjerak ispita morate predati zajedno sa svojim rješenjima.

Cjelina 1: Osnovni koncepti i linearna regresija (6 pitanja)

- 1** (T) Modeli strojnog učenja općenito su različite složenosti. S porastom složenosti modela raste vjerojatnost da model bude prenaučan. Ta vjerojatnost raste s količinom šuma u podacima. **Zašto šum u podacima za učenje može dovesti do prenaučnosti klasifikacijskog modela?**
- ☐ A Zbog šuma granica između klasa izgleda nelinearnijom nego što ona to zapravo jest, pa primjeri blizu granice znatno više doprinose pogrešci učenja nego primjeri koji su udaljeni od granice
- ☐ B Zbog šuma su oznake nekih primjera u skupu za učenje pogrešne, pa sve hipoteze iz modela imaju na tom skupu pogrešku koja je veća od nula, a još veća na ispitnom skupu
- ☐ C Povećanjem količine šuma granica između klasa postaje sve nelinearnija, pa raste i složenost modela te dobivena hipoteza očekivano neće odgovarati granici između klasa na ispitnom skupu
- ☐ D Efekt šuma je slučajna, pa će hipoteza koja se previše prilagodi šumu na skupu za učenje očekivano imati veliku pogrešku na ispitnom skupu gdje je šum drugačiji ili ga nema
- 2** (T) Multikolinearnost značajki jedan je od problema koji može nastupiti kod primjene modela regresije na stvarnim podacima. Efekt multikolinearnosti i savršene multikolinearnosti dobro je uočljiv kod optimizacijskoga postupka običnih najmanjih kvadrata (OLS) kada se on provodi izračunom pseudoinverza matrice dizajna. Neka je m broj značajki, Φ je matrica dizajna i $\mathbf{G} = \Phi^T \Phi$ je Gramova matrica. **Koji je efekt savršene multikolinearnosti kod postupka OLS?**
- ☐ A Φ ima puni rang, $\text{rang}(\mathbf{G}) > m$ i \mathbf{G} ima inverz, ali s visokim kondicijskim brojem
- ☐ B $\text{rang}(\Phi) = N$, no $\text{rang}(\mathbf{G}) < N$, pa \mathbf{G} ima pseudoinverz, ali nema numerički stabilan inverz
- ☐ C Φ nema puni rang, $\text{rang}(\mathbf{G}) < m + 1$ i \mathbf{G} nema pseudoinverz
- ☐ D $\text{rang}(\Phi) < m + 1$, \mathbf{G} nema puni rang i nema inverz, no ima pseudoinverz koji nije numerički stabilan
- 3** (P) Razmatramo klasifikacijski problem u ulaznome prostoru $\mathcal{X} = \mathbb{Z}^2$. Skup označenih primjera je $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((0, 0), 0), ((0, 2), 0), ((0, -1), 0), ((-1, 0), 1), ((0, 1), 1), ((1, 0), 1)\}$. Razmatramo sljedeće modele, parametrizirane sa $\boldsymbol{\theta} \in \mathbb{R}^{n+1}$:

$$\mathcal{H}_1 : h_1(\mathbf{x}; \boldsymbol{\theta}) = \mathbf{1}\{\boldsymbol{\theta}^T \mathbf{x} \geq 0\}$$

$$\mathcal{H}_2 : h_2(\mathbf{x}; \boldsymbol{\theta}) = \mathbf{1}\{(x_1 - \theta_1)^2 + (x_2 - \theta_2)^2 \geq \theta_0^2\}$$

Pored ova dva modela, razmatramo i njihove kombinacije, modele \mathcal{H}_3 i \mathcal{H}_4 . Neka je $\mathcal{H}_3 = \mathcal{H}_1 \cup \mathcal{H}_2$ te neka je \mathcal{H}_4 skup funkcija definiranih kao $h_4(\mathbf{x}; \boldsymbol{\theta}) = h_1(\mathbf{x}) \cdot h_2(\mathbf{x})$. Neka je E_k minimalna empirijska pogreška koja se modelom \mathcal{H}_k može ostvariti na skupu \mathcal{D} , tj. $E_k = \arg\min_{h \in \mathcal{H}_k} E(h|\mathcal{D})$. **Koji odnosi vrijede između minimalnih empirijskih pogrešaka ovih modela?**

- ☐ A $E_1 > E_2 > E_3 = E_4$ ☐ B $E_1 = E_2 > E_3 = E_4$ ☐ C $E_1 = E_2 = E_3 > E_4$ ☐ D $E_1 > E_2 = E_3 > E_4$

- 4** (P) Raspoložemo modelom \mathcal{H}_α koji ima hiperparametar α kojim se može ugađati složenost modela. Isprobavamo dvije vrijednosti hiperparametra: α_1 i α_2 . Treniramo modele \mathcal{H}_{α_1} i \mathcal{H}_{α_2} te dobivamo hipoteze h_{α_1} i h_{α_2} . Zatim računamo empirijske pogreške tih hipoteza na skupu za učenje \mathcal{D}_u i na skupu za ispitivanje \mathcal{D}_i . Utvrđujemo da vrijedi:

$$E(h_{\alpha_1}|\mathcal{D}_i) - E(h_{\alpha_1}|\mathcal{D}_u) < E(h_{\alpha_2}|\mathcal{D}_i) - E(h_{\alpha_2}|\mathcal{D}_u)$$

Što iz toga možemo zaključiti?

- ☐ A Optimalan model je onaj s hiperparametrom iz intervala $[\alpha_1, \alpha_2]$
- ☐ B Model \mathcal{H}_{α_1} je podnaučen
- ☐ C Model \mathcal{H}_{α_2} je prenaučan
- ☐ D Model \mathcal{H}_{α_1} je manje složenosti od modela \mathcal{H}_{α_2}

- 5 (P) Jednostavnom regresijom modeliramo ovisnost nezavisne varijable y o zavisnoj varijabli x . Model treniramo postupkom običnih najmanjih kvadrata (OLS) na skupu podataka $\mathcal{D} = \{(x^{(i)}, y^{(i)})\} = \{(0, 0), (2, 0), (3, 2), (5, 2)\}$. Neka je h hipoteza koju dobivamo treniranjem modela te neka je L^i gubitak hipoteze h na primjeru $x^{(i)}$, tj. $L^i = L(y^{(i)}, h(x^{(i)}))$. Što vrijedi za gubitke hipoteze na pojedinim primjerima?

- ☐ A $L^1 = L^2 = 1 < L^3 < L^4$
- ☐ B $L^1 = L^4 = 1, L^2 < L^3$
- ☐ C $L^1 = L^4 < L^2 = L^3$
- ☐ D $L^1 = L^3 = 0, L^2 = L^4 < 1$

- 6 (N) Raspoložemo sljedećim skupom primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((1, 0), 1), ((2, -3), 2), ((3, 5), -1), ((5, 0), -4)\}$$

Na ovom skupu gradijentnim spustom trenirali smo L_1 -regularizirani model linearne regresije sa $\lambda = 1$. Dobili smo težine $\mathbf{w} = (2.12, -0.94, -0.08)$. Koliko iznosi L_1 -regularizirana pogreška $E(\mathbf{w}|\mathcal{D})$?

- ☐ A 7.10
- ☐ B 1.58
- ☐ C 0.29
- ☐ D 2.69

Cjelina 2: Linearni klasifikacijski modeli (8 pitanja)

- 7 (P) Skup za učenje čine sljedeći označeni primjeri:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((-2, 3), 0), ((-1, 2), 0), ((0, 1), 0), ((0, 0), 0), ((1, 1), 0), ((1, -1), 1), ((2, 0), 1)\}$$

Na skupu \mathcal{D} treniramo logističku regresiju (LR) i stroj potpornih vektora s tvrdom marginom (SVM). Dodatno, treniramo model linearne regresije (LINR), gdje izlaz tog modela koristimo za klasifikaciju, tj. $h(\mathbf{x}) = \mathbf{1}\{\mathbf{w}^T \mathbf{x} \geq 0\}$. Za modele SVM i LINR umjesto oznake $y = 0$ koristimo oznaku $y = -1$. Za treniranje modela LR koristimo dovoljan broj iteracija tako da možemo pretpostaviti da je dobivena pogreška unakrsne entropije praktički jednaka nuli. Razmotrite primjer $\mathbf{x}^{(7)} = (2, 0)$. Neka je $d(m)$ udaljenost primjera $\mathbf{x}^{(7)}$ od granice između klasa dobivene modelom m . Što od navedenog vrijedi za tu udaljenost?

- ☐ A $d(\text{LR}) < d(\text{SVM}) < d(\text{LINR})$
- ☐ B $d(\text{SVM}) < d(\text{LINR}) < d(\text{LR})$
- ☐ C $d(\text{SVM}) < d(\text{LR}) < d(\text{LINR})$
- ☐ D $d(\text{LINR}) < d(\text{LR}) < d(\text{SVM})$

- 8 (N) Na skupu označenih primjera \mathcal{D} trenirali smo model logističke regresije. Dobili smo neki vektor težina \mathbf{w} i pomak $w_0 = 0.15$. Tako naučenom modelu neki primjer \mathbf{x} , čija je oznaka u skupu primjera $y = 0$, nanosi gubitak unakrsne entropije od $L(0, h(\mathbf{x})) = 0.274$. Koliki gubitak unakrsne entropije bi nanosio primjer \mathbf{x} kada bismo njegove značajke pomnožili sa dva i promijenili mu oznaku?

- ☐ A 4.03
- ☐ B 2.54
- ☐ C 7.11
- ☐ D 1.19

- 9 (T) Za optimizaciju parametara poopćenih linearnih modela može se koristiti stohastički gradijentni spust, odnosno pravilo LMS. Neka je (\mathbf{x}, y) označeni primjer za koji radimo ažuriranje težina pomoću pravila LMS. Što možemo reći o razlici između novih (ažuriranih) i starih težina (težina prije ažuriranja)?

- ☐ A Razlika je to manja što je oznaka y bliže jedinici
- ☐ B Razlika je to veća što je izlaz modela $h(\mathbf{x})$ bliži nuli
- ☐ C Razlika je to veća što je stopa učenja η bliža jedinici
- ☐ D Razlika je to manja što je vektor $\phi(\mathbf{x})$ bliži ishodištu

- 10 (N) Raspoložemo označenim skupom primjera iz triju klasa ($K = 3$) u trodimenzijskome ulaznom prostoru ($n = 3$). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer $\mathbf{x} = (-4, -1, -3)$ s oznakom $\mathbf{y} = (0, 0, 1)$. **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

- ☐ A 12.02 ☐ B 6.00 ☐ C 4.02 ☐ D 8.00

- 11 (N) Model logističke regresije treniramo stohastičkim gradijentnim spustom. Primjere iz dvodimenzijskog ulaznog prostora preslikali smo u prostor značajki funkcijom $\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2)$. U jednoj iteraciji treniranja modela vektor parametara jednak je $\mathbf{w} = (0.1, 0.5, -2, -0.5)$. **Koliko u toj iteraciji iznosi L_2 -norma gradijenta gubitka za primjer $(\mathbf{x}, y) = ((1, -1), 1)$?**

- ☐ A 0.09 ☐ B 0.22 ☐ C 0.50 ☐ D 1.42

- 12 (P) Na primjerima iz dvodimenzijskoga ulaznog prostora treniramo L_2 -regulariziranu logističku regresiju. Neka su $\mathbf{w}_0 = (1, -4, 4)$, $\mathbf{w}_1 = (1, -4, 6)$, $\mathbf{w}_2 = (1, -1, 7)$, $\mathbf{w}_3 = (1, -7, 1)$ i $\mathbf{w}_4 = (1, -7, -3)$ vektori u prostoru parametara. Neka je $E(\mathbf{w}|\mathcal{D})$ neregularizirana pogreška unakrsne entropije na skupu za učenje \mathcal{D} . Pritom je \mathbf{w}_0 minimizator funkcije $E(\mathbf{w}|\mathcal{D})$ te vrijedi $E(\mathbf{w}_1|\mathcal{D}) = E(\mathbf{w}_2|\mathcal{D}) = E(\mathbf{w}_3|\mathcal{D})$. Napravite skicu izokontura funkcije pogreške u potprostoru $w_1 \times w_2$. Za treniranje modela koristimo gradijentni spust s linijskim pretraživanjem uz regularizacijski faktor $\lambda = 100$. Za tako naučen model vrijednost regularizacijskog izraza $\frac{\lambda}{2}\|\mathbf{w}\|^2$ jednaka je 400. Međutim, broj koraka gradijentnog spusta (broj poziva linijskog pretraživanja) ovisi o tome koliko će spust krivudati, a to ovisi o odabiru inicijalnih parametara. Kao moguće inicijalne parametre razmotrite vektore \mathbf{w}_1 – \mathbf{w}_4 . **S kojim inicijalnim parametarima će algoritam gradijentnog spusta konvergirati u najmanjem broju koraka?**

- ☐ A \mathbf{w}_1 ☐ B \mathbf{w}_2 ☐ C \mathbf{w}_4 ☐ D \mathbf{w}_3

- 13 (N) Raspoložemo sljedećim skupom za učenje u dvodimenzijskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((-1, 4), +1), ((2, -3), -1), ((2, 5), -1)\}$$

Na ovom skupu treniramo perceptron. Pritom koristimo funkciju preslikavanja u šesterodimenzijski prostor značajki, definiranu na sljedeći način:

$$\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2, x_1^2, x_2^2)$$

Početne težine perceptrona neka su $\mathbf{w} = (1, 0, -1, 2, 3, 2)$. **Koliko iznosi empirijska pogreška perceptrona na skupu za učenje prije početka treniranja (dakle, s početnim težinama)?**

- ☐ A 96 ☐ B 40 ☐ C 18 ☐ D 100

- 14 (T) Višeklasni problem može se riješiti binarnim klasifikatorom uz primjenu sheme OVO ili sheme OVR. Obje sheme imaju svoje prednosti i nedostatke. Pretpostavite da raspoložemo sa K klasa i da svaka klasa ima N/K primjera, gdje je N ukupan broj primjera u skupu za učenje. **Što su prednosti odnosno nedostatci OVO i OVR sheme u takvom slučaju?**

- ☐ A OVR iziskuje $K - 1$ puta više klasifikatora od sheme OVO, ali kod OVO pozitivne klase imaju $K - 1$ puta manje primjera nego kod OVR
- ☐ B OVO svaki klasifikator trenira s $K/2$ puta manje primjera nego OVR, ali pozitivne klase kod OVR imaju K puta manje primjera nego kod OVO
- ☐ C OVO iziskuje $(K - 1)/2$ puta više parametara nego OVR, ali svaki OVR klasifikator ima $K - 1$ puta manje pozitivnih primjera nego negativnih
- ☐ D OVR treba K puta više klasifikatora nego OVO, ali su kod OVO pozitivne klase $K/2$ puta manje zastupljene nego OVR

Cjelina 3: SVM, jezgrene i neparametarske metode (8 pitanja)

- 15** (T) Optimizacijski problem algoritma SVM može se postaviti u formulaciji meke ili tvrde margine te u primarnoj ili dualnoj formulaciji. Ovisno o formulaciji, kvadratni program sadrži različit broj varijabli po kojima optimiramo (optimizacijske varijable). **Ako matrica dizajna ima više redaka nego stupaca, koja formulacija ima najmanje optimizacijskih varijabli?**

☐ A Dualni problem meke margine ☐ C Primarni problem meke margine
☐ B Primarni problem tvrde margine ☐ D Dualni problem tvrde margine

- 16** (P) Neka je $\mathcal{H}_{C,\gamma}$ model SVM-a s Gaussovom jezgrom. Hiperparametri tog modela su regularizacijski faktor C i preciznost jezgre γ . Odabir modela provodimo unakrsnom provjerom i to pretraživanjem po rešetci za sljedeće vrijednosti hiperparametara:

$$C = \{2^{-5}, 2^{-4}, \dots, 2^4, 2^5\}$$
$$\gamma = \{10^{-5}, 10^{-4}, \dots, 10^4, 10^5\}$$

Već ranije smo utvrdili da je model sa $C = 2^{-2}$ i $\gamma = 10^{-1}$ podnaučen, a da je model sa $C = 2^1$ i $\gamma = 10^1$ prenaučeni. Za sve ostale modele ne znamo jesu li prenaučeni, podnaučeni ili optimalni. **Koliko modela još ima smisla ispitati jer su moguće optimalni?**

☐ A 10 ☐ B 25 ☐ C 76 ☐ D 96

- 17** (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((0, 0), -1), ((-1, -1), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1))\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa $C = 1$. Kod modela s mekom marginom za dualne koeficijente vrijedi $\alpha_1 = 1$, $\alpha_2 > 0$, $\alpha_3 > 0$, $\alpha_4 > 0$ i $\alpha_5 = 1$. Skicirajte tvrdu i meku marginu u ulaznome prostoru. **Koliko je meka margina veća od tvrde margine?**

☐ A $\frac{3}{5}\sqrt{10}$ puta ☐ B $\frac{1}{6}\sqrt{2}$ puta ☐ C $\frac{4}{5}\sqrt{10}$ puta ☐ D $\frac{2}{5}\sqrt{10}$ puta

- 18** (P) Na 900 primjera sa 50 značajki treniramo rijetki jezgreni stroj s Gausovim jezgrama. Sve Gaussove jezgre imaju istu varijancu. Nakon treniranja, dobivamo model koji ima 52 prototipa. **Koliko parametara moramo optimirati te koliko parametara ima naučeni model?**

☐ A Optimiramo 51 parametar, a naučeni model ima 2653 parametara
☐ B Optimiramo 901 parametar, a naučeni model ima 2600 parametara
☐ C Optimiramo 51 parametar, a naučeni model ima 2600 parametara
☐ D Optimiramo 901 parametar, a naučeni model ima 2653 parametara

- 19** (N) Treniramo SVM s Gaussovom jezgrenom funkcijom. Model treniramo na skupu od $N = 5$ označenih primjera. Vektor oznaka je $\mathbf{y} = (+1, +1, -1, -1, +1)$. Euklidske udaljenosti između primjera dane su sljedećom matricom udaljenosti:

$$\mathbf{D} = \begin{pmatrix} 0.0 & 7.48 & 6.16 & 13.42 & 12.21 \\ 7.48 & 0.0 & 12.73 & 20.1 & 14.18 \\ 6.16 & 12.73 & 0.0 & 10.49 & 9.95 \\ 13.42 & 20.1 & 10.49 & 0.0 & 20.02 \\ 12.21 & 14.18 & 9.95 & 20.02 & 0.0 \end{pmatrix}$$

Treniranjem uz $C = 10$ i $\gamma = 0.001$ za vektor dualnih parametara dobili smo $\boldsymbol{\alpha} = (10, 0, 10, 2.779, 2.779)$. **Koliko iznosi gubitak zglobnice ovako naučenog modela SVM za prvi primjer, $L(y^{(1)}, h(\mathbf{x}^{(1)}))$?**

☐ A 0.03 ☐ B 0.24 ☐ C 1.64 ☐ D 1.18

- 20** (N) Rješavamo problem određivanja podrijetla pojedinih riječi u jeziku: za svaku riječ trebamo odrediti je li engleskog ($y = 1$) ili francuskog ($y = 0$) podrijetla. Problem rješavamo logističkom regresijom izvedenom kao rijetki jezgreni stroj, gdje za bazne funkcije koristimo jezgru κ nad znakovnim nizovima. Funkcija κ definirana je

kao $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$, gdje su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Na primjer, $\kappa(\text{water}, \text{eau}) = 2/6 = 0.33$. Skup za učenje je sljedeći:

$$\mathcal{D} = \{(\mathbf{x}, y)\}_i = \{(\text{water}, 1), (\text{eau}, 0), (\text{dog}, 1), (\text{chien}, 0), (\text{paperclip}, 1), (\text{trombone}, 0), (\text{chance}, 1), (\text{hasard}, 0)\}$$

Treniranjem rijetkoga jezgrenog stroja dobili smo vektor težina $\mathbf{w} = (-0.5, 0, 0, 0, -3.5, 1, 0, 0, 1)$. Razmotrite primjer $(\mathbf{x}, y) = (\text{nounours}, 0)$. **Koliko iznosi gubitak modela na primjeru (\mathbf{x}, y) ?**

- ☐ A 0.552 ☐ B 0.456 ☐ C 0.359 ☐ D 0.795

- 21** (N) U ulaznome prostoru dimenzije $n = 3$ trenirali smo model SVM-a s linearnom jezgrom. Potporne vektore naučenog modela čine označeni primjeri $((2, -5, 15), -1)$, $((1, 8, -305), -1)$ i $((1, -6, 225), +1)$, a njima odgovarajući dualni koeficijenti su $\alpha_1 = 0.5$, $\alpha_2 = 0.8$ i $\alpha_3 = 0.9$. Treniranje smo proveli na skaliranim značajkama: svaku smo značajku x_j standardizirali primjenom transformacije $\frac{x_j - \mu_j}{\sigma_j}$, gdje su μ_j i σ_j srednja vrijednost odnosno varijanca značajke x_j u skupu označenih podataka \mathcal{D} . Parametri skaliranja su $\boldsymbol{\mu} = (15, -2, 100)$ i $\boldsymbol{\sigma} = (4, 1, 12)$. Model SVM-a koristimo za predikciju klase primjera $\mathbf{x} = (1, -2, 5)$. **Koliko će se promijeniti izlaz modela ako kod predikcije propustimo skalirati značajke primjera \mathbf{x} ?**

- ☐ A -373.22 ☐ B +541.53 ☐ C +907.43 ☐ D -739.13

- 22** (T) Algoritmi strojnog učenja mogu biti parametarski ili neparametarski. **Što je karakteristika neparametarskih algoritama strojnog učenja?**

- ☐ A Hiperparametri nemaju utjecaja na složenost modela
☐ B Broj parametara ovisi o broju primjera
☐ C Broj značajki ne ovisi o dimenziji ulaznog prostora
☐ D Složenost modela raste s normom vektora parametara

Međuispit iz Strojnog učenja 1 (ak. god. 2022./2023.)

– NEKORIGIRANA VERZIJA –

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 35% bodova na predmetu). Pitanja nose po 1 bod, a 1/3 boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **180 minuta**. Primjerak ispita morate predati zajedno sa svojim rješenjima.

Cjelina 1: Osnovni koncepti i linearna regresija (6 pitanja)

- 1** (P) Razmatramo klasifikacijski problem u ulaznome prostoru $\mathcal{X} = \mathbb{Z}^2$. Skup označenih primjera je $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((0, 0), 0), ((0, 2), 0), ((0, -1), 0), ((-1, 0), 1), ((0, 1), 1), ((1, 0), 1)\}$. Razmatramo sljedeće modele, parametrizirane sa $\boldsymbol{\theta} \in \mathbb{R}^{n+1}$:

$$\mathcal{H}_1 : h_1(\mathbf{x}; \boldsymbol{\theta}) = \mathbf{1}\{\boldsymbol{\theta}^T \mathbf{x} \geq 0\}$$

$$\mathcal{H}_2 : h_2(\mathbf{x}; \boldsymbol{\theta}) = \mathbf{1}\{(x_1 - \theta_1)^2 + (x_2 - \theta_2)^2 \geq \theta_0^2\}$$

Pored ova dva modela, razmatramo i njihove kombinacije, modele \mathcal{H}_3 i \mathcal{H}_4 . Neka je $\mathcal{H}_3 = \mathcal{H}_1 \cup \mathcal{H}_2$ te neka je \mathcal{H}_4 skup funkcija definiranih kao $h_4(\mathbf{x}; \boldsymbol{\theta}) = h_1(\mathbf{x}) \cdot h_2(\mathbf{x})$. Neka je E_k minimalna empirijska pogreška koja se modelom \mathcal{H}_k može ostvariti na skupu \mathcal{D} , tj. $E_k = \arg\min_{h \in \mathcal{H}_k} E(h|\mathcal{D})$. **Koji odnosi vrijede između minimalnih empirijskih pogrešaka ovih modela?**

- ☐ A $E_1 > E_2 = E_3 > E_4$ ☐ B $E_1 = E_2 > E_3 = E_4$ ☐ C $E_1 > E_2 > E_3 = E_4$ ☐ D $E_1 = E_2 = E_3 > E_4$

- 2** (T) Multikolinearnost značajki jedan je od problema koji može nastupiti kod primjene modela regresije na stvarnim podacima. Efekt multikolinearnosti i savršene multikolinearnosti dobro je uočljiv kod optimizacijskoga postupka običnih najmanjih kvadrata (OLS) kada se on provodi izračunom pseudoinverza matrice dizajna. Neka je m broj značajki, Φ je matrica dizajna i $\mathbf{G} = \Phi^T \Phi$ je Gramova matrica. **Koji je efekt savršene multikolinearnosti kod postupka OLS?**

- ☐ A $\text{rang}(\Phi) = N$, no $\text{rang}(\mathbf{G}) < N$, pa \mathbf{G} ima pseudoinverz, ali nema numerički stabilan inverz
☐ B Φ nema puni rang, $\text{rang}(\mathbf{G}) < m + 1$ i \mathbf{G} nema pseudoinverz
☐ C Φ ima puni rang, $\text{rang}(\mathbf{G}) > m$ i \mathbf{G} ima inverz, ali s visokim kondicijskim brojem
☐ D $\text{rang}(\Phi) < m + 1$, \mathbf{G} nema puni rang i nema inverz, no ima pseudoinverz koji nije numerički stabilan

- 3** (P) Jednostavnom regresijom modeliramo ovisnost nezavisne varijable y o zavisnoj varijabli x . Model treniramo postupkom običnih najmanjih kvadrata (OLS) na skupu podataka $\mathcal{D} = \{(x^{(i)}, y^{(i)})\} = \{(0, 0), (2, 0), (3, 2), (5, 2)\}$. Neka je h hipoteza koju dobivamo treniranjem modela te neka je L^i gubitak hipoteze h na primjeru $x^{(i)}$, tj. $L^i = L(y^{(i)}, h(x^{(i)}))$. **Što vrijedi za gubitke hipoteze na pojedinim primjerima?**

- ☐ A $L^1 = L^3 = 0, L^2 = L^4 < 1$ ☐ C $L^1 = L^4 < L^2 = L^3$
☐ B $L^1 = L^4 = 1, L^2 < L^3$ ☐ D $L^1 = L^2 = 1 < L^3 < L^4$

- 4** (N) Raspoložemo sljedećim skupom primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((1, 0), 1), ((2, -3), 2), ((3, 5), -1), ((5, 0), -4)\}$$

Na ovom skupu gradijentnim spustom trenirali smo L_1 -regularizirani model linearne regresije sa $\lambda = 1$. Dobili smo težine $\mathbf{w} = (2.12, -0.94, -0.08)$. **Koliko iznosi L_1 -regularizirana pogreška $E(\mathbf{w}|\mathcal{D})$?**

- ☐ A 0.29 ☐ B 2.69 ☐ C 7.10 ☐ D 1.58

- 5 (P) Raspoložemo modelom \mathcal{H}_α koji ima hiperparametar α kojim se može ugađati složenost modela. Isprobavamo dvije vrijednosti hiperparametra: α_1 i α_2 . Treniramo modele \mathcal{H}_{α_1} i \mathcal{H}_{α_2} te dobivamo hipoteze h_{α_1} i h_{α_2} . Zatim računamo empirijske pogreške tih hipoteza na skupu za učenje \mathcal{D}_u i na skupu za ispitivanje \mathcal{D}_i . Utvrđujemo da vrijedi:

$$E(h_{\alpha_1}|\mathcal{D}_i) - E(h_{\alpha_1}|\mathcal{D}_u) < E(h_{\alpha_2}|\mathcal{D}_i) - E(h_{\alpha_2}|\mathcal{D}_u)$$

Što iz toga možemo zaključiti?

- ☐ A Model \mathcal{H}_{α_2} je prenaučten
 - ☐ B Optimalan model je onaj s hiperparametrom iz intervala $[\alpha_1, \alpha_2]$
 - ☐ C Model \mathcal{H}_{α_1} je manje složenosti od modela \mathcal{H}_{α_2}
 - ☐ D Model \mathcal{H}_{α_1} je podnaučten
- 6 (T) Modeli strojnog učenja općenito su različite složenosti. S porastom složenosti modela raste vjerojatnost da model bude prenaučten. Ta vjerojatnost raste s količinom šuma u podacima. **Zašto šum u podacima za učenje može dovesti do prenaučtenosti klasifikacijskog modela?**
- ☐ A Efekt šuma je slučajna, pa će hipoteza koja se previše prilagodi šumu na skupu za učenje očekivano imati veliku pogrešku na ispitnom skupu gdje je šum drugačiji ili ga nema
 - ☐ B Zbog šuma granica između klasa izgleda nelinearnijom nego što ona to zapravo jest, pa primjeri blizu granice znatno više doprinose pogrešci učenja nego primjeri koji su udaljeni od granice
 - ☐ C Zbog šuma su oznake nekih primjera u skupu za učenje pogrešne, pa sve hipoteze iz modela imaju na tom skupu pogrešku koja je veća od nula, a još veća na ispitnom skupu
 - ☐ D Povećanjem količine šuma granica između klasa postaje sve nelinearnija, pa raste i složenost modela te dobivena hipoteza očekivano neće odgovarati granici između klasa na ispitnom skupu

Cjelina 2: Linearni klasifikacijski modeli (8 pitanja)

- 7 (N) Na skupu označenih primjera \mathcal{D} trenirali smo model logističke regresije. Dobili smo neki vektor težina \mathbf{w} i pomak $w_0 = 3.15$. Tako naučenom modelu neki primjer \mathbf{x} , čija je oznaka u skupu primjera $y = 0$, nanosi gubitak unakrsne entropije od $L(0, h(\mathbf{x})) = 0.5$. **Koliki gubitak unakrsne entropije bi nanosio primjer \mathbf{x} kada bismo njegove značajke pomnožili sa dva i promijenili mu oznaku?**
- ☐ A 4.03 ☐ B 1.19 ☐ C 7.11 ☐ D 2.54
- 8 (T) Višeklasni problem može se riješiti binarnim klasifikatorom uz primjenu sheme OVO ili sheme OVR. Obje sheme imaju svoje prednosti i nedostatke. Pretpostavite da raspoložemo sa K klasa i da svaka klasa ima N/K primjera, gdje je N ukupan broj primjera u skupu za učenje. **Što su prednosti odnosno nedostatci OVO i OVR sheme u takvom slučaju?**
- ☐ A OVR treba K puta više klasifikatora nego OVO, ali su kod OVO pozitivne klase $K/2$ puta manje zastupljene nego OVR
 - ☐ B OVR iziskuje $K - 1$ puta više klasifikatora od sheme OVO, ali kod OVO pozitivne klase imaju $K - 1$ puta manje primjera nego kod OVR
 - ☐ C OVO iziskuje $(K - 1)/2$ puta više parametara nego OVR, ali svaki OVR klasifikator ima $K - 1$ puta manje pozitivnih primjera nego negativnih
 - ☐ D OVO svaki klasifikator trenira s $K/2$ puta manje primjera nego OVR, ali pozitivne klase kod OVR imaju K puta manje primjera nego kod OVO
- 9 (T) Za optimizaciju parametara poopćenih linearnih modela može se koristiti stohastički gradijentni spust, odnosno pravilo LMS. Neka je (\mathbf{x}, y) označeni primjer za koji radimo ažuriranje težina pomoću pravila LMS. **Što možemo reći o razlici između novih (ažuriranih) i starih težina (težina prije ažuriranja)?**
- ☐ A Razlika je to manja što je oznaka y bliže jedinici
 - ☐ B Razlika je to veća što je stopa učenja η bliža jedinici
 - ☐ C Razlika je to manja što je vektor $\phi(\mathbf{x})$ bliži ishodištu
 - ☐ D Razlika je to veća što je izlaz modela $h(\mathbf{x})$ bliži nuli

- 10 (P) Skup za učenje čine sljedeći označeni primjeri:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((-2, 3), 0), ((-1, 2), 0), ((0, 1), 0), ((0, 0), 0), ((1, 1), 0), ((1, -1), 1), ((2, 0), 1)\}$$

Na skupu \mathcal{D} treniramo logističku regresiju (LR) i stroj potpornih vektora s tvrdom marginom (SVM). Dodatno, treniramo model linearne regresije (LINR), gdje izlaz tog modela koristimo za klasifikaciju, tj. $h(\mathbf{x}) = \mathbf{1}\{\mathbf{w}^T \mathbf{x} \geq 0\}$. Za modele SVM i LINR umjesto oznake $y = 0$ koristimo oznaku $y = -1$. Za treniranje modela LR koristimo dovoljan broj iteracija tako da možemo pretpostaviti da je dobivena pogreška unakrsne entropije praktički jednaka nuli. Razmotrite primjer $\mathbf{x}^{(7)} = (2, 0)$. Neka je $d(m)$ udaljenost primjera $\mathbf{x}^{(7)}$ od granice između klasa dobivene modelom m . **Što od navedenog vrijedi za tu udaljenost?**

- ☐ A $d(\text{LR}) < d(\text{SVM}) < d(\text{LINR})$ ☐ C $d(\text{SVM}) < d(\text{LINR}) < d(\text{LR})$
☐ B $d(\text{LINR}) < d(\text{LR}) < d(\text{SVM})$ ☐ D $d(\text{SVM}) < d(\text{LR}) < d(\text{LINR})$

- 11 (N) Raspoložemo sljedećim skupom za učenje u dvodimenzijskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((-1, 4), +1), ((2, -3), -1), ((2, 5), -1)\}$$

Na ovom skupu treniramo perceptron. Pritom koristimo funkciju preslikavanja u šesterodimenzijski prostor značajki, definiranu na sljedeći način:

$$\phi(\mathbf{x}) = (1, x_1, x_2, x_1 x_2, x_1^2, x_2^2)$$

Početne težine perceptrona neka su $\mathbf{w} = (1, 0, -1, 2, 3, 2)$. **Koliko iznosi empirijska pogreška perceptrona na skupu za učenje prije početka treniranja (dakle, s početnim težinama)?**

- ☐ A 100 ☐ B 18 ☐ C 40 ☐ D 96

- 12 (N) Model logističke regresije treniramo stohastičkim gradijentnim spustom. Primjere iz dvodimenzijskog ulaznog prostora preslikali smo u prostor značajki funkcijom $\phi(\mathbf{x}) = (1, x_1, x_2, x_1 x_2)$. U jednoj iteraciji treniranja modela vektor parametara jednak je $\mathbf{w} = (0.1, -0.5, -2, 0.5)$. **Koliko u toj iteraciji iznosi L_2 -norma gradijenta gubitka za primjer $(\mathbf{x}, y) = ((1, -1), 1)$?**

- ☐ A 0.50 ☐ B 0.22 ☐ C 1.42 ☐ D 0.09

- 13 (N) Raspoložemo označenim skupom primjera iz triju klasa ($K = 3$) u trodimenzijskome ulaznom prostoru ($n = 3$). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer $\mathbf{x} = (-4, 1, -3)$ s oznakom $y = (0, 1, 0)$. **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

- ☐ A 6.00 ☐ B 8.00 ☐ C 12.02 ☐ D 4.02

- 14 (P) Na primjerima iz dvodimenzijskoga ulaznog prostora treniramo L_2 -regulariziranu logističku regresiju. Neka su $\mathbf{w}_0 = (1, -4, 4)$, $\mathbf{w}_1 = (1, -4, 6)$, $\mathbf{w}_2 = (1, -1, 7)$, $\mathbf{w}_3 = (1, -7, 1)$ i $\mathbf{w}_4 = (1, -7, -3)$ vektori u prostoru parametara. Neka je $E(\mathbf{w}|\mathcal{D})$ neregularizirana pogreška unakrsne entropije na skupu za učenje \mathcal{D} . Pritom je \mathbf{w}_0 minimizator funkcije $E(\mathbf{w}|\mathcal{D})$ te vrijedi $E(\mathbf{w}_1|\mathcal{D}) = E(\mathbf{w}_2|\mathcal{D}) = E(\mathbf{w}_3|\mathcal{D})$. Napravite skicu izokontura funkcije pogreške u potprostoru $w_1 \times w_2$. Za treniranje modela koristimo gradijentni spust s linijskim pretraživanjem uz regularizacijski faktor $\lambda = 100$. Za tako naučen model vrijednost regularizacijskog izraza $\frac{\lambda}{2} \|\mathbf{w}\|^2$ jednaka je 400. Međutim, broj koraka gradijentnog spusta (broj poziva linijskog pretraživanja) ovisi o tome koliko će spust krivudati, a to ovisi o odabiru inicijalnih parametara. Kao moguće inicijalne parametre razmotrite vektore \mathbf{w}_1 – \mathbf{w}_4 . **S kojim inicijalnim parametarima će algoritam gradijentnog spusta konvergirati u najmanjem broju koraka?**

- ☐ A \mathbf{w}_3 ☐ B \mathbf{w}_1 ☐ C \mathbf{w}_2 ☐ D \mathbf{w}_4

Cjelina 3: SVM, jezgrene i neparametarske metode (8 pitanja)

- 15 (T) Algoritmi strojnog učenja mogu biti parametarski ili neparametarski. Što je karakteristika neparametarskih algoritama strojnog učenja?

☐ A Broj značajki ne ovisi o dimenziji ulaznog prostora
☐ B Eksplicitno modeliraju granicu između primjera
☐ C Svaki primjer ima globalan utjecaj na izgled hipoteze
☐ D Broj parametara ovisi o broju primjera

- 16 (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((0, 0), -1), ((-1, -1), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1))\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa $C = 1$. Kod modela s mekom marginom za dualne koeficijente vrijedi $\alpha_1 = 1$, $\alpha_2 > 0$, $\alpha_3 > 0$, $\alpha_4 > 0$ i $\alpha_5 = 1$. Skicirajte tvrdu i meku marginu u ulaznome prostoru. **Koliko je meka margina veća od tvrde margine?**

☐ A $\frac{3}{5}\sqrt{10}$ puta ☐ B $\frac{1}{6}\sqrt{2}$ puta ☐ C $\frac{2}{5}\sqrt{10}$ puta ☐ D $\frac{4}{5}\sqrt{10}$ puta

- 17 (N) U ulaznome prostoru dimenzije $n = 3$ trenirali smo model SVM-a s linearnom jezgrom. Potporne vektore naučenog modela čine označeni primjeri $((2, -5, 15), -1)$, $((1, 8, -305), -1)$ i $((1, -6, 225), +1)$, a njima odgovarajući dualni koeficijenti su $\alpha_1 = 0.5$, $\alpha_2 = 0.8$ i $\alpha_3 = 0.9$. Treniranje smo proveli na skaliranim značajkama: svaku smo značajku x_j standardizirali primjenom transformacije $\frac{x_j - \mu_j}{\sigma_j}$, gdje su μ_j i σ_j srednja vrijednost odnosno varijanca značajke x_j u skupu označenih podataka \mathcal{D} . Parametri skaliranja su $\boldsymbol{\mu} = (15, -2, 100)$ i $\boldsymbol{\sigma} = (4, 1, 12)$. Model SVM-a koristimo za predikciju klase primjera $\mathbf{x} = (1, 2, -20)$. **Koliko će se promijeniti izlaz modela ako kod predikcije propustimo skalirati značajke primjera \mathbf{x} ?**

☐ A -373.22 ☐ B -739.13 ☐ C $+907.43$ ☐ D $+541.53$

- 18 (P) Neka je $\mathcal{H}_{C,\gamma}$ model SVM-a s Gaussovom jezgrom. Hiperparametri tog modela su regularizacijski faktor C i preciznost jezgre γ . Odabir modela provodimo unakrsnom provjerom i to pretraživanjem po rešetci za sljedeće vrijednosti hiperparametara:

$$C = \{2^{-5}, 2^{-4}, \dots, 2^4, 2^5\}$$
$$\gamma = \{10^{-5}, 10^{-4}, \dots, 10^4, 10^5\}$$

Već ranije smo utvrdili da je model sa $C = 2^{-2}$ i $\gamma = 10^{-1}$ podnaučen, a da je model sa $C = 2^1$ i $\gamma = 10^1$ prenaučan. Za sve ostale modele ne znamo jesu li prenaučeni, podnaučeni ili optimalni. **Koliko modela još ima smisla ispitati jer su moguće optimalni?**

☐ A 10 ☐ B 76 ☐ C 96 ☐ D 25

- 19 (N) Treniramo SVM s Gaussovom jezgrenom funkcijom. Model treniramo na skupu od $N = 5$ označenih primjera. Vektor oznaka je $\mathbf{y} = (+1, +1, -1, -1, +1)$. Euklidske udaljenosti između primjera dane su sljedećom matricom udaljenosti:

$$\mathbf{D} = \begin{pmatrix} 0.0 & 7.48 & 6.16 & 13.42 & 12.21 \\ 7.48 & 0.0 & 12.73 & 20.1 & 14.18 \\ 6.16 & 12.73 & 0.0 & 10.49 & 9.95 \\ 13.42 & 20.1 & 10.49 & 0.0 & 20.02 \\ 12.21 & 14.18 & 9.95 & 20.02 & 0.0 \end{pmatrix}$$

Treniranjem uz $C = 10$ i $\gamma = 0.0001$ za vektor dualnih parametara dobili smo $\boldsymbol{\alpha} = (10, 1.052, 10, 10, 8.948)$. **Koliko iznosi gubitak zglobnice ovako naučenog modela SVM za prvi primjer, $L(y^{(1)}, h(\mathbf{x}^{(1)}))$?**

☐ A 0.03 ☐ B 0.24 ☐ C 1.64 ☐ D 1.18

- 20** (P) Na 700 primjera sa 100 značajki treniramo rijetki jezgreni stroj s Gaussovim jezgrama. Sve Gaussove jezgre imaju istu varijancu. Nakon treniranja, dobivamo model koji ima 42 prototipa. **Koliko parametara moramo optimirati te koliko parametara ima naučeni model?**
- ☐ A Optimiramo 701 parametar, a naučeni model ima 4200 parametara
- ☐ B Optimiramo 701 parametar, a naučeni model ima 4243 parametara
- ☐ C Optimiramo 101 parametar, a naučeni model ima 4243 parametara
- ☐ D Optimiramo 101 parametar, a naučeni model ima 4200 parametara
- 21** (T) Optimizacijski problem algoritma SVM može se postaviti u formulaciji meke ili tvrde margine te u primarnoj ili dualnoj formulaciji. Ovisno o formulaciji, kvadratni program sadrži različit broj varijabli po kojima optimiramo (optimizacijske varijable). **Ako matrica dizajna ima više redaka nego stupaca, koja formulacija ima najmanje optimizacijskih varijabli?**
- ☐ A Dualni problem tvrde margine ☐ C Dualni problem meke margine
- ☐ B Primarni problem tvrde margine ☐ D Primarni problem meke margine
- 22** (N) Rješavamo problem određivanja podrijetla pojedinih riječi u jeziku: za svaku riječ trebamo odrediti je li engleskog ($y = 1$) ili francuskog ($y = 0$) podrijetla. Problem rješavamo logističkom regresijom izvedenom kao rijetki jezgreni stroj, gdje za bazne funkcije koristimo jezgru κ nad znakovnim nizovima. Funkcija κ definirana je kao $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$, gdje su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Na primjer, $\kappa(\text{water}, \text{eau}) = 2/6 = 0.33$. Skup za učenje je sljedeći:
- $$\mathcal{D} = \{(\mathbf{x}, y)\}_i = \{(\text{water}, 1), (\text{eau}, 0), (\text{dog}, 1), (\text{chien}, 0), (\text{paperclip}, 1), (\text{trombone}, 0), (\text{chance}, 1), (\text{hasard}, 0)\}$$
- Treniranjem rijetkoga jezgrenog stroja dobili smo vektor težina $\mathbf{w} = (-0.5, 0, 0, 0, -3.5, 1, 0, 0, 1)$. Razmotrite primjer $(\mathbf{x}, y) = (\text{nounours}, 0)$. **Koliko iznosi gubitak modela na primjeru (\mathbf{x}, y) ?**
- ☐ A 0.552 ☐ B 0.359 ☐ C 0.795 ☐ D 0.456

Međuispit iz Strojnog učenja 1 (ak. god. 2022./2023.)

– NEKORIGIRANA VERZIJA –

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 35% bodova na predmetu). Pitanja nose po 1 bod, a $1/3$ boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **180 minuta**. Primjerak ispita morate zajedno sa svojim rješenjima.

Cjelina 1: Osnovni koncepti i linearna regresija (6 pitanja)

- 1** (P) Jednostavnom regresijom modeliramo ovisnost nezavisne varijable y o zavisnoj varijabli x . Model treniramo postupkom običnih najmanjih kvadrata (OLS) na skupu podataka $\mathcal{D} = \{(x^{(i)}, y^{(i)})\} = \{(0, 0), (2, 0), (3, 2), (5, 2)\}$. Neka je h hipoteza koju dobivamo treniranjem modela te neka je L^i gubitak hipoteze h na primjeru $x^{(i)}$, tj. $L^i = L(y^{(i)}, h(x^{(i)}))$. Što vrijedi za gubitke hipoteze na pojedinim primjerima?

- ☐ A $L^1 = L^4 < L^2 = L^3$ ☐ C $L^1 = L^2 = 1 < L^3 < L^4$
☐ B $L^1 = L^4 = 1, L^2 < L^3$ ☐ D $L^1 = L^3 = 0, L^2 = L^4 < 1$

- 2** (T) Modeli strojnog učenja općenito su različite složenosti. S porastom složenosti modela raste vjerojatnost da model bude prenaučan. Ta vjerojatnost raste s količinom šuma u podatcima. Zašto šum u podatcima za učenje može dovesti do prenaučenosti klasifikacijskog modela?

- ☐ A Zbog šuma granica između klasa izgleda nelinearnijom nego što ona to zapravo jest, pa primjeri blizu granice znatno više doprinose pogrešci učenja nego primjeri koji su udaljeni od granice
☐ B Povećanjem količine šuma granica između klasa postaje sve nelinearnija, pa raste i složenost modela te dobivena hipoteza očekivano neće odgovarati granici između klasa na ispitnom skupu
☐ C Zbog šuma su oznake nekih primjera u skupu za učenje pogrešne, pa sve hipoteze iz modela imaju na tom skupu pogrešku koja je veća od nula, a još veća na ispitnom skupu
☐ D Efekt šuma je slučajna, pa će hipoteza koja se previše prilagodi šumu na skupu za učenje očekivano imati veliku pogrešku na ispitnom skupu gdje je šum drugačiji ili ga nema

- 3** (N) Raspolažemo sljedećim skupom primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((1, 0), 1), ((2, -3), 2), ((3, 5), -1), ((5, 0), -4)\}$$

Na ovom skupu gradijentnim spustom trenirali smo L_1 -regularizirani model linearne regresije sa $\lambda = 1$. Dobili smo težine $\mathbf{w} = (2.12, -0.94, -0.08)$. Koliko iznosi L_1 -regularizirana pogreška $E(\mathbf{w}|\mathcal{D})$?

- ☐ A 2.69 ☐ B 0.29 ☐ C 1.58 ☐ D 7.10

- 4** (T) Multikolinearnost značajki jedan je od problema koji može nastupiti kod primjene modela regresije na stvarnim podatcima. Efekt multikolinearnosti i savršene multikolinearnosti dobro je uočljiv kod optimizacijskoga postupka običnih najmanjih kvadrata (OLS) kada se on provodi izračunom pseudoinverza matrice dizajna. Neka je m broj značajki, Φ je matrica dizajna i $\mathbf{G} = \Phi^T \Phi$ je Gramova matrica. Koji je efekt savršene multikolinearnosti kod postupka OLS?

- ☐ A $\text{rang}(\Phi) = N$, no $\text{rang}(\mathbf{G}) < N$, pa \mathbf{G} ima pseudoinverz, ali nema numerički stabilan inverz
☐ B Φ ima puni rang, $\text{rang}(\mathbf{G}) > m$ i \mathbf{G} ima inverz, ali s visokim kondicijskim brojem
☐ C Φ nema puni rang, $\text{rang}(\mathbf{G}) < m + 1$ i \mathbf{G} nema pseudoinverz
☐ D $\text{rang}(\Phi) < m + 1$, \mathbf{G} nema puni rang i nema inverz, no ima pseudoinverz koji nije numerički stabilan

- 5 (P) Razmatramo klasifikacijski problem u ulaznome prostoru $\mathcal{X} = \mathbb{Z}^2$. Skup označenih primjera je $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((0, 0), 0), ((0, 2), 0), ((0, -1), 0), ((-1, 0), 1), ((0, 1), 1), ((1, 0), 1)\}$. Razmatramo sljedeće modele, parametrizirane sa $\boldsymbol{\theta} \in \mathbb{R}^{n+1}$:

$$\begin{aligned}\mathcal{H}_1 : h_1(\mathbf{x}; \boldsymbol{\theta}) &= \mathbf{1}\{\boldsymbol{\theta}^T \mathbf{x} \geq 0\} \\ \mathcal{H}_2 : h_2(\mathbf{x}; \boldsymbol{\theta}) &= \mathbf{1}\{(x_1 - \theta_1)^2 + (x_2 - \theta_2)^2 \geq \theta_0^2\}\end{aligned}$$

Pored ova dva modela, razmatramo i njihove kombinacije, modele \mathcal{H}_3 i \mathcal{H}_4 . Neka je $\mathcal{H}_3 = \mathcal{H}_1 \cup \mathcal{H}_2$ te neka je \mathcal{H}_4 skup funkcija definiranih kao $h_4(\mathbf{x}; \boldsymbol{\theta}) = h_1(\mathbf{x}) \cdot h_2(\mathbf{x})$. Neka je E_k minimalna empirijska pogreška koja se modelom \mathcal{H}_k može ostvariti na skupu \mathcal{D} , tj. $E_k = \arg\min_{h \in \mathcal{H}_k} E(h|\mathcal{D})$. **Koji odnosi vrijede između minimalnih empirijskih pogrešaka ovih modela?**

- ☐ A $E_1 = E_2 > E_3 = E_4$ ☐ B $E_1 = E_2 = E_3 > E_4$ ☐ C $E_1 > E_2 = E_3 > E_4$ ☐ D $E_1 > E_2 > E_3 = E_4$

- 6 (P) Raspoložemo modelom \mathcal{H}_α koji ima hiperparametar α kojim se može ugađati složenost modela. Isprobavamo dvije vrijednosti hiperparametra: α_1 i α_2 . Treniramo modele \mathcal{H}_{α_1} i \mathcal{H}_{α_2} te dobivamo hipoteze h_{α_1} i h_{α_2} . Zatim računamo empirijske pogreške tih hipoteza na skupu za učenje \mathcal{D}_u i na skupu za ispitivanje \mathcal{D}_i . Utvrđujemo da vrijedi:

$$E(h_{\alpha_1}|\mathcal{D}_i) - E(h_{\alpha_1}|\mathcal{D}_u) < E(h_{\alpha_2}|\mathcal{D}_i) - E(h_{\alpha_2}|\mathcal{D}_u)$$

Što iz toga možemo zaključiti?

- ☐ A Model \mathcal{H}_{α_1} je manje složenosti od modela \mathcal{H}_{α_2}
☐ B Optimalan model je onaj s hiperparametrom iz intervala $[\alpha_1, \alpha_2]$
☐ C Model \mathcal{H}_{α_2} je prenaučeni
☐ D Model \mathcal{H}_{α_1} je podnaučeni

Cjelina 2: Linearni klasifikacijski modeli (8 pitanja)

- 7 (N) Na skupu označenih primjera \mathcal{D} trenirali smo model logističke regresije. Dobili smo neki vektor težina \mathbf{w} i pomak $w_0 = 3.15$. Tako naučenom modelu neki primjer \mathbf{x} , čija je oznaka u skupu primjera $y = 0$, nanosi gubitak unakrsne entropije od $L(0, h(\mathbf{x})) = 0.5$. **Koliki gubitak unakrsne entropije bi nanosio primjer \mathbf{x} kada bismo njegove značajke pomnožili sa dva i promijenili mu oznaku?**

- ☐ A 7.11 ☐ B 2.54 ☐ C 4.03 ☐ D 1.19

- 8 (N) Raspoložemo sljedećim skupom za učenje u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((-1, 4), +1), ((2, -3), -1), ((2, 5), -1)\}$$

Na ovom skupu treniramo perceptron. Pritom koristimo funkciju preslikavanja u šesterodimenzijaski prostor značajki, definiranu na sljedeći način:

$$\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2, x_1^2, x_2^2)$$

Početne težine perceptrona neka su $\mathbf{w} = (1, 0, -1, 2, 3, 0)$. **Koliko iznosi empirijska pogreška perceptrona na skupu za učenje prije početka treniranja (dakle, s početnim težinama)?**

- ☐ A 18 ☐ B 100 ☐ C 96 ☐ D 40

- 9 (N) Raspoložemo označenim skupom primjera iz triju klasa ($K = 3$) u trodimenzijaskome ulaznom prostoru ($n = 3$). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer $\mathbf{x} = (-4, -1, -3)$ s oznakom $\mathbf{y} = (1, 0, 0)$. **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

- ☐ A 8.00 ☐ B 4.02 ☐ C 6.00 ☐ D 12.02

10 (T) Za optimizaciju parametara poopćenih linearnih modela može se koristiti stohastički gradijentni spust, odnosno pravilo LMS. Neka je (\mathbf{x}, y) označeni primjer za koji radimo ažuriranje težina pomoću pravila LMS. **Što možemo reći o razlici između novih (ažuriranih) i starih težina (težina prije ažuriranja)?**

- ☐ A Razlika je to manja što je oznaka y bliže jedinici
- ☐ B Razlika je to manja što je vektor $\phi(\mathbf{x})$ bliži ishodištu
- ☐ C Razlika je to veća što je izlaz modela $h(\mathbf{x})$ bliži nuli
- ☐ D Razlika je to veća što je stopa učenja η bliža jedinici

11 (N) Model logističke regresije treniramo stohastičkim gradijentnim spustom. Primjere iz dvodimenzijanskog ulaznog prostora preslikali smo u prostor značajki funkcijom $\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2)$. U jednoj iteraciji treniranja modela vektor parametara jednak je $\mathbf{w} = (0.1, 0.5, 2, -0.5)$. **Koliko u toj iteraciji iznosi L_2 -norma gradijenta gubitka za primjer $(\mathbf{x}, y) = ((1, -1), 1)$?**

- ☐ A 0.50 ☐ B 0.09 ☐ C 1.42 ☐ D 0.22

12 (P) Skup za učenje čine sljedeći označeni primjeri:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((-2, 3), 0), ((-1, 2), 0), ((0, 1), 0), ((0, 0), 0), ((1, 1), 0), ((1, -1), 1), ((2, 0), 1)\}$$

Na skupu \mathcal{D} treniramo logističku regresiju (LR) i stroj potpornih vektora s tvrdom marginom (SVM). Dodatno, treniramo model linearne regresije (LINR), gdje izlaz tog modela koristimo za klasifikaciju, tj. $h(\mathbf{x}) = \mathbf{1}\{\mathbf{w}^T \mathbf{x} \geq 0\}$. Za modele SVM i LINR umjesto oznake $y = 0$ koristimo oznaku $y = -1$. Za treniranje modela LR koristimo dovoljan broj iteracija tako da možemo pretpostaviti da je dobivena pogreška unakrsne entropije praktički jednaka nuli. Razmotrite primjer $\mathbf{x}^{(7)} = (2, 0)$. Neka je $d(m)$ udaljenost primjera $\mathbf{x}^{(7)}$ od granice između klasa dobivene modelom m . **Što od navedenog vrijedi za tu udaljenost?**

- ☐ A $d(\text{SVM}) < d(\text{LR}) < d(\text{LINR})$ ☐ C $d(\text{LINR}) < d(\text{LR}) < d(\text{SVM})$
- ☐ B $d(\text{SVM}) < d(\text{LINR}) < d(\text{LR})$ ☐ D $d(\text{LR}) < d(\text{SVM}) < d(\text{LINR})$

13 (T) Višeklasni problem može se riješiti binarnim klasifikatorom uz primjenu sheme OVO ili sheme OVR. Obje sheme imaju svoje prednosti i nedostatke. Pretpostavite da raspolazemo sa K klasa i da svaka klasa ima N/K primjera, gdje je N ukupan broj primjera u skupu za učenje. **Što su prednosti odnosno nedostatci OVO i OVR sheme u takvom slučaju?**

- ☐ A OVO svaki klasifikator trenira s $K/2$ puta manje primjera nego OVR, ali pozitivne klase kod OVR imaju K puta manje primjera nego kod OVO
- ☐ B OVO iziskuje $(K - 1)/2$ puta više parametara nego OVR, ali svaki OVR klasifikator ima $K - 1$ puta manje pozitivnih primjera nego negativnih
- ☐ C OVR treba K puta više klasifikatora nego OVO, ali su kod OVO pozitivne klase $K/2$ puta manje zastupljene nego OVR
- ☐ D OVR iziskuje $K - 1$ puta više klasifikatora od sheme OVO, ali kod OVO pozitivne klase imaju $K - 1$ puta manje primjera nego kod OVR

14 (P) Na primjerima iz dvodimenzijanskog ulaznog prostora treniramo L_2 -regulariziranu logističku regresiju. Neka su $\mathbf{w}_0 = (1, -4, 4)$, $\mathbf{w}_1 = (1, -4, 6)$, $\mathbf{w}_2 = (1, -1, 7)$, $\mathbf{w}_3 = (1, -7, 1)$ i $\mathbf{w}_4 = (1, -7, -3)$ vektori u prostoru parametara. Neka je $E(\mathbf{w}|\mathcal{D})$ neregularizirana pogreška unakrsne entropije na skupu za učenje \mathcal{D} . Pritom je \mathbf{w}_0 minimizator funkcije $E(\mathbf{w}|\mathcal{D})$ te vrijedi $E(\mathbf{w}_1|\mathcal{D}) = E(\mathbf{w}_2|\mathcal{D}) = E(\mathbf{w}_3|\mathcal{D})$. Napravite skicu izokontura funkcije pogreške u potprostoru $w_1 \times w_2$. Za treniranje modela koristimo gradijentni spust s linijskim pretraživanjem uz regularizacijski faktor $\lambda = 100$. Za tako naučen model vrijednost regularizacijskog izraza $\frac{\lambda}{2} \|\mathbf{w}\|^2$ jednaka je 400. Međutim, broj koraka gradijentnog spusta (broj poziva linijskog pretraživanja) ovisi o tome koliko će spust krivudati, a to ovisi o odabiru inicijalnih parametara. Kao moguće inicijalne parametre razmotrite vektore \mathbf{w}_1 – \mathbf{w}_4 . **S kojim inicijalnim parametarima će algoritam gradijentnog spusta konvergirati u najmanjem broju koraka?**

- ☐ A \mathbf{w}_4 ☐ B \mathbf{w}_3 ☐ C \mathbf{w}_1 ☐ D \mathbf{w}_2

Cjelina 3: SVM, jezgrene i neparametarske metode (8 pitanja)

- 15 (T) Optimizacijski problem algoritma SVM može se postaviti u formulaciji meke ili tvrde margine te u primarnoj ili dualnoj formulaciji. Ovisno o formulaciji, kvadratni program sadrži različit broj varijabli po kojima optimiramo (optimizacijske varijable). **Ako matrica dizajna ima više redaka nego stupaca, koja formulacija ima najmanje optimizacijskih varijabli?**

☐ A Dualni problem tvrde margine ☐ C Dualni problem meke margine
☐ B Primarni problem meke margine ☐ D Primarni problem tvrde margine

- 16 (T) Algoritmi strojnog učenja mogu biti parametarski ili neparametarski. **Što je karakteristika neparametarskih algoritama strojnog učenja?**

☐ A Pretpostavljaju teorijsku distribuciju podataka
☐ B Broj parametara ovisi o broju primjera
☐ C Hiperparametri nemaju utjecaja na složenost modela
☐ D Broj značajki ne ovisi o dimenziji ulaznog prostora

- 17 (N) Treniramo SVM s Gaussovom jezgrenom funkcijom. Model treniramo na skupu od $N = 5$ označenih primjera. Vektor oznaka je $\mathbf{y} = (+1, +1, -1, -1, +1)$. Euklidske udaljenosti između primjera dane su sljedećom matricom udaljenosti:

$$\mathbf{D} = \begin{pmatrix} 0.0 & 7.48 & 6.16 & 13.42 & 12.21 \\ 7.48 & 0.0 & 12.73 & 20.1 & 14.18 \\ 6.16 & 12.73 & 0.0 & 10.49 & 9.95 \\ 13.42 & 20.1 & 10.49 & 0.0 & 20.02 \\ 12.21 & 14.18 & 9.95 & 20.02 & 0.0 \end{pmatrix}$$

Treniranjem uz $C = 10$ i $\gamma = 0.001$ za vektor dualnih parametara dobili smo $\boldsymbol{\alpha} = (10, 0, 10, 2.779, 2.779)$. **Koliko iznosi gubitak zglobnice ovako naučenog modela SVM za prvi primjer, $L(y^{(1)}, h(\mathbf{x}^{(1)}))$?**

☐ A 0.24 ☐ B 1.18 ☐ C 0.03 ☐ D 1.64

- 18 (P) Na 900 primjera sa 50 značajki treniramo rijetki jezgri stroj s Gausovim jezgrama. Sve Gaussove jezgre imaju istu varijancu. Nakon treniranja, dobivamo model koji ima 52 prototipa. **Koliko parametara moramo optimirati te koliko parametara ima naučeni model?**

☐ A Optimiramo 51 parametar, a naučeni model ima 2653 parametara
☐ B Optimiramo 901 parametar, a naučeni model ima 2653 parametara
☐ C Optimiramo 51 parametar, a naučeni model ima 2600 parametara
☐ D Optimiramo 901 parametar, a naučeni model ima 3501 parametar

- 19 (N) U ulaznome prostoru dimenzije $n = 3$ trenirali smo model SVM-a s linearnom jezgrom. Potporne vektore naučenog modela čine označeni primjeri $((2, -5, 15), -1)$, $((1, 8, -305), -1)$ i $((1, -6, 225), +1)$, a njima odgovarajući dualni koeficijenti su $\alpha_1 = 0.5$, $\alpha_2 = 0.8$ i $\alpha_3 = 0.9$. Treniranje smo proveli na skaliranim značajkama: svaku smo značajku x_j standardizirali primjenom transformacije $\frac{x_j - \mu_j}{\sigma_j}$, gdje su μ_j i σ_j srednja vrijednost odnosno varijanca značajke x_j u skupu označenih podataka \mathcal{D} . Parametri skaliranja su $\boldsymbol{\mu} = (15, -2, 100)$ i $\boldsymbol{\sigma} = (4, 1, 12)$. Model SVM-a koristimo za predikciju klase primjera $\mathbf{x} = (1, 2, -30)$. **Koliko će se promijeniti izlaz modela ako kod predikcije propustimo skalirati značajke primjera \mathbf{x} ?**

☐ A -373.22 ☐ B +907.43 ☐ C +541.53 ☐ D -739.13

- 20 (N) Rješavamo problem određivanja podrijetla pojedinih riječi u jeziku: za svaku riječ trebamo odrediti je li engleskog ($y = 1$) ili francuskog ($y = 0$) podrijetla. Problem rješavamo logističkom regresijom izvedenom kao rijetki jezgri stroj, gdje za bazne funkcije koristimo jezgru κ nad znakovnim nizovima. Funkcija κ definirana je kao $\kappa(\mathbf{x}_1, \mathbf{x}_2) = |\mathbf{x}_1 \cap \mathbf{x}_2| / |\mathbf{x}_1 \cup \mathbf{x}_2|$, gdje su operacije unije i presjeka definirane nad skupovima slova od kojih se riječi sastoje. Na primjer, $\kappa(\text{water}, \text{eau}) = 2/6 = 0.33$. Skup za učenje je sljedeći:

$$\mathcal{D} = \{(\mathbf{x}, y)\}_i = \{(\text{water}, 1), (\text{eau}, 0), (\text{dog}, 1), (\text{chien}, 0), (\text{paperclip}, 1), (\text{trombone}, 0), (\text{chance}, 1), (\text{hasard}, 0)\}$$

Treniranjem rijetkoga jezgrenog stroja dobili smo vektor težina $\mathbf{w} = (-0.5, 0, 0, 0, -3.5, 1, 0, 0, 1)$. Razmotrite primjer $(\mathbf{x}, y) = (\text{nounours}, 0)$. **Koliko iznosi gubitak modela na primjeru (\mathbf{x}, y) ?**

- ☐ A 0.359 ☐ B 0.456 ☐ C 0.552 ☐ D 0.795

- 21** (P) Neka je $\mathcal{H}_{C,\gamma}$ model SVM-a s Gaussovom jezgrom. Hiperparametri tog modela su regularizacijski faktor C i preciznost jezgre γ . Odabir modela provodimo unakrsnom provjerom i to pretraživanjem po rešetci za sljedeće vrijednosti hiperparametara:

$$C = \{2^{-5}, 2^{-4}, \dots, 2^4, 2^5\}$$
$$\gamma = \{10^{-5}, 10^{-4}, \dots, 10^4, 10^5\}$$

Za model sa $C = 2^{-2}$ i $\gamma = 10^1$ utvrdili smo da je podnaučen, a za model sa $C = 2^1$ i $\gamma = 10^1$ utvrdili smo da je prenaučten. **Koliko modela još ima smisla ispitati jer su moguće optimalni?**

- ☐ A 10 ☐ B 25 ☐ C 68 ☐ D 96

- 22** (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_i = \{((0, 0), -1), ((-1, -1), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1))\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa $C = 1$. Kod modela s mekom marginom za dualne koeficijente vrijedi $\alpha_1 = 1$, $\alpha_2 > 0$, $\alpha_3 > 0$, $\alpha_4 > 0$ i $\alpha_5 = 1$. Skicirajte tvrdu i meku marginu u ulaznome prostoru. **Koliko je meka margina veća od tvrde margine?**

- ☐ A $\frac{3}{5}\sqrt{10}$ puta ☐ B $\frac{2}{5}\sqrt{10}$ puta ☐ C $\frac{4}{5}\sqrt{10}$ puta ☐ D $\frac{1}{6}\sqrt{2}$ puta

| | | | | | | | | | | | | | | | | | | | | | | | |
|---------|--|-------------|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| | | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 2 | 2 | 2 |
| | | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 0 | 1 | 2 |
| | | -----+----- | | | | | | | | | | | | | | | | | | | | | |
| Grupa A | | B | A | D | A | B | B | B | C | D | B | B | A | C | A | A | A | A | D | D | C | A | C |
| Grupa B | | C | B | D | C | C | D | D | D | B | B | D | A | A | B | D | C | A | C | A | D | A | A |
| Grupa C | | B | C | C | D | B | B | C | D | B | A | D | C | C | B | D | B | D | B | C | A | B | B |
| Grupa D | | A | A | D | A | B | A | A | D | D | D | D | B | D | D | C | C | C | A | D | A | C | D |
| Grupa E | | A | A | C | B | B | B | C | A | D | B | B | C | D | C | C | C | B | D | B | C | D | C |
| Grupa F | | D | D | D | D | C | D | A | B | D | D | A | C | D | C | B | C | A | D | A | B | B | B |
| Grupa G | | A | D | C | B | C | A | A | C | C | A | A | A | C | D | D | A | A | B | B | B | B | D |
| Grupa H | | A | D | A | D | C | A | C | D | C | B | C | D | B | A | D | B | C | B | D | B | C | A |