

Međuispit iz Strojnog učenja 1 (ak. god. 2021./2022.)

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 35% bodova na predmetu). Pitanja nose po 1 bod, a 1/3 boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **150 minuta**. Primjerak ispita morate predati zajedno sa svojim rješenjima.

Cjelina 1: Osnove i regresija (6 pitanja)

- 1** (P) Optimizacija parametara modela temelji se na funkciji gubitka $L : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}_0^+$, gdje je $L(y, h(\mathbf{x}))$ gubitak na primjeru (\mathbf{x}, y) . U većini primjena koristimo simetričan gubitak 0-1. Međutim, u nekim primjenama ima više smisla definirati asimetričan gubitak. Jedan takav primjer je zadatak detekcije neželjenih elektroničkih poruka (*spam filtering*). Taj zadatak možemo formalizirati kao problem binarne klasifikacije s oznakama $\mathcal{Y} = \{0, 1\}$, gdje $y = 1$ označava da je poruka neželjena (spam), a $y = 0$ da ona to nije. **Koje od sljedećih svojstava bi trebala zadovoljiti asimetrična funkcija gubitka za takav zadatak?**
- ☐ A $L(0, 0) = L(1, 1) < L(0, 1) < L(1, 0)$
- ☐ B $L(0, 1) = 1$ i $L(1, 0) = L(1, 1) = L(0, 0) = 0$
- ☐ C $L(0, 1) > L(1, 0)$ i $L(1, 1) = L(0, 0) = 0$
- ☐ D $L(0, 1) = L(1, 0) > 0$ i $L(1, 1) = L(0, 0) = 0$
- 2** (T) Hipoteza h je funkcija koja primjerima iz \mathcal{X} pridjeljuje oznake iz \mathcal{Y} . Za h kažemo da je definirana “do na parametre θ ”. **Što to znači?**
- ☐ A Funkcija h definirana je bez parametara, i njih treba odrediti naknadno postupkom odabira modela \mathcal{H}
- ☐ B Različite vrijednosti za θ mogu dati različite funkcije h , a skup svih takvih različitih funkcija definira model \mathcal{H}
- ☐ C Funkcija h definira preslikavanja iz označenog skupa primjera $\mathcal{X} \times \mathcal{Y}$ u prostor parametara θ
- ☐ D Funkcija h jednoznačno određuje parametre θ iz skupa svih mogućih parametara, koji nazivamo prostor parametara
- 3** (P) Razmatramo klasifikacijski problem u ulaznome prostoru $\mathcal{X} = \mathbb{Z}^2$. Skup označenih primjera je $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), 1), ((-1, -1), 0), ((1, 1), 0)\}$. Razmatramo sljedeće modele \mathcal{H} i funkcije preslikavanja $\phi : \mathbb{Z}^2 \rightarrow \mathbb{Z}^2$, kojom primjere iz \mathcal{D} preslikavamo u matricu dizajna Φ :

$$\begin{aligned}\mathcal{H}_1 : h_1(\mathbf{x}|\theta_0, \theta_1) &= \mathbf{1}\{\theta_1 x_1 + \theta_0 \geq 0\} & \phi_1(\mathbf{x}) &= (1, x_2, x_1) \\ \mathcal{H}_2 : h_2(\mathbf{x}|\theta_0, \theta_2) &= \mathbf{1}\{\theta_2 x_2 + \theta_0 \geq 0\} & \phi_2(\mathbf{x}) &= (1, x_1, x_1 x_2) \\ \mathcal{H}_3 : h_3(\mathbf{x}|\theta) &= \mathbf{1}\{\theta^T \mathbf{x} \geq 0\} \\ \mathcal{H}_4 : h_4(\mathbf{x}|\theta_0) &= \mathbf{1}\{x_1^2 + x_2^2 \geq \theta_0\}\end{aligned}$$

U svim modelima parametri su realni brojevi, $\theta_j \in \mathbb{R}$. Odredite veličinu prostora inačica, $|VS_{\mathcal{H}, \Phi}|$, za ove kombinacije modela i funkcije preslikavanja. **Za koju kombinaciju modela i funkcije preslikavanja prostor inačica sadržava točno jednu hipotezu, $|VS_{\mathcal{H}, \Phi}| = 1$?**

- ☐ A $h_1 + \phi_1$ ☐ B $h_3 + \phi_2$ ☐ C $h_4 + \phi_1$ ☐ D $h_2 + \phi_2$

- 4** (T) Optimizacijom regularizirane funkcije pogreške smanjuje se prenaučenos modela. **Kakve parametre modela nalazi optimizacija L_2 -regularizirane pogreške?**
- ☐ A Parametre koji uz što veću magnitudu vrijednosti daju što manje očekivanje gubitka na skupu za ispitivanje
- ☐ B Parametre koji uz što veću magnitudu vrijednosti daju što veće očekivanje gubitka na skupu za učenje
- ☐ C Parametre koji uz što manju magnitudu vrijednosti daju što veće očekivanje gubitka na skupu za ispitivanje
- ☐ D Parametre koji uz što manju magnitudu vrijednosti daju što manje očekivanje gubitka na skupu za učenje

- 5 (N) Raspoložemo sljedećim skupom primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((2, -3), -5), ((2, 3), -10), ((-3, 5), 5), ((5, 0), 20)\}$$

Na ovom skupu gradijentnim spustom trenirali smo L_1 -regularizirani model linearne regresije sa $\lambda = 2$. Dobili smo težine $\mathbf{w} = (-0.156, 1.330, 0.529)$. **Koliko iznosi L_1 -regularizirana pogreška $E(\mathbf{w}|\mathcal{D})$?**

- ☐ A 230.98 ☐ B 191.95 ☐ C 165.89 ☐ D 31.70

- 6 (P) Koristimo regresiju za predviđanje kreditne sposobnosti klijenata. Na raspolaganju imamo podatke o dobi x_1 , ukupnom prinosu na račune x_2 , ukupnoj ušteđevini u kunama x_3 , ukupnoj deviznoj ušteđevini u eurima x_4 , ukupnom iznosu odobrenih kredita x_5 , ukupnom iznosu do sada otplaćenih kredita x_6 te preostalom ukupnom dugovanju po svim kreditima x_7 . Ove podatke želimo iskoristiti kao značajke, ali pritom naravno moramo paziti da ne uvedemo multikolinearnost, pa možda nećemo upotrijebiti sve značajke. Za funkciju preslikavanja ϕ koristimo preslikavanje s linearnim, kvadratnim i interakcijskim značajkama. Za interakcije razmatramo parove i trojke značajki, uključivo kombinacije kvadriranih i nekvadriranih značajki (npr., x_1x_2 , $x_1^2x_2$ i $x_1x_2^2x_3^2$). **Koliko minimalno primjera za učenje trebamo imati, a da bi rješenje bilo stabilno i bez regularizacije?**

- ☐ A 86 ☐ B 48 ☐ C 92 ☐ D 79

Cjelina 2: Linearni klasifikacijski modeli (8 pitanja)

- 7 (N) Raspoložemo označenim skupom primjera iz triju klasa ($K = 3$) u trodimenzijaskome ulaznom prostoru ($n = 3$). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer $\mathbf{x} = (-4, -1, -3)$ s oznakom $\mathbf{y} = (0, 0, 1)$. **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

- ☐ A 6.00 ☐ B 4.02 ☐ C 12.02 ☐ D 8.00

- 8 (T) Algoritam strojnog učenja idealno bi minimizirao gubitak 0-1. Međutim, funkciju gubitka 0-1 u praksi ne možemo koristiti za optimizaciju parametara modela. **Zašto gubitak 0-1 ne možemo koristiti za optimizaciju?**

- ☐ A Gradijent gubitka 0-1 svugdje je nula osim za $h(\mathbf{x}) = 0$, pa funkcija pogreške ima zaravni po kojima se gradijentni spust ne može spuštati
- ☐ B Funkcija gubitka 0-1 nije konveksna, pa ni funkcija pogreške nije konveksna već ima lokalne minimume te ne postoji minimizator u zatvorenoj formi
- ☐ C Gubitak 0-1 pored neispravno klasificiranih primjera kažnjava i ispravno klasificirane primjere, i to tim više što su oni dalje od granice između klasa
- ☐ D Funkcija gubitka 0-1 nije diferencijabilna, pa ne postoji rješenje u zatvorenoj formi i ne postoji gradijent

- 9 (P) Poopćeni linearni modeli mogu koristiti adaptivne bazne funkcije. Prednost toga je da ne moramo ručno definirati preslikavanje ϕ u prostor značajki, već se to preslikavanje može naučiti na temelju podataka. Rasplažemo podatcima iz $K = 2$ klase u 100-dimenzijaskome ulaznom prostoru. Za taj klasifikacijski problem koristimo binarnu logističku regresiju, ali s adaptivnim baznim funkcijama. Svaka adaptivna bazna funkcija ϕ_j je i sama jedan model logističke regresije, pri čemu $\phi_0(\mathbf{x}) = 1$. Naš je model onda definiran ovako:

$$h(\mathbf{x}) = \sigma\left(\sum_{j=0}^5 w_j \phi_j(\mathbf{x})\right)$$

Koliko ukupno parametara ima ovaj model?

- ☐ A 511 ☐ B 506 ☐ C 256 ☐ D 261

- 10 (P) Razmotrimo sljedeći skup označenih primjera:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((-2, 0), -1), ((-1, 0), +1), ((1, 0), +1), ((2, 0), -1))\}$$

Nad ovim skupom treniramo dva modela: neregulariziranu logističku regresiju (LR) i L_2 -regulariziranu logističku regresiju (L2LR). Pored toga, razmatramo tri funkcije preslikavanja:

$$\begin{aligned}\phi_0(\mathbf{x}) &= (1, x_1, x_2) \\ \phi_1(\mathbf{x}) &= (1, x_1, x_2, x_1^2, x_2^2) \\ \phi_2(\mathbf{x}) &= (1, x_1, x_2, x_1x_2)\end{aligned}$$

Ukupno, dakle, isprobavamo šest algoritama, odnosno šest kombinacija modela i funkcije preslikavanja. **Za koje algoritme (model+preslikavanje) optimizacijski postupak na skupu za učenje ne konvergira?**

- ☐ A LR+ ϕ_0 ☐ B LR+ ϕ_2 ☐ C LR+ ϕ_1 ☐ D L2LR+ ϕ_0

- 11 (N) Model regularizirane logističke regresije treniramo stohastičkim gradijentnim spustom. Koristimo faktor regularizacije $\lambda = 1000$ i stopu učenja $\eta = 0.01$. Primjere iz dvodimenzijskog ulaznog prostora preslikali smo u prostor značajki funkcijom $\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2)$. U jednoj iteraciji treniranja modela vektor parametara jednak je $\mathbf{w} = (0.5, 1.2, -1.1, 2.7)$. **Koliko u toj iteraciji iznosi promjena težine w_1 za primjer $(\mathbf{x}, y) = ((-1, 2), 1)$?**

- ☐ A -2 ☐ B +22 ☐ C -5 ☐ D -12

- 12 (N) Raspoložemo sljedećim skupom za učenje u dvodimenzijskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((1, 0), +1), ((2, -3), -1), ((2, 5), -1))\}$$

Na ovom skupu treniramo perceptron. Pritom koristimo funkciju preslikavanja u peterodimenzijaski prostor značajki, koja je definirana na sljedeći način:

$$\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2, x_1^2, x_2^2)$$

Početne težine perceptrona neka su sljedeće:

$$\mathbf{w} = (1, 0, 1, 2, -3, 0)$$

Koliko iznosi empirijska pogreška perceptrona na skupu za učenje prije početka treniranja (dakle, s početnim težinama)?

- ☐ A 6 ☐ B 22 ☐ C 16 ☐ D 32

- 13 (N) Na skupu označenih primjera \mathcal{D} trenirali smo model logističke regresije. Dobili smo neki vektor težina \mathbf{w} i pomak $w_0 = 0.15$. Tako naučenom modelu neki primjer \mathbf{x} , čija je oznaka u skupu primjera $y = 0$, nanosi gubitak unakrsne entropije od $L(0, h(\mathbf{x})) = 0.274$. **Koliki gubitak unakrsne entropije bi nanosio primjer \mathbf{x} kada bismo njegove značajke pomnožili sa dva i promijenili mu oznaku?**

- ☐ A 1.19 ☐ B 7.11 ☐ C 2.54 ☐ D 4.03

- 14 (T) Poopćeni linearni modeli (linearna regresija, logistička regresija i multinomijalna regresija) probabilistički su algoritmi strojnog učenja. Njihova probabilistička priroda dolazi do izražaja kako kod modela tako i kod optimizacijskog postupka. **Koji je probabilistički princip ugrađen u optimizacijski postupak tih algoritama?**

- ☐ A Maksimizirati $\sum_{i=1}^N \ln h(\mathbf{x}^{(i)}; \mathbf{w})$, gdje je $h(\mathbf{x}; \mathbf{w}) = f(\mathbf{w}^T \mathbf{x})$
☐ B Minimizirati $\sum_{i=1}^N \ln h(\mathbf{x}^{(i)}; \mathbf{w})$, gdje je $h(\mathbf{x}; \mathbf{w}) = f(\mathbf{w}^T \mathbf{x})$
☐ C Minimizirati $-\sum_{i=1}^N y^{(i)} p(y^{(i)} | \mathbf{x}^{(i)})$, gdje je $p(y^{(i)} | \mathbf{x}^{(i)}) = h(\mathbf{x}; \mathbf{w})$
☐ D Maksimizirati $\sum_{i=1}^N \ln p(y^{(i)} | \mathbf{x}^{(i)})$, gdje je $\mathbb{E}[p(y^{(i)} | \mathbf{x}^{(i)})] = f(\mathbf{w}^T \mathbf{x})$

Cjelina 3: Jezgrene i neparametarske metode (8 pitanja)

- 15** (P) Za binarnu klasifikaciju koristimo SVM s Gaussovom jezgrenom funkcijom. Razmatramo tri primjera u ulaznome prostoru: $\mathbf{x}^{(1)}$, $\mathbf{x}^{(2)}$ i $\mathbf{x}^{(3)}$. Euklidska udaljenosti između primjera $\mathbf{x}^{(1)}$ i $\mathbf{x}^{(2)}$ manja je nego euklidska udaljenost između primjera $\mathbf{x}^{(1)}$ i $\mathbf{x}^{(3)}$. Za izračun sličnosti između primjera koristimo Gaussovu jezgrenu funkciju $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ s preciznošću γ , gdje $\gamma = 1/2\sigma^2$. **Kakav bi efekt na sličnosti između primjera imalo smanjenje preciznosti γ Gaussove jezgrene funkcije?**

- ☐ A Sličnosti bi se povećale, ali $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se povećala više nego što bi se povećala $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$
- ☐ B Sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se smanjila, a sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$ bi se povećala, ali za veći iznos
- ☐ C Sličnosti bi se povećale, ali $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se povećala manje nego što bi se povećala $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$
- ☐ D Sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi postala manja od sličnosti $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$

- 16** (N) Rješavamo binarni klasifikacijski problem. Raspoložemo označenim skupom primjera. Odgovarajuća matrica dizajna je sljedeća:

$$\mathbf{X} = \begin{pmatrix} 1 & 3 & 16 & -8 & -11 \\ 1 & -5 & 4 & -8 & -7 \\ 1 & 7 & -4 & 11 & 9 \\ 1 & 15 & -20 & 25 & 25 \end{pmatrix}$$

Na ovom skupu treniramo model SVM-a s tvrdom marginom i linearnom jezgrenom funkcijom (tj. bez preslikavanja u prostor značajki). Model treniramo u primarnoj formulaciji. Za rješenje maksimalne margine dobili smo ovaj vektor težina (uključivo s težinom w_0):

$$\mathbf{w} = (-1.3214, +0.0714, +0.1071, 0, -0.0357)$$

Umjesto u primarnoj formulaciji, model smo mogli trenirati u dualnoj formulaciji, pa bismo umjesto vektora težina \mathbf{w} dobili vektor dualnih parametara α , odnosno Lagrangeove multiplikatore. Prisjetite se da su vektori čiji su Lagrangeovi multiplikatori veći od nule potporni vektori. Premda to nije uvijek moguće, u ovom konkretnom slučaju dualni parametri modela mogu se izvesti iz rješenja primarnog modela. Izvedite vektor dualnih parametara α . **Koliko iznosi najveća vrijednost parametra u vektoru dualnih parametara α ?** (Rezultate uspoređujte po prve tri decimale.)

- ☐ A 0.0013 ☐ B 0.0089 ☐ C 0.0024 ☐ D 0.0045

- 17** (N) Pomoću SVM-a rješavamo problem binarne klasifikacije grafova. Budući da su primjeri \mathbf{x} grafovi, koristimo SVM s jezgrenom funkcijom nad grafovima. Model treniramo na skupu od $N = 5$ označenih primjera, s vektorom oznaka jednakim $\mathbf{y} = (+1, +1, -1, -1, +1)$ i sa sljedećom jezgrenom matricom:

$$\mathbf{K} = \begin{pmatrix} 1.0 & 0.97 & -0.949 & -0.555 & -0.986 \\ 0.97 & 1.0 & -0.844 & -0.336 & -0.917 \\ -0.949 & -0.844 & 1.0 & 0.789 & 0.988 \\ -0.555 & -0.336 & 0.789 & 1.0 & 0.684 \\ -0.986 & -0.917 & 0.988 & 0.684 & 1.0 \end{pmatrix}$$

Treniranjem uz $C = 1$ za vektor dualnih parametara dobili smo $\alpha = (0, 0.754, 0.754, 1, 1)$. **Koliko iznosi gubitak zglobnice ovako naučenog modela SVM za četvrti primjer, $L(y^{(4)}, h(\mathbf{x}^{(4)}))$?**

- ☐ A 0.03 ☐ B 1.86 ☐ C 0.40 ☐ D 2.06

- 18** (N) Treniramo SVM s polinomijalnom jezgrom definiramo kao:

$$\kappa(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^T \mathbf{z})^2$$

Ova jezgra je Mercerova jezgra, što znači da postoji funkcija ϕ takva da $\kappa(\mathbf{x}, \mathbf{z}) = \phi(\mathbf{x})^T \phi(\mathbf{z})$. Konkretno, u slučaju dvodimenzijskoga ulaznog prostora ($n = 2$), ova jezgra odgovara preslikavanju u šesterodimenzijski prostor. Međutim, postoji odstupanje u konkretnim koeficijentima polinoma. Razmotrite primjer $\mathbf{x} = (1, 0)$ te izračunajte $\phi_\kappa(\mathbf{x})$, koji dobivamo preslikavanjem definiranim implicitno preko jezgre, te $\phi_p(\mathbf{x})$, koji dobivamo preslikavanjem definiranim kao polinom drugog stupnja. **Koliko iznosi euklidska udaljenost između $\phi_\kappa(\mathbf{x})$ i $\phi_p(\mathbf{x})$?**

- ☐ A $\sqrt{2}$ ☐ B $2\sqrt{2}$ ☐ C 0 ☐ D 4

- 19 (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), -1), ((-1, -1), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1))\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa $C = 1$. Kod modela s mekom marginom za dualne koeficijente vrijedi $\alpha_1 = 1$, $\alpha_2 > 0$, $\alpha_3 > 0$, $\alpha_4 > 0$ i $\alpha_5 = 1$. Skicirajte tvrdu i meku marginu u ulaznome prostoru. **Koliko je meka margina šira od tvrde margine?**

- ☐ A $\frac{4}{5}\sqrt{10}$ puta ☐ B $\frac{2}{5}\sqrt{10}$ puta ☐ C $\frac{3}{5}\sqrt{10}$ puta ☐ D $\frac{1}{6}\sqrt{2}$ puta

- 20 (T) Problem prokletstva dimenzionalnosti (engl. *curse of dimensionality*) pojavljuje se kod algoritama koji rade u visokodimenzijaskome vektorskom prostoru i manifestira se na različite načine. **Kako se problem prokletstva dimenzionalnosti u visokodimenzijaskim prostorima manifestira kod algoritma k -NN?**

- ☐ A Broj susjeda k povećava se za svaki primjer te model postaje sve jednostavniji
☐ B Udaljenost primjera do njegovih prvih k susjeda se smanjuje i svaki primjer postaje klasa za sebe
☐ C Prvih k susjeda nekog primjera su vrlo udaljeni od dotičnog primjera
☐ D Povećava se broj susjeda u okolini svakog primjera i model k -NN postaje sve jednostavniji

- 21 (P) Neka je $\mathcal{H}_{C,\gamma}$ model SVM-a s Gaussovom jezgrom. Hiperparametri tog modela su regularizacijski faktor C i preciznost jezgre γ . Odabir modela provodimo unakrsnom provjerom i to pretraživanjem po rešetci za sljedeće vrijednosti hiperparametara:

$$C = \{2^{-5}, 2^{-4}, \dots, 2^4, 2^5\}$$

$$\gamma = \{10^{-5}, 10^{-4}, \dots, 10^4, 10^5\}$$

Već ranije smo utvrdili da je model sa $C = 2^{-2}$ i $\gamma = 10^{-1}$ podnaučen, a da je model sa $C = 2^1$ i $\gamma = 10^1$ prenaučeni. Za sve ostale modele ne znamo jesu li prenaučeni, podnaučeni ili optimalni. **Koliko modela još ima smisla ispitati jer su moguće optimalni?**

- ☐ A 76 ☐ B 25 ☐ C 10 ☐ D 96

- 22 (T) Problem meke margine SVM-a s u primarnoj se formulaciji svodi na rješavanje sljedećeg optimizacijskog problema:

$$\operatorname{argmin}_{\mathbf{w}, w_0, \xi} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i \right\}$$

uz određena linearna ograničenja. Ovaj optimizacijski problem odgovara optimizaciji regularizirane pogreške. Kod regularizirane pogreške u opreci su dva cilja: smanjenje vrijednosti funkcije gubitka i smanjenje složenosti modela. **Kako se ta opreka manifestira kod optimizacijskog problema meke margine SVM-a?**

- ☐ A Što je manji hiperparametar C , to je manja važnost zbroja od ξ_i , pa je vrijednost $\|\mathbf{w}\|^2$ veća i model je veće složenosti
☐ B Što je manja vrijednost $\|\mathbf{w}\|^2$, to je margina šira, no tim više primjera ulazi u marginu i to je veći zbroj od ξ_i
☐ C Što je veći hiperparametar C , to se više kažnjava ulazak primjera u marginu, i to je manja vrijednost $\|\mathbf{w}\|^2$
☐ D Što je veća vrijednost $\|\mathbf{w}\|^2$ to je model složeniji, no tim je veća nelinearnost granice i to je veći hiperparametar C

Međuispit iz Strojnog učenja 1 (ak. god. 2021./2022.)

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 35% bodova na predmetu). Pitanja nose po 1 bod, a 1/3 boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **150 minuta**. Primjerak ispita morate predati zajedno sa svojim rješenjima.

Cjelina 1: Osnove i regresija (6 pitanja)

- 1** (P) Razmatramo klasifikacijski problem u ulaznome prostoru $\mathcal{X} = \mathbb{Z}^2$. Skup označenih primjera je $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), 1), ((-1, -1), 0), ((1, 1), 0)\}$. Razmatramo sljedeće modele \mathcal{H} i funkcije preslikavanja $\phi : \mathbb{Z}^2 \rightarrow \mathbb{Z}^2$, kojom primjere iz \mathcal{D} preslikavamo u matricu dizajna Φ :

$$\begin{aligned}\mathcal{H}_1 : h_1(\mathbf{x}|\theta_0, \theta_1) &= \mathbf{1}\{\theta_1 x_1 + \theta_0 \geq 0\} & \phi_1(\mathbf{x}) &= (1, x_2, x_1) \\ \mathcal{H}_2 : h_2(\mathbf{x}|\theta_0, \theta_2) &= \mathbf{1}\{\theta_2 x_2 + \theta_0 \geq 0\} & \phi_2(\mathbf{x}) &= (1, x_1, x_1 x_2) \\ \mathcal{H}_3 : h_3(\mathbf{x}|\theta) &= \mathbf{1}\{\theta^T \mathbf{x} \geq 0\} \\ \mathcal{H}_4 : h_4(\mathbf{x}|\theta_0) &= \mathbf{1}\{x_1^2 + x_2^2 \geq \theta_0\}\end{aligned}$$

U svim modelima parametri su realni brojevi, $\theta_j \in \mathbb{R}$. Odredite veličinu prostora inačica, $|VS_{\mathcal{H}, \Phi}|$, za ove kombinacije modela i funkcije preslikavanja. **Za koju kombinaciju modela i funkcije preslikavanja prostor inačica sadržava točno jednu hipotezu, $|VS_{\mathcal{H}, \Phi}| = 1$?**

- ☐ A $h_2 + \phi_2$ ☐ B $h_3 + \phi_2$ ☐ C $h_4 + \phi_1$ ☐ D $h_1 + \phi_1$

- 2** (T) Hipoteza h je funkcija koja primjerima iz \mathcal{X} pridjeljuje oznake iz \mathcal{Y} . Za h kažemo da je definirana “do na parametre θ ”. **Što to znači?**

- ☐ A Funkcija h jednoznačno određuje parametre θ iz skupa svih mogućih parametara, koji nazivamo prostor parametara
☐ B Funkcija h definirana je bez parametara, i njih treba odrediti naknadno postupkom odabira modela \mathcal{H}
☐ C Funkcija h definira preslikavanje iz označenog skupa primjera $\mathcal{X} \times \mathcal{Y}$ u prostor parametara θ
☐ D Svaka funkcija h ima svoje parametre θ koji u potpunosti definiraju preslikavanje $\mathcal{X} \rightarrow \mathcal{Y}$

- 3** (N) Raspoložemo sljedećim skupom primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((2, -3), -5), ((2, 3), 10), ((-3, 5), 5), ((5, 0), 20)\}$$

Na ovom skupu gradijentnim spustom trenirali smo L_1 -regularizirani model linearne regresije sa $\lambda = 2$. Dobili smo težine $\mathbf{w} = (-0.050, 2.965, 2.482)$. **Koliko iznosi L_1 -regularizirana pogreška $E(\mathbf{w}|\mathcal{D})$?**

- ☐ A 165.89 ☐ B 31.70 ☐ C 230.98 ☐ D 191.95

- 4** (P) Optimizacija parametara modela temelji se na funkciji gubitka $L : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}_0^+$, gdje je $L(y, h(\mathbf{x}))$ gubitak na primjeru (\mathbf{x}, y) . U većini primjena koristimo simetričan gubitak 0-1. Međutim, u nekim primjenama ima više smisla definirati asimetričan gubitak. Jedan takav primjer je zadatak detekcije neželjenih elektroničkih poruka (*spam filtering*). Taj zadatak možemo formalizirati kao problem binarne klasifikacije s oznakama $\mathcal{Y} = \{0, 1\}$, gdje $y = 1$ označava da je poruka neželjena (spam), a $y = 0$ da ona to nije. **Koje od sljedećih svojstava bi trebala zadovoljiti asimetrična funkcija gubitka za takav zadatak?**

- ☐ A $L(0, 1) > L(1, 0)$ i $L(1, 1) = L(0, 0) = 0$
☐ B $L(0, 0) = L(1, 1) < L(0, 1) < L(1, 0)$
☐ C $L(0, 1) = L(1, 0) > 0$ i $L(1, 1) = L(0, 0) = 0$
☐ D $L(0, 1) = 1$ i $L(1, 0) = L(1, 1) = L(0, 0) = 0$

- 5 (T) Optimizacijom regularizirane funkcije pogreške smanjuje se prenaučenos modela. **Kakve parametre modela nalazi optimizacija L_2 -regularizirane pogreške?**
- ☐ A Parametre koji uz što manju magnitudu vrijednosti daju što veće očekivanje gubitka na skupu za ispitivanje
- ☐ B Parametre koji uz što manju magnitudu vrijednosti daju što manje očekivanje gubitka na skupu za učenje
- ☐ C Parametre koji uz što veću magnitudu vrijednosti daju što manje očekivanje gubitka na skupu za ispitivanje
- ☐ D Parametre koji uz što veću magnitudu vrijednosti daju što veće očekivanje gubitka na skupu za učenje
- 6 (P) Koristimo regresiju za predviđanje kreditne sposobnosti klijenata. Na raspolaganju imamo podatke o dobi x_1 , ukupnom prinosu na račune x_2 , ukupnoj ušteđevini u kunama x_3 , ukupnoj deviznoj ušteđevini u eurima x_4 , ukupnom iznosu odobrenih kredita x_5 , ukupnom iznosu do sada otplaćenih kredita x_6 te preostalom ukupnom dugovanju po svim kreditima x_7 . Ove podatke želimo iskoristiti kao značajke, ali pritom naravno moramo paziti da ne uvedemo multikolinearnost, pa možda nećemo upotrijebiti sve značajke. Za funkciju preslikavanja ϕ koristimo preslikavanje s linearnim, kvadratnim i interakcijskim značajkama. Za interakcije razmatramo parove i trojke značajki, uključivo kombinacije kvadriranih i nekvriranih značajki (npr., x_1x_2 , $x_1^2x_2$ i $x_1x_2^2x_3^2$). **Koliko minimalno primjera za učenje trebamo imati, a da bi rješenje bilo stabilno i bez regularizacije?**
- ☐ A 48 ☐ B 92 ☐ C 86 ☐ D 79

Cjelina 2: Linearni klasifikacijski modeli (8 pitanja)

- 7 (N) Model regularizirane logističke regresije treniramo stohastičkim gradijentnim spustom. Koristimo faktor regularizacije $\lambda = 1000$ i stopu učenja $\eta = 0.01$. Primjere iz dvodimenzijskog ulaznog prostora preslikali smo u prostor značajki funkcijom $\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2)$. U jednoj iteraciji treniranja modela vektor parametara jednak je $\mathbf{w} = (0.5, -2.2, -1.1, 2.7)$. **Koliko u toj iteraciji iznosi promjena težine w_1 za primjer $(\mathbf{x}, y) = ((-1, 2), 1)$?**
- ☐ A -2 ☐ B +22 ☐ C -12 ☐ D -5
- 8 (N) Raspoložemo označenim skupom primjera iz triju klasa ($K = 3$) u trodimenzijskome ulaznom prostoru ($n = 3$). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer $\mathbf{x} = (-4, 1, -3)$ s oznakom $\mathbf{y} = (0, 1, 0)$. **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

- ☐ A 4.02 ☐ B 6.00 ☐ C 8.00 ☐ D 12.02
- 9 (P) Poopćeni linearni modeli mogu koristiti adaptivne bazne funkcije. Prednost toga je da ne moramo ručno definirati preslikavanje ϕ u prostor značajki, već se to preslikavanje može naučiti na temelju podataka. Rasplažemo podacima iz $K = 2$ klase u 50-dimenzijaskome ulaznom prostoru. Za taj klasifikacijski problem koristimo binarnu logističku regresiju, ali s adaptivnim baznim funkcijama. Svaka adaptivna bazna funkcija ϕ_j je i sama jedan model logističke regresije, pri čemu $\phi_0(\mathbf{x}) = 1$. Naš je model onda definiran ovako:

$$h(\mathbf{x}) = \sigma\left(\sum_{j=0}^5 w_j \phi_j(\mathbf{x})\right)$$

Koliko ukupno parametara ima ovaj model?

- ☐ A 506 ☐ B 261 ☐ C 256 ☐ D 511

- 10 (P) Razmotrimo sljedeći skup označenih primjera:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((-2, 0), -1), ((-1, 0), +1), ((1, 0), +1), ((2, 0), -1))\}$$

Nad ovim skupom treniramo dva modela: neregulariziranu logističku regresiju (LR) i L_2 -regulariziranu logističku regresiju (L2LR). Pored toga, razmatramo tri funkcije preslikavanja:

$$\begin{aligned}\phi_0(\mathbf{x}) &= (1, x_1, x_2) \\ \phi_1(\mathbf{x}) &= (1, x_1, x_2, x_1^2, x_2^2) \\ \phi_2(\mathbf{x}) &= (1, x_1, x_2, x_1x_2)\end{aligned}$$

Ukupno, dakle, isprobavamo šest algoritama, odnosno šest kombinacija modela i funkcije preslikavanja. **Za koje algoritme (model+preslikavanje) optimizacijski postupak na skupu za učenje ne konvergira?**

- ☐ A LR+ ϕ_2 ☐ B L2LR+ ϕ_2 ☐ C L2LR+ ϕ_0 ☐ D LR+ ϕ_1

- 11 (T) Algoritam strojnog učenja idealno bi minimizirao gubitak 0-1. Međutim, funkciju gubitka 0-1 u praksi ne možemo koristiti za optimizaciju parametara modela. **Zašto gubitak 0-1 ne možemo koristiti za optimizaciju?**

- ☐ A Funkcija gubitka 0-1 nije diferencijabilna, pa ne postoji rješenje u zatvorenoj formi i ne postoji gradijent
☐ B Funkcija gubitka 0-1 nije konveksna, pa ni funkcija pogreške nije konveksna već ima lokalne minimume te ne postoji minimizator u zatvorenoj formi
☐ C Gubitak 0-1 pored neispravno klasificiranih primjera kažnjava i ispravno klasificirane primjere, i to tim više što su oni dalje od granice između klasa
☐ D Gradijent gubitka 0-1 svugdje je nula osim za $h(\mathbf{x}) = 0$, pa funkcija pogreške ima zaravni po kojima se gradijentni spust ne može spuštati

- 12 (N) Na skupu označenih primjera \mathcal{D} trenirali smo model logističke regresije. Dobili smo neki vektor težina \mathbf{w} i pomak $w_0 = 0.15$. Tako naučenom modelu neki primjer \mathbf{x} , čija je oznaka u skupu primjera $y = 0$, nanosi gubitak unakrsne entropije od $L(0, h(\mathbf{x})) = 0.274$. **Koliki gubitak unakrsne entropije bi nanosio primjer \mathbf{x} kada bismo njegove značajke pomnožili sa dva i promijenili mu oznaku?**

- ☐ A 1.19 ☐ B 4.03 ☐ C 2.54 ☐ D 7.11

- 13 (N) Raspoložemo sljedećim skupom za učenje u dvodimenzijskom ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((1, 0), +1), ((2, -3), -1), ((2, 5), -1))\}$$

Na ovom skupu treniramo perceptron. Pritom koristimo funkciju preslikavanja u peterodimenzijski prostor značajki, koja je definirana na sljedeći način:

$$\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2, x_1^2, x_2^2)$$

Početne težine perceptrona neka su sljedeće:

$$\mathbf{w} = (1, 0, 1, 2, -3, 0)$$

Koliko iznosi empirijska pogreška perceptrona na skupu za učenje prije početka treniranja (dakle, s početnim težinama)?

- ☐ A 6 ☐ B 22 ☐ C 16 ☐ D 32

- 14 (T) Poopćeni linearni modeli (linearna regresija, logistička regresija i multinomijalna regresija) probabilistički su algoritmi strojnog učenja. Njihova probabilistička priroda dolazi do izražaja kako kod modela tako i kod optimizacijskog postupka. **Koji je probabilistički princip ugrađen u optimizacijski postupak tih algoritama?**

- ☐ A Minimizarati $-\sum_{i=1}^N y^{(i)} p(y^{(i)}|\mathbf{x}^{(i)})$, gdje je $p(y^{(i)}|\mathbf{x}^{(i)}) = h(\mathbf{x}; \mathbf{w})$
☐ B Maksimizirati $\prod_{i=1}^N \ln p(y^{(i)}|\mathbf{x}^{(i)})$, gdje je $\mathbb{E}[p(y^{(i)}|\mathbf{x}^{(i)})] = \mathbf{w}^T \mathbf{x}$
☐ C Minimizarati $-\ln \prod_{i=1}^N p(y^{(i)}|\mathbf{x}^{(i)})$, gdje je $\mathbb{E}[p(y^{(i)}|\mathbf{x}^{(i)})] = f(\mathbf{w}^T \mathbf{x})$
☐ D Minimizarati $\sum_{i=1}^N \ln h(\mathbf{x}^{(i)}; \mathbf{w})$, gdje je $h(\mathbf{x}; \mathbf{w}) = f(\mathbf{w}^T \mathbf{x})$

Cjelina 3: Jezgrene i neparametarske metode (8 pitanja)

- 15 (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), -1), ((-2, -2), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1))\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa $C = 1$. Kod modela s mekom marginom za dualne koeficijente vrijedi $\alpha_1 = 1$, $\alpha_2 > 0$, $\alpha_3 > 0$, $\alpha_4 > 0$ i $\alpha_5 = 1$. Skicirajte tvrdu i meku marginu u ulaznome prostoru. **Koliko je meka margina šira od tvrde margine?**

- ☐ A $\frac{4}{5}\sqrt{10}$ puta ☐ B $\frac{3}{5}\sqrt{10}$ puta ☐ C $\frac{2}{5}\sqrt{10}$ puta ☐ D $\frac{1}{6}\sqrt{2}$ puta

- 16 (N) Pomoću SVM-a rješavamo problem binarne klasifikacije grafova. Budući da su primjeri \mathbf{x} grafovi, koristimo SVM s jezgrenom funkcijom nad grafovima. Model treniramo na skupu od $N = 5$ označenih primjera, s vektorom oznaka jednakim $\mathbf{y} = (-1, -1, -1, +1, +1)$ i sa sljedećom jezgrenom matricom:

$$\mathbf{K} = \begin{pmatrix} 1.0 & 0.97 & -0.949 & -0.555 & -0.986 \\ 0.97 & 1.0 & -0.844 & -0.336 & -0.917 \\ -0.949 & -0.844 & 1.0 & 0.789 & 0.988 \\ -0.555 & -0.336 & 0.789 & 1.0 & 0.684 \\ -0.986 & -0.917 & 0.988 & 0.684 & 1.0 \end{pmatrix}$$

Treniranjem uz $C = 1$ za vektor dualnih parametara dobili smo $\boldsymbol{\alpha} = (0, 0.733, 1, 1, 0.733)$. **Koliko iznosi gubitak zglobnice ovako naučenog modela SVM za četvrti primjer, $L(y^{(4)}, h(\mathbf{x}^{(4)}))$?**

- ☐ A 0.03 ☐ B 0.40 ☐ C 1.86 ☐ D 2.06

- 17 (T) Problem prokletstva dimenzionalnosti (engl. *curse of dimensionality*) pojavljuje se kod algoritama koji rade u visokodimenzijaskome vektorskom prostoru i manifestira se na različite načine. **Kako se problem prokletstva dimenzionalnosti u visokodimenzijaskim prostorima manifestira kod algoritma k -NN?**

- ☐ A Udaljenosti između primjera se smanjuju i model k -NN postaje sve složeniji
☐ B Primjeri se grupiraju u središte vektorskog prostora i udaljenost postaje nediskriminativna
☐ C Povećava se broj susjeda u okolini svakog primjera i model k -NN postaje sve jednostavniji
☐ D Svi primjeri su međusobno vrlo udaljeni i gube se razlike u udaljenosti

- 18 (N) Treniramo SVM s polinomijalnom jezgrom definiramo kao:

$$\kappa(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^T \mathbf{z})^2$$

Ova jezgra je Mercerova jezgra, što znači da postoji funkcija ϕ takva da $\kappa(\mathbf{x}, \mathbf{z}) = \phi(\mathbf{x})^T \phi(\mathbf{z})$. Konkretno, u slučaju dvodimenzijaskoga ulaznog prostora ($n = 2$), ova jezgra odgovara preslikavanju u šesterodimenzijaski prostor. Međutim, postoji odstupanje u konkretnim koeficijentima polinoma. Razmotrite primjer $\mathbf{x} = (1, 0)$ te izračunajte $\phi_\kappa(\mathbf{x})$, koji dobivamo preslikavanjem definiranim implicitno preko jezgre, te $\phi_p(\mathbf{x})$, koji dobivamo preslikavanjem definiranim kao polinom drugog stupnja. **Koliko iznosi euklidska udaljenost između $\phi_\kappa(\mathbf{x})$ i $\phi_p(\mathbf{x})$?**

- ☐ A $2\sqrt{2}$ ☐ B $\sqrt{2}$ ☐ C 0 ☐ D 4

- 19 (P) Za binarnu klasifikaciju koristimo SVM s Gaussovom jezgrenom funkcijom. Razmatramo tri primjera u ulaznome prostoru: $\mathbf{x}^{(1)}$, $\mathbf{x}^{(2)}$ i $\mathbf{x}^{(3)}$. Euklidska udaljenosti između primjera $\mathbf{x}^{(1)}$ i $\mathbf{x}^{(2)}$ manja je nego euklidska udaljenost između primjera $\mathbf{x}^{(1)}$ i $\mathbf{x}^{(3)}$. Za izračun sličnosti između primjera koristimo Gaussovu jezgrenu funkciju $\kappa(\mathbf{x}^{(i)}, \mathbf{x}^{(j)})$ s preciznošću γ , gdje $\gamma = 1/2\sigma^2$. **Kakav bi efekt na sličnosti između primjera imalo povećanje preciznosti γ Gaussove jezgrene funkcije?**

- ☐ A Sličnosti bi se povećale, ali $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se povećala manje nego što bi se povećala $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$
☐ B Sličnosti bi se smanjile, ali $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se smanjila više nego što bi se smanjila $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$
☐ C Sličnosti bi se smanjile, ali $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se smanjila manje nego što bi se smanjila $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$
☐ D Sličnosti bi se povećale, ali $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se povećala više nego što bi se povećala $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$

- 20 (P) Neka je $\mathcal{H}_{C,\gamma}$ model SVM-a s Gaussovom jezgrom. Hiperparametri tog modela su regularizacijski faktor C i preciznost jezgre γ . Odabir modela provodimo unakrsnom provjerom i to pretraživanjem po rešetci za sljedeće vrijednosti hiperparametara:

$$C = \{2^{-5}, 2^{-4}, \dots, 2^4, 2^5\}$$

$$\gamma = \{10^{-5}, 10^{-4}, \dots, 10^4, 10^5\}$$

Za model sa $C = 2^{-2}$ i $\gamma = 10^1$ utvrdili smo da je podnaučen, a za model sa $C = 2^1$ i $\gamma = 10^1$ utvrdili smo da je prenaučan. **Koliko modela još ima smisla ispitati jer su moguće optimalni?**

- ☐ A 25 ☐ B 96 ☐ C 68 ☐ D 10

- 21 (N) Rješavamo binarni klasifikacijski problem. Raspoložemo označenim skupom primjera. Odgovarajuća matrica dizajna je sljedeća:

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 22 & 0 & -5 \\ 1 & 6 & 28 & 8 & 2 \\ 1 & -6 & -15 & -9 & -6 \\ 1 & -11 & -34 & -16 & -9 \end{pmatrix}$$

Na ovom skupu treniramo model SVM-a s tvrdom marginom i linearnom jezgrenom funkcijom (tj. bez preslikavanja u prostor značajki). Model treniramo u primarnoj formulaciji. Za rješenje maksimalne margine dobili smo ovaj vektor težina (uključivo s težinom w_0):

$$\mathbf{w} = (+2.7838, +0.0225, +0.0856, +0.0315, +0.0135)$$

Umjesto u primarnoj formulaciji, model smo mogli trenirati u dualnoj formulaciji, pa bismo umjesto vektora težina \mathbf{w} dobili vektor dualnih parametara α , odnosno Lagrangeove multiplikatore. Prisjetite se da su vektori čiji su Lagrangeovi multiplikatori veći od nule potporni vektori. Premda to nije uvijek moguće, u ovom konkretnom slučaju dualni parametri modela mogu se izvesti iz rješenja primarnog modela. Izvedite vektor dualnih parametara α . **Koliko iznosi najveća vrijednost parametra u vektoru dualnih parametara α ?** (Rezultate uspoređujte po prve tri decimale.)

- ☐ A 0.0089 ☐ B 0.0013 ☐ C 0.0024 ☐ D 0.0045

- 22 (T) Problem meke margine SVM-a s u primarnoj se formulaciji svodi na rješavanje sljedećeg optimizacijskog problema:

$$\operatorname{argmin}_{\mathbf{w}, w_0, \xi} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i \right\}$$

uz određena linearna ograničenja. Ovaj optimizacijski problem odgovara optimizaciji regularizirane pogreške. Kod regularizirane pogreške u opreci su dva cilja: smanjenje vrijednosti funkcije gubitka i smanjenje složenosti modela. **Kako se ta opreka manifestira kod optimizacijskog problema meke margine SVM-a?**

- ☐ A Što je manji zbroj od ξ_i , to više primjera može ući u marginu i tim je veća vrijednost $\|\mathbf{w}\|^2$ te je model manje složenosti
- ☐ B Što je veći hiperparametar C , to se više kažnjava ulazak primjera u marginu, i to je manja vrijednost $\|\mathbf{w}\|^2$
- ☐ C Što je veća vrijednost $\|\mathbf{w}\|^2$ to je model složeniji, no tim je veća nelinearnost granice i to je veći hiperparametar C
- ☐ D Što je manja vrijednost $\|\mathbf{w}\|^2$, to je margina šira, no tim više primjera ulazi u marginu i to je veći zbroj od ξ_i

Međuispit iz Strojnog učenja 1 (ak. god. 2021./2022.)

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 35% bodova na predmetu). Pitanja nose po 1 bod, a 1/3 boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **150 minuta**. Primjerak ispita morate predati zajedno sa svojim rješenjima.

Cjelina 1: Osnove i regresija (6 pitanja)

- 1** (T) Optimizacijom regularizirane funkcije pogreške smanjuje se prenaučenos modela. **Kakve parametre modela nalazi optimizacija L_2 -regularizirane pogreške?**
- ☐ A Parametre koji uz što veću magnitudu vrijednosti daju što veće očekivanje gubitka na skupu za učenje
- ☐ B Parametre koji uz što veću magnitudu vrijednosti daju što manje očekivanje gubitka na skupu za ispitivanje
- ☐ C Parametre koji uz što manju magnitudu vrijednosti daju što manje očekivanje gubitka na skupu za učenje
- ☐ D Parametre koji uz što manju magnitudu vrijednosti daju što veće očekivanje gubitka na skupu za ispitivanje
- 2** (T) Hipoteza h je funkcija koja primjerima iz \mathcal{X} pridjeljuje oznake iz \mathcal{Y} . Za h kažemo da je definirana “do na parametre θ ”. **Što to znači?**
- ☐ A Funkcija h definirana je bez parametara, i njih treba odrediti naknadno postupkom odabira modela \mathcal{H}
- ☐ B Svaka vrijednost parametara θ daje jednu konkretnu funkciju h koja se razlikuje od svih drugih funkcija u modelu \mathcal{H}
- ☐ C Funkcija h jednoznačno određuje parametre θ iz skupa svih mogućih parametara, koji nazivamo prostor parametara
- ☐ D Funkcija h izračunava oznaku \mathcal{Y} na temelju parametra θ , koje treba podesiti optimizacijskim postupkom
- 3** (P) Koristimo regresiju za predviđanje kreditne sposobnosti klijenata. Na raspolaganju imamo podatke o dobi x_1 , ukupnom prinosu na račune x_2 , ukupnoj ušteđevini u kunama x_3 , ukupnoj deviznoj ušteđevini u eurima x_4 , ukupnom iznosu odobrenih kredita x_5 , ukupnom iznosu do sada otplaćenih kredita x_6 te preostalom ukupnom dugovanju po svim kreditima x_7 . Ove podatke želimo iskoristiti kao značajke, ali pritom naravno moramo paziti da ne uvedemo multikolinearnost, pa možda nećemo upotrijebiti sve značajke. Za funkciju preslikavanja ϕ koristimo preslikavanje s linearnim, kvadratnim i interakcijskim značajkama. Za interakcije razmatramo parove i trojke značajki, uključivo kombinacije kvadriranih i nekvadriranih značajki (npr., x_1x_2 , $x_1^2x_2$ i $x_1x_2^2x_3^2$). **Koliko minimalno primjera za učenje trebamo imati, a da bi rješenje bilo stabilno i bez regularizacije?**
- ☐ A 48 ☐ B 86 ☐ C 92 ☐ D 79
- 4** (P) Razmatramo klasifikacijski problem u ulaznome prostoru $\mathcal{X} = \mathbb{Z}^2$. Skup označenih primjera je $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), 1), ((-1, -1), 0), ((1, 1), 0)\}$. Razmatramo sljedeće modele \mathcal{H} i funkcije preslikavanja $\phi : \mathbb{Z}^2 \rightarrow \mathbb{Z}^2$, kojom primjere iz \mathcal{D} preslikavamo u matricu dizajna Φ :
- $$\begin{aligned}\mathcal{H}_1 : h_1(\mathbf{x}|\theta_0, \theta_1) &= \mathbf{1}\{\theta_1 x_1 + \theta_0 \geq 0\} & \phi_1(\mathbf{x}) &= (1, x_2, x_1) \\ \mathcal{H}_2 : h_2(\mathbf{x}|\theta_0, \theta_2) &= \mathbf{1}\{\theta_2 x_2 + \theta_0 \geq 0\} & \phi_2(\mathbf{x}) &= (1, x_1, x_1 x_2) \\ \mathcal{H}_3 : h_3(\mathbf{x}|\theta) &= \mathbf{1}\{\theta^T \mathbf{x} \geq 0\} \\ \mathcal{H}_4 : h_4(\mathbf{x}|\theta_0) &= \mathbf{1}\{x_1^2 + x_2^2 \geq \theta_0\}\end{aligned}$$
- U svim modelima parametri su realni brojevi, $\theta_j \in \mathbb{R}$. Odredite veličinu prostora inačica, $|VS_{\mathcal{H}, \Phi}|$, za ove kombinacije modela i funkcije preslikavanja. **Za koju kombinaciju modela i funkcije preslikavanja prostor inačica sadržava točno jednu hipotezu, $|VS_{\mathcal{H}, \Phi}| = 1$?**
- ☐ A $h_4 + \phi_1$ ☐ B $h_3 + \phi_2$ ☐ C $h_1 + \phi_1$ ☐ D $h_2 + \phi_2$

- 5 (N) Raspoložemo sljedećim skupom primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((2, -3), -5), ((2, 3), -10), ((-3, 5), 5), ((5, 0), 20)\}$$

Na ovom skupu gradijentnim spustom trenirali smo L_1 -regularizirani model linearne regresije sa $\lambda = 2$. Dobili smo težine $\mathbf{w} = (-0.156, 1.330, 0.529)$. **Koliko iznosi L_1 -regularizirana pogreška $E(\mathbf{w}|\mathcal{D})$?**

- ☐ A 31.70 ☐ B 165.89 ☐ C 230.98 ☐ D 191.95

- 6 (P) Optimizacija parametara modela temelji se na funkciji gubitka $L : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}_0^+$, gdje je $L(y, h(\mathbf{x}))$ gubitak na primjeru (\mathbf{x}, y) . U većini primjena koristimo simetričan gubitak 0-1. Međutim, u nekim primjenama ima više smisla definirati asimetričan gubitak. Jedan takav primjer je zadatak detekcije neželjenih elektroničkih poruka (*spam filtering*). Taj zadatak možemo formalizirati kao problem binarne klasifikacije s oznakama $\mathcal{Y} = \{0, 1\}$, gdje $y = 1$ označava da je poruka neželjena (spam), a $y = 0$ da ona to nije. **Koje od sljedećih svojstava bi trebala zadovoljiti asimetrična funkcija gubitka za takav zadatak?**

- ☐ A $L(0, 1) = L(1, 0) > 0$ i $L(1, 1) = L(0, 0) = 0$
☐ B $L(0, 1) = 1$ i $L(1, 0) = L(1, 1) = L(0, 0) = 0$
☐ C $L(0, 0) = L(1, 1) < L(0, 1) < L(1, 0)$
☐ D $L(0, 1) > L(1, 0)$ i $L(1, 1) = L(0, 0) = 0$

Cjelina 2: Linearni klasifikacijski modeli (8 pitanja)

- 7 (N) Raspoložemo označenim skupom primjera iz triju klasa ($K = 3$) u trodimenzijaskome ulaznom prostoru ($n = 3$). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer $\mathbf{x} = (-4, -1, -3)$ s oznakom $\mathbf{y} = (0, 0, 1)$. **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

- ☐ A 4.02 ☐ B 6.00 ☐ C 8.00 ☐ D 12.02

- 8 (T) Algoritam strojnog učenja idealno bi minimizirao gubitak 0-1. Međutim, funkciju gubitka 0-1 u praksi ne možemo koristiti za optimizaciju parametara modela. **Zašto gubitak 0-1 ne možemo koristiti za optimizaciju?**

- ☐ A Funkcija gubitka 0-1 nije diferencijabilna, pa ne postoji rješenje u zatvorenoj formi i ne postoji gradijent
☐ B Gubitak 0-1 pored neispravno klasificiranih primjera kažnjava i ispravno klasificirane primjere, i to tim više što su oni dalje od granice između klasa
☐ C Funkcija gubitka 0-1 nije konveksna, pa ni funkcija pogreške nije konveksna već ima lokalne minimume te ne postoji minimizator u zatvorenoj formi
☐ D Gradijent gubitka 0-1 svugdje je nula osim za $h(\mathbf{x}) = 0$, pa funkcija pogreške ima zaravni po kojima se gradijentni spust ne može spuštati

- 9 (P) Poopćeni linearni modeli mogu koristiti adaptivne bazne funkcije. Prednost toga je da ne moramo ručno definirati preslikavanje ϕ u prostor značajki, već se to preslikavanje može naučiti na temelju podataka. Rasplažemo podatcima iz $K = 2$ klase u 50-dimenzijaskome ulaznom prostoru. Za taj klasifikacijski problem koristimo binarnu logističku regresiju, ali s adaptivnim baznim funkcijama. Svaka adaptivna bazna funkcija ϕ_j je i sama jedan model logističke regresije, pri čemu $\phi_0(\mathbf{x}) = 1$. Naš je model onda definiran ovako:

$$h(\mathbf{x}) = \sigma\left(\sum_{j=0}^5 w_j \phi_j(\mathbf{x})\right)$$

Koliko ukupno parametara ima ovaj model?

- ☐ A 506 ☐ B 511 ☐ C 261 ☐ D 256

- 10** (N) Model regularizirane logističke regresije treniramo stohastičkim gradijentnim spustom. Koristimo faktor regularizacije $\lambda = 1000$ i stopu učenja $\eta = 0.01$. Primjere iz dvodimenzijskog ulaznog prostora preslikali smo u prostor značajki funkcijom $\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2)$. U jednoj iteraciji treniranja modela vektor parametara jednak je $\mathbf{w} = (0.2, 0.5, -1.1, 2.7)$. **Koliko u toj iteraciji iznosi promjena težine w_1 za primjer $(\mathbf{x}, y) = ((-1, 2), 1)$?**

☐ A -12 ☐ B -5 ☐ C $+22$ ☐ D -2

- 11** (N) Raspoložemo sljedećim skupom za učenje u dvodimenzijskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((1, 0), +1), ((2, -3), -1), ((2, 5), -1))\}$$

Na ovom skupu treniramo perceptron. Pritom koristimo funkciju preslikavanja u peterodimenzijski prostor značajki, koja je definirana na sljedeći način:

$$\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2, x_1^2, x_2^2)$$

Početne težine perceptrona neka su sljedeće:

$$\mathbf{w} = (1, 0, -1, 2, -3, 0)$$

Koliko iznosi empirijska pogreška perceptrona na skupu za učenje prije početka treniranja (dakle, s početnim težinama)?

☐ A 6 ☐ B 16 ☐ C 32 ☐ D 22

- 12** (T) Poopćeni linearni modeli (linearna regresija, logistička regresija i multinomijalna regresija) probabilistički su algoritmi strojnog učenja. Njihova probabilistička priroda dolazi do izražaja kako kod modela tako i kod optimizacijskog postupka. **Koji je probabilistički princip ugrađen u optimizacijski postupak tih algoritama?**

- ☐ A Minimizirati $-\sum_{i=1}^N y^{(i)} p(y^{(i)}|\mathbf{x}^{(i)})$, gdje je $p(y^{(i)}|\mathbf{x}^{(i)}) = h(\mathbf{x}; \mathbf{w})$
☐ B Minimizirati $\sum_{i=1}^N \ln h(\mathbf{x}^{(i)}; \mathbf{w})$, gdje je $h(\mathbf{x}; \mathbf{w}) = f(\mathbf{w}^T \mathbf{x})$
☐ C Minimizirati $-\sum_{i=1}^N \ln y^{(i)} h(\mathbf{x}^{(i)}; \mathbf{w})$, gdje je $h(\mathbf{x}; \mathbf{w}) = \mathbf{w}^T \mathbf{x}$
☐ D Minimizirati $-\ln \prod_{i=1}^N p(y^{(i)}|\mathbf{x}^{(i)})$, gdje je $\mathbb{E}[p(y^{(i)}|\mathbf{x}^{(i)})] = f(\mathbf{w}^T \mathbf{x})$

- 13** (N) Na skupu označenih primjera \mathcal{D} trenirali smo model logističke regresije. Dobili smo neki vektor težina \mathbf{w} i pomak $w_0 = 0.15$. Tako naučenom modelu neki primjer \mathbf{x} , čija je oznaka u skupu primjera $y = 0$, nanosi gubitak unakrsne entropije od $L(0, h(\mathbf{x})) = 0.274$. **Koliki gubitak unakrsne entropije bi nanosio primjer \mathbf{x} kada bismo njegove značajke pomnožili sa dva i promijenili mu oznaku?**

☐ A 7.11 ☐ B 2.54 ☐ C 4.03 ☐ D 1.19

- 14** (P) Razmotrimo sljedeći skup označenih primjera:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((-2, 0), -1), ((-1, 0), +1), ((1, 0), +1), ((2, 0), -1))\}$$

Nad ovim skupom treniramo dva modela: neregulariziranu logističku regresiju (LR) i L_2 -regulariziranu logističku regresiju (L2LR). Pored toga, razmatramo tri funkcije preslikavanja:

$$\begin{aligned}\phi_0(\mathbf{x}) &= (1, x_1, x_2) \\ \phi_1(\mathbf{x}) &= (1, x_1, x_2, x_1^2, x_2^2) \\ \phi_2(\mathbf{x}) &= (1, x_1, x_2, x_1x_2)\end{aligned}$$

Ukupno, dakle, isprobavamo šest algoritama, odnosno šest kombinacija modela i funkcije preslikavanja. **Za koje algoritme (model+preslikavanje) optimizacijski postupak na skupu za učenje ne konvergira?**

☐ A L2LR+ ϕ_2 ☐ B LR+ ϕ_0 ☐ C LR+ ϕ_1 ☐ D L2LR+ ϕ_0

Cjelina 3: Jezgrene i neparametarske metode (8 pitanja)

- 15 (N) Treniramo SVM s polinomijalnom jezgrom definiramo kao:

$$\kappa(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^T \mathbf{z})^2$$

Ova jezgra je Mercerova jezgra, što znači da postoji funkcija ϕ takva da $\kappa(\mathbf{x}, \mathbf{z}) = \phi(\mathbf{x})^T \phi(\mathbf{z})$. Konkretno, u slučaju dvodimenzijskoga ulaznog prostora ($n = 2$), ova jezgra odgovara preslikavanju u šesterodimenzijski prostor. Međutim, postoji odstupanje u konkretnim koeficijentima polinoma. Razmotrite primjer $\mathbf{x} = (1, 0)$ te izračunajte $\phi_\kappa(\mathbf{x})$, koji dobivamo preslikavanjem definiranim implicitno preko jezgre, te $\phi_p(\mathbf{x})$, koji dobivamo preslikavanjem definiranim kao polinom drugog stupnja. **Koliko iznosi euklidska udaljenost između $\phi_\kappa(\mathbf{x})$ i $\phi_p(\mathbf{x})$?**

- ☐ A 4 ☐ B $2\sqrt{2}$ ☐ C 0 ☐ D $\sqrt{2}$

- 16 (N) Pomoću SVM-a rješavamo problem binarne klasifikacije grafova. Budući da su primjeri \mathbf{x} grafovi, koristimo SVM s jezgrenom funkcijom nad grafovima. Model treniramo na skupu od $N = 5$ označenih primjera, s vektorom oznaka jednakim $\mathbf{y} = (-1, -1, -1, +1, +1)$ i sa sljedećom jezgrenom matricom:

$$\mathbf{K} = \begin{pmatrix} 1.0 & 0.97 & -0.949 & -0.555 & -0.986 \\ 0.97 & 1.0 & -0.844 & -0.336 & -0.917 \\ -0.949 & -0.844 & 1.0 & 0.789 & 0.988 \\ -0.555 & -0.336 & 0.789 & 1.0 & 0.684 \\ -0.986 & -0.917 & 0.988 & 0.684 & 1.0 \end{pmatrix}$$

Treniranjem uz $C = 1$ za vektor dualnih parametara dobili smo $\boldsymbol{\alpha} = (0, 0.733, 1, 1, 0.733)$. **Koliko iznosi gubitak zglobnice ovako naučenog modela SVM za četvrti primjer, $L(y^{(4)}, h(\mathbf{x}^{(4)}))$?**

- ☐ A 0.03 ☐ B 2.06 ☐ C 1.86 ☐ D 0.40

- 17 (T) Problem meke margine SVM-a s u primarnoj se formulaciji svodi na rješavanje sljedećeg optimizacijskog problema:

$$\operatorname{argmin}_{\mathbf{w}, w_0, \boldsymbol{\xi}} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i \right\}$$

uz određena linearna ograničenja. Ovaj optimizacijski problem odgovara optimizaciji regularizirane pogreške. Kod regularizirane pogreške u opreci su dva cilja: smanjenje vrijednosti funkcije gubitka i smanjenje složenosti modela. **Kako se ta opreka manifestira kod optimizacijskog problema meke margine SVM-a?**

- ☐ A Što je manji hiperparametar C , to je manja važnost zbroja od ξ_i , pa je vrijednost $\|\mathbf{w}\|^2$ veća i model je veće složenosti
- ☐ B Što je veći zbroj od ξ_i , to više primjera ulazi u marginu i tim je manja vrijednost $\|\mathbf{w}\|^2$ te je model veće složenosti
- ☐ C Što je manja vrijednost $\|\mathbf{w}\|^2$, to je margina šira, no tim više primjera ulazi u marginu i to je veći zbroj od ξ_i
- ☐ D Što je veći hiperparametar C , to se više kažnjava ulazak primjera u marginu, i to je manja vrijednost $\|\mathbf{w}\|^2$

- 18 (T) Problem prokletstva dimenzionalnosti (engl. *curse of dimensionality*) pojavljuje se kod algoritama koji rade u visokodimenzijskome vektorskom prostoru i manifestira se na različite načine. **Kako se problem prokletstva dimenzionalnosti u visokodimenzijskim prostorima manifestira kod algoritma k -NN?**

- ☐ A Prvih k susjeda nekog primjera su vrlo udaljeni od dotičnog primjera
- ☐ B Broj susjeda k nekog primjera se smanjuje i gube se granice između klasa
- ☐ C Primjeri se grupiraju u središte vektorskog prostora i udaljenost postaje nediskriminativna
- ☐ D Udaljenosti između primjera se smanjuju i model k -NN postaje sve složeniji

- 19 (P) Neka je $\mathcal{H}_{C,\gamma}$ model SVM-a s Gaussovom jezgrom. Hiperparametri tog modela su regularizacijski faktor C i preciznost jezgre γ . Odabir modela provodimo unakrsnom provjerom i to pretraživanjem po rešetci za sljedeće vrijednosti hiperparametara:

$$C = \{2^{-5}, 2^{-4}, \dots, 2^4, 2^5\}$$

$$\gamma = \{10^{-5}, 10^{-4}, \dots, 10^4, 10^5\}$$

Za model sa $C = 2^{-2}$ i $\gamma = 10^1$ utvrdili smo da je podnaučen, a za model sa $C = 2^1$ i $\gamma = 10^1$ utvrdili smo da je prenaučan. **Koliko modela još ima smisla ispitati jer su moguće optimalni?**

- ☐ A 68 ☐ B 96 ☐ C 25 ☐ D 10

- 20 (N) Rješavamo binarni klasifikacijski problem. Raspoložemo označenim skupom primjera. Odgovarajuća matrica dizajna je sljedeća:

$$\mathbf{X} = \begin{pmatrix} 1 & 3 & 16 & -8 & -11 \\ 1 & -5 & 4 & -8 & -7 \\ 1 & 7 & -4 & 11 & 9 \\ 1 & 15 & -20 & 25 & 25 \end{pmatrix}$$

Na ovom skupu treniramo model SVM-a s tvrdom marginom i linearnom jezgrenom funkcijom (tj. bez preslikavanja u prostor značajki). Model treniramo u primarnoj formulaciji. Za rješenje maksimalne margine dobili smo ovaj vektor težina (uključivo s težinom w_0):

$$\mathbf{w} = (+0.1370, -0.0290, +0.0194, -0.0461, -0.0388)$$

Umjesto u primarnoj formulaciji, model smo mogli trenirati u dualnoj formulaciji, pa bismo umjesto vektora težina \mathbf{w} dobili vektor dualnih parametara α , odnosno Lagrangeove multiplikatore. Prisjetite se da su vektori čiji su Lagrangeovi multiplikatori veći od nule potporni vektori. Premda to nije uvijek moguće, u ovom konkretnom slučaju dualni parametri modela mogu se izvesti iz rješenja primarnog modela. Izvedite vektor dualnih parametara α . **Koliko iznosi najveća vrijednost parametra u vektoru dualnih parametara α ?** (Rezultate uspoređujte po prve tri decimale.)

- ☐ A 0.0045 ☐ B 0.0013 ☐ C 0.0024 ☐ D 0.0089

- 21 (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), -1), ((-1, -1), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1))\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa $C = 1$. Kod modela s mekom marginom za dualne koeficijente vrijedi $\alpha_1 = 1$, $\alpha_2 > 0$, $\alpha_3 > 0$, $\alpha_4 > 0$ i $\alpha_5 = 1$. Skicirajte tvrdi i meku marginu u ulaznome prostoru. **Koliko je meka margina šira od tvrde margine?**

- ☐ A $\frac{2}{5}\sqrt{10}$ puta ☐ B $\frac{1}{6}\sqrt{2}$ puta ☐ C $\frac{3}{5}\sqrt{10}$ puta ☐ D $\frac{4}{5}\sqrt{10}$ puta

- 22 (P) Za binarnu klasifikaciju koristimo SVM s Gaussovom jezgrenom funkcijom. Razmatramo tri primjera u ulaznome prostoru: $\mathbf{x}^{(1)}$, $\mathbf{x}^{(2)}$ i $\mathbf{x}^{(3)}$. Euklidska udaljenosti između primjera $\mathbf{x}^{(1)}$ i $\mathbf{x}^{(2)}$ manja je nego euklidska udaljenost između primjera $\mathbf{x}^{(1)}$ i $\mathbf{x}^{(3)}$. Za izračun sličnosti između primjera koristimo Gaussovu jezgrenu funkciju $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ s preciznošću γ , gdje $\gamma = 1/2\sigma^2$. **Kakav bi efekt na sličnosti između primjera imalo smanjenje preciznosti γ Gaussove jezgrene funkcije?**

- ☐ A Sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se povećala, a sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$ bi se smanjila, ali za veći iznos
- ☐ B Sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se smanjila, a sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$ bi se povećala, ali za veći iznos
- ☐ C Sličnosti bi se smanjile, ali $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se smanjila manje nego što bi se smanjila $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$
- ☐ D Sličnosti bi se povećale, ali $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se povećala više nego što bi se povećala $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$

Međuispit iz Strojnog učenja 1 (ak. god. 2021./2022.)

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 35% bodova na predmetu). Pitanja nose po 1 bod, a 1/3 boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **150 minuta**. Primjerak ispita morate predati zajedno sa svojim rješenjima.

Cjelina 1: Osnove i regresija (6 pitanja)

1 (T) Hipoteza h je funkcija koja primjerima iz \mathcal{X} pridjeljuje oznake iz \mathcal{Y} . Za h kažemo da je definirana “do na parametre θ ”. Što to znači?

- ☐ A Funkcija h definirana je bez parametara, i njih treba odrediti naknadno postupkom odabira modela \mathcal{H}
- ☐ B Različite vrijednosti za θ mogu dati različite funkcije h , a skup svih takvih različitih funkcija definira model \mathcal{H}
- ☐ C Funkcija h jednoznačno određuje parametre θ iz skupa svih mogućih parametara, koji nazivamo prostor parametara
- ☐ D Svaka funkcija h definirana je uz pomoć parametara θ , pa različite vrijednosti za θ daju različite funkcije h

2 (P) Optimizacija parametara modela temelji se na funkciji gubitka $L : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}_0^+$, gdje je $L(y, h(\mathbf{x}))$ gubitak na primjeru (\mathbf{x}, y) . U većini primjena koristimo simetričan gubitak 0-1. Međutim, u nekim primjenama ima više smisla definirati asimetričan gubitak. Jedan takav primjer je zadatak detekcije neželjenih elektroničkih poruka (*spam filtering*). Taj zadatak možemo formalizirati kao problem binarne klasifikacije s oznakama $\mathcal{Y} = \{0, 1\}$, gdje $y = 1$ označava da je poruka neželjena (spam), a $y = 0$ da ona to nije. **Koje od sljedećih svojstava bi trebala zadovoljiti asimetrična funkcija gubitka za takav zadatak?**

- ☐ A $L(0, 1) = 1$ i $L(1, 0) = L(1, 1) = L(0, 0) = 0$
- ☐ B $L(0, 1) = L(1, 0) > 0$ i $L(1, 1) = L(0, 0) = 0$
- ☐ C $L(0, 1) > L(1, 0)$ i $L(1, 1) = L(0, 0) = 0$
- ☐ D $L(0, 0) = L(1, 1) < L(0, 1) < L(1, 0)$

3 (T) Optimizacijom regularizirane funkcije pogreške smanjuje se prenaučenosť modela. **Kakve parametre modela nalazi optimizacija L_2 -regularizirane pogreške?**

- ☐ A Parametre koji uz što veću magnitudu vrijednosti daju što veće očekivanje gubitka na skupu za učenje
- ☐ B Parametre koji uz što manju magnitudu vrijednosti daju što veće očekivanje gubitka na skupu za ispitivanje
- ☐ C Parametre koji uz što manju magnitudu vrijednosti daju što manje očekivanje gubitka na skupu za učenje
- ☐ D Parametre koji uz što veću magnitudu vrijednosti daju što manje očekivanje gubitka na skupu za ispitivanje

4 (N) Raspoložemo sljedećim skupom primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((2, -3), -5), ((2, 3), 10), ((-3, 5), 5), ((5, 0), 20)\}$$

Na ovom skupu gradijentnim spustom trenirali smo L_1 -regularizirani model linearne regresije sa $\lambda = 2$. Dobili smo težine $\mathbf{w} = (-0.050, 2.965, 2.482)$. **Koliko iznosi L_1 -regularizirana pogreška $E(\mathbf{w}|\mathcal{D})$?**

- ☐ A 230.98
- ☐ B 31.70
- ☐ C 191.95
- ☐ D 165.89

- 5 (P) Razmatramo klasifikacijski problem u ulaznome prostoru $\mathcal{X} = \mathbb{Z}^2$. Skup označenih primjera je $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), 1), ((-1, -1), 0), ((1, 1), 0)\}$. Razmatramo sljedeće modele \mathcal{H} i funkcije preslikavanja $\phi : \mathbb{Z}^2 \rightarrow \mathbb{Z}^2$, kojom primjere iz \mathcal{D} preslikavamo u matricu dizajna Φ :

$$\begin{aligned}\mathcal{H}_1 : h_1(\mathbf{x}|\theta_0, \theta_1) &= \mathbf{1}\{\theta_1 x_1 + \theta_0 \geq 0\} & \phi_1(\mathbf{x}) &= (1, x_2, x_1) \\ \mathcal{H}_2 : h_2(\mathbf{x}|\theta_0, \theta_2) &= \mathbf{1}\{\theta_2 x_2 + \theta_0 \geq 0\} & \phi_2(\mathbf{x}) &= (1, x_1, x_1 x_2) \\ \mathcal{H}_3 : h_3(\mathbf{x}|\theta) &= \mathbf{1}\{\theta^T \mathbf{x} \geq 0\} \\ \mathcal{H}_4 : h_4(\mathbf{x}|\theta_0) &= \mathbf{1}\{x_1^2 + x_2^2 \geq \theta_0\}\end{aligned}$$

U svim modelima parametri su realni brojevi, $\theta_j \in \mathbb{R}$. Odredite veličinu prostora inačica, $|VS_{\mathcal{H}, \Phi}|$, za ove kombinacije modela i funkcije preslikavanja. **Za koju kombinaciju modela i funkcije preslikavanja prostor inačica sadržava točno jednu hipotezu, $|VS_{\mathcal{H}, \Phi}| = 1$?**

- ☐ A $h_4 + \phi_1$ ☐ B $h_1 + \phi_1$ ☐ C $h_2 + \phi_2$ ☐ D $h_3 + \phi_2$

- 6 (P) Koristimo regresiju za predviđanje kreditne sposobnosti klijenata. Na raspolaganju imamo podatke o dobi x_1 , ukupnom prinosu na račune x_2 , ukupnoj ušteđevini u kunama x_3 , ukupnoj deviznoj ušteđevini u eurima x_4 , ukupnom iznosu odobrenih kredita x_5 , ukupnom iznosu do sada otplaćenih kredita x_6 te preostalom ukupnom dugovanju po svim kreditima x_7 . Ove podatke želimo iskoristiti kao značajke, ali pritom naravno moramo paziti da ne uvedemo multikolinearnost, pa možda nećemo upotrijebiti sve značajke. Za funkciju preslikavanja ϕ koristimo preslikavanje s linearnim, kvadratnim i interakcijskim značajkama. Za interakcije razmatramo parove i trojke značajki, uključivo kombinacije kvadriranih i nekvadriranih značajki (npr., $x_1 x_2$, $x_1^2 x_2$ i $x_1 x_2^2 x_3^2$). **Koliko minimalno primjera za učenje trebamo imati, a da bi rješenje bilo stabilno i bez regularizacije?**

- ☐ A 92 ☐ B 86 ☐ C 79 ☐ D 48

Cjelina 2: Linearni klasifikacijski modeli (8 pitanja)

- 7 (T) Poopćeni linearni modeli (linearna regresija, logistička regresija i multinomijalna regresija) probabilistički su algoritmi strojnog učenja. Njihova probabilistička priroda dolazi do izražaja kako kod modela tako i kod optimizacijskog postupka. **Koji je probabilistički princip ugrađen u optimizacijski postupak tih algoritama?**

- ☐ A Maksimizirati $\sum_{i=1}^N \ln h(\mathbf{x}^{(i)}; \mathbf{w})$, gdje je $h(\mathbf{x}; \mathbf{w}) = f(\mathbf{w}^T \mathbf{x})$
☐ B Minimizirati $-\sum_{i=1}^N \ln y^{(i)} h(\mathbf{x}^{(i)}; \mathbf{w})$, gdje je $h(\mathbf{x}; \mathbf{w}) = \mathbf{w}^T \mathbf{x}$
☐ C Maksimizirati $\sum_{i=1}^N \ln p(y^{(i)}|\mathbf{x}^{(i)})$, gdje je $\mathbb{E}[p(y^{(i)}|\mathbf{x}^{(i)})] = f(\mathbf{w}^T \mathbf{x})$
☐ D Minimizirati $-\sum_{i=1}^N y^{(i)} p(y^{(i)}|\mathbf{x}^{(i)})$, gdje je $p(y^{(i)}|\mathbf{x}^{(i)}) = h(\mathbf{x}; \mathbf{w})$

- 8 (P) Razmotrimo sljedeći skup označenih primjera:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((-2, 0), -1), ((-1, 0), +1), ((1, 0), +1), ((2, 0), -1))\}$$

Nad ovim skupom treniramo dva modela: neregulariziranu logističku regresiju (LR) i L_2 -regulariziranu logističku regresiju (L2LR). Pored toga, razmatramo tri funkcije preslikavanja:

$$\begin{aligned}\phi_0(\mathbf{x}) &= (1, x_1, x_2) \\ \phi_1(\mathbf{x}) &= (1, x_1, x_2, x_1^2, x_2^2) \\ \phi_2(\mathbf{x}) &= (1, x_1, x_2, x_1 x_2)\end{aligned}$$

Ukupno, dakle, isprobavamo šest algoritama, odnosno šest kombinacija modela i funkcije preslikavanja. **Za koje algoritme (model+preslikavanje) optimizacijski postupak na skupu za učenje ne konvergira?**

- ☐ A L2LR+ ϕ_1 ☐ B L2LR+ ϕ_2 ☐ C LR+ ϕ_2 ☐ D LR+ ϕ_1

- 9 (N) Model regularizirane logističke regresije treniramo stohastičkim gradijentnim spustom. Koristimo faktor regularizacije $\lambda = 1000$ i stopu učenja $\eta = 0.01$. Primjere iz dvodimenzijskog ulaznog prostora preslikali smo u prostor značajki funkcijom $\phi(\mathbf{x}) = (1, x_1, x_2, x_1 x_2)$. U jednoj iteraciji treniranja modela vektor parametara jednak je $\mathbf{w} = (0.2, 0.5, -1.1, 2.7)$. **Koliko u toj iteraciji iznosi promjena težine w_1 za primjer $(\mathbf{x}, y) = ((-1, 2), 1)$?**

- ☐ A -5 ☐ B +22 ☐ C -12 ☐ D -2

- 10 (N) Na skupu označenih primjera \mathcal{D} trenirali smo model logističke regresije. Dobili smo neki vektor težina \mathbf{w} i pomak $w_0 = 0.15$. Tako naučenom modelu neki primjer \mathbf{x} , čija je oznaka u skupu primjera $y = 0$, nanosi gubitak unakrsne entropije od $L(0, h(\mathbf{x})) = 0.274$. **Koliki gubitak unakrsne entropije bi nanosio primjer \mathbf{x} kada bismo njegove značajke pomnožili sa dva i promijenili mu oznaku?**

☐ A 1.19 ☐ B 7.11 ☐ C 4.03 ☐ D 2.54

- 11 (N) Raspoložemo označenim skupom primjera iz triju klasa ($K = 3$) u trodimenzijskome ulaznom prostoru ($n = 3$). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer $\mathbf{x} = (-4, -1, -3)$ s oznakom $\mathbf{y} = (0, 0, 1)$. **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

☐ A 8.00 ☐ B 12.02 ☐ C 6.00 ☐ D 4.02

- 12 (T) Algoritam strojnog učenja idealno bi minimizirao gubitak 0-1. Međutim, funkciju gubitka 0-1 u praksi ne možemo koristiti za optimizaciju parametara modela. **Zašto gubitak 0-1 ne možemo koristiti za optimizaciju?**

- ☐ A Funkcija gubitka 0-1 nije diferencijabilna, pa ne postoji rješenje u zatvorenoj formi i ne postoji gradijent
- ☐ B Funkcija gubitka 0-1 nije konveksna, pa ni funkcija pogreške nije konveksna već ima lokalne minimume te ne postoji minimizator u zatvorenoj formi
- ☐ C Gubitak 0-1 pored neispravno klasificiranih primjera kažnjava i ispravno klasificirane primjere, i to tim više što su oni dalje od granice između klasa
- ☐ D Gradijent gubitka 0-1 svugdje je nula osim za $h(\mathbf{x}) = 0$, pa funkcija pogreške ima zaravni po kojima se gradijentni spust ne može spuštati

- 13 (N) Raspoložemo sljedećim skupom za učenje u dvodimenzijskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}(i), y(i))\} = \{((1, 0), +1), ((2, -3), -1), ((2, 5), -1))\}$$

Na ovom skupu treniramo perceptron. Pritom koristimo funkciju preslikavanja u peterodimenzijski prostor značajki, koja je definirana na sljedeći način:

$$\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2, x_1^2, x_2^2)$$

Početne težine perceptrona neka su sljedeće:

$$\mathbf{w} = (1, 0, -1, 2, -3, 0)$$

Koliko iznosi empirijska pogreška perceptrona na skupu za učenje prije početka treniranja (dakle, s početnim težinama)?

☐ A 6 ☐ B 22 ☐ C 16 ☐ D 32

- 14 (P) Poopćeni linearni modeli mogu koristiti adaptivne bazne funkcije. Prednost toga je da ne moramo ručno definirati preslikavanje ϕ u prostor značajki, već se to preslikavanje može naučiti na temelju podataka. Rasplažemo podatcima iz $K = 2$ klase u 100-dimenzijskome ulaznom prostoru. Za taj klasifikacijski problem koristimo binarnu logističku regresiju, ali s adaptivnim baznim funkcijama. Svaka adaptivna bazna funkcija ϕ_j je i sama jedan model logističke regresije, pri čemu $\phi_0(\mathbf{x}) = 1$. Naš je model onda definiran ovako:

$$h(\mathbf{x}) = \sigma\left(\sum_{j=0}^5 w_j \phi_j(\mathbf{x})\right)$$

Koliko ukupno parametara ima ovaj model?

☐ A 511 ☐ B 506 ☐ C 256 ☐ D 261

Cjelina 3: Jezgrene i neparametarske metode (8 pitanja)

- 15 (N) Pomoću SVM-a rješavamo problem binarne klasifikacije grafova. Budući da su primjeri \mathbf{x} grafovi, koristimo SVM s jezgrenom funkcijom nad grafovima. Model treniramo na skupu od $N = 5$ označenih primjera, s vektorom oznaka jednakim $\mathbf{y} = (+1, +1, -1, -1, +1)$ i sa sljedećom jezgrenom matricom:

$$\mathbf{K} = \begin{pmatrix} 1.0 & 0.97 & -0.949 & -0.555 & -0.986 \\ 0.97 & 1.0 & -0.844 & -0.336 & -0.917 \\ -0.949 & -0.844 & 1.0 & 0.789 & 0.988 \\ -0.555 & -0.336 & 0.789 & 1.0 & 0.684 \\ -0.986 & -0.917 & 0.988 & 0.684 & 1.0 \end{pmatrix}$$

Treniranjem uz $C = 1$ za vektor dualnih parametara dobili smo $\boldsymbol{\alpha} = (0, 0.754, 0.754, 1, 1)$. **Koliko iznosi gubitak zglobnice ovako naučenog modela SVM za četvrti primjer, $L(y^{(4)}, h(\mathbf{x}^{(4)}))$?**

- ☐ A 2.06 ☐ B 1.86 ☐ C 0.03 ☐ D 0.40

- 16 (N) Treniramo SVM s polinomijalnom jezgrom definiramo kao:

$$\kappa(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^T \mathbf{z})^2$$

Ova jezgra je Mercerova jezgra, što znači da postoji funkcija ϕ takva da $\kappa(\mathbf{x}, \mathbf{z}) = \phi(\mathbf{x})^T \phi(\mathbf{z})$. Konkretno, u slučaju dvodimenzijskoga ulaznog prostora ($n = 2$), ova jezgra odgovara preslikavanju u šesterodimenzijski prostor. Međutim, postoji odstupanje u konkretnim koeficijentima polinoma. Razmotrite primjer $\mathbf{x} = (1, 0)$ te izračunajte $\phi_\kappa(\mathbf{x})$, koji dobivamo preslikavanjem definiranim implicitno preko jezgre, te $\phi_p(\mathbf{x})$, koji dobivamo preslikavanjem definiranim kao polinom drugog stupnja. **Koliko iznosi euklidska udaljenost između $\phi_\kappa(\mathbf{x})$ i $\phi_p(\mathbf{x})$?**

- ☐ A $\sqrt{2}$ ☐ B $2\sqrt{2}$ ☐ C 0 ☐ D 4

- 17 (T) Problem prokletstva dimenzionalnosti (engl. *curse of dimensionality*) pojavljuje se kod algoritama koji rade u visokodimenzijskome vektorskom prostoru i manifestira se na različite načine. **Kako se problem prokletstva dimenzionalnosti u visokodimenzijskim prostorima manifestira kod algoritma k -NN?**

- ☐ A Prvih k susjeda nekog primjera su vrlo udaljeni od dotičnog primjera
☐ B Udaljenost primjera do njegovih prvih k susjeda se smanjuje i svaki primjer postaje klasa za sebe
☐ C Udaljenosti između primjera se smanjuju i model k -NN postaje sve složeniji
☐ D Povećava se broj susjeda u okolini svakog primjera i model k -NN postaje sve jednostavniji

- 18 (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), -1), ((-2, -2), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1))\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa $C = 1$. Kod modela s mekom marginom za dualne koeficijente vrijedi $\alpha_1 = 1$, $\alpha_2 > 0$, $\alpha_3 > 0$, $\alpha_4 > 0$ i $\alpha_5 = 1$. Skicirajte tvrdi i meku marginu u ulaznome prostoru. **Koliko je meka margina šira od tvrde margine?**

- ☐ A $\frac{3}{5}\sqrt{10}$ puta ☐ B $\frac{1}{6}\sqrt{2}$ puta ☐ C $\frac{2}{5}\sqrt{10}$ puta ☐ D $\frac{4}{5}\sqrt{10}$ puta

- 19 (T) Problem meke margine SVM-a s u primarnoj se formulaciji svodi na rješavanje sljedećeg optimizacijskog problema:

$$\operatorname{argmin}_{\mathbf{w}, w_0, \boldsymbol{\xi}} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i \right\}$$

uz određena linearna ograničenja. Ovaj optimizacijski problem odgovara optimizaciji regularizirane pogreške. Kod regularizirane pogreške u opreci su dva cilja: smanjenje vrijednosti funkcije gubitka i smanjenje složenosti modela.

Kako se ta opreka manifestira kod optimizacijskog problema meke margine SVM-a?

- ☐ A Što je veća vrijednost $\|\mathbf{w}\|^2$ to je model složeniji, no tim je veća nelinearnost granice i to je veći hiperparametar C
- ☐ B Što je veći hiperparametar C , to se više kažnjava ulazak primjera u marginu, i to je manja vrijednost $\|\mathbf{w}\|^2$
- ☐ C Što je manji hiperparametar C , to je manja važnost zbroja od ξ_i , pa je vrijednost $\|\mathbf{w}\|^2$ veća i model je veće složenosti
- ☐ D Što je veća vrijednost $\|\mathbf{w}\|^2$, to je margina uža i tim manje primjera ulazi u marginu, pa je tim manji zbroj od ξ_i

20 (P) Za binarnu klasifikaciju koristimo SVM s Gaussovom jezgrenom funkcijom. Razmatramo tri primjera u ulaznome prostoru: $\mathbf{x}^{(1)}$, $\mathbf{x}^{(2)}$ i $\mathbf{x}^{(3)}$. Euklidska udaljenosti između primjera $\mathbf{x}^{(1)}$ i $\mathbf{x}^{(2)}$ manja je nego euklidska udaljenost između primjera $\mathbf{x}^{(1)}$ i $\mathbf{x}^{(3)}$. Za izračun sličnosti između primjera koristimo Gaussovu jezgrenu funkciju $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ s preciznošću γ , gdje $\gamma = 1/2\sigma^2$. **Kakav bi efekt na sličnosti između primjera imalo smanjenje preciznosti γ Gaussove jezgrene funkcije?**

- ☐ A Sličnosti bi se povećale, ali $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se povećala manje nego što bi se povećala $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$
- ☐ B Sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se povećala, a sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$ bi se smanjila, ali za manji iznos
- ☐ C Sličnosti bi se povećale, ali $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se povećala više nego što bi se povećala $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$
- ☐ D Sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se smanjila, a sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$ bi se povećala, ali za manji iznos

21 (P) Neka je $\mathcal{H}_{C,\gamma}$ model SVM-a s Gaussovom jezgrom. Hiperparametri tog modela su regularizacijski faktor C i preciznost jezgre γ . Odabir modela provodimo unakrsnom provjerom i to pretraživanjem po rešetci za sljedeće vrijednosti hiperparametara:

$$C = \{2^{-5}, 2^{-4}, \dots, 2^4, 2^5\}$$

$$\gamma = \{10^{-5}, 10^{-4}, \dots, 10^4, 10^5\}$$

Za model sa $C = 2^{-2}$ i $\gamma = 10^1$ utvrdili smo da je podnaučen, a za model sa $C = 2^1$ i $\gamma = 10^1$ utvrdili smo da je prenaučan. **Koliko modela još ima smisla ispitati jer su moguće optimalni?**

- ☐ A 25
- ☐ B 10
- ☐ C 96
- ☐ D 68

22 (N) Rješavamo binarni klasifikacijski problem. Raspoložemo označenim skupom primjera. Odgovarajuća matrica dizajna je sljedeća:

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 22 & 0 & -5 \\ 1 & 6 & 28 & 8 & 2 \\ 1 & -6 & -15 & -9 & -6 \\ 1 & -11 & -34 & -16 & -9 \end{pmatrix}$$

Na ovom skupu treniramo model SVM-a s tvrdom marginom i linearnom jezgrenom funkcijom (tj. bez preslikavanja u prostor značajki). Model treniramo u primarnoj formulaciji. Za rješenje maksimalne margine dobili smo ovaj vektor težina (uključivo s težinom w_0):

$$\mathbf{w} = (+2.7838, +0.0225, +0.0856, +0.0315, +0.0135)$$

Umjesto u primarnoj formulaciji, model smo mogli trenirati u dualnoj formulaciji, pa bismo umjesto vektora težina \mathbf{w} dobili vektor dualnih parametara $\boldsymbol{\alpha}$, odnosno Lagrangeove multiplikatore. Prisjetite se da su vektori čiji su Lagrangeovi multiplikatori veći od nule potporni vektori. Premda to nije uvijek moguće, u ovom konkretnom slučaju dualni parametri modela mogu se izvesti iz rješenja primarnog modela. Izvedite vektor dualnih parametara $\boldsymbol{\alpha}$. **Koliko iznosi najveća vrijednost parametra u vektoru dualnih parametara $\boldsymbol{\alpha}$?** (Rezultate uspoređujte po prve tri decimale.)

- ☐ A 0.0089
- ☐ B 0.0024
- ☐ C 0.0045
- ☐ D 0.0013

Međuispit iz Strojnog učenja 1 (ak. god. 2021./2022.)

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 35% bodova na predmetu). Pitanja nose po 1 bod, a 1/3 boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **150 minuta**. Primjerak ispita morate predati zajedno sa svojim rješenjima.

Cjelina 1: Osnove i regresija (6 pitanja)

- 1** (P) Koristimo regresiju za predviđanje kreditne sposobnosti klijenata. Na raspolaganju imamo podatke o dobi x_1 , ukupnom prinosu na račune x_2 , ukupnoj ušteđevini u kunama x_3 , ukupnoj deviznoj ušteđevini u eurima x_4 , ukupnom iznosu odobrenih kredita x_5 , ukupnom iznosu do sada otplaćenih kredita x_6 te preostalom ukupnom dugovanju po svim kreditima x_7 . Ove podatke želimo iskoristiti kao značajke, ali pritom naravno moramo paziti da ne uvedemo multikolinearnost, pa možda nećemo upotrijebiti sve značajke. Za funkciju preslikavanja ϕ koristimo preslikavanje s linearnim, kvadratnim i interakcijskim značajkama. Za interakcije razmatramo parove i trojke značajki, uključivo kombinacije kvadriranih i nekvadriranih značajki (npr., x_1x_2 , $x_1^2x_2$ i $x_1x_2^2x_3^2$). **Koliko minimalno primjera za učenje trebamo imati, a da bi rješenje bilo stabilno i bez regularizacije?**

☐ A 48 ☐ B 79 ☐ C 86 ☐ D 92

- 2** (P) Razmatramo klasifikacijski problem u ulaznome prostoru $\mathcal{X} = \mathbb{Z}^2$. Skup označenih primjera je $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), 1), ((-1, -1), 0), ((1, 1), 0)\}$. Razmatramo sljedeće modele \mathcal{H} i funkcije preslikavanja $\phi : \mathbb{Z}^2 \rightarrow \mathbb{Z}^2$, kojom primjere iz \mathcal{D} preslikavamo u matricu dizajna Φ :

$$\begin{aligned}\mathcal{H}_1 : h_1(\mathbf{x}|\theta_0, \theta_1) &= \mathbf{1}\{\theta_1 x_1 + \theta_0 \geq 0\} & \phi_1(\mathbf{x}) &= (1, x_2, x_1) \\ \mathcal{H}_2 : h_2(\mathbf{x}|\theta_0, \theta_2) &= \mathbf{1}\{\theta_2 x_2 + \theta_0 \geq 0\} & \phi_2(\mathbf{x}) &= (1, x_1, x_1 x_2) \\ \mathcal{H}_3 : h_3(\mathbf{x}|\theta) &= \mathbf{1}\{\theta^T \mathbf{x} \geq 0\} \\ \mathcal{H}_4 : h_4(\mathbf{x}|\theta_0) &= \mathbf{1}\{x_1^2 + x_2^2 \geq \theta_0\}\end{aligned}$$

U svim modelima parametri su realni brojevi, $\theta_j \in \mathbb{R}$. Odredite veličinu prostora inačica, $|VS_{\mathcal{H}, \Phi}|$, za ove kombinacije modela i funkcije preslikavanja. **Za koju kombinaciju modela i funkcije preslikavanja prostor inačica sadržava točno jednu hipotezu, $|VS_{\mathcal{H}, \Phi}| = 1$?**

☐ A $h_2 + \phi_2$ ☐ B $h_3 + \phi_2$ ☐ C $h_4 + \phi_1$ ☐ D $h_1 + \phi_1$

- 3** (N) Raspoložemo sljedećim skupom primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((2, -3), 5), ((2, 3), -10), ((-3, 5), 5), ((5, 0), 20)\}$$

Na ovom skupu gradijentnim spustom trenirali smo L_1 -regularizirani model linearne regresije sa $\lambda = 2$. Dobili smo težine $\mathbf{w} = (4.568, 0.746, -0.550)$. **Koliko iznosi L_1 -regularizirana pogreška $E(\mathbf{w}|\mathcal{D})$?**

☐ A 31.70 ☐ B 191.95 ☐ C 165.89 ☐ D 230.98

- 4** (T) Optimizacijom regularizirane funkcije pogreške smanjuje se prenaučenosť modela. **Kakve parametre modela nalazi optimizacija L_2 -regularizirane pogreške?**

- ☐ A Parametre koji uz što manju magnitudu vrijednosti daju što manje očekivanje gubitka na skupu za učenje
☐ B Parametre koji uz što manju magnitudu vrijednosti daju što veće očekivanje gubitka na skupu za ispitivanje
☐ C Parametre koji uz što veću magnitudu vrijednosti daju što veće očekivanje gubitka na skupu za učenje
☐ D Parametre koji uz što veću magnitudu vrijednosti daju što manje očekivanje gubitka na skupu za ispitivanje

- 5 (T) Hipoteza h je funkcija koja primjerima iz \mathcal{X} pridjeljuje oznake iz \mathcal{Y} . Za h kažemo da je definirana “do na parametre θ ”. Što to znači?
- ☐ A Funkcija h izračunava oznaku \mathcal{Y} na temelju parametra θ , koje treba podesiti optimizacijskim postupkom
- ☐ B Funkcija h definirana je bez parametara, i njih treba odrediti naknadno postupkom odabira modela \mathcal{H}
- ☐ C Svaka vrijednost parametara θ daje jednu konkretnu funkciju h koja se razlikuje od svih drugih funkcija u modelu \mathcal{H}
- ☐ D Funkcija h definira preslikavanja iz označenog skupa primjera $\mathcal{X} \times \mathcal{Y}$ u prostor parametara θ
- 6 (P) Optimizacija parametara modela temelji se na funkciji gubitka $L : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}_0^+$, gdje je $L(y, h(\mathbf{x}))$ gubitak na primjeru (\mathbf{x}, y) . U većini primjena koristimo simetričan gubitak 0-1. Međutim, u nekim primjenama ima više smisla definirati asimetričan gubitak. Jedan takav primjer je zadatak detekcije neželjenih elektroničkih poruka (*spam filtering*). Taj zadatak možemo formalizirati kao problem binarne klasifikacije s oznakama $\mathcal{Y} = \{0, 1\}$, gdje $y = 1$ označava da je poruka neželjena (spam), a $y = 0$ da ona to nije. Koje od sljedećih svojstava bi trebala zadovoljiti asimetrična funkcija gubitka za takav zadatak?
- ☐ A $L(0, 0) = L(1, 1) < L(0, 1) < L(1, 0)$
- ☐ B $L(0, 1) > L(1, 0)$ i $L(1, 1) = L(0, 0) = 0$
- ☐ C $L(0, 1) = L(1, 0) > 0$ i $L(1, 1) = L(0, 0) = 0$
- ☐ D $L(0, 1) = 1$ i $L(1, 0) = L(1, 1) = L(0, 0) = 0$

Cjelina 2: Linearni klasifikacijski modeli (8 pitanja)

- 7 (T) Poopćeni linearni modeli (linearna regresija, logistička regresija i multinomijalna regresija) probabilistički su algoritmi strojnog učenja. Njihova probabilistička priroda dolazi do izražaja kako kod modela tako i kod optimizacijskog postupka. Koji je probabilistički princip ugrađen u optimizacijski postupak tih algoritama?
- ☐ A Maksimizirati $\sum_{i=1}^N \ln h(\mathbf{x}^{(i)}; \mathbf{w})$, gdje je $h(\mathbf{x}; \mathbf{w}) = f(\mathbf{w}^T \mathbf{x})$
- ☐ B Maksimizirati $\sum_{i=1}^N \ln p(y^{(i)} | \mathbf{x}^{(i)})$, gdje je $\mathbb{E}[p(y^{(i)} | \mathbf{x}^{(i)})] = f(\mathbf{w}^T \mathbf{x})$
- ☐ C Minimizarati $-\sum_{i=1}^N y^{(i)} p(y^{(i)} | \mathbf{x}^{(i)})$, gdje je $p(y^{(i)} | \mathbf{x}^{(i)}) = h(\mathbf{x}; \mathbf{w})$
- ☐ D Minimizarati $-\sum_{i=1}^N \ln y^{(i)} h(\mathbf{x}^{(i)}; \mathbf{w})$, gdje je $h(\mathbf{x}; \mathbf{w}) = \mathbf{w}^T \mathbf{x}$
- 8 (N) Raspoložemo sljedećim skupom za učenje u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((1, 0), +1), ((2, -3), -1), ((2, 5), -1)\}$$

Na ovom skupu treniramo perceptron. Pritom koristimo funkciju preslikavanja u peterodimenzijaski prostor značajki, koja je definirana na sljedeći način:

$$\phi(\mathbf{x}) = (1, x_1, x_2, x_1 x_2, x_1^2, x_2^2)$$

Početne težine perceptrona neka su sljedeće:

$$\mathbf{w} = (1, 0, 1, 2, -3, 0)$$

Koliko iznosi empirijska pogreška perceptrona na skupu za učenje prije početka treniranja (dakle, s početnim težinama)?

- ☐ A 16 ☐ B 32 ☐ C 6 ☐ D 22
- 9 (P) Poopćeni linearni modeli mogu koristiti adaptivne bazne funkcije. Prednost toga je da ne moramo ručno definirati preslikavanje ϕ u prostor značajki, već se to preslikavanje može naučiti na temelju podataka. Rasplažemo podatcima iz $K = 2$ klase u 100-dimenzijaskome ulaznom prostoru. Za taj klasifikacijski problem koristimo binarnu logističku regresiju, ali s adaptivnim baznim funkcijama. Svaka adaptivna bazna funkcija ϕ_j je i sama jedan model logističke regresije, pri čemu $\phi_0(\mathbf{x}) = 1$. Naš je model onda definiran ovako:

$$h(\mathbf{x}) = \sigma\left(\sum_{j=0}^5 w_j \phi_j(\mathbf{x})\right)$$

Koliko ukupno parametara ima ovaj model?

- ☐ A 506 ☐ B 256 ☐ C 261 ☐ D 511

- 10 (P) Razmotrimo sljedeći skup označenih primjera:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((-2, 0), -1), ((-1, 0), +1), ((1, 0), +1), ((2, 0), -1))\}$$

Nad ovim skupom treniramo dva modela: neregulariziranu logističku regresiju (LR) i L_2 -regulariziranu logističku regresiju (L2LR). Pored toga, razmatramo tri funkcije preslikavanja:

$$\begin{aligned}\phi_0(\mathbf{x}) &= (1, x_1, x_2) \\ \phi_1(\mathbf{x}) &= (1, x_1, x_2, x_1^2, x_2^2) \\ \phi_2(\mathbf{x}) &= (1, x_1, x_2, x_1x_2)\end{aligned}$$

Ukupno, dakle, isprobavamo šest algoritama, odnosno šest kombinacija modela i funkcije preslikavanja. **Za koje algoritme (model+preslikavanje) optimizacijski postupak na skupu za učenje ne konvergira?**

- ☐ A LR+ ϕ_1 ☐ B L2LR+ ϕ_2 ☐ C LR+ ϕ_2 ☐ D L2LR+ ϕ_0

- 11 (N) Model regularizirane logističke regresije treniramo stohastičkim gradijentnim spustom. Koristimo faktor regularizacije $\lambda = 1000$ i stopu učenja $\eta = 0.01$. Primjere iz dvodimenzijskog ulaznog prostora preslikali smo u prostor značajki funkcijom $\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2)$. U jednoj iteraciji treniranja modela vektor parametara jednak je $\mathbf{w} = (0.5, -2.2, -1.1, 2.7)$. **Koliko u toj iteraciji iznosi promjena težine w_1 za primjer $(\mathbf{x}, y) = ((-1, 2), 1)$?**

- ☐ A +22 ☐ B -2 ☐ C -12 ☐ D -5

- 12 (N) Na skupu označenih primjera \mathcal{D} trenirali smo model logističke regresije. Dobili smo neki vektor težina \mathbf{w} i pomak $w_0 = 0.15$. Tako naučenom modelu neki primjer \mathbf{x} , čija je oznaka u skupu primjera $y = 0$, nanosi gubitak unakrsne entropije od $L(0, h(\mathbf{x})) = 0.274$. **Koliki gubitak unakrsne entropije bi nanosio primjer \mathbf{x} kada bismo njegove značajke pomnožili sa dva i promijenili mu oznaku?**

- ☐ A 2.54 ☐ B 7.11 ☐ C 4.03 ☐ D 1.19

- 13 (N) Raspoložemo označenim skupom primjera iz triju klasa ($K = 3$) u trodimenzijskome ulaznom prostoru ($n = 3$). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer $\mathbf{x} = (-4, 1, -3)$ s oznakom $\mathbf{y} = (0, 1, 0)$. **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

- ☐ A 4.02 ☐ B 6.00 ☐ C 12.02 ☐ D 8.00

- 14 (T) Algoritam strojnog učenja idealno bi minimizirao gubitak 0-1. Međutim, funkciju gubitka 0-1 u praksi ne možemo koristiti za optimizaciju parametara modela. **Zašto gubitak 0-1 ne možemo koristiti za optimizaciju?**

- ☐ A Gubitak 0-1 pored neispravno klasificiranih primjera kažnjava i ispravno klasificirane primjere, i to tim više što su oni dalje od granice između klasa
- ☐ B Gradijent gubitka 0-1 svugdje je nula osim za $h(\mathbf{x}) = 0$, pa funkcija pogreške ima zaravni po kojima se gradijentni spust ne može spuštati
- ☐ C Funkcija gubitka 0-1 nije konveksna, pa ni funkcija pogreške nije konveksna već ima lokalne minimume te ne postoji minimizator u zatvorenoj formi
- ☐ D Funkcija gubitka 0-1 nije diferencijabilna, pa ne postoji rješenje u zatvorenoj formi i ne postoji gradijent

Cjelina 3: Jezgrene i neparametarske metode (8 pitanja)

- 15 (P) Neka je $\mathcal{H}_{C,\gamma}$ model SVM-a s Gaussovom jezgrom. Hiperparametri tog modela su regularizacijski faktor C i preciznost jezgre γ . Odabir modela provodimo unakrsnom provjerom i to pretraživanjem po rešetci za sljedeće vrijednosti hiperparametara:

$$C = \{2^{-5}, 2^{-4}, \dots, 2^4, 2^5\}$$
$$\gamma = \{10^{-5}, 10^{-4}, \dots, 10^4, 10^5\}$$

Već ranije smo utvrdili da je model sa $C = 2^{-2}$ i $\gamma = 10^{-1}$ podnaučen, a da je model sa $C = 2^1$ i $\gamma = 10^1$ prenaučeni. Za sve ostale modele ne znamo jesu li prenaučeni, podnaučeni ili optimalni. **Koliko modela još ima smisla ispitati jer su moguće optimalni?**

- ☐ A 10 ☐ B 96 ☐ C 25 ☐ D 76

- 16 (T) Problem prokletstva dimenzionalnosti (engl. *curse of dimensionality*) pojavljuje se kod algoritama koji rade u visokodimenzijskom vektorskom prostoru i manifestira se na različite načine. **Kako se problem prokletstva dimenzionalnosti u visokodimenzijskim prostorima manifestira kod algoritma k -NN?**

- ☐ A Primjeri se grupiraju u središte vektorskog prostora i udaljenost postaje nediskriminativna
☐ B Svi primjeri su međusobno vrlo udaljeni i gube se razlike u udaljenosti
☐ C Povećava se broj susjeda u okolini svakog primjera i model k -NN postaje sve jednostavniji
☐ D Broj susjeda k nekog primjera se smanjuje i gube se granice između klasa

- 17 (N) Pomoću SVM-a rješavamo problem binarne klasifikacije grafova. Budući da su primjeri \mathbf{x} grafovi, koristimo SVM s jezgrenom funkcijom nad grafovima. Model treniramo na skupu od $N = 5$ označenih primjera, s vektorom oznaka jednakim $\mathbf{y} = (-1, -1, -1, +1, +1)$ i sa sljedećom jezgrenom matricom:

$$\mathbf{K} = \begin{pmatrix} 1.0 & 0.97 & -0.949 & -0.555 & -0.986 \\ 0.97 & 1.0 & -0.844 & -0.336 & -0.917 \\ -0.949 & -0.844 & 1.0 & 0.789 & 0.988 \\ -0.555 & -0.336 & 0.789 & 1.0 & 0.684 \\ -0.986 & -0.917 & 0.988 & 0.684 & 1.0 \end{pmatrix}$$

Treniranjem uz $C = 1$ za vektor dualnih parametara dobili smo $\boldsymbol{\alpha} = (0, 0.733, 1, 1, 0.733)$. **Koliko iznosi gubitak zglobnice ovako naučenog modela SVM za četvrti primjer, $L(y^{(4)}, h(\mathbf{x}^{(4)}))$?**

- ☐ A 2.06 ☐ B 1.86 ☐ C 0.03 ☐ D 0.40

- 18 (T) Problem meke margine SVM-a s u primarnoj se formulaciji svodi na rješavanje sljedećeg optimizacijskog problema:

$$\operatorname{argmin}_{\mathbf{w}, w_0, \boldsymbol{\xi}} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i \right\}$$

uz određena linearna ograničenja. Ovaj optimizacijski problem odgovara optimizaciji regularizirane pogreške. Kod regularizirane pogreške u opreci su dva cilja: smanjenje vrijednosti funkcije gubitka i smanjenje složenosti modela. **Kako se ta opreka manifestira kod optimizacijskog problema meke margine SVM-a?**

- ☐ A Što je veći zbroj od ξ_i , to više primjera ulazi u marginu i tim je manja vrijednost $\|\mathbf{w}\|^2$ te je model veće složenosti
☐ B Što je veća vrijednost $\|\mathbf{w}\|^2$, to je margina uža i tim manje primjera ulazi u marginu, pa je tim manji zbroj od ξ_i
☐ C Što je manji zbroj od ξ_i , to više primjera može ući u marginu i tim je veća vrijednost $\|\mathbf{w}\|^2$ te je model manje složenosti
☐ D Što je veći hiperparametar C , to se više kažnjava ulazak primjera u marginu, i to je manja vrijednost $\|\mathbf{w}\|^2$

- 19 (P) Za binarnu klasifikaciju koristimo SVM s Gaussovom jezgrenom funkcijom. Razmatramo tri primjera u ulaznome prostoru: $\mathbf{x}^{(1)}$, $\mathbf{x}^{(2)}$ i $\mathbf{x}^{(3)}$. Euklidska udaljenosti između primjera $\mathbf{x}^{(1)}$ i $\mathbf{x}^{(2)}$ manja je nego euklidska udaljenost između primjera $\mathbf{x}^{(1)}$ i $\mathbf{x}^{(3)}$. Za izračun sličnosti između primjera koristimo Gaussovu jezgrenu funkciju $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ s preciznošću γ , gdje $\gamma = 1/2\sigma^2$. **Kakav bi efekt na sličnosti između primjera imalo smanjenje preciznosti γ Gaussove jezgrene funkcije?**

- ☐ A Sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se povećala, a sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$ bi se smanjila, ali za manji iznos
- ☐ B Sličnosti bi se povećale, ali $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se povećala više nego što bi se povećala $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$
- ☐ C Sličnosti bi se smanjile, ali $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se smanjila više nego što bi se smanjila $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$
- ☐ D Sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se smanjila, a sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$ bi se povećala, ali za manji iznos

- 20 (N) Rješavamo binarni klasifikacijski problem. Raspoložemo označenim skupom primjera. Odgovarajuća matrica dizajna je sljedeća:

$$\mathbf{X} = \begin{pmatrix} 1 & 3 & 16 & -8 & -11 \\ 1 & -5 & 4 & -8 & -7 \\ 1 & 7 & -4 & 11 & 9 \\ 1 & 15 & -20 & 25 & 25 \end{pmatrix}$$

Na ovom skupu treniramo model SVM-a s tvrdom marginom i linearnom jezgrenom funkcijom (tj. bez preslikavanja u prostor značajki). Model treniramo u primarnoj formulaciji. Za rješenje maksimalne margine dobili smo ovaj vektor težina (uključivo s težinom w_0):

$$\mathbf{w} = (+0.1370, -0.0290, +0.0194, -0.0461, -0.0388)$$

Umjesto u primarnoj formulaciji, model smo mogli trenirati u dualnoj formulaciji, pa bismo umjesto vektora težina \mathbf{w} dobili vektor dualnih parametara α , odnosno Lagrangeove multiplikatore. Prisjetite se da su vektori čiji su Lagrangeovi multiplikatori veći od nule potporni vektori. Premda to nije uvijek moguće, u ovom konkretnom slučaju dualni parametri modela mogu se izvesti iz rješenja primarnog modela. Izvedite vektor dualnih parametara α . **Koliko iznosi najveća vrijednost parametra u vektoru dualnih parametara α ?** (Rezultate uspoređujte po prve tri decimale.)

- ☐ A 0.0024 ☐ B 0.0089 ☐ C 0.0045 ☐ D 0.0013

- 21 (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), -1), ((-2, -2), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1)\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa $C = 1$. Kod modela s mekom marginom za dualne koeficijente vrijedi $\alpha_1 = 1$, $\alpha_2 > 0$, $\alpha_3 > 0$, $\alpha_4 > 0$ i $\alpha_5 = 1$. Skicirajte tvrdu i meku marginu u ulaznome prostoru. **Koliko je meka margina šira od tvrde margine?**

- ☐ A $\frac{2}{5}\sqrt{10}$ puta ☐ B $\frac{4}{5}\sqrt{10}$ puta ☐ C $\frac{1}{6}\sqrt{2}$ puta ☐ D $\frac{3}{5}\sqrt{10}$ puta

- 22 (N) Treniramo SVM s polinomijalnom jezgrom definiramo kao:

$$\kappa(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^T \mathbf{z})^2$$

Ova jezgra je Mercerova jezgra, što znači da postoji funkcija ϕ takva da $\kappa(\mathbf{x}, \mathbf{z}) = \phi(\mathbf{x})^T \phi(\mathbf{z})$. Konkretno, u slučaju dvodimenzijaskoga ulaznog prostora ($n = 2$), ova jezgra odgovara preslikavanju u šesterodimenzijaski prostor. Međutim, postoji odstupanje u konkretnim koeficijentima polinoma. Razmotrite primjer $\mathbf{x} = (1, 0)$ te izračunajte $\phi_\kappa(\mathbf{x})$, koji dobivamo preslikavanjem definiranim implicitno preko jezgre, te $\phi_p(\mathbf{x})$, koji dobivamo preslikavanjem definiranim kao polinom drugog stupnja. **Koliko iznosi euklidska udaljenost između $\phi_\kappa(\mathbf{x})$ i $\phi_p(\mathbf{x})$?**

- ☐ A 4 ☐ B $\sqrt{2}$ ☐ C 0 ☐ D $2\sqrt{2}$

Međuispit iz Strojnog učenja 1 (ak. god. 2021./2022.)

Ispit sadrži **22 pitanja** i ukupno nosi najviše 20 bodova (za 35% bodova na predmetu). Pitanja nose po 1 bod, a 1/3 boda oduzima se za pogrešan odgovor. Za maksimalan broj bodova dovoljno je točno riješiti **20 pitanja**, a višak bodova iznad 20 se zanemaruje. Trajanje ispita je **150 minuta**. Primjerak ispita morate predati zajedno sa svojim rješenjima.

Cjelina 1: Osnove i regresija (6 pitanja)

- 1** (P) Razmatramo klasifikacijski problem u ulaznome prostoru $\mathcal{X} = \mathbb{Z}^2$. Skup označenih primjera je $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), 1), ((-1, -1), 0), ((1, 1), 0)\}$. Razmatramo sljedeće modele \mathcal{H} i funkcije preslikavanja $\phi : \mathbb{Z}^2 \rightarrow \mathbb{Z}^2$, kojom primjere iz \mathcal{D} preslikavamo u matricu dizajna Φ :

$$\begin{aligned}\mathcal{H}_1 : h_1(\mathbf{x}|\theta_0, \theta_1) &= \mathbf{1}\{\theta_1 x_1 + \theta_0 \geq 0\} & \phi_1(\mathbf{x}) &= (1, x_2, x_1) \\ \mathcal{H}_2 : h_2(\mathbf{x}|\theta_0, \theta_2) &= \mathbf{1}\{\theta_2 x_2 + \theta_0 \geq 0\} & \phi_2(\mathbf{x}) &= (1, x_1, x_1 x_2) \\ \mathcal{H}_3 : h_3(\mathbf{x}|\theta) &= \mathbf{1}\{\theta^T \mathbf{x} \geq 0\} \\ \mathcal{H}_4 : h_4(\mathbf{x}|\theta_0) &= \mathbf{1}\{x_1^2 + x_2^2 \geq \theta_0\}\end{aligned}$$

U svim modelima parametri su realni brojevi, $\theta_j \in \mathbb{R}$. Odredite veličinu prostora inačica, $|VS_{\mathcal{H}, \Phi}|$, za ove kombinacije modela i funkcije preslikavanja. **Za koju kombinaciju modela i funkcije preslikavanja prostor inačica sadržava točno jednu hipotezu, $|VS_{\mathcal{H}, \Phi}| = 1$?**

- ☐ A $h_2 + \phi_2$ ☐ B $h_4 + \phi_1$ ☐ C $h_1 + \phi_1$ ☐ D $h_3 + \phi_2$

- 2** (N) Raspoložemo sljedećim skupom primjera u dvodimenzijskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((2, -3), -5), ((2, 3), 10), ((-3, 5), 5), ((5, 0), 20)\}$$

Na ovom skupu gradijentnim spustom trenirali smo L_1 -regularizirani model linearne regresije sa $\lambda = 2$. Dobili smo težine $\mathbf{w} = (-0.050, 2.965, 2.482)$. **Koliko iznosi L_1 -regularizirana pogreška $E(\mathbf{w}|\mathcal{D})$?**

- ☐ A 191.95 ☐ B 165.89 ☐ C 230.98 ☐ D 31.70

- 3** (T) Optimizacijom regularizirane funkcije pogreške smanjuje se prenaučenost modela. **Kakve parametre modela nalazi optimizacija L_2 -regularizirane pogreške?**

- ☐ A Parametre koji uz što veću magnitudu vrijednosti daju što veće očekivanje gubitka na skupu za učenje
☐ B Parametre koji uz što manju magnitudu vrijednosti daju što manje očekivanje gubitka na skupu za učenje
☐ C Parametre koji uz što veću magnitudu vrijednosti daju što manje očekivanje gubitka na skupu za ispitivanje
☐ D Parametre koji uz što manju magnitudu vrijednosti daju što veće očekivanje gubitka na skupu za ispitivanje

- 4** (P) Koristimo regresiju za predviđanje kreditne sposobnosti klijenata. Na raspolaganju imamo podatke o dobi x_1 , ukupnom prinosu na račune x_2 , ukupnoj ušteđevini u kunama x_3 , ukupnoj deviznoj ušteđevini u eurima x_4 , ukupnom iznosu odobrenih kredita x_5 , ukupnom iznosu do sada otplaćenih kredita x_6 te preostalom ukupnom dugovanju po svim kreditima x_7 . Ove podatke želimo iskoristiti kao značajke, ali pritom naravno moramo paziti da ne uvedemo multikolinearnost, pa možda nećemo upotrijebiti sve značajke. Za funkciju preslikavanja ϕ koristimo preslikavanje s linearnim, kvadratnim i interakcijskim značajkama. Za interakcije razmatramo parove i trojke značajki, uključivo kombinacije kvadriranih i nekadriranih značajki (npr., $x_1 x_2$, $x_1^2 x_2$ i $x_1 x_2^2 x_3^2$). **Koliko minimalno primjera za učenje trebamo imati, a da bi rješenje bilo stabilno i bez regularizacije?**

- ☐ A 92 ☐ B 48 ☐ C 79 ☐ D 86

- 5 (T) Hipoteza h je funkcija koja primjerima iz \mathcal{X} pridjeljuje oznake iz \mathcal{Y} . Za h kažemo da je definirana “do na parametre θ ”. Što to znači?
- ☐ A Svaka vrijednost parametara θ daje jednu konkretnu funkciju h koja se razlikuje od svih drugih funkcija u modelu \mathcal{H}
- ☐ B Funkcija h definirana je bez parametara, i njih treba odrediti naknadno postupkom odabira modela \mathcal{H}
- ☐ C Funkcija h jednoznačno određuje parametre θ iz skupa svih mogućih parametara, koji nazivamo prostor parametara
- ☐ D Različite vrijednosti za θ mogu dati različite funkcije h , a skup svih takvih različitih funkcija definira model \mathcal{H}
- 6 (P) Optimizacija parametara modela temelji se na funkciji gubitka $L : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}_0^+$, gdje je $L(y, h(\mathbf{x}))$ gubitak na primjeru (\mathbf{x}, y) . U većini primjena koristimo simetričan gubitak 0-1. Međutim, u nekim primjenama ima više smisla definirati asimetričan gubitak. Jedan takav primjer je zadatak detekcije neželjenih elektroničkih poruka (*spam filtering*). Taj zadatak možemo formalizirati kao problem binarne klasifikacije s oznakama $\mathcal{Y} = \{0, 1\}$, gdje $y = 1$ označava da je poruka neželjena (spam), a $y = 0$ da ona to nije. Koje od sljedećih svojstava bi trebala zadovoljiti asimetrična funkcija gubitka za takav zadatak?
- ☐ A $L(0, 0) = L(1, 1) < L(0, 1) < L(1, 0)$
- ☐ B $L(0, 1) = 1$ i $L(1, 0) = L(1, 1) = L(0, 0) = 0$
- ☐ C $L(0, 1) > L(1, 0)$ i $L(1, 1) = L(0, 0) = 0$
- ☐ D $L(0, 1) = L(1, 0) > 0$ i $L(1, 1) = L(0, 0) = 0$

Cjelina 2: Linearni klasifikacijski modeli (8 pitanja)

- 7 (N) Raspoložemo sljedećim skupom za učenje u dvodimenzijaskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}(i), y(i))\} = \{((1, 0), +1), ((2, -3), -1), ((2, 5), -1))\}$$

Na ovom skupu treniramo perceptron. Pritom koristimo funkciju preslikavanja u peterodimenzijaski prostor značajki, koja je definirana na sljedeći način:

$$\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2, x_1^2, x_2^2)$$

Početne težine perceptrona neka su sljedeće:

$$\mathbf{w} = (1, 0, 1, 2, -3, 0)$$

Koliko iznosi empirijska pogreška perceptrona na skupu za učenje prije početka treniranja (dakle, s početnim težinama)?

- ☐ A 22 ☐ B 16 ☐ C 6 ☐ D 32

- 8 (N) Na skupu označenih primjera \mathcal{D} trenirali smo model logističke regresije. Dobili smo neki vektor težina \mathbf{w} i pomak $w_0 = 3.15$. Tako naučenom modelu neki primjer \mathbf{x} , čija je oznaka u skupu primjera $y = 0$, nanosi gubitak unakrsne entropije od $L(0, h(\mathbf{x})) = 0.5$. Koliki gubitak unakrsne entropije bi nanosio primjer \mathbf{x} kada bismo njegove značajke pomnožili sa dva i promijenili mu oznaku?

- ☐ A 4.03 ☐ B 7.11 ☐ C 1.19 ☐ D 2.54

- 9 (N) Model regularizirane logističke regresije treniramo stohastičkim gradijentnim spustom. Koristimo faktor regularizacije $\lambda = 1000$ i stopu učenja $\eta = 0.01$. Primjere iz dvodimenzijaskog ulaznog prostora preslikali smo u prostor značajki funkcijom $\phi(\mathbf{x}) = (1, x_1, x_2, x_1x_2)$. U jednoj iteraciji treniranja modela vektor parametara jednak je $\mathbf{w} = (0.5, -2.2, -1.1, 2.7)$. Koliko u toj iteraciji iznosi promjena težine w_1 za primjer $(\mathbf{x}, y) = ((-1, 2), 1)$?

- ☐ A -12 ☐ B +22 ☐ C -2 ☐ D -5

- 10 (P) Razmotrimo sljedeći skup označenih primjera:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((-2, 0), -1), ((-1, 0), +1), ((1, 0), +1), ((2, 0), -1))\}$$

Nad ovim skupom treniramo dva modela: neregulariziranu logističku regresiju (LR) i L_2 -regulariziranu logističku regresiju (L2LR). Pored toga, razmatramo tri funkcije preslikavanja:

$$\begin{aligned}\phi_0(\mathbf{x}) &= (1, x_1, x_2) \\ \phi_1(\mathbf{x}) &= (1, x_1, x_2, x_1^2, x_2^2) \\ \phi_2(\mathbf{x}) &= (1, x_1, x_2, x_1x_2)\end{aligned}$$

Ukupno, dakle, isprobavamo šest algoritama, odnosno šest kombinacija modela i funkcije preslikavanja. **Za koje algoritme (model+preslikavanje) optimizacijski postupak na skupu za učenje ne konvergira?**

- ☐ A LR+ ϕ_1 ☐ B L2LR+ ϕ_1 ☐ C L2LR+ ϕ_2 ☐ D LR+ ϕ_0

- 11 (N) Raspoložemo označenim skupom primjera iz triju klasa ($K = 3$) u trodimenzijskome ulaznom prostoru ($n = 3$). Na tom skupu treniramo model multinomijalne logističke regresije. Treniranje provodimo gradijentnim spustom. U nekoj od iteracija gradijentnog spusta matrica težina je sljedeća (stupci odgovaraju težinama za pojedine klase):

$$\mathbf{W} = \begin{pmatrix} 3 & 3 & 3 \\ 2 & 0 & -2 \\ 3 & -4 & 6 \\ -3 & 0 & 2 \end{pmatrix}$$

Jedan od primjera u skupu za učenje je primjer $\mathbf{x} = (-4, -1, -3)$ s oznakom $\mathbf{y} = (1, 0, 0)$. **Koliko iznosi gubitak unakrsne entropije koji u ovoj iteraciji optimizacijskog postupka nanosi dotični primjer?**

- ☐ A 4.02 ☐ B 8.00 ☐ C 12.02 ☐ D 6.00

- 12 (P) Poopćeni linearni modeli mogu koristiti adaptivne bazne funkcije. Prednost toga je da ne moramo ručno definirati preslikavanje ϕ u prostor značajki, već se to preslikavanje može naučiti na temelju podataka. Rasplažemo podatcima iz $K = 2$ klase u 50-dimenzijskome ulaznom prostoru. Za taj klasifikacijski problem koristimo binarnu logističku regresiju, ali s adaptivnim baznim funkcijama. Svaka adaptivna bazna funkcija ϕ_j je i sama jedan model logističke regresije, pri čemu $\phi_0(\mathbf{x}) = 1$. Naš je model onda definiran ovako:

$$h(\mathbf{x}) = \sigma\left(\sum_{j=0}^5 w_j \phi_j(\mathbf{x})\right)$$

Koliko ukupno parametara ima ovaj model?

- ☐ A 261 ☐ B 506 ☐ C 256 ☐ D 511

- 13 (T) Algoritam strojnog učenja idealno bi minimizirao gubitak 0-1. Međutim, funkciju gubitka 0-1 u praksi ne možemo koristiti za optimizaciju parametara modela. **Zašto gubitak 0-1 ne možemo koristiti za optimizaciju?**

- ☐ A Gradijent gubitka 0-1 svugdje je nula osim za $h(\mathbf{x}) = 0$, pa funkcija pogreške ima zaravni po kojima se gradijentni spust ne može spuštati
☐ B Funkcija gubitka 0-1 nije diferencijabilna, pa ne postoji rješenje u zatvorenoj formi i ne postoji gradijent
☐ C Funkcija gubitka 0-1 nije konveksna, pa ni funkcija pogreške nije konveksna već ima lokalne minimume te ne postoji minimizator u zatvorenoj formi
☐ D Gubitak 0-1 pored neispravno klasificiranih primjera kažnjava i ispravno klasificirane primjere, i to tim više što su oni dalje od granice između klasa

- 14 (T) Poopćeni linearni modeli (linearna regresija, logistička regresija i multinomijalna regresija) probabilistički su algoritmi strojnog učenja. Njihova probabilistička priroda dolazi do izražaja kako kod modela tako i kod optimizacijskog postupka. **Koji je probabilistički princip ugrađen u optimizacijski postupak tih algoritama?**

- ☐ A Minimizirati $-\sum_{i=1}^N \ln y^{(i)} h(\mathbf{x}^{(i)}; \mathbf{w})$, gdje je $h(\mathbf{x}; \mathbf{w}) = \mathbf{w}^T \mathbf{x}$
☐ B Maksimizirati $\sum_{i=1}^N \ln p(y^{(i)} | \mathbf{x}^{(i)})$, gdje je $\mathbb{E}[p(y^{(i)} | \mathbf{x}^{(i)})] = f(\mathbf{w}^T \mathbf{x})$
☐ C Maksimizirati $\prod_{i=1}^N \ln p(y^{(i)} | \mathbf{x}^{(i)})$, gdje je $\mathbb{E}[p(y^{(i)} | \mathbf{x}^{(i)})] = \mathbf{w}^T \mathbf{x}$
☐ D Maksimizirati $\sum_{i=1}^N \ln h(\mathbf{x}^{(i)}; \mathbf{w})$, gdje je $h(\mathbf{x}; \mathbf{w}) = f(\mathbf{w}^T \mathbf{x})$

Cjelina 3: Jezgrene i neparametarske metode (8 pitanja)

- 15 (N) Treniramo SVM s polinomijalnom jezgrom definiramo kao:

$$\kappa(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^T \mathbf{z})^2$$

Ova jezgra je Mercerova jezgra, što znači da postoji funkcija ϕ takva da $\kappa(\mathbf{x}, \mathbf{z}) = \phi(\mathbf{x})^T \phi(\mathbf{z})$. Konkretno, u slučaju dvodimenzijskoga ulaznog prostora ($n = 2$), ova jezgra odgovara preslikavanju u šesterodimenzijski prostor. Međutim, postoji odstupanje u konkretnim koeficijentima polinoma. Razmotrite primjer $\mathbf{x} = (1, 0)$ te izračunajte $\phi_\kappa(\mathbf{x})$, koji dobivamo preslikavanjem definiranim implicitno preko jezgre, te $\phi_p(\mathbf{x})$, koji dobivamo preslikavanjem definiranim kao polinom drugog stupnja. **Koliko iznosi euklidska udaljenost između $\phi_\kappa(\mathbf{x})$ i $\phi_p(\mathbf{x})$?**

- ☐ A 0 ☐ B $\sqrt{2}$ ☐ C 4 ☐ D $2\sqrt{2}$

- 16 (P) Za binarnu klasifikaciju koristimo SVM s Gaussovom jezgrenom funkcijom. Razmatramo tri primjera u ulaznome prostoru: $\mathbf{x}^{(1)}$, $\mathbf{x}^{(2)}$ i $\mathbf{x}^{(3)}$. Euklidska udaljenosti između primjera $\mathbf{x}^{(1)}$ i $\mathbf{x}^{(2)}$ veća je nego euklidska udaljenost između primjera $\mathbf{x}^{(1)}$ i $\mathbf{x}^{(3)}$. Za izračun sličnosti između primjera koristimo Gaussovu jezgrenu funkciju $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ s preciznošću γ , gdje $\gamma = 1/2\sigma^2$. **Kakav bi efekt na sličnosti između primjera imalo povećanje preciznosti γ Gaussove jezgrene funkcije?**

- ☐ A Sličnosti bi se smanjile, ali $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se smanjila manje nego što bi se smanjila $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$
☐ B Sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se povećala, a sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$ bi se smanjila, ali za manji iznos
☐ C Sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi postala manja od sličnosti $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$
☐ D Sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(2)})$ bi se povećala, a sličnost $\kappa(\mathbf{x}^{(1)}, \mathbf{x}^{(3)})$ bi se smanjila, ali za veći iznos

- 17 (T) Problem meke margine SVM-a s u primarnoj se formulaciji svodi na rješavanje sljedećeg optimizacijskog problema:

$$\operatorname{argmin}_{\mathbf{w}, w_0, \xi} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i \right\}$$

uz određena linearna ograničenja. Ovaj optimizacijski problem odgovara optimizaciji regularizirane pogreške. Kod regularizirane pogreške u opreci su dva cilja: smanjenje vrijednosti funkcije gubitka i smanjenje složenosti modela. **Kako se ta opreka manifestira kod optimizacijskog problema meke margine SVM-a?**

- ☐ A Što je manji hiperparametar C , to je manja važnost zbroja od ξ_i , pa je vrijednost $\|\mathbf{w}\|^2$ veća i model je veće složenosti
☐ B Što je veći zbroj od ξ_i , to više primjera ulazi u marginu i tim je manja vrijednost $\|\mathbf{w}\|^2$ te je model veće složenosti
☐ C Što je manji zbroj od ξ_i , to više primjera može ući u marginu i tim je veća vrijednost $\|\mathbf{w}\|^2$ te je model manje složenosti
☐ D Što je manja vrijednost $\|\mathbf{w}\|^2$, to je margina šira, no tim više primjera ulazi u marginu i to je veći zbroj od ξ_i

- 18 (P) Razmatramo sljedeći skup označenih primjera u dvodimenzijskome ulaznom prostoru:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), -1), ((-2, -2), -1), ((1, 3), +1), ((2, 2), +1), ((3, -1), +1))\}$$

Na ovom skupu treniramo model SVM-a, i to model s tvrdom marginom te model s mekom marginom sa $C = 1$. Kod modela s mekom marginom za dualne koeficijente vrijedi $\alpha_1 = 1$, $\alpha_2 > 0$, $\alpha_3 > 0$, $\alpha_4 > 0$ i $\alpha_5 = 1$. Skicirajte tvrdu i meku marginu u ulaznome prostoru. **Koliko je meka margina šira od tvrde margine?**

- ☐ A $\frac{1}{6}\sqrt{2}$ puta ☐ B $\frac{2}{5}\sqrt{10}$ puta ☐ C $\frac{3}{5}\sqrt{10}$ puta ☐ D $\frac{4}{5}\sqrt{10}$ puta

- 19 (N) Pomoću SVM-a rješavamo problem binarne klasifikacije grafova. Budući da su primjeri \mathbf{x} grafovi, koristimo SVM s jezgrenom funkcijom nad grafovima. Model treniramo na skupu od $N = 5$ označenih primjera, s vektorom oznaka jednakim $\mathbf{y} = (+1, +1, -1, -1, +1)$ i sa sljedećom jezgrenom matricom:

$$\mathbf{K} = \begin{pmatrix} 1.0 & 0.97 & -0.949 & -0.555 & -0.986 \\ 0.97 & 1.0 & -0.844 & -0.336 & -0.917 \\ -0.949 & -0.844 & 1.0 & 0.789 & 0.988 \\ -0.555 & -0.336 & 0.789 & 1.0 & 0.684 \\ -0.986 & -0.917 & 0.988 & 0.684 & 1.0 \end{pmatrix}$$

Treniranjem uz $C = 5$ za vektor dualnih parametara dobili smo $\alpha = (0, 0.688, 5, 0.688, 5)$. **Koliko iznosi gubitak zglobnice ovako naučenog modela SVM za peti primjer, $L(y^{(5)}, h(\mathbf{x}^{(5)}))$?**

- ☐ A 0.40 ☐ B 2.06 ☐ C 1.86 ☐ D 0.03

20 (T) Problem prokletstva dimenzionalnosti (engl. *curse of dimensionality*) pojavljuje se kod algoritama koji rade u visokodimenzijskom vektorskom prostoru i manifestira se na različite načine. **Kako se problem prokletstva dimenzionalnosti u visokodimenzijskim prostorima manifestira kod algoritma k -NN?**

- ☐ A Broj susjeda k povećava se za svaki primjer te model postaje sve jednostavniji
☐ B Svi primjeri su međusobno vrlo udaljeni i gube se razlike u udaljenosti
☐ C Broj susjeda k nekog primjera se smanjuje i gube se granice između klasa
☐ D Udaljenosti između primjera se smanjuju i model k -NN postaje sve složeniji

21 (P) Neka je $\mathcal{H}_{C,\gamma}$ model SVM-a s Gaussovom jezgrom. Hiperparametri tog modela su regularizacijski faktor C i preciznost jezgre γ . Odabir modela provodimo unakrsnom provjerom i to pretraživanjem po rešetci za sljedeće vrijednosti hiperparametara:

$$C = \{2^{-5}, 2^{-4}, \dots, 2^4, 2^5\}$$

$$\gamma = \{10^{-5}, 10^{-4}, \dots, 10^4, 10^5\}$$

Već ranije smo utvrdili da je model sa $C = 2^{-2}$ i $\gamma = 10^{-1}$ podnaučen, a da je model sa $C = 2^1$ i $\gamma = 10^1$ prenaučeni. Za sve ostale modele ne znamo jesu li prenaučeni, podnaučeni ili optimalni. **Koliko modela još ima smisla ispitati jer su moguće optimalni?**

- ☐ A 25 ☐ B 10 ☐ C 76 ☐ D 96

22 (N) Rješavamo binarni klasifikacijski problem. Raspoložemo označenim skupom primjera. Odgovarajuća matrica dizajna je sljedeća:

$$\mathbf{X} = \begin{pmatrix} 1 & 3 & 16 & -8 & -11 \\ 1 & -5 & 4 & -8 & -7 \\ 1 & 7 & -4 & 11 & 9 \\ 1 & 15 & -20 & 25 & 25 \end{pmatrix}$$

Na ovom skupu treniramo model SVM-a s tvrdom marginom i linearnom jezgrenom funkcijom (tj. bez preslikavanja u prostor značajki). Model treniramo u primarnoj formulaciji. Za rješenje maksimalne margine dobili smo ovaj vektor težina (uključivo s težinom w_0):

$$\mathbf{w} = (-1.3214, +0.0714, +0.1071, 0, -0.0357)$$

Umjesto u primarnoj formulaciji, model smo mogli trenirati u dualnoj formulaciji, pa bismo umjesto vektora težina \mathbf{w} dobili vektor dualnih parametara α , odnosno Lagrangeove multiplikatore. Prisjetite se da su vektori čiji su Lagrangeovi multiplikatori veći od nule potporni vektori. Premda to nije uvijek moguće, u ovom konkretnom slučaju dualni parametri modela mogu se izvesti iz rješenja primarnog modela. Izvedite vektor dualnih parametara α . **Koliko iznosi najveća vrijednost parametra u vektoru dualnih parametara α ?** (Rezultate uspoređujte po prve tri decimale.)

- ☐ A 0.0024 ☐ B 0.0013 ☐ C 0.0089 ☐ D 0.0045

0 0 0 0 0 0 0 0 0 1 1 1 1 1 1 1 1 1 2 2 2
1 2 3 4 5 6 7 8 9 0 1 2 3 4 5 6 7 8 9 0 1 2

--+-----

Grupa A | C B D D A D D A A C D C C D A B A A C C A B
Grupa B | A D B A B D B D B D D C C C A C D B B C D D
Grupa C | C D D D C D C D C B A D B C D C C A A C C D
Grupa D | B C C B C C C D A D A D A A C A A D D C D C
Grupa E | B A B A A B B A D A A A C B D B B B A B B
Grupa F | A D B C D C B A B A D A A B B A D D A B C C