

2. Osnovni koncepti

Strojno učenje 1, UNIZG FER, ak. god. 2022./2023.

Jan Šnajder, vježbe, v2.3

1 Zadatci za učenje

1. [*Svrha: Na stvarim problemima razlikovati klasifikaciju od regresije.*] Objasnite razliku između klasifikacije i regresije. Koji je od ta dva pristupa prikladan za: (a) filtriranje neželjene e-pošte (*spam*), (b) predviđanje kretanja dionica, (c) rangiranje rezultata tražilice? Kako biste u ovim slučajevima definirali ciljne oznake y ?

2. [*Svrha: Razumjeti što je hipoteza, što je model i koja je veza između njih.*]

- (a) Dopunite praznine:

Hipoteza je funkcija koja preslikava _____ u _____, definirana do na _____. Model je _____ hipoteza, indeksiranih _____. Model također nazivamo prostorom _____, a dimenzija tog prostora jednaka je _____. Učenje modela odgovara pretraživanju _____ u potrazi za _____ hipotezom. To je ona hipoteza koja _____ klasificira označene primjere, što procjenjujemo pomoću _____ mjerene na _____. Drugim riječima, učenje modela svodi se na _____ parametara modela s _____ kao kriterijskom funkcijom.

- (b) Rješavamo problem binarne klasifikacije u prostoru primjera $\mathcal{X} = \{0, 1\}^2$. Definirajte linearni model koji će primjere odvajati pravcem.

- (c) Koja je dimenzija prostora parametra? Koliko različitih hipoteza postoji u \mathcal{H} ?

- (d) Neka je skup označenih primjera sljedeći:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0), 0), ((1, 1), 0), ((1, 0), 1), ((0, 1), 1)\}.$$

Odredite konkretnu hipotezu $h \in \mathcal{H}$ koja ima najmanju empirijsku pogrešku.

3. [*Svrha: Shvatiti što je to induktivna pristranost i kako ona određuje klasifikaciju neviđenih primjera.*] Pročitajte poglavlje 2.3 u skripti (tu temu nismo obradili na predavanju).

- (a) Definirajte induktivnu pristranost (neformalno i formalno). Koje su dvije vrste pristranosti koje sačinjavaju induktivnu pristranost?

- (b) Raspoložemo skupom označenih primjera u ulaznome prostoru $\mathcal{X} = \{0, 1\}^3$:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0, 0), 0), ((1, 0, 0), 1), ((1, 0, 1), 1), ((0, 1, 0), 1), ((0, 1, 1), 1)\}.$$

Koja je klasifikacija neviđenih primjera?

- (c) Definirajte linearni model \mathcal{H} za $\mathcal{X} = \{0, 1\}^3$. Koja je to vrsta pristranosti?

- (d) Možete li odrediti klasifikaciju neviđenih primjera uz odabrani model \mathcal{H} ? Je li pristranost koja proizlazi iz odabira modela dovoljna za jednoznačnu klasifikaciju primjera iz \mathcal{D} ?

- (e) Definirajte (neformalno) neku dodatnu pristranost takvu da klasifikacija svakog primjera slijeđi jednoznačno na temelju skupa primjera \mathcal{D} . Koje je vrste ta dodatna pristranost?

4. [*Svrha: Znati nabrojati osnovne komponente algoritma strojnog učenja i povezati ih s induktivnom pristranošću.*]

- (a) Nabrojite tri osnovne komponente algoritma strojnog učenja.

- (b) Identificirajte uz koje se komponente veže koja vrsta induktivne pristranosti.
5. [Svrha: Razumjeti vezu između funkcije gubitka i empirijske pogreške te mogućnost njihove prilagodbe konkretnom problemu.]
- (a) Pogreška hipoteze je očekivanje funkcije gubitka L . Nad kojom distribucijom je definirano to očekivanje? Koji je problem s takvom definicijom u praksi?
 - (b) Definirajte *empirijsku* pogrešku preko funkcije gubitka L . Koja je pretpostavka implicitno ugrađena u tu definiciju?
 - (c) Kod asimetričnih gubitaka funkciju L možemo definirati preko matrice gubitka (v. skriptu: poglavlje 2.7 i primjer 2.6). Definirajte takvu matricu za problem klasifikacije neželjene e-pošte te izračunajte funkciju pogreške za slučaj pet pogrešno negativnih i dvije pogrešno pozitivne klasifikacije od ukupno deset ($N = 10$) primjera.
6. [Svrha: Razviti ispravnu intuiciju za odabir modela temeljem unakrsne provjere.]
- (a) Skicirajte krivulje pogreške učenje i ispitne pogreške u ovisnosti o složenosti modela. Naznačite područje prenaučivosti i podnaučivosti.
 - (b) Objasnite zašto pogreška učenja s povećanjem složenosti modela teži k nuli.
 - (c) Raspoložemo modelom \mathcal{H}_α koji ima hiperparametar α kojim se može ugađati složenost modela. Za odabrani α naučili smo hipotezu koja minimizira empirijsku pogrešku. Unakrsnom provjerom utvrdili smo da je ispitna pogreška znatno veća od pogreške učenja. Je li naš odabir hiperparametra α suboptimalan?
 - (d) Raspoložemo modelom \mathcal{H}_α s hiperparametrom α (veći α daje složeniji model). Raspoložemo dvama optimizacijskim algoritmima: L_1 i L_2 . Algoritam L_2 lošiji je od algoritma L_1 , u smislu da L_2 pronalazi parametre θ_2 koji su lošiji od parametara θ_1 koje pronalazi L_1 , tj. $E(\theta_2|\mathcal{D}) > E(\theta_1|\mathcal{D})$. Neka α_1^* označava optimalnu vrijednost hiperparametra za \mathcal{H}_α učenog algoritmom L_1 , a α_2^* optimalnu vrijednost za \mathcal{H}_α učenog algoritmom L_2 . Načinite skicu analognu onoj iz zadatka (a) i naznačite vrijednosti pogrešaka za modele $\mathcal{H}_{\alpha_1^*}$ i $\mathcal{H}_{\alpha_2^*}$.
 - (e) Može li model učen lošijim algoritmom L_2 imati manju ispitnu pogrešku od modela koji je učen boljim algoritmom L_1 , ali nije optimalan? Skicirajte takvu situaciju na prethodnoj skici.

2 Zadaci s ispita

1. (T) Model \mathcal{H} je skup svih parametriziranih funkcija $h(\mathbf{x}; \theta)$ indeksiran parametrima θ . To jest:

$$\mathcal{H} = \{h(\mathbf{x}; \theta)\}_\theta$$

Što to zapravo znači?

- ☐ A Da različite funkcije h imaju različite parametre θ , i da su sve one sadržane u modelu, to jest za sve njih vrijedi $h \in \mathcal{H}$
 - ☐ B Da za različite parametre θ dobivamo različite funkcije h , i da su sve one sadržane u modelu, to jest za sve njih vrijedi $h \in \mathcal{H}$
 - ☐ C Da model sadrži beskonačno mnogo funkcija h čija konkretna definicija ovisi o vrijednostima parametara θ
 - ☐ D Da su funkcije h definirane sa slobodnim parametrima θ i da broj različitih funkcija odgovara broju parametara
2. (P) U ulaznom prostoru $\mathcal{X} = \{0, 1\}^3$ definiramo sljedeći klasifikacijski model:

$$h(\mathbf{x}; \theta) = \mathbf{1}\{\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 \geq 0\}$$

Koja je dimenzija prostora parametara te koliko različitih hipoteza postoji u ovom modelu?

- ☐ A Dimenzija prostora parametara je 4, a hipoteza ima beskonačno mnogo
- ☐ B Dimenzija prostora parametara je 4, a hipoteza ima manje od 256
- ☐ C Dimenzija prostora parametara i broj hipoteza su beskonačni
- ☐ D Dimenzija prostora parametara je 256, a hipoteza ima 14

3. (P) Za ulazni prostor $\mathcal{X} = \{0, 1\}^3$ definiramo klasifikacijski model \mathcal{H} kao skup parametriziranih funkcija definiranih na sljedeći način:

$$h(\mathbf{x}; \boldsymbol{\theta}) = \mathbf{1}\{(\theta_{1,1} \leq x_1 \leq \theta_{1,2}) \wedge (\theta_{2,1} \leq x_2 \leq \theta_{2,2}) \wedge (\theta_{3,1} \leq x_3 \leq \theta_{3,2})\}$$

Parametri su trodimenzijski vektori realnih brojeva, tj. prostor parametara definiran je kao $\boldsymbol{\theta} \in \mathbb{R}^6$.
Koliko iznosi $|\mathcal{H}|$?

- ☐ A 42 ☐ B ∞ ☐ C 56 ☐ D 28

4. (P) Skup označenih primjera u dvodimenzijskome ulaznom prostoru je:

$$\mathcal{D} = \{((0, 0), 0), ((0, 1), 0), ((1, 1), 1)\}$$

Koliko hipoteza ostvaruje empirijsku pogrešku jednaku nuli?

- ☐ A 16 ☐ B Pitanje nema smisla jer nije definiran model ☐ C Beskonačno mnogo ☐ D 14

5. (P) Za linearan klasifikator u $\mathcal{X} = \{0, 1\}^3$ zadan je sljedeći skup primjera za učenje:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0, 0), 0), ((1, 0, 0), 1), ((1, 0, 1), 1), ((0, 1, 0), 1), ((0, 1, 1), 1), ((1, 1, 0), 0)\}$$

Razmatramo dva modela:

$$\begin{aligned}\mathcal{H}_a : h_a(\mathbf{x}|\boldsymbol{\theta}) &= \mathbf{1}\{\theta_0 + x_1\theta_1 + x_2\theta_2 + x_3\theta_3 \geq 0\} \\ \mathcal{H}_b : h_b(\mathbf{x}|\boldsymbol{\theta}) &= h_a(\mathbf{x}; \boldsymbol{\theta}_1) \cdot h_a(\mathbf{x}; \boldsymbol{\theta}_2)\end{aligned}$$

Uočite da svaka hipoteza iz modela \mathcal{H}_b kombinira dvije hipoteze iz modela \mathcal{H}_a (operacijom množenja).
Neka:

$$\begin{aligned}h_a^* &= \operatorname{argmin}_{h \in \mathcal{H}_a} E(h|\mathcal{D}) \\ h_b^* &= \operatorname{argmin}_{h \in \mathcal{H}_b} E(h|\mathcal{D})\end{aligned}$$

Koja je od navedenih tvrdnji točna?

- ☐ A $E(h_a^*|\mathcal{D}) = E(h_b^*|\mathcal{D}) > 0$
☐ B $E(h_a^*|\mathcal{D}) > E(h_b^*|\mathcal{D}) = 0$
☐ C $0 < (E(h_a^*|\mathcal{D}) < E(h_b^*|\mathcal{D}) < 1$
☐ D $E(h_a^*|\mathcal{D}) = E(h_b^*|\mathcal{D}) = 0$

6. (P) Za linearan model u $\mathcal{X} = \{0, 1\}^3$ zadan je sljedeći skup primjera za učenje:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\} = \{((0, 0, 0), 0), ((1, 0, 0), 1), ((1, 0, 1), 1), ((0, 1, 0), 1), ((0, 1, 1), 1)\}$$

Optimizacijski postupak klasifikatora funkcionira tako da minimizira empirijsku pogrešku, definiranu kao očekivanje funkcije gubitka 0-1, i postupak u tome uvijek uspijeva. Želimo znati koju bi klasu ovaj klasifikator dodijelio primjeru $\mathbf{x} = (1, 1, 1)$. **Možemo li, na temelju iznesenih informacija, odrediti klasifikaciju dotičnog primjera i što nam to govori o induktivnoj pristranosti ovog algoritma?**

- ☐ A Ne možemo, jer nije definirana induktivna pristranost preferencijom, pa činjenica da je model linearan nije dovoljan skup pretpostavki da bismo jednoznačno odredili klasifikaciju svih novih primjera
☐ B Možemo, klasifikacija je $y = 1$, i ovaj klasifikator ima definiranu induktivnu pristranost pomoću koje može jednoznačno odrediti klasifikaciju svakog primjera
☐ C Možemo, klasifikacija je $y = 1$, premda dane informacije nisu dovoljne za definiciju induktivne pristranosti, pa za ovaj skup primjera više hipoteza savršeno točno klasificira primjere
☐ D Možemo, $y = 1$, jer klasifikator ima induktivnu pristranost jezikom (linearan model) i preferencijom (primjeri za koje je $h(x) \geq 0$ klasificiraju se pozitivno)

7. (P) Optimizacija parametara modela temelji se na funkciji gubitka $L : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}_0^+$, gdje je $L(y, h(\mathbf{x}))$ gubitak na primjeru (\mathbf{x}, y) . U većini primjena koristimo simetričan gubitak 0-1. Međutim, u nekim primjenama ima više smisla definirati asimetričan gubitak. Jedan takav primjer je zadatak detekcije karcinoma iz medicinskih slika. Taj zadatak možemo formalizirati kao problem binarne klasifikacije s oznakama $\mathcal{Y} = \{0, 1\}$, gdje $y = 1$ označava postojanje karcinoma, a $y = 0$ nepostojanje karcinoma. **Koje od sljedećih svojstava bi trebala zadovoljiti asimetrična funkcija gubitka za takav zadatak?**

- ☐ A $L(0, 1) = 1$ i $L(1, 0) = L(1, 1) = L(0, 0) = 0$
☐ B $L(0, 1) > L(1, 0)$ i $L(1, 1) = L(0, 0) > 0$
☐ C $L(1, 0) > L(0, 1)$ i $L(1, 1) = L(0, 0) = 0$
☐ D $L(0, 1) = L(1, 0) > 0$ i $L(1, 1) = L(0, 0) = 0$

8. (T) Pogreška hipoteze definirana je kao očekivanje funkcije gubitka na primjerima iz $\mathcal{X} \times \mathcal{Y}$. Međutim, u praksi tu pogrešku aproksimiramo empirijskom pogreškom, koju računamo kao srednju vrijednost funkcije gubitka na skupu označenih primjera $\mathcal{D} \subseteq \mathcal{X} \times \mathcal{Y}$. **Zašto pogrešku hipoteze aproksimiramo empirijskom pogreškom i na kojoj se pretpostavci temelji ta aproksimacija?**

- ☐ A Očekivanje gubitka ne možemo izračunati jer primjera iz $\mathcal{X} \times \mathcal{Y}$ ima potencijalno beskonačno, stoga pogrešku računamo na temelju skupa \mathcal{D} za koji pretpostavljamo da je konačan
☐ B Različitih primjera iz $\mathcal{X} \times \mathcal{Y}$ potencijalno ima beskonačno mnogo, pa pogrešku računamo na uzorku \mathcal{D} za koji pretpostavljamo da je reprezentativan
☐ C Funkciju gubitka jednostavnije je definirati nego funkciju pogreške, a aproksimacija je točna uz pretpostavku i.i.d.
☐ D Ne možemo izračunati očekivanje gubitka jer nam nije poznata distribucija primjera iz $\mathcal{X} \times \mathcal{Y}$, no pretpostavljamo da je \mathcal{D} reprezentativan uzorak iz te distribucije


9. (P) Zadan je sljedeći skup sa $N = 6$ označenih primjera iz \mathbb{R}^3 :

$$\begin{aligned} \mathcal{D} &= \{(\mathbf{x}^{(i)}, y^{(i)})\} \\ &= \{((0, 0, 0), 0), ((1, 1, 0), 0), ((1, 0, 0), 1), ((1, 0, 1), 1), ((0, 1, 0), 1), ((0, 1, 1), 1)\} \end{aligned}$$

Razmatramo linearan model i računamo empirijsku pogrešku $E(h|\mathcal{D})$ hipoteza iz tog modela definiranu kao očekivanje asimetričnog gubitka. Gubitak je definiran tako da lažno negativne primjere kažnjava sa 1, a lažno pozitivne primjere sa 0.5. **Koliko iznosi najmanja a koliko najveća moguća vrijednost tako definirane empirijske pogreške $E(h|\mathcal{D})$?**

- ☐ A $0 \leq E(h|\mathcal{D}) \leq 1/4$
☐ B $1/4 \leq E(h|\mathcal{D}) \leq 2/3$
☐ C $\frac{1}{48} \leq E(h|\mathcal{D}) \leq 2/3$
☐ D $1/12 \leq E(h|\mathcal{D}) \leq 3/4$

10. (P) Na slici ispod prikazan je graf funkcije pogreške učenja i pogreške ispitivanja za neku familiju modela i neki označeni skup primjera:



Crvenom linijom označena je složenost nekog modela \mathcal{H} . Crvene točke odgovaraju ispitnoj pogrešci i pogrešci učenja za hipotezu $h \in \mathcal{H}$ iz tog modela, dobivenoj nekim optimizacijskim algoritmom. **Što možemo reći o modelu \mathcal{H} i o hipotezi h ?**

- ☐ A Model \mathcal{H} nije optimalne složenosti, a čak ni hipoteza h ne mora biti optimalna na skupu za učenje, ako je optimizacijski algoritam loš
 - ☐ B Model \mathcal{H} je podnaučen, ali je barem hipoteza h hipoteza s najmanjom ispitnom pogreškom unutar takvog suboptimalnog modela
 - ☐ C Model \mathcal{H} je nedovoljne složenosti, ali je barem hipoteza h optimalna u smislu najmanje moguće pogreške na skupu za učenje
 - ☐ D Model \mathcal{H} je prenaučan, a hipoteza h će loše generalizirati na neviđene primjere
11. (T) Modeli strojnog učenja tipično imaju i parametre i hiperparametre. **Koja je razlika između parametara i hiperparametara?**
- ☐ A Algoritam strojnog učenja minimizira parametre te istovremeno maksimizira hiperparametre
 - ☐ B Hiperparametri mogu biti diskretni ili kontinuirani, dok su parametri uvijek kontinuirani
 - ☐ C Parametre optimira algoritam strojnog učenja, dok optimizacija hiperparametara nije u nadležnosti tog algoritma
 - ☐ D Parametri određuju iznos empirijske pogreške na skupu za učenje, a hiperparametri iznos te pogreške na skupu za provjeru
12. (P) Raspoložemo modelom \mathcal{H}_α , koji ima hiperparametar α kojim se može ugađati složenost modela. Isprobavamo dvije vrijednosti hiperparametra: α_1 i α_2 . Treniramo modele \mathcal{H}_{α_1} i \mathcal{H}_{α_2} te dobivamo hipoteze h_{α_1} i h_{α_2} . Zatim računamo empirijske pogreške tih hipoteza na skupu za učenje \mathcal{D}_u i na skupu za ispitivanje \mathcal{D}_i . Utvrđujemo da vrijedi:

$$E(h_{\alpha_1}|\mathcal{D}_i) - E(h_{\alpha_1}|\mathcal{D}_u) < E(h_{\alpha_2}|\mathcal{D}_i) - E(h_{\alpha_2}|\mathcal{D}_u)$$

Što iz toga možemo zaključiti?

- ☐ A Model \mathcal{H}_{α_2} je prenaučan
- ☐ B Optimalan model je onaj s vrijednošću hiperparametra iz intervala $[\alpha_1, \alpha_2]$
- ☐ C Model \mathcal{H}_{α_1} je podnaučen
- ☐ D Model \mathcal{H}_{α_1} je manje složenosti od modela \mathcal{H}_{α_2}