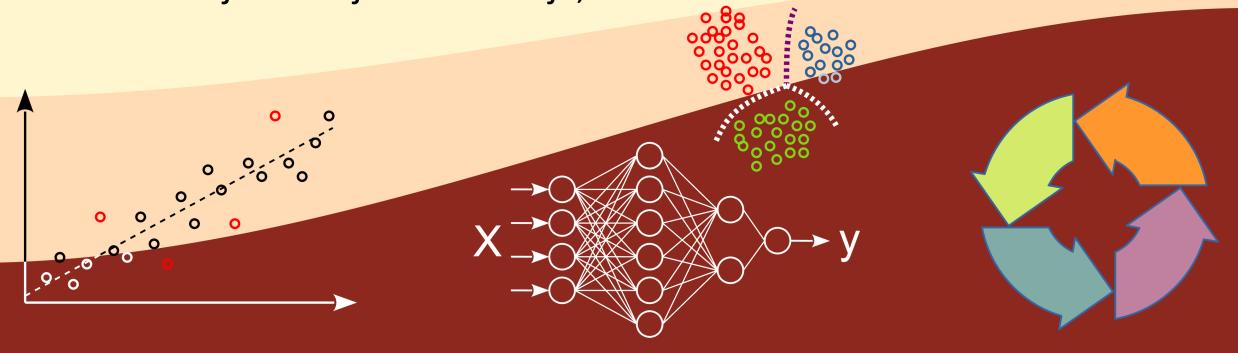


# Arhitektura i Razvoj Inteligentnih Sustava

**Tjedan 2:** Razlike u arhitekturi sustava, značajni slučajevi korištenja, model kao osnova



#### Creative Commons













- imenovanje: morate priznati i označiti autorstvo djela na način kako je specificirao autor ili davatelj licence (ali ne način koji bi sugerirao da Vi ili Vaše korištenje njegova djela imate njegovu izravnu podršku).
- nekomercijalno: ovo djelo ne smijete koristiti u komercijalne svrhe.
- dijeli pod istim uvjetima: ako ovo djelo izmijenite, preoblikujete ili stvarate koristeći ga, preradu možete distribuirati samo pod licencom koja je ista ili slična ovoj.







U slučaju daljnjeg korištenja ili distribuiranja morate drugima jasno dati do znanja licencne uvjete ovog djela. Od svakog od gornjih uvjeta moguće je odstupiti, ako dobijete dopuštenje nositelja autorskog prava. Ništa u ovoj licenci ne narušava ili ograničava autorova moralna prava. Tekst licence preuzet je s http://creativecommons.org/



#### Projekt

- Tri voditelja projekta neka mi se jave na dalibor.krleza@fer.hr
  - Koncept first-come first-serve
  - Srediti popis ljudi u grupama
  - Voditi rad na projektu





#### Procesni pogled

- Sve oko nas je hrpa procesa
  - Poslovni, tehnički, prirodni
  - Dijelovi našeg života i poslovanja se mogu dizajnirati kao proces
  - Proces kupnje, parkiranja u garaži, dnevna rutina, način kako posluje naše poduzeće
  - Ciklička i ponavljajuće priroda procesa
- Naša želja je
  - Pratiti te procese
  - Simulirati te procese
  - Upravljati tim procesima
  - Omogućiti intervenciju u proces
- Sve te stvari već imamo u klasičnom obliku
  - Na papiru
  - U klasičnim tehničkim i informacijskim sustavima
  - Itd...

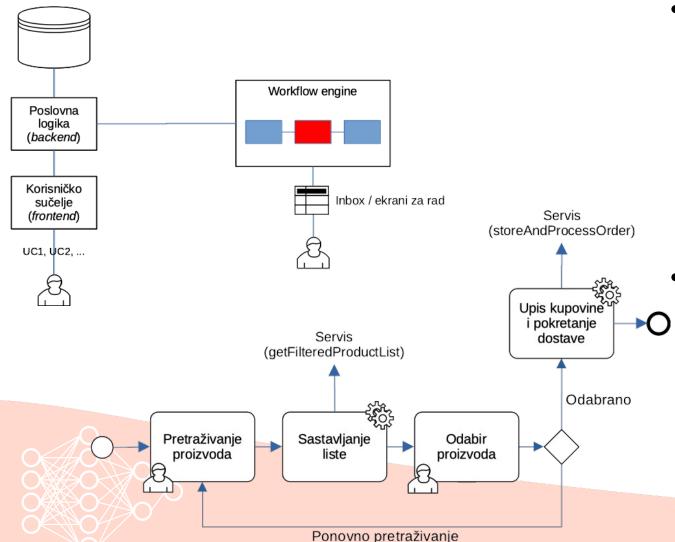


#### Klasični IT sustavi

- Simuliraju poslovni proces u organizaciji
  - Ta simulacija ne pokriva nužno cijeli poslovni proces
- Dva osnovna tipa pristupa
  - Kroz slučajeve korištenja (use cases)
    - Dekomponira poslovni proces u niz interakcija korisnika sa sustavom
    - Nema mogućnosti striktne definicije slijeda interakcija
  - Kroz sustave za automatizaciju poslovnih procesa (workflow engine, BPM engine)
    - Simulira poslovni proces
    - Interakcija s korisnikom je kroz "ljudske zadatke" (human task) servis i ili prozor koji omogućava korisniku da odradi neki dio zadatka
    - Slijed interakcija strogo slijedi poslovni proces



#### Klasični IT sustavi



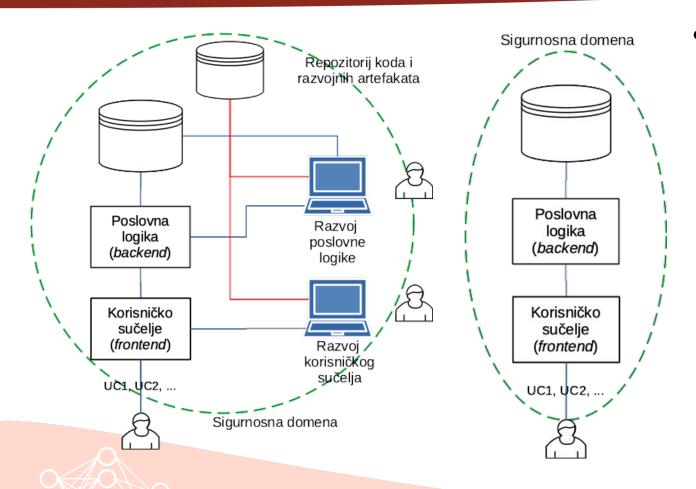
#### U standardnom pristupu

- Korisnik kroz slijed slučajeva korištenja na ekranu pristupa pozadinskim servisima
- Pozadinski servisi sadrže poslovnu logiku i čitanje/spremanje podataka
- Korisnik neformalno kroz svoju dnevnu radnu rutinu, sljedeći pravila poslovanja, simulira poslovni proces
- Redoslijed zadataka nije striktan

#### U BPM pristupu

- Poslovni proces je striktno definiran i izvodi se u workflow engine-u
- Korisnik kroz princip inboxa i hrpe ekrana dobiva zadatke
- Pozadinski servisi ostaju isti jer sadrže elementarnu poslovnu logiku

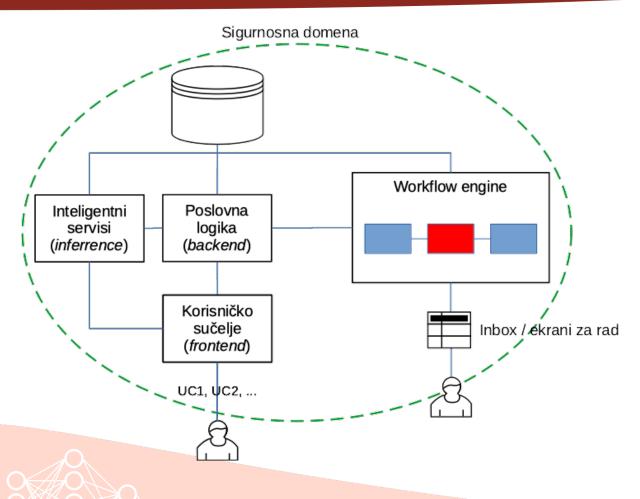
#### Okoline



- Standardni pristup kroz tri (možda i koja dodatna) okoline
  - Razvojna, testna (predprodukcijska – staging), produkcijska
  - Verzija razvijenog sustava (i funkcionalnosti) propagiraju od razvojne -> produkcijske
  - Podaci su različiti u različitim okolinama (!!!)
    - Što to znači za skupljanje znanja i učenje raznih modela?
  - devOps pipeline u razvojnoj okolini!?



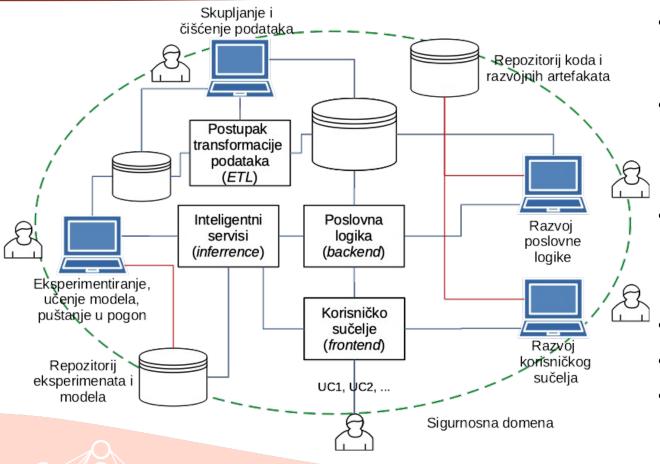
#### Uvođenje inteligentnih servisa



- Uvodimo pozadinski poslužitelj koji poslužuje razne modele kroz servisno sučelje (inference services)
  - Ti se servisi mogu pozvati iz ostatka klasičnog informacijskog sustava
  - Uključivo i workflow engine
  - Rezultati obrade u modelu utječu na rad informacijskog sustava
  - Podaci koji se skupljaju iz informacijskog sustava sadrže utjecaj inteligentnih servisa
- U testnoj (predprodukcijskoj) i produkcijskoj okolini dovoljan je poslužitelj modela (npr. Seldon Core)



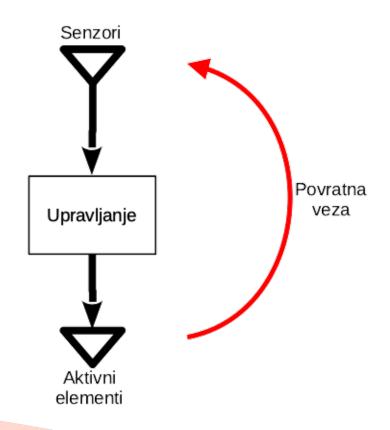
#### Razvojna okolina



- Skupljanje i čišćenje podataka koju okolinu koristimo?
  - Produkcija želimo stvarne podatke
- Inkrementalno spremanje za eksperimentiranje i automatsko učenje modela
  - Želimo li to raditi online kroz ETL?
  - Kakva pohrana? Baza podataka ili tok podataka (kafka)?
- Repozitorij za modele nije isti kao i kod klasične izvedbe
  - Repozitorij eksperimenata i modela
  - Repozitorij samo naučenih modela (S3, GCS, minio, ...)
- Pozadinski poslužitelj se razlikuje po okolinama
- MLOps pipeline? Automatizacija?
- Ovo utječe i na sam informacijski sustav netko treba napisati poziv inteligentnog servisa na pravom mjestu



#### Klasični tehnički sustavi

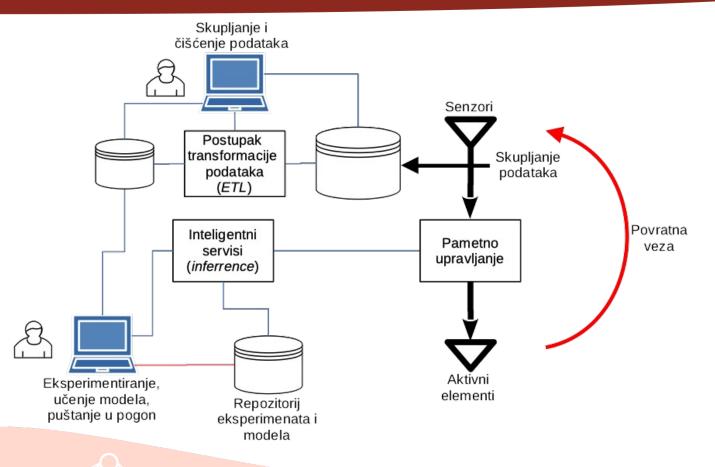


- Standardni upravljački pristup u tehničkim sustavima
  - Obrada signala za senzora skup ulaznih podataka
    - Zapravo je nebitno otkud ti podaci
  - Prevođenje u izlazne aktivnosti





#### Pametni tehnički sustavi



- Učimo na temelju podataka sa senzora
  - Recimo regresijski modeli
  - Modeli koji mogu predvidjeti ponašanje sustava i pomoći kod upravljanja
  - Upravljanje podesimo tako da poziva inteligentni servis za ulaz sa senzora
  - Odgovor se koristi u upravljačkom procesu



#### Standardni slučajevi korištenja

- Vrlo rašireni
  - Raspoznavanje biometrijskih podataka otisak prsta, zjenice
  - Raspoznavanje nestrukturiranog sadržaja:
    - Slika razno prepoznavanje uzoraka primjer mobilne aplikacije koja prepoznaje tip madeža (pa i detekcija raka kože)
    - Video prepoznavanje lica traženih osoba
    - Audio govor, pjesme (Shazam, SoundHound, ...)
  - Klasični slučaj korištenja: klasifikatori (classifiers)
    - Jednostavan iris skup podataka: <a href="https://archive.ics.uci.edu/ml/datasets/iris">https://archive.ics.uci.edu/ml/datasets/iris</a>





- Preporučivači (recommenders)
  - Temeljem povijesnih podataka stvaramo model koji klijentu ili kupcu preporuča proizvode ili tijek aktivnosti
    - Podatke možemo skupiti na samom kupcu
    - Češće skupljamo na grupi kupaca i radimo zajednički model
  - Content based vs. Collaborative filtering
- Preporučivač za kupnju
  - Temeljem prethodnih kupnji kupca ili određenog segmenta prodaje stvara se model za grupe proizvoda ili pojedinačne proizvode
  - Dosta kategoričkih podataka
  - Model po kupcu dosta skup? Potrebno puno resursa za tisuće kupaca?
  - Preporuka kupcu u obliku posebne liste proizvoda lista se pamti zbog metrike
  - Metrika uspoređuje tendenciju prodaje za preporučene proizvode



- Preporučivač u financijskoj industriji
  - Temeljem dinamike računa stvara se regresijski model kompleksnije nego izgleda
  - Tendencija sredstava na pojedinom računu
    - Osoba isplaćuje više nego uplaćuje ili vice versa
  - Ima li osoba depozita? Kredita? Kreditna sposobnost?
  - Preporuka: kreditna linija, depozitna linija, investicije





- Pametni trener (smart workout) http://extrasensory.ucsd.edu
  - Nosivi uređaji skupljaju podatke (wearable devices)
  - Korisnik upisuje dodatne podatke npr. težina, visina, obroci
  - Kolaborativni model daje preporuke za vježbe u ovisnosti o zadanom cilju
    - Recimo cilj je istrčati maraton
- Preporučivanje sadržaja (content recommender)
  - Pratimo što osoba gleda ili sluša i pamtimo te grupe sadržaja
  - Temeljem kolaborativnog modela preporučamo novi sadržaj
  - Netflix, Youtube, TikTok, Facebook, Deezer, ...





- Procesni preporučivači optimizacija procesa
  - Na određenim mjestima u procesu skupljamo podatke
  - Stvara se model koji ocjenjuje uspješnost odluke prema ulaznim podacima
  - U trenutku odluke od sustava se očekuje preporuka
    - Recimo kojeg od dobavljača uzeti i slično





- Predviđanje na temelju povijesnih podataka (forecasting)
  - Budući događaji ili kretanja
  - Uobičajeno regresijski modeli ili nekakav LSTM
  - Vrlo korišteni i ima puno slučajeva korištenja
  - Velika uloga sezonskog kretanja u procesima
  - Puno podataka, dugotrajno učenje, kompleksni modeli
- Generalni primjeri
  - Predviđanje prometa, broja putnika, bilo kakvog opterećenja
  - Broj vozača, pilota, kontrolora, radne snage
  - Nabavka materijala, proizvoda, održavanje skladišta



#### Zdravstvo

- Kombinacija nosivih uređaja (wearables), biomarkera i ručno unesenih podataka
- Predviđanje patoloških stanja na temelju vremenskih serija podataka
  - Sepsa, aritmija i slično
- Velika uloga znanja eksperata u označavanju (labeliranju) podataka
- https://physionet.org/content/challenge-2019/
- https://physionet.org/content/challenge-2020/





- Pametno upravljanje zgradama (smart building management)
  - http://db.csail.mit.edu/labdata/labdata.html
  - Dnevni i sezonski podaci
    - Temperatura, osvjetljenje, vlaga, ...
    - Zima-ljeto, dnevno kretanje sunca, lokalna klima, klimatske promjene
  - Vremenska regresija, clustering
  - Kako upravljati zgradom
    - Grijanje, hlađenje, osvjetljenje
  - Metrika: potrošnja energenata, plaćanje računa





- Trgovanje dionicama
  - Povijesna kretanja
  - Uzimanje u obzir specifičnih socio-ekonomskih situacija
  - Kritičan je brz odaziv
  - Najbolje rade agregacije metoda (ensemble) stablo odluka + regresijski modeli





## Slučajevi korištenja: detektori

- Često se koriste za detekciju događaja u okolini
  - Detekcija prijevara, outliera
    - Neuronske mreže, clustering
  - Često potreban brz odaziv
  - Neizraziti izlazi bolje funkcioniraju
    - Vjerojatnost da je viđeni događaj u određenoj klasi na primjer softmax izlaz
  - Često je kombinacija prethodno viđenih događaja i detekcije "statistički" novog događaja najbolja kombinacija
  - Za detekciju prethodno viđenog nadzirano učenje
  - Za detekciju novih *outliera* nenadzirano učenje





## Slučajevi korištenja: detektori

- Financijska industrija transakcije karticama, MSC kartica na non-chip bankomatu
- Sigurnost pametni vatrozid (firewall)
- Prijevare
  - Osiguranje
  - Plaćanje poreza npr. missing trader fraud
  - Telekomunikacije npr. SIM swap fraud, premium rate call, missed call
  - ... <beskonačan broj raznih varijanti prijevara> ...

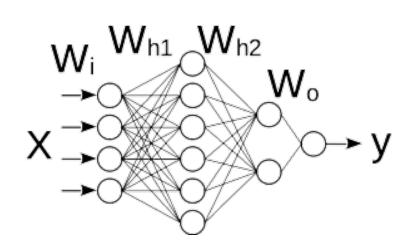


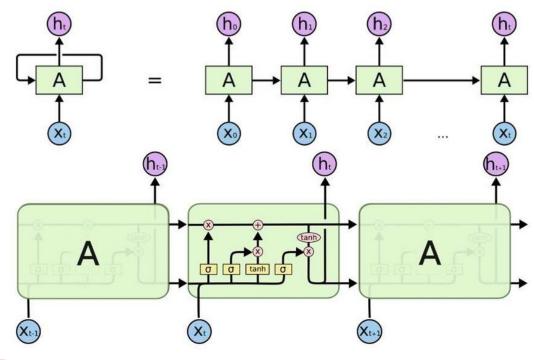


- Standardno klasično programiranje završava u hrpi imperativnog koda
  - Rješavanje standardnog problema u slijedu koraka pisanom u određenom programskom jeziku
  - Preveden na izvršni kod, direktno se izvodi na standardnom računalnom procesoru
- Strojno učenje počiva na skupu matematičkih struktura
  - Često se recimo čuje izraz "arhitektura neuronske mreže"
  - Regresijska metoda se koristi funkcijama koje najbolje opisuju dane podatke za učenje
  - Clustering (grupiranje) rezultira skupom područja u kojima se podaci grupiraju, ili barem centroidima tih grupa



- Neuronske mreže su skup parametara na ulazima i izlazima neurona i tranzicijskih funkcija
- Lijevo MLP, desno RNN (vidi GRU arhitekturu) i LSTM







- Svi ovi algoritmi imaju unutarnje stanje u obliku skupa parametara hiperparametri
  - Ti parametri sadrže naučeno znanje
  - Oni se mogu spremiti na disk i ponovno učitati u istu klasu algoritma strojnog učenja
    - U istu arhitekturu neuronske mreže
    - U isti algoritam za clustering
    - ...
  - To je koncept modela: algoritam (+arhitektura) + parametri (znanje)
    - Moguće je spremiti trenutne gradijente recimo za nastavak učenja
  - Parametre, to jest model, u nekom standardnom formatu (joblib, pth, ...) spremimo u repozitorij modela
    - Poslužitelj uzme tu datoteku modela u učita ju u istovjetni algoritam (+arhitektura)



- Zašto GPU kod CNN, DCNN ili DNN arhitektura?
  - Vrlo jednostavne matematičke operacije kod učenja: zbrajanje, oduzimanje, množenje
  - GPU arhitektura je napravljena upravo za takve operacije: računalna grafika
    - NVIDIA CUDA sučelje
    - NVIDIA TESLA kartice
    - NVIDIA Triton ML server
  - Što kada nam je ulazni prostor značajki ogroman i imamo puno uzoraka za učenje???



